

Наука о данных в R для программы Цифровых гуманитарных исследований

Г. А. Мороз, И. С. Поздняков

Оглавление

1	О курсе	7
2	Введение в R	9
2.1	Наука о данных	9
2.2	Установка R и RStudio	10
2.3	Полезные ссылки	10
2.4	Rstudio	11
2.5	Введение в R	12
2.6	Логические операторы	19
2.7	Типы данных	20
2.8	Вектор	24
2.9	Матрицы (matrix)	40
2.10	Списки (list)	43
2.11	Датафрейм	45
3	Импорт данных	49
3.1	Рабочая папка и проекты RStudio	49
3.2	Проверка импортированных данных	53
3.3	Экспорт данных	55
3.4	Импорт таблиц в бинарном формате: таблицы Excel, SPSS	55
3.5	Быстрый импорт данных	56
4	Условные конструкции и циклы	61
4.1	Выражения if, else, else if	61
4.2	Циклы for	63
4.3	Векторизованные условные конструкции: функции ifelse() и dplyr::case_when()	65
5	Функциональное программирование в R	67
5.1	Создание функций	67
5.2	Проверка на адекватность	69
5.3	Когда и зачем создавать функции?	70
5.4	Функции как объекты первого порядка	71
5.5	Семейство функций apply()	72

5.6	Вселенная tidyverse	77
5.7	Загрузка данных с помощью <code>readr</code>	79
5.8	<code>magrittr::%>%</code>	81
5.9	Главные пакеты tidyverse: <code>dplyr</code> и <code>tidyR</code>	82
5.10	Работа с колонками тибла	83
5.11	Работа со строками тибла	94
5.12	Создание колонок: <code>dplyr::mutate()</code> и <code>dplyr::transmute()</code>	100
5.13	Агрегация данных в тибле	102
5.14	Трансформация нескольких колонок: <code>dplyr::across()</code>	108
5.15	Объединение нескольких датафреймов	113
5.16	<code>Tidy data: tidyR::pivot_longer(), tidyR::pivot_wider()</code>	121
6	Визуализация данных	125
6.1	Зачем визуализировать данные?	125
6.2	Основы <code>ggplot2</code>	128
6.3	Столбчатые диаграммы (barplots)	139
6.4	Факторы	143
6.5	Дотплот	150
6.6	Гистограммы	153
6.7	Функции плотности	158
6.8	Точки, джиттер (<code>jitter</code>), вайолинплот (<code>violinplot</code>), ящики с усами (<code>boxplot</code>)	161
6.9	Фасетизация	165
6.10	Визуализация комбинаций признаков	170
7	Задания	175
7.1	Приведение типов	177
7.2	Векторизация	177
7.3	Индексирование векторов	178
7.4	Матрицы	180
7.5	Списки	182
7.6	Датафрейм	183
7.7	Условные конструкции	188
7.8	Создание функций	189
7.9	Семейство функций <code>apply()</code>	193
7.10	<code>magrittr::%>%</code>	196
7.11	Сортировка строк: <code>dplyr::arrange()</code>	199
7.12	Уникальные значения: <code>dplyr::distinct()</code>	200
7.13	Создание колонок: <code>dplyr::mutate()</code> и <code>dplyr::transmute()</code>	201
7.14	Агрегация: <code>dplyr::group_by() %>% summarise()</code>	202
7.15	Операции с несколькими колонками: <code>across()</code>	202
7.16	Соединение датафреймов: <code>*_join {#task_join}</code>	203
7.17	<code>Tidy data</code>	205
8	Решения заданий	209
8.1	Приведение типов	212
8.2	Векторизация	213

8.3	Индексирование векторов	215
8.4	Матрицы	218
8.5	Списки	221
8.6	Датафрейм	223
8.7	Условные конструкции	228
8.8	Создание функций	230
8.9	Семейство функций <code>apply()</code>	236
8.10	<code>magrittr::%>%</code>	239
8.11	Сортировка строк: <code>dplyr::arrange()</code>	243
8.12	Уникальные значения: <code>dplyr::distinct()</code>	244
8.13	Создание колонок: <code>dplyr::mutate()</code> и <code>dplyr::transmute()</code>	245
8.14	Агрегация: <code>dplyr::group_by() %>% summarise()</code>	246
8.15	Операции с несколькими колонками: <code>across()</code>	247
8.16	Соединение датафреймов: <code>*_join {#solution_join}</code>	249
8.17	<code>Tidy data</code>	251

Глава 1

О курсе

Материалы для курса Наука о данных для магистерской программы Цифровых гуманитарных исследований НИУ ВШЭ.

Глава 2

Введение в R

2.1 Наука о данных

Наука о данных — это новая область знаний, которая активно развивается в последнее время. Она находится на пересечении компьютерных наук, статистики и математики, и трудно сказать, действительно ли это наука. При этом это движение развивается в самых разных научных направлениях, иногда даже оформляясь в отдельную отрасль:

- биоинформатика
- вычислительная криминалистика
- цифровые гуманитарные исследования
- датаждурналистика
- ...

Все больше книг “Data Science for ...”:

- psychologists (Hansjörg, 2019)
- immunologists (Thomas and Pallett, 2019)
- business (Provost and Fawcett, 2013)
- public policy (Brooks and Cooper, 2013)
- fraud detection (Baesens et al., 2015)
- ...

Среди умений датасаентистов можно перечислить следующие:

- сбор и обработка данных
- трансформация данных
- визуализация данных
- статистическое моделирование данных
- представление полученных результатов
- организация всей работы **воспроизводимым способом**

Большинство этих тем в той или иной мере будет представлено в нашем курсе.

2.2 Установка R и RStudio

В данной книге используется исключительно R (R Core Team, 2019), так что для занятий понадобятся:

- R
 - на Windows¹
 - на Mac²
 - на Linux³, также можно добавить зеркало и установить из командной строки:

```
sudo apt-get install r-cran-base
```

- RStudio — IDE для R (можно скачать здесь⁴)
- и некоторые пакеты на R

Часто можно увидеть или услышать, что R — язык программирования для “статистической обработки данных”. Изначально это, конечно, было правдой, но уже давно R — это полноценный язык программирования, который при помощи своих пакетов позволяет решать огромный спектр задач. В данной книге используется следующая версия R:

```
## [1] "R version 4.0.3 (2020-10-10)"
```

Некоторые люди не любят устанавливать лишние программы себе на компьютер, несколько вариантов есть и для них:

- RStudio cloud⁵ — полная функциональность RStudio, пока бесплатная, но скоро это исправят;
- RStudio on rollApp⁶ — облачная среда, позволяющая разворачивать программы.

Первый и вполне закономерный вопрос: зачем мы ставили R и отдельно еще какой-то RStudio? Если опустить незначительные детали, то R — это сам язык программирования, а RStudio — это среда (IDE), которая позволяет в этом языке очень удобно работать.

2.3 Полезные ссылки

В интернете легко найти документацию и туториалы по самым разным вопросам в R, так что главный залог успеха — грамотно пользоваться поисковиком, и лучше на

¹<https://cran.r-project.org/bin/windows/base/>

²<https://cran.r-project.org/bin/macosx/>

³<https://cran.rstudio.com/bin/linux/>

⁴<https://www.rstudio.com/products/rstudio/download/>

⁵<https://rstudio.cloud/>

⁶<https://www.rollapp.com/app/rstudio>

английском языке.

- книга (Wickham and Grolemund, 2016)⁷ является достаточно сильной альтернативой всему курсу
- stackoverflow⁸ — сервис, где достаточно быстро отвечают на любые вопросы (не обязательно по R)
- RStudio community⁹ — быстро отвечают на вопросы, связанные с R
- русский stackoverflow¹⁰
- R-bloggers¹¹ — сайт, где собираются новинки, связанные с R
- чат¹², где можно спрашивать про R на русском (но почитайте правила чата¹³, перед тем как спрашивать)
- чат¹⁴ по визуализации данных, чат¹⁵ датажурналистов
- канал про визуализацию¹⁶, data-блог “Новой газеты”¹⁷, ...

2.4 Rstudio

Когда вы откроете RStudio первый раз, вы увидите три панели: консоль, окружение и историю, а также панель для всего остального. Если ткнуть в консоли на значок уменьшения, то можно открыть дополнительную панель, где можно писать скрипты.

⁷<https://r4ds.had.co.nz/>

⁸<https://stackoverflow.com>

⁹<https://community.rstudio.com/>

¹⁰<https://ru.stackoverflow.com>

¹¹<https://www.r-bloggers.com/>

¹²https://t.me/rlang_ru

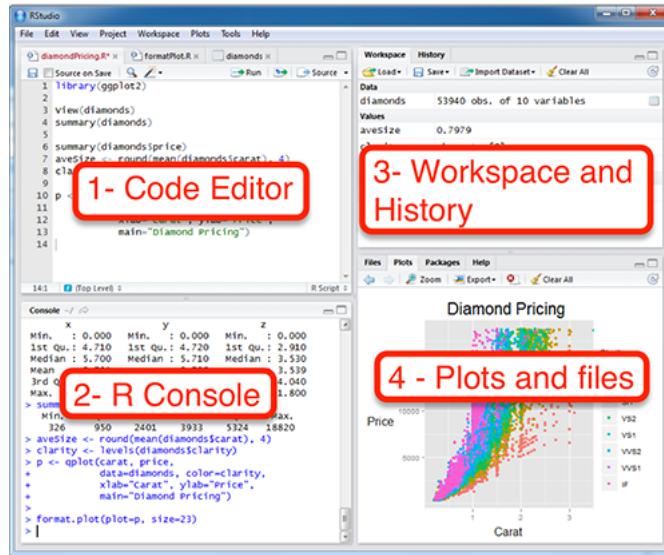
¹³<https://github.com/r-lang-group-ru/group-rules/blob/master/README.md>

¹⁴<https://t.me/joinchat/CxZg5goGc6rlWGjcv0YrpA>

¹⁵<https://t.me/ddjrus>

¹⁶<https://t.me/chartomojka>

¹⁷https://t.me/novaya_data



Существуют разные типы пользователей: одни любят работать в консоли (на картинке это **2 — R Console**), другие предпочитают скрипты (**1 — Code Editor**). Консоль позволяет использовать интерактивный режим команда-ответ, а скрипт является по сути текстовым документом, фрагменты которого можно для отладки запускать в консоли.

3 — Workspace and History: Здесь можно увидеть переменные. Это поле будет автоматически обновляться по мере того, как Вы будете запускать строчки кода и создавать новые переменные. Еще там есть вкладка с историей последних команд, которые были запущены.

4 — Plots and files: Здесь есть очень много всего. Во-первых, небольшой файловый менеджер, во-вторых, там будут появляться графики, когда вы будете их рисовать. Там же есть вкладка с вашими пакетами (Packages) и Help по функциям. Но об этом потом.

2.5 Введение в R

2.5.1 R как калькулятор

Ой-ей, консоль, скрипт че-то все непонятно.

Давайте начнем с самого простого и попробуем использовать R как простой калькулятор. $+$, $-$, $*$, $/$, $^$ (степень), $()$ и т.д.

Просто запускайте в консоли пока не надоест:

40 + 2

```
## [1] 42
```

```
3 - 2
```

```
## [1] 1
```

```
5 * 6
```

```
## [1] 30
```

```
99 / 9
```

```
## [1] 11
```

```
2 ^ 3
```

```
## [1] 8
```

```
(2 + 2) * 2
```

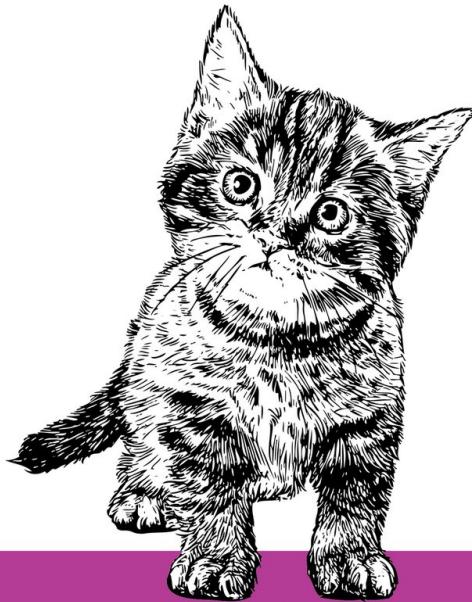
```
## [1] 8
```

Ничего сложного, верно? Вводим выражение и получаем результат. Порядок выполнения арифметических операций как в математике, так что не забывайте про скобочки. Подсказку по порядку выполнения операций в R можно получить с помощью следующей команды:

```
?Syntax
```

Если Вы не уверены в том, какие операции имеют приоритет, то используйте скобочки, чтобы точно обозначить, в каком порядке нужно производить операции.

How to actually learn any new programming concept



Essential

Changing Stuff and
Seeing What Happens

O RLY?

@ThePracticalDev

2.5.2 Функции

Давайте теперь извлечем корень из какого-нибудь числа. В принципе, тем, кто помнит школьный курс математики, возведения в степень вполне достаточно:

```
16 ^ 0.5
```

```
## [1] 4
```

Ну а если нет, то можете воспользоваться специальной функцией: это обычно какие-то буквенные символы с круглыми скобками сразу после названия функции. Мы подаем на вход (внутрь скобочек) какие-то данные, внутри этих функций происходят

какие-то вычисления, которые выдают в ответ какие-то другие данные (или же функция записывает файл, рисует график и т.д.).

Данные на входе называются **аргументом** функции, а иногда — **параметром** функции. В обыденной речи часто говорят **инпут** (калька с английского *input*).

Вот, например, функция для корня:

```
sqrt(16)
```

```
## [1] 4
```

R — case-sensitive язык, т.е. регистр важен. SQRT(16) не будет работать.

А вот так выглядит функция логарифма:

```
log(8)
```

```
## [1] 2.079442
```

Так, вроде бы все нормально, но... Если Вы еще что-то помните из школьной математики, то должны понимать, что что-то здесь не так.

Здесь не хватает основания логарифма!

Логарифм — показатель степени, в которую надо возвести число, называемое основанием, чтобы получить данное число.

То есть у логарифма 8 по основанию 2 будет значение 3:

$$\log_2 8 = 3$$

То есть если возвести 2 в степень 3 у нас будет 8:

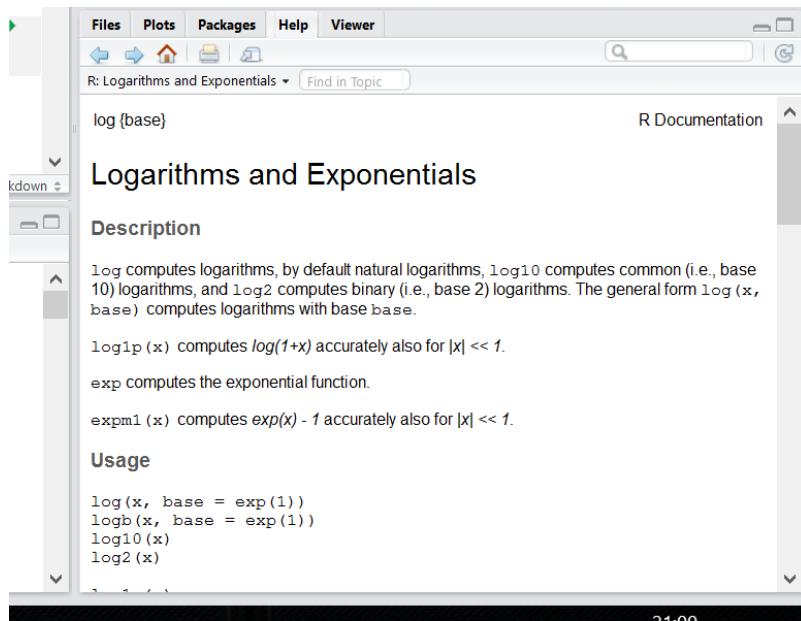
$$2^3 = 8$$

Только наша функция считает все как-то не так.

Чтобы понять, что происходит, нам нужно залезть в хэлп этой функции:

```
?log
```

Справа внизу в RStudio появится вот такое окно:



Действительно, у этой функции есть еще аргумент `base` =. По умолчанию он равен числу Эйлера ($2.7182818\dots$), т.е. функция считает натуральный логарифм. В большинстве функций R есть какой-то основной input — данные в том или ином формате, а есть и дополнительные параметры, которые можно прописывать вручную, если параметры по умолчанию вас не устраивают.

```
log(x = 8, base = 2)
```

```
## [1] 3
```

...или просто (если Вы уверены в порядке аргументов):

```
log(8, 2)
```

```
## [1] 3
```

Более того, Вы можете использовать результат выполнения одних функций в качестве аргумента для других:

```
log(8, sqrt(4))
```

```
## [1] 3
```

Если эксплицитно писать имена аргументов, то их порядок в функции не важен:

```
log(base = 2, x = 8)
```

```
## [1] 3
```

А еще можно недописывать имена аргументов, если они не совпадают с другими:

```
log(b = 2, x = 8)
```

```
## [1] 3
```

Мы еще много раз будем возвращаться к функциям. Вообще, функции — это одна из важнейших штук в R (примерно так же как и в Python). Мы будем создавать свои функции, использовать функции как input для функций и многое-многое другое. В R очень крутые возможности работы с функциями. Поэтому подружитесь с функциями, они клевые.

Арифметические знаки, которые мы использовали: +,-,/,[^] и т.д. называются **операторами** и на самом деле тоже являются функциями:

```
'+'(3,4)
```

```
## [1] 7
```

2.5.3 Переменные

Важная штука в программировании на практически любом языке — возможность сохранять значения в **переменных**. В R это обычно делается с помощью вот этих символов: <- (но можно использовать и обычное =, хотя это не очень принято). Для этого есть удобное сочетание клавиш: нажмите одновременно Alt - (или option - на Маке).

```
a <- 2
a
```

```
## [1] 2
```

Справа от <- находится значение, которое вы хотите сохранить, или же какое-то выражение, результата которого вы хотите сохранить в эту переменную¹⁸:

```
a <- log(9, 3)
```

Слева от <- находится название будущей переменной. Название переменных может быть самым разным. Есть несколько ограничений для синтаксически валидных имен

¹⁸Есть еще оператор ->, который позволяет присваивать значения слева направо, но так делать не рекомендуется, хотя это бывает довольно удобным.

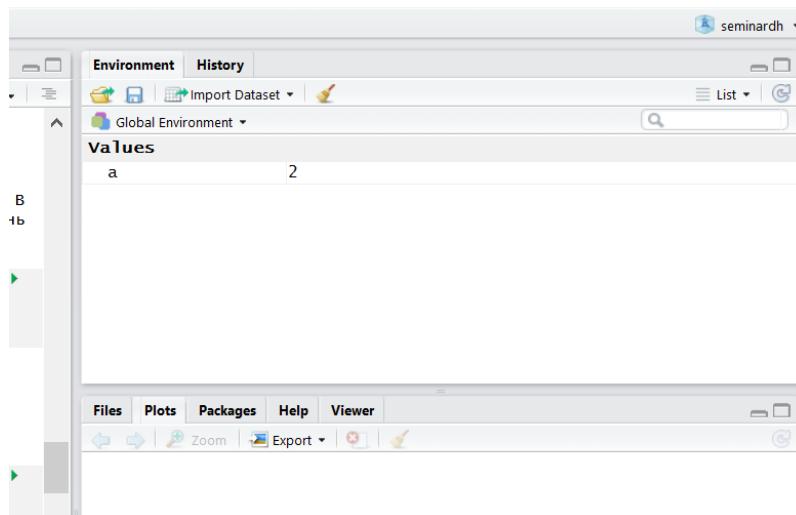
переменных: они должны включать в себя буквы, цифры, . или _, начинаться на букву (или точку, за которой не будет следовать цифра), не должны совпадать с коротким списком зарезервированных слов¹⁹. Короче говоря, название не должно включать в себя пробелы и большинство других знаков.

Нельзя: - new variable - _new_variable - .1var - v - r

Можно: - new_variable - .new.variable - var_2

Обязательно делайте названия переменных осмысленными! Страйтесь делать при этом их понятными и короткими, это сохранит вам очень много времени, когда вы (или кто-то еще) будете пытаться разобраться в написанном ранее коде. Если название все-таки получается длинным и состоящим из нескольких слов, то лучше всего использовать нижнее подчеркивание в качестве разделителя: some_variable²⁰.

После присвоения переменная появляется во вкладке Environment в RStudio:



Можно использовать переменные в функциях и просто вычислениях:

```
b <- a ^ a + a * a
```

```
## [1] 8
```

```
log(b, a)
```

```
## [1] 3
```

¹⁹<https://stat.ethz.ch/R-manual/R-devel/library/base/html/Reserved.html>

²⁰Еще иногда используются большие буквы SomeVariable, но это плохо читается, а иногда — точка, но это тоже не рекомендуется.

2.6 Логические операторы

Вы можете сравнивать разные переменные:

```
a == b
```

```
## [1] FALSE
```

Заметьте, что сравнивая две переменные мы используем два знака равно ==, а не один =. Иначе это будет означать присвоение.

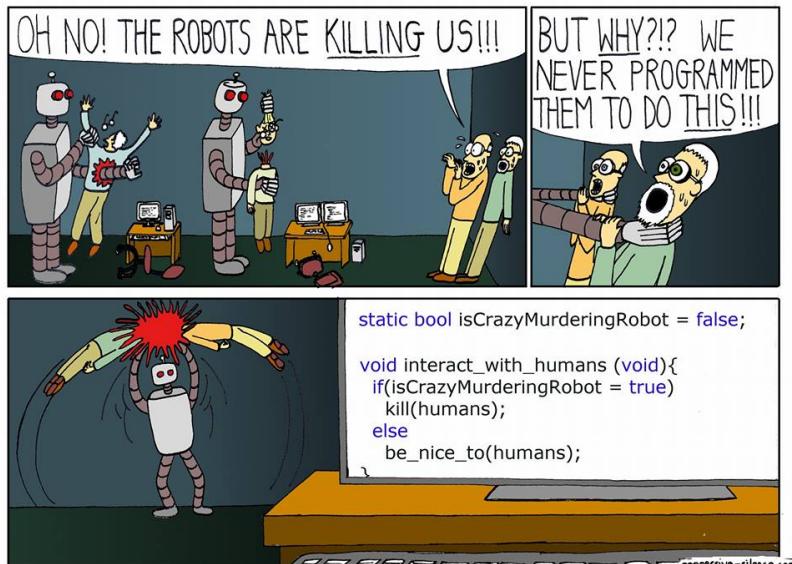
```
a = b # , !  
a
```

```
## [1] 8
```

```
b
```

```
## [1] 8
```

Теперь Вы сможете понять комикс про восстание роботов на следующей странице (пусть он и совсем про другой язык программирования)



Этот комикс объясняет, как важно не путать присваивание и сравнение (хотя я иногда путаю до сих пор =()).

Иногда нам нужно проверить на неравенство:

```
a <- 2
b <- 3

a == b
```

```
## [1] FALSE
```

```
a != b
```

```
## [1] TRUE
```

Восклицательный язык в программировании вообще и в R в частности стандартно означает отрицание.

Еще мы можем сравнивать на больше/меньше:

```
a > b
```

```
## [1] FALSE
```

```
a < b
```

```
## [1] TRUE
```

```
a >= b
```

```
## [1] FALSE
```

```
a <= b
```

```
## [1] TRUE
```

Этим мы будем пользоваться в дальнейшем регулярно! Именно на таких простых логических операциях построено большинство операций с данными.

2.7 Типы данных

До этого момента мы работали только с числами (numeric):

```
class(a)
```

```
## [1] "numeric"
```

На самом деле, в R три типа numeric, integer (целые), double (дробные), complex (комплексные числа)²¹. R сам будет конвертировать числа в нужный тип numeric при необходимости, поэтому этим можно не заморачиваться.

Если же все-таки нужно задать конкретный тип числа эксплицитно, то можно воспользоваться функциями `as.integer()`, `as.double()` и `as.complex()`. Кроме того, при создании числа можно поставить в конце L, чтобы обозначить число как integer:

```
is.integer(5)
```

```
## [1] FALSE
```

```
is.integer(5L)
```

```
## [1] TRUE
```

Про double есть еще один маленький секрет. Дело в том, что дробные числа хранятся в R как числа с плавающей запятой двойной точности²². Дробные числа в компьютере могут быть записаны только с определенной степенью точности, поэтому иногда встречаются вот такие вот ситуации:

```
sqrt(2)^2 == 2
```

```
## [1] FALSE
```

Это довольно стандартная ситуация, характерная не только для R. Чтобы ее избежать, можно воспользоваться функцией `all.equal()`:

```
all.equal(sqrt(2)^2, 2)
```

```
## [1] TRUE
```

Теперь же нам нужно ознакомиться с двумя другими важными типами данных в R:

1. **character**: строки символов. Они должны выделяться кавычками.

```
s <- "          !"
s
```

```
## [1] "          !"
```

²¹Комплексные числа в R пишутся так: `complexnumber <- 2+2i.i` здесь - это та самая мнимая единица, которая является квадратным корнем из -1.

²²<https://ru.wikipedia.org/wiki/>

```
class(s)
```

```
## [1] "character"
```

Можно использовать как ", так и ' (что удобно, когда строчка внутри уже содержит какие-то кавычки).

```
"Ph'nglui mglw'nafh Cthulhu R'lyeh wgah'nagl fhtagn"
```

```
## [1] "Ph'nglui mglw'nafh Cthulhu R'lyeh wgah'nagl fhtagn"
```

2. logical: просто TRUE или FALSE.

```
t1 <- TRUE  
f1 <- FALSE
```

```
t1
```

```
## [1] TRUE
```

```
f1
```

```
## [1] FALSE
```

Вообще, можно еще писать T и F (но не True и False!).

```
t2 <- T  
f2 <- F
```

Это дурная практика, так как R защищает от перезаписи переменные TRUE и FALSE, но не защищает от этого T и F.

```
TRUE <- FALSE
```

```
## Error in TRUE <- FALSE: invalid (do_set) left-hand side to assignment
```

```
TRUE
```

```
## [1] TRUE
```

```
T <- FALSE  
T
```

```
## [1] FALSE
```

Мы уже встречались с логическими значениями при сравнении двух числовых переменных. Теперь вы можете догадаться, что результаты сравнения, например, числовых или строковых переменных, можно тоже сохранять в переменные!

```
comparison <- a == b  
comparison
```

```
## [1] FALSE
```

Это нам очень понадобится, когда мы будем работать с реальными данными: нам нужно будет постоянно вытаскивать какие-то данные из датасета, что как раз и построено на игре со сравнением переменных.

Чтобы этим хорошо уметь пользоваться, нам нужно еще освоить как работать с логическими операторами. Про один мы немного уже говорили — это логическое НЕ (!). ! превращает TRUE в FALSE, а FALSE в TRUE:

```
t1
```

```
## [1] TRUE
```

```
!t1
```

```
## [1] FALSE
```

```
!!t1 # !
```

```
## [1] TRUE
```

Еще есть логическое И (выдаст TRUE только в том случае если обе переменные TRUE):

```
t1 & t2
```

```
## [1] TRUE
```

```
t1 & f1
```

```
## [1] FALSE
```

А еще логическое ИЛИ (выдаст TRUE в случае если хотя бы одна из переменных TRUE):

```
t1 | f1
```

```
## [1] TRUE
```

```
f1 | f2
```

```
## [1] FALSE
```

Если кому-то вдруг понадобится другое ИЛИ (строгое ЛИБО) — есть функция `xor()`, принимающая два аргумента.

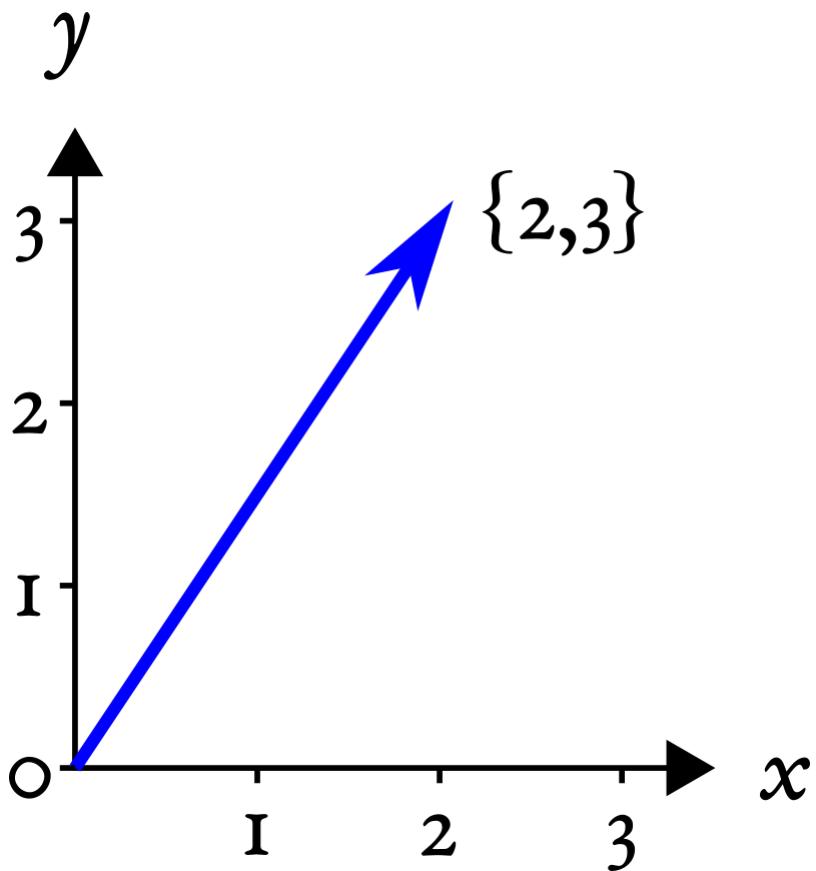
Итак, мы только что разобрались с самой занудной (хотя и важной) частью - с основными типами данных в R и как с ними работать²³. Пора переходить к чему-то более интересному и специальному для R. Вперед к ВЕКТОРАМ!

2.8 Вектор

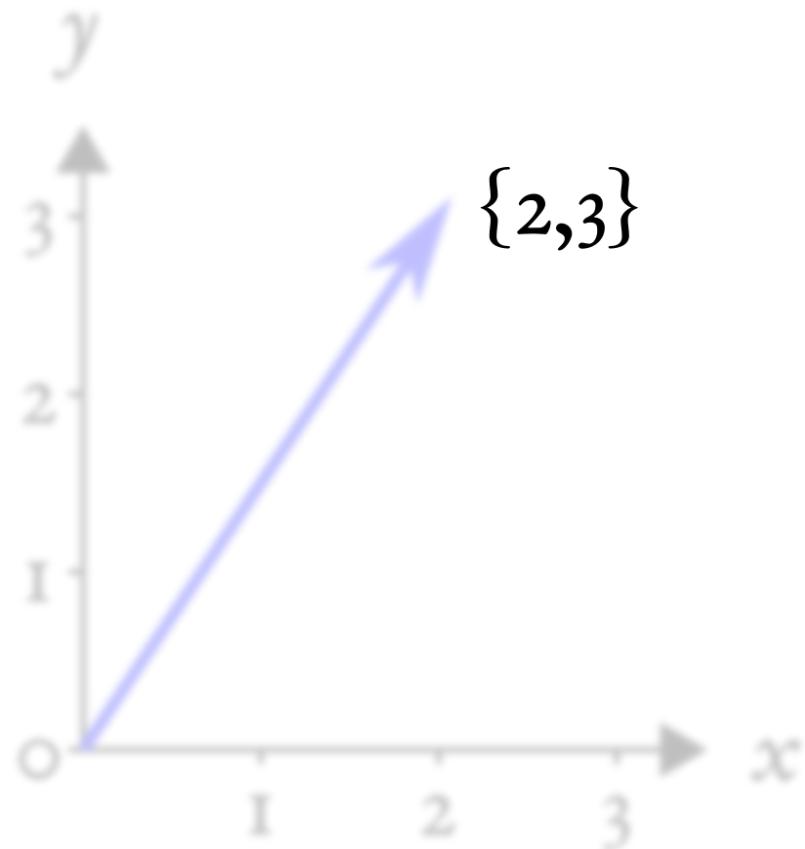
Если у вас не было линейной алгебры (или у вас с ней было все плохо), то просто запомните, что **вектор** (или `atomic vector` или `atomic`) — это набор (столбик) чисел в определенном порядке.

Если вы привыкли из школьного курса физики считать вектора стрелочками, то не спешите возмущаться и паниковать. Представьте стрелочки как точки из нуля координат {0,0} до какой-то точки на координатной плоскости, например, {2,3}:

²³Кроме описанных пяти типов данных (`integer`, `double`, `complex`, `character` и `logical`) есть еще и шестой — это `raw`, сырая последовательность байтов, но нам она не понадобится.



Вот последние два числа и будем считать вектором. Попытайтесь теперь мысленно стереть координатную плоскость и выбросить стрелочки из головы, оставив только последовательность чисел {2,3}:



На самом деле, мы уже работали с векторами в R, но, возможно, вы об этом даже не догадывались. Дело в том, что в R нет как таковых “значений”, есть вектора *длиной 1*. Такие дела!

Чтобы создать вектор из нескольких значений, нужно воспользоваться функцией `c()`:

```
c(4, 8, 15, 16, 23, 42)
```

```
## [1] 4 8 15 16 23 42
```

```
c(" ", " ", " ")
```

```
## [1] " " " "
```

Одна из самых мерзких и раздражающих причин ошибок в коде — это использование из кириллицы вместо с из латиницы. Видите разницу? И я не вижу. А R видит. И об этом сообщает:

```
(3, 4, 5)
```

```
## Error in (3, 4, 5): could not find function "
```

Для создания числовых векторов есть удобный оператор :

```
1:10
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

```
5:-3
```

```
## [1] 5 4 3 2 1 0 -1 -2 -3
```

Этот оператор создает вектор от первого числа до второго с шагом 1. Вы не представляете, как часто эта штука нам пригодится... Если же нужно сделать вектор с другим шагом, то есть функция `seq()`:

```
seq(10, 100, by = 10)
```

```
## [1] 10 20 30 40 50 60 70 80 90 100
```

Кроме того, можно задавать не шаг, а длину вектора. Тогда шаг функция `seq()` посчитает сама:

```
seq(1, 13, length.out = 4)
```

```
## [1] 1 5 9 13
```

Другая функция — `rep()` — позволяет создавать вектора с повторяющимися значениями. Первый аргумент — значение, которое нужно повторять, а второй аргумент — сколько раз повторять.

```
rep(1, 5)
```

```
## [1] 1 1 1 1 1
```

И первый, и второй аргумент могут быть векторами!

```
rep(1:3, 3)
```

```
## [1] 1 2 3 1 2 3 1 2 3
```

```
rep(1:3, 1:3)
```

```
## [1] 1 2 2 3 3 3
```

Еще можно объединять вектора (что мы, по сути, и делали, просто с векторами длиной 1):

```
v1 <- c("Hey", "Ho")
v2 <- c("Let's", "Go!")
c(v1, v2)
```

```
## [1] "Hey"    "Ho"     "Let's"   "Go!"
```

2.8.1 Приведение типов

Что будет, если вы объедините два вектора с значениями разных типов? Ошибка?

Мы уже обсуждали, что в *atomic* может быть только один тип данных. В некоторых языках программирования при операции с данными разных типов мы бы получили ошибку. А вот в R при несовпадении типов произойдет попытка привести типы к “общему знаменателю”, то есть конвертировать данные в более “широкий” тип.

Например:

```
c(FALSE, 2)
```

```
## [1] 0 2
```

`FALSE` превратился в 0 (а `TRUE` превратился бы в 1), чтобы оба значения можно было объединить в вектор. То же самое произошло бы в случае операций с векторами:

```
2 + TRUE
```

```
## [1] 3
```

Это называется **неявным приведением типов** (*implicit coercion*).

Вот более сложный пример:

```
c(TRUE, 3, "")
```

```
## [1] "TRUE"   "3"      ""       "
```

У R есть иерархия приведения типов:

```
NULL < raw < logical < integer < double < complex < character <
list < expression.
```

Мы из этого списка еще много не знаем, сейчас важно запомнить, что логические данные — TRUE и FALSE — превращаются в 0 и 1 соответственно, а 0 и 1 в строчки "0" и "1".

Если Вы боитесь полагаться на приведение типов, то можете воспользоваться функциями `as.` для явного приведения типов (**explicit coercion**):

```
as.numeric(c(T, F, F))

## [1] 0 0 0

as.character(as.numeric(c(T, F, F)))

## [1] "0" "0" "0"
```

Можно превращать и обратно, например, строковые значения в числовые. Если среди числа встретится буква или другой неподходящий знак, то мы получим предупреждение NA — пропущенное значение (мы очень скоро научимся с ними работать).

```
as.numeric(c("1", "2", " "))

## Warning: NAs introduced by coercion

## [1] 1 2 NA
```

Один из распространенных примеров использования неявного приведения типов — использования функций `sum()` и `mean()` для подсчета в логическом векторе количества и доли TRUE соответственно. Мы будем много раз пользоваться этим приемом в дальнейшем!

2.8.2 Векторизация

Все те арифметические операторы, что мы использовали ранее, можно использовать с векторами одинаковой длины:

```
n <- 1:4
m <- 4:1
n + m

## [1] 5 5 5 5

n - m

## [1] -3 -1  1  3
```

```
n * m
## [1] 4 6 6 4

n / m
## [1] 0.2500000 0.6666667 1.5000000 4.0000000

n ^ m + m * (n - m)
## [1] -11    5   11    7
```

Если применить операторы на двух векторах одинаковой длины, то мы получим результат поэлементного применения оператора к двум векторам. Это называется **векторизацией (vectorization)**.

Если после какого-нибудь MATLAB Вы привыкли, что по умолчанию операторы работают по правилам линейной алгебры и $m*n$ будет давать скалярное произведение (*dot product*), то снова нет. Для скалярного произведения нужно использовать операторы с % по краям:

```
n %*% m
##      [,1]
## [1,] 20
```

Абсолютно так же и с операциями с матрицами в R, хотя про матрицы будет немного позже.

В принципе, большинство функций в R, которые работают с отдельными значениями, так же хорошо работают и с целыми векторами. Скажем, Вы хотите извлечь корень из нескольких чисел, для этого не нужны никакие циклы (как это обычно делается в других языках программирования). Можно просто “скормить” вектор функции и получить результат применения функции к каждому элементу вектора:

```
sqrt(1:10)
```

```
## [1] 1.000000 1.414214 1.732051 2.000000 2.236068 2.449490 2.645751 2.828427
## [9] 3.000000 3.162278
```

Таких векторизованных функций в R очень много. Многие из них написаны на более низкоуровневых языках программирования (C, C++, FORTRAN), за счет чего использование таких функций приводит не только к более элегантному, лаконичному, но и к более быстрому коду.

Векторизация в R — это очень важная фишка, которая отличает этот язык программирования от многих других. Если вы уже имеете опыт программирования на другом языке, то вам во многих задачах захочется использовать циклы типа `for` и `while`^{4.2}. Не спешите этого делать! В очень многих случаях циклы можно заменить векторизацией. Тем не менее, векторизация — это не единственный способ избавить от циклов типа `for` и `while`^{5.5.1}.

2.8.3 Ресайклинг

Допустим мы хотим совершить какую-нибудь операцию с двумя векторами. Как мы убедились, с этим обычно нет никаких проблем, если они совпадают по длине. А что если вектора не совпадают по длине? Ничего страшного! Здесь будет работать правило **ресурсклинга** (*правило переписывания, recycling rule*). Это означает, что если мы делаем операцию на двух векторах разной длины, то если короткий вектор кратен по длине длинному, короткий вектор будет повторяться необходимое количество раз:

```
n <- 1:4
m <- 1:2
n * m
```

```
## [1] 1 4 3 8
```

А что будет, если совершать операции с вектором и отдельным значением? Можно считать это частным случаем ресайклинга: короткий вектор длиной 1 будет повторяться столько раз, сколько нужно, чтобы он совпадал по длине с длинным:

```
n * 2
```

```
## [1] 2 4 6 8
```

Если же меньший вектор не кратен большему (например, один из них длиной 3, а другой длиной 4), то R посчитает результат, но выдаст предупреждение.

```
n + c(3, 4, 5)
```

```
## Warning in n + c(3, 4, 5): longer object length is not a multiple of shorter
## object length
## [1] 4 6 8 7
```

Проблема в том, что эти предупреждения могут в неожиданный момент стать причиной ошибок. Поэтому не стоит полагаться на ресайклинг некратных по длине векторов. См. здесь²⁴. А вот ресайклинг кратных по длине векторов — это очень удобная штука, которая используется очень часто.

²⁴<https://stackoverflow.com/questions/6555651/under-what-circumstances-does-r-recycle>

2.8.4 Индексирование векторов

Итак, мы подошли к одному из самых сложных моментов. И одному из основных. От того, как хорошо вы научитесь с этим работать, зависит весь Ваш дальнейший успех на R-поприще!

Речь пойдет об **индексировании** векторов. Задача, которую Вам придется решать каждые пять минут работы в R - как выбрать из вектора (или же списка, матрицы и датафрейма) какую-то его часть. Для этого используются квадратные скобочки [] (не круглые - они для функций!).

Самое простое - индексировать по номеру индекса, т.е. порядку значения в векторе.

```
n <- 1:10
n[1]
```

```
## [1] 1
```

```
n[10]
```

```
## [1] 10
```

Если вы знакомы с другими языками программирования (не MATLAB, там все так же) и уже научились думать, что индексация с 0 — это очень удобно и очень правильно (ну или просто привыкли с этим), то в R Вам придется переучиться обратно. Здесь первый индекс — это 1, а последний равен длине вектора — ее можно узнать с помощью функции `length()`. С обоих сторон индексы берутся включительно.

С помощью индексирования можно не только вытаскивать имеющиеся значения в векторе, но и присваивать им новые:

```
n[3] <- 20
n
```

```
## [1] 1 2 20 4 5 6 7 8 9 10
```

Конечно, можно использовать целые векторы для индексирования:

```
n[4:7]
```

```
## [1] 4 5 6 7
```

```
n[10:1]
```

```
## [1] 10 9 8 7 6 5 4 20 2 1
```

Индексирование с минусом выдаст вам все значения вектора кроме выбранных:

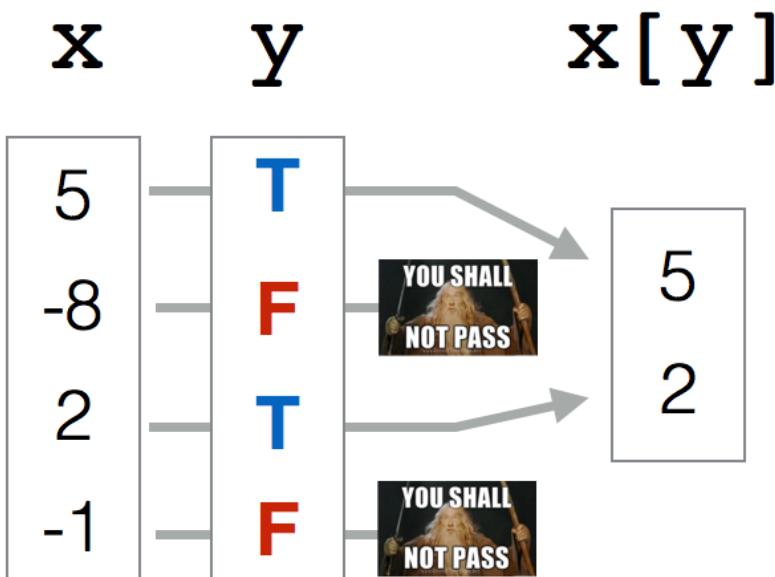
```
n[-1]  
## [1] 2 20 4 5 6 7 8 9 10  
  
n[c(-4, -5)]  
## [1] 1 2 20 6 7 8 9 10
```

Минус здесь “выключает” выбранные значения из вектора, а не означает отсчет с конца как в Python.

Более того, можно использовать логический вектор для индексирования. В этом случае нужен логический вектор такой же длины:

```
n[c(TRUE, FALSE, TRUE, FALSE, TRUE, FALSE, TRUE, FALSE, TRUE, FALSE)]  
## [1] 1 20 5 7 9
```

Логический вектор работает здесь как фильтр: пропускает только те значения, где на соответствующей позиции в логическом векторе для индексирования содержится TRUE, и не пропускает те значения, где на соответствующей позиции в логическом векторе для индексирования содержится FALSE.



Ну а если эти два вектора (исходный вектор и логический вектор индексов) не равны по длине, то тут будет снова работать правило ресайклнга!

```
n[c(TRUE, FALSE)] # - recycling rule!
```

```
## [1] 1 20 5 7 9
```

Есть еще один способ индексирования векторов, но он несколько более редкий: индексирование по имени. Дело в том, что для значений векторов можно (но не обязательно) присваивать имена:

```
my_named_vector <- c(first = 1,
                      second = 2,
                      third = 3)
my_named_vector['first']
```

```
## first
##      1
```

А еще можно “вытаскивать” имена из вектора с помощью функции `names()` и присваивать таким образом новые имена.

```
d <- 1:4
names(d) <- letters[1:4]
d["a"]
```

```
## a
## 1
```

`letters` - это “зашитая” в R константа - вектор букв от a до z. Иногда это очень удобно! Кроме того, есть константа LETTERS - то же самое, но заглавными буквами. А еще в R есть названия месяцев на английском и числовая константа pi.

Теперь посчитаем среднее вектора n:

```
mean(n)
```

```
## [1] 7.2
```

А как вытащить все значения, которые больше среднего?

Сначала получим логический вектор — какие значения больше среднего:

```
larger <- n > mean(n)
larger
```

```
## [1] FALSE FALSE TRUE FALSE FALSE FALSE TRUE TRUE TRUE
```

А теперь используем его для индексирования вектора n:

```
n[larger]
```

```
## [1] 20 8 9 10
```

Можно все это сделать в одну строчку:

```
n[n>mean(n)]
```

```
## [1] 20 8 9 10
```

Предыдущая строчка отражает то, что мы будем постоянно делать в R: вычленять (subset) из данных отдельные куски на основании разных условий.

2.8.5 NA — пропущенные значения

В реальных данных у нас часто чего-то не хватает. Например, из-за технической ошибки или невнимательности не получилось записать какое-то измерение. Для обозначения пропущенных значений в R есть специальное значение NA. NA — это не строка "NA", не 0, не пустая строка и не FALSE. NA — это NA. Большинство операций с векторами, содержащими NA будут выдавать NA:

```
missed <- NA
missed == "NA"
```

```
## [1] NA
```

```
missed == "
```

```
## [1] NA
```

```
missed == NA
```

```
## [1] NA
```

Заметьте: даже сравнение NA с NA выдает NA!

Иногда NA в данных очень бесит:

```
n[5] <- NA
n
```

```
## [1] 1 2 20 4 NA 6 7 8 9 10
```

```
mean(n)
```

```
## [1] NA
```

Что же делать?

Наверное, надо сравнить вектор с NA и исключить этих пакостников. Давайте попробуем:

```
n == NA
```

```
## [1] NA NA NA NA NA NA NA NA NA NA
```

Ах да, мы ведь только что узнали, что даже сравнение NA с NA приводит к NA!

Чтобы выбраться из этой непростой ситуации, используйте функцию `is.na()`:

```
is.na(n)
```

```
## [1] FALSE FALSE FALSE FALSE TRUE FALSE FALSE FALSE FALSE FALSE
```

Результат выполнения `is.na(n)` выдает FALSE в тех местах, где у нас числа и TRUE там, где у нас NA. Чтобы вычленить из вектора `n` все значения кроме NA нам нужно, чтобы было наоборот: TRUE, если это не NA, FALSE, если это NA. Здесь нам понадобится логический оператор `НЕ !` (мы его уже встречали), который инвертирует логические значения:

```
n[!is.na(n)]
```

```
## [1] 1 2 20 4 6 7 8 9 10
```

Ура, мы можем считать среднее!

```
mean(n[!is.na(n)])
```

```
## [1] 7.444444
```

Теперь Вы понимаете, зачем нужно отрицание (`!`)

Вообще, есть еще один из способов посчитать среднее, если есть NA. Для этого надо залезть в хэлп по функции `mean()`:

```
?mean()
```

В хэлпе мы найдем параметр `na.rm =`, который по умолчанию FALSE. Вы знаете, что нужно делать!

```
mean(n, na.rm = TRUE)
```

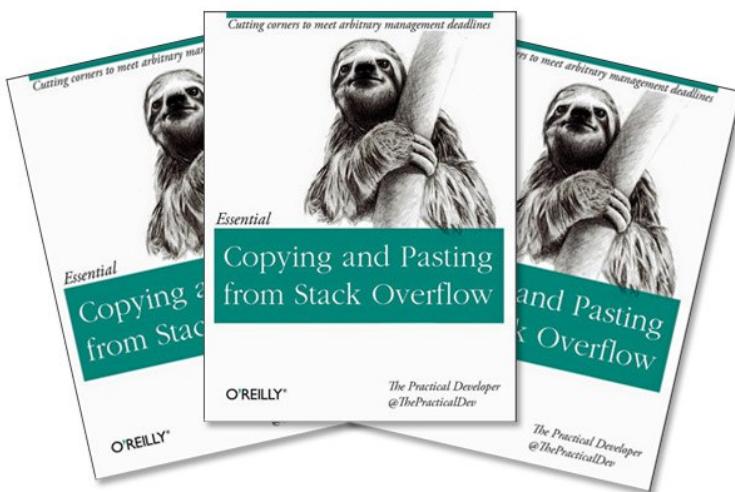
```
## [1] 7.444444
```

NA может появляться в векторах других типов тоже. На самом деле, NA - это специальное значение в логических векторах, тогда как в векторах других типов NA появляется как NA_integer_, NA_real_, NA_complex_ или NA_character_, но R обычно сам все переводит в нужный формат и показывает как просто NA.

Кроме NA есть еще NaN — это разные вещи. NaN расшифровывается как Not a Number и получается в результате таких операций как 0/0.

2.8.6 В любой непонятной ситуации — ищите в поисковике

Если вдруг вы не знаете, что искать в хэлпе, или хэлпа попросту недостаточно, то ищите в поисковике!



Нет ничего постыдного в том, чтобы искать в Интернете решения проблем. Это абсолютно нормально. Используйте силу интернета во благо и да помогут вам Stackoverflow и бесчисленные R-тutorиалы!

Computer Programming To Be Officially Renamed “Googling Stack Overflow”
Source: <http://t.co/xu7acfXvFF> pic.twitter.com/iJ9k7aAVhd

— Stack Exchange July 20, 2015

Главное, помните: загуглить работающий ответ всегда недостаточно. Надо понять, как и почему он работает. Иначе что-то обязательно пойдет не так.

Кроме того, правильно загуглить проблему — не так уж и просто.

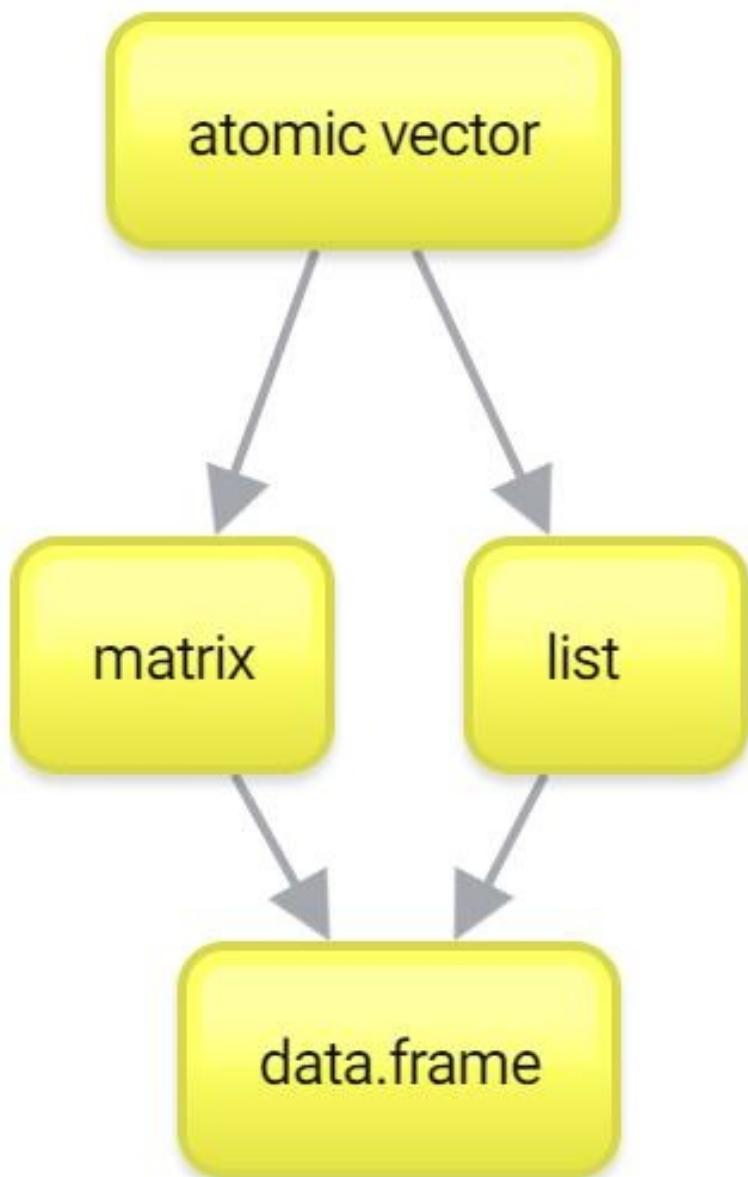
Does anyone ever get good at R or do they just get good at googling how to do things in R

— https://twitter.com/mousquemere/status/1125522375141883907?ref_src=twsrc%5Etfw May 6, 2019

Doctors: Googling stuff online does not make you a doctor.
Programmers:



Итак, с векторами мы более-менее разобрались. Помните, что вектора — это один из краеугольных камней Вашей работы в R. Если Вы хорошо с ними разобрались, то дальше все будет довольно несложно. Тем не менее, вектора — это не все. Есть еще два важных типа данных: списки (`list`) и матрицы (`matrix`). Их можно рассматривать как своеобразное “расширение” векторов, каждый в свою сторону. Ну а списки и матрицы нужны чтобы понять основной тип данных в R — `data.frame`.



2.9 Матрицы (matrix)

Если вдруг Вас пугает это слово, то совершенно зря. Матрица — это всего лишь “двумерный” вектор: вектор, у которого есть не только длина, но и ширина. Создать матрицу можно с помощью функции `matrix()` из вектора, указав при этом количество строк и столбцов.

```
A <- matrix(1:20, nrow=5, ncol=4)
A

##      [,1] [,2] [,3] [,4]
## [1,]    1    6   11   16
## [2,]    2    7   12   17
## [3,]    3    8   13   18
## [4,]    4    9   14   19
## [5,]    5   10   15   20
```

Заметьте, значения вектора заполняются следующим образом: сначала заполняется первый столбик сверху вниз, потом второй сверху вниз и так до конца, т.е. заполнение значений матрицы идет в первую очередь по вертикали. Это довольно стандартный способ создания матриц, характерный не только для R.

Если мы знаем сколько значений в матрице и сколько мы хотим строк, то количество столбцов указывать необязательно:

```
A <- matrix(1:20, nrow=5)
A

##      [,1] [,2] [,3] [,4]
## [1,]    1    6   11   16
## [2,]    2    7   12   17
## [3,]    3    8   13   18
## [4,]    4    9   14   19
## [5,]    5   10   15   20
```

Все остальное так же как и с векторами: внутри находится данные только одного типа. Поскольку матрица — это уже двумерный массив, то у него имеется два индекса. Эти два индекса разделяются запятыми.

```
A[2,3]
```

```
## [1] 12
```

```
A[2:4, 1:3]
```

```
##      [,1] [,2] [,3]
## [1,]    2    7   12
## [2,]    3    8   13
## [3,]    4    9   14
```

Первый индекс — выбор строк, второй индекс — выбор колонок. Если же мы оставляем пустое поле вместо числа, то мы выбираем все строки/колонки в зависимости от того, оставили мы поле пустым до или после запятой:

A[, 1:3]

```
##      [,1] [,2] [,3]
## [1,]    1    6   11
## [2,]    2    7   12
## [3,]    3    8   13
## [4,]    4    9   14
## [5,]    5   10   15
```

A[2:4,]

```
##      [,1] [,2] [,3] [,4]
## [1,]    2    7   12   17
## [2,]    3    8   13   18
## [3,]    4    9   14   19
```

A[,]

```
##      [,1] [,2] [,3] [,4]
## [1,]    1    6   11   16
## [2,]    2    7   12   17
## [3,]    3    8   13   18
## [4,]    4    9   14   19
## [5,]    5   10   15   20
```

Если мы выберем только одну колонку/строчку, то на выходе получим уже вектор, а не матрицу:

A[2,]

```
## [1] 2 7 12 17
```

Это называется “схлопыванием размерности”. Чтобы этого избежать, нужно поставить `drop = FALSE` после второй запятой внутри квадратных скобок.

```
A[2,, drop = FALSE]
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    2    7   12   17
```

Для соединения двух или более матриц можно воспользоваться функциями `rbind()` и `cbind()` для соединения матриц по вертикали и по горизонтали соответственно.

```
rbind(A, A)
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    1    6   11   16
## [2,]    2    7   12   17
## [3,]    3    8   13   18
## [4,]    4    9   14   19
## [5,]    5   10   15   20
## [6,]    1    6   11   16
## [7,]    2    7   12   17
## [8,]    3    8   13   18
## [9,]    4    9   14   19
## [10,]   5   10   15   20
```

```
cbind(A, A)
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8]
## [1,]    1    6   11   16    1    6   11   16
## [2,]    2    7   12   17    2    7   12   17
## [3,]    3    8   13   18    3    8   13   18
## [4,]    4    9   14   19    4    9   14   19
## [5,]    5   10   15   20    5   10   15   20
```

В принципе, это все, что нам нужно знать о матрицах. Матрицы используются в R довольно редко, особенно по сравнению, например, с MATLAB. Но вот индексировать матрицы хорошо бы уметь: это понадобится в работе с датафреймами.

То, что матрица - это просто двумерный вектор, не является метафорой: в R матрица - это по сути своей вектор с дополнительными *атрибутами* `dim` и `dimnames`. Атрибуты — это неотъемлемые свойства объектов, для всех объектов есть обязательные атрибуты типа и длины и могут быть любые необязательные атрибуты. Можно задавать свои атрибуты или удалять уже присвоенные: удаление атрибута `dim` у матрицы превратит ее в обычный вектор. Про атрибуты подробнее можно почитать здесь²⁵ или на стр. 99–101 книги “R in a Nutshell” (Adler, 2010).

²⁵<https://perso.esiee.fr/~courivad/R/06-objects.html>

2.10 Списки (list)

Теперь представим себе вектор без ограничения на одинаковые данные внутри. И получим список!

```
simple_list <- list(42, " ", TRUE)
simple_list
```

```
## [[1]]
## [1] 42
##
## [[2]]
## [1] "
##
## [[3]]
## [1] TRUE
```

А это значит, что там могут содержаться самые разные данные, в том числе и другие списки и векторы!

```
complex_list <- list(c("Wow", "this", "list", "is", "so", "big"), "16", simple_list)
complex_list
```

```
## [[1]]
## [1] "Wow"  "this" "list" "is"    "so"    "big"
##
## [[2]]
## [1] "16"
##
## [[3]]
## [[3]][[1]]
## [1] 42
##
## [[3]][[2]]
## [1] "
##
## [[3]][[3]]
## [1] TRUE
```

Если у нас сложный список, то есть очень классная функция, чтобы посмотреть, как он устроен, под названием `str()`:

```
str(complex_list)
```

```
## List of 3
```

```
## $ : chr [1:6] "Wow" "this" "list" "is" ...
## $ : chr "16"
## $ :List of 3
## ..$ : num 42
## ..$ : chr "
## ..$ : logi TRUE
```

Как и в случае с векторами мы можем давать имена элементам списка:

```
named_list <- list(age = 24, phd_student = T, language = "Russian")
named_list
```

```
## $age
## [1] 24
##
## $phd_student
## [1] FALSE
##
## $language
## [1] "Russian"
```

К списку можно обращаться как с помощью индексов, так и по именам. Начнем с последнего:

```
named_list$age
```

```
## [1] 24
```

А вот с индексами сложнее, и в этом очень легко запутаться. Давайте попробуем сделать так, как мы делали это раньше:

```
named_list[1]
```

```
## $age
## [1] 24
```

Мы, по сути, получили элемент списка - просто как часть списка, т.е. как список длиной один:

```
class(named_list)
```

```
## [1] "list"
```

```
class(named_list[1])
```

```
## [1] "list"
```

А вот чтобы добраться до самого элемента списка (и сделать с ним что-то хорошее) нам нужна не одна, а две квадратных скобочки:

```
named_list[[1]]
```

```
## [1] 24
```

```
class(named_list[[1]])
```

```
## [1] "numeric"
```

Indexing lists in #rstats. Inspired by the Residence Inn pic.twitter.com/YQ6axb2w7t

— Hadley Wickham (@ href="https://twitter.com/hadleywickham/status/643381054758363136?ref_src=twsrc%5Etfw" ref_src="twsrc%5Etfw">September 14, 2015

Как и в случае с вектором, к элементу списка можно обращаться по имени.

```
named_list[['age']]
```

```
## [1] 24
```

Хотя последнее — практически то же самое, что и использование знака \$.

Списки довольно часто используются в R, но реже, чем в Python. Со многими объектами в R, такими как результаты статистических тестов, объекты ggplot и т.д. удобно работать именно как со списками — к ним все вышеописанное применимо. Кроме того, некоторые данные мы изначально получаем в виде древообразной структуры — хочешь не хочешь, а придется работать с этим как со списком. Особенно это характерно для данных, выкачанных из веб-страниц (HTML страницы, XML данные) или полученных с помощью API различных веб-сайтов (например, в формате JSON). Но обычно после этого стоит как можно скорее превратить список в датафрейм.

2.11 Датафрейм

Итак, мы перешли к самому главному. Самому-самому. Датафреймы (**data.frames**). Более того, сейчас станет понятно, зачем нам нужно было разбираться со всеми предыдущими темами.

Без векторов мы не смогли бы разобраться с матрицами и списками. А без последних мы не сможем понять, что такое датафрейм.

```
name <- c("Ivan", "Eugeny", "Lena", "Misha", "Sasha")
age <- c(26, 34, 23, 27, 26)
student <- c(FALSE, FALSE, TRUE, TRUE, TRUE)
df = data.frame(name, age, student)
df
```

```
##      name age student
## 1    Ivan  26   FALSE
## 2 Eugeny  34   FALSE
## 3   Lena  23    TRUE
## 4   Misha 27    TRUE
## 5   Sasha 26    TRUE
```

```
str(df)
```

```
## 'data.frame': 5 obs. of 3 variables:
## $ name : chr "Ivan" "Eugeny" "Lena" "Misha" ...
## $ age  : num 26 34 23 27 26
## $ student: logi FALSE FALSE TRUE TRUE TRUE
```

Вообще, очень похоже на список, не правда ли? Так и есть, датафрейм — это что-то вроде проименованного списка, каждый элемент которого является atomic вектором фиксированной длины. Скорее всего, список Вы представляли “горизонтально”. Если это так, то теперь “переверните” его у себя в голове. Так, чтобы названия векторов оказались сверху, а колонки стали столбцами. Поскольку длина всех этих векторов равна (обязательное условие!), то данные представляют собой табличку, похожую на матрицу. Но в отличие от матрицы, разные столбцы могут иметь разные типы данных: первая колонка — character, вторая колонка — numeric, третья колонка — logical. Тем не менее, обращаться с датафреймом можно и как с проименованным списком, и как с матрицей:

```
df$age[2:3]
```

```
## [1] 34 23
```

Здесь мы сначала вытащили колонку age с помощью оператора \$. Результатом этой операции является числовой вектор, из которого мы вытащили кусок, выбрав индексы 2 и 3.

Используя оператор \$ и присваивание можно создавать новые колонки датафрейма:

```
df$lovesR <- TRUE #      recycling - ?
df
```

```
##      name age student lovesR
```

```
## 1 Ivan 26 FALSE TRUE
## 2 Eugeny 34 FALSE TRUE
## 3 Lena 23 TRUE TRUE
## 4 Misha 27 TRUE TRUE
## 5 Sasha 26 TRUE TRUE
```

Ну а можно просто обращаться с помощью двух индексов через запятую, как мы это делали с матрицей:

```
df[3:5, 2:3]
```

```
##   age student
## 3 23    TRUE
## 4 27    TRUE
## 5 26    TRUE
```

Как и с матрицами, первый индекс означает строчки, а второй — столбцы.

А еще можно использовать названия колонок внутри квадратных скобок:

```
df[1:2, "age"]
```

```
## [1] 26 34
```

И здесь перед нами открываются невообразимые возможности! Узнаем, любят ли R те, кто моложе среднего возраста в группе:

```
df[df$age < mean(df$age), 4]
```

```
## [1] TRUE TRUE TRUE TRUE
```

Эту же задачу можно выполнить другими способами:

```
df$lovesR[df$age < mean(df$age)]
```

```
## [1] TRUE TRUE TRUE TRUE
```

```
df[df$age < mean(df$age), 'lovesR']
```

```
## [1] TRUE TRUE TRUE TRUE
```

В большинстве случаев подходят сразу несколько способов — тем не менее, стоит овладеть ими всеми.

Датафреймы удобно просматривать в RStudio. Для этого нужно написать команду `View(df)` или же просто нажать на название нужной переменной из списка вверху

справа (там где Environment). Тогда увидите табличку, очень похожую на Excel и тому подобные программы для работы с таблицами. Там же есть и всякие возможности для фильтрации, сортировки и поиска... Но, конечно, интереснее все эти вещи делать руками, т.е. с помощью написания кода.

На этом пора заканчивать с введением и приступать к реальным данным.

Глава 3

Импорт данных

Итак, пришло время перейти к реальным данным. Мы начнем с использования датасета (так мы будем называть любой набор данных) по супергероям. Этот датасет представляет собой табличку, каждая строка которой — отдельный супергерой, а столбик — какая-либо информация о нем. Например, цвет глаз, цвет волос, вселенная супергероя¹, рост, вес, пол и так далее. Несложно заметить, что этот датасет идеально подходит под структуру датафрейма: прямоугольная табличка, внутри которой есть разные колонки, каждая из которых имеет свой тип (числовой или строковый).

3.1 Рабочая папка и проекты RStudio

Для начала скачайте файл по ссылке²

Он, скорее всего, появился у Вас в папке “Загрузки”. Если мы будем просто пытаться прочитать этот файл (например, с помощью `read.csv()` — мы к этой функции очень скоро перейдем), указав его имя и разрешение, то наткнемся на такую ошибку:

```
read.csv("heroes_information.csv")  
  
## Warning in file(file, "rt"): cannot open file 'heroes_information.csv': No such  
## file or directory  
  
## Error in file(file, "rt"): cannot open the connection
```

Это означает, что R не может найти нужный файл. Вообще-то мы даже не сказали, где искать. Нам нужно как-то совместить место, где R ищет загружаемые файлы и сами

¹супергерои в комиксах, фильмах и телесериалах часто взаимодействуют друг с другом, однако обычно это взаимодействие происходит между супергероями одного издателя. Два крупнейших издателя комиксов — DC и Marvel, поэтому принято говорить о вселенной DC и Marvel.

²https://raw.githubusercontent.com/agricolamz/2020-2021-ds4dh/master/data/heroes_information.csv

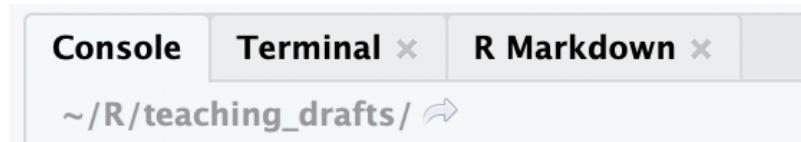
файлы. Для этого есть несколько способов.

- Магомет идет к горе: перемещение файлов в рабочую папку.

Для этого нужно узнать, какая папка является рабочей с помощью функции `getwd()` (без аргументов), найти эту папку в проводнике и переместить туда файл. После этого можно использовать просто название файла с разрешением:

```
heroes <- read.csv("heroes_information.csv")
```

Кроме того, путь к рабочей папке можно увидеть в RStudio во вкладке с консолью, в самой верхней части (прямо под надписью “Console”):



- Гора идет к Магомету: изменение рабочей папки.

Можно просто сменить рабочую папку с помощью `setwd()` на ту, где сейчас лежит файл, прописав путь до этой папки. Теперь файл находится в рабочей папке:

```
heroes <- read.csv("heroes_information.csv")
```

Этот вариант использовать не рекомендуется! Как минимум, это сразу делает невозможным запустить скрипт на другом компьютере.

- Гора находит Магомета по месту прописки: указание полного пути файла.

```
heroes <- read.csv("/Users/Username/Some_Folder/heroes_information.csv")
```

Этот вариант страдает теми же проблемами, что и предыдущий, поэтому тоже не рекомендуется!

Для пользователей Windows есть дополнительная сложность: знак `/` является особым знаком для R, поэтому вместо него нужно использовать двойной `//`.

- Магомет использует кнопочный интерфейс: Import Dataset.

Во вкладке Environment справа в окне RStudio есть кнопка “Import Dataset”. Возможно, у Вас возникло непреодолимое желание отдохнуть от написания кода и понажимать кнопочки — сопротивляйтесь этому всеми силами, но не вините себя, если не сдержитесь.

- Гора находит Магомета в интернете.

Многие функции в R, предназначенные для чтения файлов, могут прочитать файл не только на Вашем компьютере, но и сразу из интернета. Для этого просто используйте ссылку вместо пути:

```
heroes <- read.csv("https://raw.githubusercontent.com/agricolamz/2020-2021-ds4dh/master/data/hero
```

- Каждый Магомет получает по своей горе: использование проектов в RStudio.

На первый взгляд это кажется чем-то очень сложным, но это не так. Это очень просто и ОЧЕНЬ удобно. При создании проекта создается отдельная папочка, где у Вас лежат данные, хранятся скрипты, вспомогательные файлы и отчеты. Если нужно вернуться к другому проекту — просто открываете другой проект, с другими файлами и скриптами. Это еще помогает не пересекаться переменным из разных проектов — а то, знаете, использование двух переменных `data` в разных скриптах чревато ошибками. Поэтому очень удобным решением будет выделение отдельного проекта под этот курс.

При закрытии проекта все переменные по умолчанию тоже будут сохраняться, а при открытии — восстанавливаются. Это очень удобно, хотя некоторые рекомендуют от этого отказаться³. Это можно сделать во вкладке Tool – Global Options...

3.1.1 Табличные данные: текстовые и бинарные данные

Как Вы уже поняли, импортирование данных - одна из самых муторных и неприятных вещей в R. Если у Вас получится с этим справится, то все остальное - ерунда. Мы уже разобрались с первой частью этого процесса - нахождением файла с данными, осталось научиться их читать.

Здесь стоит сделать небольшую ремарку. Довольно часто данные представляют собой табличку. Или же их можно свести к табличке. Такая табличка, как мы уже выяснили, удобно презентируется в виде датафрейма. Но как эти данные хранятся на компьютере? Есть два варианта: в *бинарном* и в *текстовом* файле.

Текстовый файл означает, что такой файл можно открыть в программе “Блокнот” или аналоге (например,TextEdit на macOS) и увидеть напечатанный текст: скрипт, роман или упорядоченный набор цифр и букв. Нас сейчас интересует именно последний случай. Таблица может быть представлена как текст: отдельные строчки в файле будут разделять разные строчки таблицы, а какой-нибудь знак-разделитель отделять колонки друг от друга.

Для чтения данных из текстового файла есть довольно удобная функция `read.table()`. Почитайте хэлп по ней и ужаснитесь: столько разных параметров на входе! Но там же вы увидете функции `read.csv()`, `read.csv2()` и некоторые другие — по сути, это тот же `read.table()`, но с другими параметрами по умолчанию, соответствующие формату файла, который мы загружаем. В данном случае используется формат

³<https://r4ds.had.co.nz/workflow-projects.html>

.csv, что означает “Comma Separated Values” (Значения, Разделенные Запятыми). Формат .csv — это самый известный способ хранения табличных данных в файле на сегодняшний день. Файлы с расширением .csv можно легко открыть в любой программе, работающей с таблицами, в том числе Microsoft Excel и его аналогах.

Файл с расширением .csv — это просто текстовый файл, в котором “закодирована” таблица: разные строчки разделяют разные строчки таблицы, а столбцы отделяются запятыми (отсюда и название). Вы можете вручную создать такие файлы в Блокноте и сохранять их с форматом .csv - и такая табличка будет нормально открываться в Microsoft Excel и других программах для работы с таблицами. Можете попробовать это сделать самостоятельно!

Как говорилось ранее, в качестве разделителя ячеек по горизонтали — то есть разделителя между столбцами — используется запятая. С этим связана одна проблема: в некоторых странах (в т.ч. и России) принято использовать запятую для разделения дробной части числа, а не точку, как это делается в большинстве стран мира. Поэтому есть альтернативный вариант формата .csv, где значения разделены точкой с запятой (;), а дробные значения - запятой (,). В этом и различие функций `read.csv()` и `read.csv2()` — первая функция предназначена для “международного” формата, вторая - для (условно) “Российского”. Оба варианта формата имеют расширение .csv, поэтому заранее понять какой именно будет вариант довольно сложно, приходится либо пробовать оба, либо заранее открывать файл в текстовом редакторе.

В первой строчке обычно содержатся названия столбцов - и это чертовски удобно, функции `read.csv()` и `read.csv2()` по умолчанию считают первую строчку именно как название для колонок.

Кроме .csv формата есть и другие варианты хранения таблиц в виде текста. Например, .tsv — тоже самое, что и .csv, но разделитель - знак табуляции. Для чтения таких файлов есть функция `read.delim()` и `read.delim2()`. Впрочем, даже если бы ее и не было, можно было бы просто подобрать нужные параметры для функции `read.table()`. Есть даже функции, которые пытаются сами “угадать” нужные параметры для чтения — часто они справляются с этим довольно удачно. Но не всегда. Поэтому стоит научиться справляться с любого рода данными на входе.

Итак, прочитаем наш файл. Для этого используем только параметр `file =`, который идет первым, и для параметра `stringsAsFactors =` поставим значение FALSE:

```
heroes <- read.csv("data/heroes_information.csv", stringsAsFactors = FALSE)
```

Параметр `stringsAsFactors =` задает то, как будут прочитаны строковые значения - как уже знакомые нам строки или как факторы. По сути, факторы - это примерно то же самое, что и `character`, но закодированные числами. Когда-то это было придумано для экономии используемых времени и памяти, сейчас же обычно становится просто лишней морокой. Но некоторые функции требуют именно `character`, некоторые `factor`, в большинстве случаев это без разницы. Но иногда непонимание может

привести к дурацким ошибкам. В данном случае мы просто пока обойдемся без факторов. Если у вас версия R выше 4.0, то `stringsAsFactors = FALSE` по умолчанию.

Можете проверить с помощью `View(heroes)`: все работает! Если же вылезает какая-то странная ерунда или же просто ошибка - попробуйте другие функции (`read.table()`, `read.delim()`) и покопаться с параметрами. Для этого читайте `Help`.

3.2 Проверка импортированных данных

При импорте данных обратите внимания на предупреждения (если таковые появляются), в большинстве случаев они указывают на то, что данные импортированы некорректно.

Проверим, что все прочиталось нормально с помощью уже известной нам функции `str()`:

```
str(heroes)
```

```
## 'data.frame':    734 obs. of  11 variables:
##   $ X          : int  0 1 2 3 4 5 6 7 8 9 ...
##   $ name       : chr  "A-Bomb" "Abe Sapien" "Abin Sur" "Abomination" ...
##   $ Gender     : chr  "Male" "Male" "Male" "Male" ...
##   $ Eye.color  : chr  "yellow" "blue" "blue" "green" ...
##   $ Race        : chr  "Human" "Icthyo Sapien" "Ungaran" "Human / Radiation" ...
##   $ Hair.color: chr  "No Hair" "No Hair" "No Hair" "No Hair" ...
##   $ Height     : num  203 191 185 203 -99 193 -99 185 173 178 ...
##   $ Publisher  : chr  "Marvel Comics" "Dark Horse Comics" "DC Comics" "Marvel Comics" ...
##   $ Skin.color: chr  "--" "blue" "red" "--" ...
##   $ Alignment   : chr  "good" "good" "good" "bad" ...
##   $ Weight     : int  441 65 90 441 -99 122 -99 88 61 81 ...
```

Всегда проверяйте данные на входе и никогда не верьте на слово, если вам говорят, что данные вычищенные и не содержат никаких ошибок.

На что нужно обращать внимание?

1. Прочитаны ли пропущенные значения как NA. По умолчанию пропущенные значения обозначаются пропущенной строчкой или "NA", но встречаются самые разнообразные варианты. Возможные варианты кодирования пропущенных значений можно задать в параметре `na.strings` = функции `read.table()` и ее вариантов. В нашем датасете как раз такая ситуация, где нужно самостоятельно задавать, какие значения будут прочитаны как NA. Попытайтесь самостоятельно догадаться, как именно.
2. Прочитаны ли те столбики, которые должны быть числовыми, как `int` или `num`. Если в колонке содержатся числа, а написано `chr (= "character")` или `Factor`

(в случае если `stringsAsFactors = TRUE`), то, скорее всего, одна из строчек содержит в себе нечисловые знаки, которые не были прочитаны как `NA`.

3. Странные названия колонок. Это может случиться по самым разным причинам, но в таких случаях стоит открывать файл в другой программе и смотреть первые строчки. Например, может оказаться, что первые несколько строчек — пустые или что первая строчка не содержит название столбцов (тогда для параметра `header =` нужно поставить `FALSE`)
4. Вместо строковых данных у вас кракозябы. Это означает проблемы с кодировкой. В первую очередь попробуйте выставить значение `"UTF-8"` для параметра `encoding =` в функции для чтения файла:

```
heroes <- read.csv("data/heroes_information.csv",
                    stringsAsFactors = FALSE,
                    encoding = "UTF-8")
```

В случае если это не помогает, попробуйте разобрать⁴, что это за кодировка.

5. Все прочиталось как одна колонка. В этом случае, скорее всего, неправильно подобран разделитель колонок — параметр `sep =`. Откройте файл в текстовом редакторе, чтобы понять какой нужно использовать.
6. В отдельных строчках все прочиталось как одна колонка, а в остальных нормально. Скорее всего, в файле есть значения типа `\` или `",`, которые в функциях `read.csv()`, `read.delim()`, `read.csv2()`, `read.delim2()` читаются как символы для закавычивания значений. Это может понадобиться, если у вас в таблице есть строковые значения со знаками `,` или `;`, которые могут восприниматься как разделитель столбцов.
7. Появились какие-то новые числовые колонки. Возможно неправильно поставлен разделитель дробной части. Обычно это либо `.` (`read.table()`, `read.csv()`, `read.delim()`), либо `,` (`read.csv2()`, `read.delim2()`).

Конкретно в нашем случае все прочиталось хорошо с помощью функции `read.csv()`, но в строковых переменных есть много прочерков, которые обозначают отсутствие информации по данному параметру супергероя, т.е. пропущенное значение. А вот с числовыми значениями все не так просто: для всех супергероев прописано какое-то число, но во многих случаях это `-99`. Очевидно, отрицательного роста и массы не бывает, это просто обозначение пропущенных значений (такое часто используется). Таким образом, чтобы адекватно прочитать файл, нам нужно поменять параметр `na.strings =` функции `read.csv()`:

```
heroes <- read.csv("data/heroes_information.csv",
                    stringsAsFactors = FALSE,
                    na.strings = c("-", "-99"))
```

⁴<https://www.artlebedev.ru/decoder/>

3.3 Экспорт данных

Представим, что вы хотите сохранить табличку с данными про супергероев из вселенной DC в виде отдельного файла .csv.

```
dc <- heroes[heroes$Publisher == "DC Comics",]
```

Функция `write.csv()` позволит записать датафрейм в файл формата .csv:

```
write.csv(dc, "data/dc_heroes_information.csv")
```

Обычно названия строк не используются, и их лучше не записывать, поставив для `row.names =` значение FALSE:

```
write.csv(dc, "data/dc_heroes_information.csv", row.names = FALSE)
```

По аналогии с `read.csv2()`, `write.csv2()` позволит записать файлы формата .csv с разделителем ;.

```
write.csv2(dc, "data/dc_heroes_information.csv", row.names = FALSE)
```

3.4 Импорт таблиц в бинарном формате: таблицы Excel, SPSS

Тем не менее, далеко не всегда таблицы представлены в виде текстового файла. Самый распространенный пример таблицы в бинарном виде — родные форматы Microsoft Excel. Если Вы попробуете открыть .xlsx файл в Блокноте, то увидите кракозябры. Это делает работу с этим файлами гораздо менее удобной, поэтому стоит избегать экселеевых форматов и стараться все сохранять в .csv.

Такие файлы не получится прочитать при помощи базового инструментария R. Тем не менее, для чтения таких файлов есть много дополнительных пакетов:

- файлы Microsoft Excel: лучше всего справляется пакет `readxl` (является частью расширенного tidyverse), у него есть много альтернатив (`xlsx`, `openxlsx`).
- файлы SPSS, SAS, Stata: существуют два основных пакета — `haven` (часть расширенного tidyverse) и `foreign`.

Что такое пакеты и как их устанавливать мы изучим очень скоро.

3.5 Быстрый импорт данных

Чтение табличных данных обычно происходит очень быстро. По крайней мере, до тех пор пока ваши данные не содержат очень много значений. Если вы попробуете прочитать с помощью `read.csv()` таблицу с миллионами строчками, то заметите, что это происходит довольно медленно. Впрочем, эта проблема эффективно решается дополнительными пакетами.

- Пакет `readr` (часть базового tidyverse) предлагает функции, очень похожие на стандартные `read.csv()`, `read.csv2()` и тому подобные, только в названиях используется нижнее подчеркивание: `read_csv()` и `read_csv2()`. Они быстрее и немного удобнее, особенно если вы работаете в tidyverse.

```
readr::read_csv("data/heroes_information.csv",
  na = c("-", "-99"))

## Warning: Missing column names filled in: 'X1' [1]

##
## -- Column specification -----
## cols(
##   X1 = col_double(),
##   name = col_character(),
##   Gender = col_character(),
##   `Eye color` = col_character(),
##   Race = col_character(),
##   `Hair color` = col_character(),
##   Height = col_double(),
##   Publisher = col_character(),
##   `Skin color` = col_character(),
##   Alignment = col_character(),
##   Weight = col_double()
## )

## # A tibble: 734 x 11
##       X1 name  Gender `Eye color` Race  `Hair color` Height Publisher
##   <dbl> <chr> <chr>    <chr> <chr>    <chr> <dbl> <chr>
## 1     0 A-Bo~ Male    yellow Human No Hair      203 Marvel C~
## 2     1 Abe ~ Male    blue  Icth~ No Hair      191 Dark Hor~
## 3     2 Abin~ Male    blue  Unga~ No Hair      185 DC Comics
## 4     3 Abom~ Male    green Huma~ No Hair      203 Marvel C~
## 5     4 Abra~ Male    blue  Cosm~ Black        NA Marvel C~
## 6     5 Abso~ Male    blue  Human No Hair      193 Marvel C~
## 7     6 Adam~ Male    blue  <NA> Blond        NA NBC - He~
## 8     7 Adam~ Male    blue  Human Blond       185 DC Comics
## 9     8 Agen~ Female  blue  <NA> Blond        173 Marvel C~
## 10    9 Agen~ Male    brown Human Brown       178 Marvel C~
```

```
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>
```

- Пакет `vroom` - это часть расширенного tidyverse. Это такая альтернатива `readr` из того же tidyverse, но еще быстрее (отсюда и название).

```
vroom::vroom("data/heroes_information.csv")
```

```
## New names:
## * `` -> ...1

## Rows: 734
## Columns: 11
## Delimiter: ","
## chr [8]: name, Gender, Eye color, Race, Hair color, Publisher, Skin color, Alignment
## dbl [3]: ...1, Height, Weight
##
## Use `spec()` to retrieve the guessed column specification
## Pass a specification to the `col_types` argument to quiet this message

## # A tibble: 734 x 11
##       ...1 name  Gender `Eye color` `Race` `Hair color` Height Publisher
##       <dbl> <chr> <chr>    <chr>    <chr>    <dbl> <chr>
## 1      0 A-Bo~ Male   yellow   Human No Hair     203 Marvel C~
## 2      1 Abe ~ Male   blue    Icth~ No Hair     191 Dark Hor~
## 3      2 Abin~ Male   blue    Unga~ No Hair     185 DC Comics
## 4      3 Abom~ Male   green   Huma~ No Hair     203 Marvel C~
## 5      4 Abra~ Male   blue    Cosm~ Black      -99 Marvel C~
## 6      5 Abso~ Male   blue   Human No Hair     193 Marvel C~
## 7      6 Adam~ Male   blue    -     Blond      -99 NBC - He~
## 8      7 Adam~ Male   blue   Human Blond      185 DC Comics
## 9      8 Agen~ Female blue    -     Blond      173 Marvel C~
## 10     9 Agen~ Male   brown   Human Brown     178 Marvel C~

## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>
```

- Пакет `data.table` - это не просто пакет, а целый фреймворк для работы с R, основной конкурент tidyverse. Одна из основных фишек `data.table` - быстрота работы. Это касается не только процессинга данных, но и их загрузки и записи. Поэтому некоторые используют функции `data.table` для чтения и записи данных в отдельности от всего остального пакета - они даже и называются соответствующе: `fread()` и `fwrite()`, где `f` означает fast⁵.

⁵А еще friendly: `fread()` обычно самостоятельно хорошо угадывает формат таблицы на входе. `vroom` тоже так умеет.

```
data.table::fread("data/heroes_information.csv")

##      V1           name Gender Eye color          Race   Hair color
## 1:   0        A-Bomb    Male  yellow     Human No Hair
## 2:   1       Abe Sapien    Male   blue  Icthyo Sapien No Hair
## 3:   2        Abin Sur    Male   blue     Ungaran No Hair
## 4:   3  Abomination    Male green Human / Radiation No Hair
## 5:   4       Abraxas    Male   blue   Cosmic Entity Black
## ---
## 730: 729 Yellowjacket II Female   blue     Human Strawberry Blond
## 731: 730         Ymir    Male white Frost Giant No Hair
## 732: 731         Yoda    Male brown Yoda's species White
## 733: 732      Zatanna Female   blue     Human Black
## 734: 733         Zoom    Male   red      - Brown
##      Height Publisher Skin color Alignment Weight
## 1: 203.0  Marvel Comics   -  good   441
## 2: 191.0 Dark Horse Comics  blue  good    65
## 3: 185.0    DC Comics   red  good    90
## 4: 203.0  Marvel Comics   -  bad   441
## 5: -99.0  Marvel Comics   -  bad   -99
## ---
## 730: 165.0  Marvel Comics   -  good    52
## 731: 304.8  Marvel Comics white  good   -99
## 732:  66.0 George Lucas green  good    17
## 733: 170.0    DC Comics   -  good    57
## 734: 185.0    DC Comics   -  bad     81
```

Чем же пользоваться среди всего этого многообразия? Бенчмарки⁶⁷ показывают, что быстрее всех `vroom` и `data.table`. Если же у вас нет задачи ускорить работу кода на несколько миллисекунд или прочитать датасет на много миллионов строк, то стандартного `read.csv()` (если вы работаете в базовом R) и `readr::read_csv()` (если вы работаете в `tidyverse`) должно быть достаточно.

Все перечисленные пакеты позволяют не только быстро импортировать данные, но и быстро (и удобно!) экспортовать их:

```
readr::write_csv(dc, "data/dc_heroes_information.csv")
readr::write_excel_csv(dc, "data/dc_heroes_information.csv") #      Excel
vroom::vroom_write(dc, "data/dc_heroes_information.csv", delim = ",")
data.table::fwrite(dc, "data/dc_heroes_information.csv")
```

В плане скорости записи файлов соотношение сил примерно такое же, как и для чте-

⁶<https://www.danielecook.com/speeding-up-reading-and-writing-in-r/>

⁷бенчмаркинг — это тест производительности, в данном случае — сравнение скорости работы конкурирующих пакетов.

ния: `vroom` и `data.table` обгоняют всех, затем идет `readr`, и только после него - базовые функции R.

Глава 4

Условные конструкции и циклы

4.1 Выражения `if, else, else if`

Стандартная часть практически любого языка программирования — условные конструкции. R не исключение. Однако и здесь есть свои особенности. Начнем с самого простого варианта с одним условием. Выглядеть условная конструкция будет вот так:

```
if ( )
```

Вот так это будет работать на практике:

```
number <- 1
if (number > 0) "
```



```
## [1] "
```

Если выражение (expression) содержит больше одной строчки, то они объединяются фигурными скобками. Впрочем, использовать их можно, даже если строчка всего в выражении всего одна.

```
number <- 1
if (number > 0) {
  "
}
```



```
## [1] "
```

В рассмотренной нами конструкции происходит проверка на условие. Если условие верно¹, то происходит то, что записано в последующем выражении. Если же условие

¹В принципе, необязательно внутри должны быть проверка условий, достаточно просто значения TRUE.

неверно², то ничего не происходит.

Оператор `else` позволяет задавать действие на все остальные случаи:

```
if (      )      else
```

Работает это так:

```
number <- -3
if (number > 0) {
  "
}
} else {
  "
  "
}
```

```
## [1] "
```

Иногда нам нужна последовательная проверка на несколько условий. Для этого есть оператор `else if`. Вот как выглядит ее применение:

```
number <- 0
if (number > 0) {
  "
}
} else if (number < 0){
  "
}
} else {
  "
  "
}
```

```
## [1] " "
```

Как мы помним, R — язык, в котором векторизация играет большое значение. Но вот незадача — условные конструкции не векторизованы в R! Давайте попробуем применить эти конструкции для вектора значений и посмотрим, что получится.

```
number <- -2:2
if (number > 0) {
  "
}
} else if (number < 0){
  "
}
} else {
  "
  "
}
```

```
## Warning in if (number > 0) {: the condition has length > 1 and only the first
## element will be used
```

²Аналогично, достаточно просто значения `FALSE`.

```
## Warning in if (number < 0) {:
# the condition has length > 1 and only the first
## element will be used
## [1] "
```

R выдаст сообщение, что используется только первое значение логического вектора внутри условия. Остальные просто игнорируются. Как же посчитать для всего вектора сразу?

4.2 Циклы for

Во-первых, можно использовать `for`. Синтаксис у `for` похож на синтаксис условных конструкций.

```
for(      in      )
```

Теперь мы можем объединить условные конструкции и `for`. Немножко монструозно, но это работает:

```
for (i in number) {
  if (i > 0) {
    print("      ")
  } else if (i < 0) {
    print("      ")
  } else {
    print("      ")
  }
}

## [1] "
## [1] "
## [1] "
## [1] "
## [1] "
```

Чтобы выводить в консоль результат вычислений внутри `for`, нужно использовать `print()`.

Здесь стоит отметить, что `for` используется в R относительно редко. В подавляющем числе ситуаций использование `for` можно избежать. Обычно мы работаем в R с векторами или датафреймами, которые представляют собой множество относительно независимых наблюдений. Если мы хотим провести какие-нибудь операции с этими наблюдениями, то они обычно могут быть выполнены параллельно. Скажем, вы хотите для каждого испытуемого пересчитать его массу из фунтов в килограммы. Этот пересчет осуществляется по одинаковой формуле для каждого испытуемого. Эта формула не изменится из-за того, что какой-то испытуемый слишком большой или слишком маленький - для следующего испытуемого формула будет прежняя. Если Вы встречае-

те подобную задачу (где функцию можно применить независимо для всех значений), то без цикла `for` вполне можно обойтись.

Даже во многих случаях, где расчеты для одной строчки зависят от расчетов предыдущих строчек, можно обойтись без `for` векторизованными функциями, например, `cumsum()` для подсчета кумулятивной суммы.

```
cumsum(1:10)
```

```
## [1] 1 3 6 10 15 21 28 36 45 55
```

Если же нет подходящей векторизованной функции, то можно воспользоваться семейством функций `apply()` (см. @ref(`apply_f`)).

После этих объяснений кому-то может показаться странным, что я вообще упоминаю про эти циклы. Но для кого-то циклы `for` настолько привычны, что их полное отсутствие в курсе может показаться еще более странным. Поэтому лучше от меня, чем на улице.

Зачем вообще избегать конструкций `for`? Некоторые говорят, что они слишком медленные, и частично это верно, если мы сравниваем с векторизованными функциями, которые написаны на более низкоуровневых языках. Но в большинстве случаев низкая скорость `for` связана с неправильным использованием этой конструкции. Например, стоит избегать ситуации, когда на каждой итерации `for` какой-то объект (вектор, список, что угодно) изменяется в размере. Лучше будет создать заранее объект нужного размера, который затем будет наполняться значениями:

```
number_descriptions <- character(length(number)) #
for (i in 1:length(number)) {
  if (number[i] > 0) {
    number_descriptions[i] <- " "
  } else if (number[i] < 0) {
    number_descriptions[i] <- " "
  } else {
    number_descriptions[i] <- " "
  }
}
number_descriptions

## [1] " " " "
## [4] " " " "
```

В общем, при правильном обращении с `for` особых проблем со скоростью не будет. Но все равно это будет громоздкая конструкция, в которой легко ошибиться, и которую, скорее всего, можно заменить одной короткой строчкой. Кроме того, без конструкции `for` код обычно легко превратить в набор функций, последовательно применяющихся к данным, что мы будем по максимуму использовать, работая в `tidyverse`.

и применяя пайпы (см. [pipe]).

4.3 Векторизованные условные конструкции: функции ifelse() и dplyr::case_when()

Альтернатива сочетанию условных конструкций и циклов `for` является использование встроенной функции `ifelse()`. Функция `ifelse()` принимает три аргумента - 1) условие (т.е. просто логический вектор, состоящий из TRUE и FALSE), 2) что выдавать в случае TRUE, 3) что выдавать в случае FALSE. На выходе получается вектор такой же длины, как и изначальный логический вектор (условие).

```
ifelse(number > 0, "           ", "           ")
```

```
## [1] "           "
## [3] "           "
## [5] "           "
```

Периодически я встречаю у студентов строчку вроде такой: `ifelse(, TRUE, FALSE)`. Эта конструкция избыточна, т.к. получается, что логический вектор из TRUE и FALSE превращается в абсолютно такой же вектор из TRUE и FALSE на тех же самых местах. Выходит, что ничего не меняется!

У `ifelse()` тоже есть недостаток: он не может включать в себя дополнительных условий по типу `else if`. В простых ситуациях можно вставлять `ifelse()` внутри `ifelse()`:

```
ifelse(number > 0,
      "           ",
      ifelse(number < 0, "           ", "           "))
```

```
## [1] "           "
## [4] "           "
```

Достаточно симпатичное решение предлагает пакет `dplyr` (основа `tidyverse`) — функция `case_when()`, которая работает с использованием формулы:

```
dplyr::case_when(
  number > 0 ~ "           ",
  number < 0 ~ "           ",
  number == 0 ~ "           ")
```

```
## [1] "           "
## [4] "           "
```


Глава 5

Функциональное программирование в R

5.1 Создание функций

Поздравляю, сейчас мы выйдем на качественно новый уровень владения R. Вместо того, чтобы пользоваться теми функциями, которые уже написали за нас, мы можем сами создавать свои функции! В этом нет ничего сложного.

Синтаксис создания функции внешне похож на создание циклов или условных конструкций. Мы пишем ключевое слово `function`, в круглых скобках обозначаем переменные, с которыми собираемся что-то делать. Внутри фигурных скобок пишем выражения, которые будут выполняться при запуске функции. У функции есть свое собственное окружение — место, где хранятся переменные. Именно те объекты, которые мы передаем в скобочках, и будут в окружении, так же как и “обычные” переменные для нас в глобальном окружении. Это означает, что функция будет искать переменные в первую очередь среди объектов, которые переданы в круглых скобочках. С ними функция и будет работать. На выходе функция выдаст то, что вычисляется внутри функции `return()`. Если `return()` появляется в теле функции несколько раз, то до результата будет возвращаться из той функции `return()`, до которой выполнение дошло первым.

```
pow <- function(x, p) {  
  power <- x ^ p  
  return(power)  
}  
pow(3, 2)
```

```
## [1] 9
```

Если функция проработала до конца, а функция `return()` так и не встретилась, то возвращается последнее посчитанное значение.

```
pow <- function(x, p) {
  x ^ p
}
pow(3, 2)
```

```
## [1] 9
```

Если в последней строчке будет присвоение, то функция ничего не вернет обратно. Это очень распространенная ошибка: функция вроде бы работает правильно, но ничего не возвращает. Нужно писать так, как будто бы в последней строчке результат выполнения выводится в консоль.

```
pow <- function(x, p) {
  power <- x ^ p # ,
}
pow(3, 2) # !
```

Если функция небольшая, то ее можно записать в одну строчку без фигурных скобок.

```
pow <- function(x, p) x ^ p
pow(3, 2)
```

```
## [1] 9
```

Вообще, фигурные скобки используются для того, чтобы выполнить серию выражений, но вернуть только результат выполнения последнего выражения. Это можно использовать, чтобы не создавать лишних временных переменных в глобальном окружении.

Мы можем оставить в функции параметры по умолчанию.

```
pow <- function(x, p = 2) x ^ p
pow(3)
```

```
## [1] 9
```

```
pow(3, 3)
```

```
## [1] 27
```

В R работают **ленивые вычисления** (*lazy evaluations*). Это означает, что параметры функций будут только когда они понадобятся, а не заранее. Например,

мер, эта функция не будет выдавать ошибку, если мы не зададим параметр `we_will_not_use_this_parameter =`, потому что он нигде не используется в расчетах.

```
pow <- function(x, p = 2, we_will_not_use_this_parameter) x ^ p
pow(x = 3)

## [1] 9
```

5.2 Проверка на адекватность

Лучший способ не бояться ошибок и предупреждений — научиться прописывать их самостоятельно в собственных функциях. Это позволит понять, что за текстом предупреждений и ошибок, которые у вас возникают, стоит забота разработчиков о пользователях, которые хотят максимально обезопасить нас от наших непродуманных действий.

Хорошо написанные функции не только выдают правильный результат на все возможные адекватные данные на входе, но и не дают получить правдоподобные результаты при неадекватных входных данных. Как вы уже знаете, если на входе у вас имеются пропущенные значения, то многие функции будут в ответ тоже выдавать пропущенные значения. И это вполне осознанное решение, которое позволяет избегать ситуаций вроде той, когда около одной пятой научных статей по генетике содержало ошибки в приложенных данных¹ и замечать пропущенные значения на ранней стадии. Кроме того, можно проводить проверки на адекватность входящих данных (`sanity check`).

Разберем это на примере самодельной функции `imt()`, которая выдает индекс массы тела, если на входе задать вес (аргумент `weight =`) в килограммах и рост (аргумент `height =`) в метрах.

```
imt <- function(weight, height) weight / height ^ 2
```

Проверим, что функция работает верно:

```
w <- c(60, 80, 120)
h <- c(1.6, 1.7, 1.8)
imt(weight = w, height = h)
```

```
## [1] 23.43750 27.68166 37.03704
```

Очень легко перепутать и написать рост в сантиметрах. Было бы здорово предупредить об этом пользователю, показав ему предупреждающее сообщение, если рост больше, чем, например, 3. Это можно сделать с помощью функции `warning()`

¹<https://genomeweb.biomedcentral.com/articles/10.1186/s13059-016-1044-7>

```

imt <- function(weight, height) {
  if (height > 3) warning("           height      3:      ,
                           weight / height ^ 2
}
imt(78, 167)

## Warning in imt(78, 167):           height      3:      ,
## [1] 0.002796802

```

В некоторых случаях ответ будет совершенно точно некорректным, хотя функция все посчитает и выдаст ответ, как будто так и надо. Например, если какой-то из аргументов функции `imt()` будет меньше или равен 0. В этом случае нужно прописать проверку на это условие, и если это действительно так, то выдать пользователю ошибку.

```

imt <- function(weight, height) {
  if (any(weight <= 0 | height <= 0)) stop("           ")
  if (height > 3) warning("           height      3:      ,
                           weight / height ^ 2
}
imt(-78, 167)

## Error in imt(-78, 167):

```

Когда вы попробуете самостоятельно прописывать предупреждения и ошибки в функциях, то быстро поймете, что ошибки - это вовсе не обязательно результат того, что где-то что-то сломалось и нужно паниковать. Совсем даже наоборот, прописанная ошибка - чья-то забота о пользователях, которых пытаются максимально проинформировать о том, что и почему пошло не так.

Это естественно в начале работы с R (и вообще с программированием) избегать ошибок, конечно, в самом начале обучения большая часть из них остается непонятной. Но постарайтесь понять текст ошибки, вспомнить в каких случаях у вас возникала похожая ошибка. Очень часто этого оказывается достаточно чтобы понять причину ошибки даже если вы только-только начали изучать R.

Ну а в дальнейшем я советую ознакомиться со средствами отладки кода в R² для того, чтобы научиться справляться с ошибками в своем коде на более продвинутом уровне.

5.3 Когда и зачем создавать функции?

Когда стоит создавать функции? Существует “правило трех”³ — если у вас есть три куска очень похожего кода, то самое время превратить код в функцию. Это очень услов-

²<https://adv-r.hadley.nz/debugging.html>

³[https://en.wikipedia.org/wiki/Rule_of_three_\(computer_programming\)](https://en.wikipedia.org/wiki/Rule_of_three_(computer_programming))

ное правило, но, действительно, стоит избегать копипастинга в коде. В этом случае очень легко ошибиться, а сам код становится нечитаемым.

Есть и другой подход к созданию функций: их стоит создавать не столько для того, чтобы использовать тот же код снова, сколько для абстрагирования от того, что происходит в отдельных строчках кода. Если несколько строчек кода были написаны для того, чтобы решить одну задачу, которой можно дать понятное название (например, подсчет какой-то особенной метрики, для которой нет готовой функции в R), то этот код стоит обернуть в функцию. Если функция работает корректно, то теперь не нужно думать над тем, что происходит внутри нее. Вы ее можете мысленно представить как операцию, которая имеет определенный вход и выход — как и встроенные функции в R.

Отсюда следует важный вывод, что хорошее название для функции — это очень важно. Очень, очень, очень важно.

5.4 Функции как объекты первого порядка

Ранее мы убедились, что арифметические операторы — это тоже функции. На самом деле, практически все в R — это функции. Даже `function` — это функция `function()`. Даже скобочки `(, {` — это функции!

А сами функции — это объекты первого порядка в R. Это означает, что с функциями вы можете делать практически все то же самое, что и с другими объектами в R (векторами, датафреймами и т.д.). Небольшой пример, который может взорвать ваш мозг:

```
list(mean, min, `{`)

## [[1]]
## function (x, ...)
## UseMethod("mean")
## <bytecode: 0x6038cf4582d8>
## <environment: namespace:base>
##
## [[2]]
## function (... , na.rm = FALSE) .Primitive("min")
##
## [[3]]
## .Primitive("{")
```

Мы можем создать список из функций! Зачем — это другой вопрос, но ведь можем же!

Еще можно создавать функции внутри функций⁴, использовать функции в качестве аргументов функций, сохранять функции как переменные. Пожалуй, самое важное из

⁴Функция, которая создает другие функции, называется фабрикой функций.

этого всего - это то, что функция может быть аргументом в функции. Не просто название функции как строковая переменная, не результат выполнения функции, а именно сама функция. Это лежит в основе использования семейства функций `apply()` (`@ref{apply_f}`) и многих фишек tidyverse.

В Python дело обстоит похожим образом: функции там тоже являются объектами первого порядка, поэтому все эти фишки функционального программирования (с поправкой на синтаксис, конечно) будут работать и там.

5.5 Семейство функций `apply()`

5.5.1 Применение `apply()` для матриц

Семейство? Да, их целое множество: `apply()`, `lapply()`, `sapply()`, `vapply()`, `tapply()`, `mapply()`, `taapply()`... Ладно, не пугайтесь, всех их знать не придется. Обычно достаточно первых двух-трех. Проще всего пояснить как они работают на простой матрице с числами:

```
A <- matrix(1:12, 3, 4)
A

##      [,1] [,2] [,3] [,4]
## [1,]    1    4    7   10
## [2,]    2    5    8   11
## [3,]    3    6    9   12
```

Функция `apply()` предназначена для работы с матрицами (или многомерными массивами). Если вы скормите функции `apply()` датафрейм, то этот датафрейм будет сначала превращен в матрицу. Главное отличие матрицы от датафрейма в том, что в матрице все значения одного типа, поэтому будьте готовы, что сработает имплицитное приведение к общему типу данных. Например, если среди колонок датафрейма есть хотя бы одна строковая колонка, то все колонки станут строковыми.

Теперь представим, что нам нужно посчитать что-нибудь (например, сумму) по каждой из строк. С помощью функции `apply()` вы можете в буквальном смысле “применить” функцию к матрице или датафрейму. Синтаксис такой: `apply(X, MARGIN, FUN, ...)`, где `X` — данные, `MARGIN` это `1` (для строк), `2` (для колонок), `c(1, 2)` для строк и колонок (т.е. для каждого элемента по отдельности), а `FUN` — это функция, которую вы хотите применить! `apply()` будет брать строки/колонки из `X` в качестве первого аргумента для функции.

Заметьте, мы вставляем функцию без скобок и кавычек как аргумент в функцию. Это как раз тот случай, когда аргументом в функции выступает сама функция, а не ее название или результат ее выполнения.

Давайте разберем на примере:

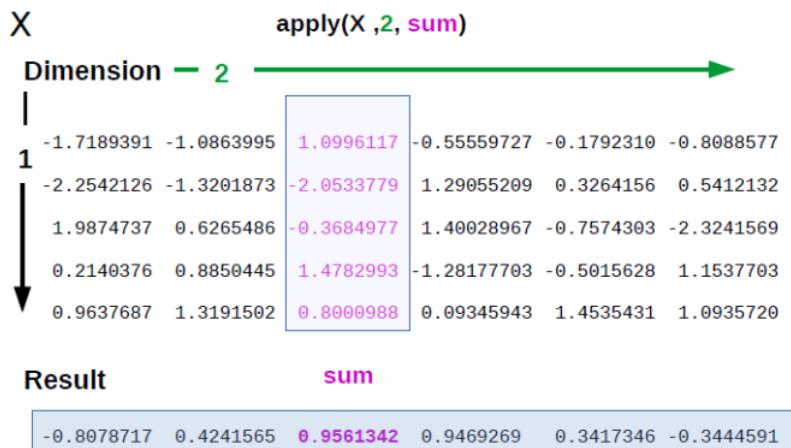


Рис. 5.1: apply

```
apply(A, 1, sum) #
## [1] 22 26 30

apply(A, 2, sum) #
## [1] 6 15 24 33

apply(A, c(1,2), sum) # ...
##      [,1] [,2] [,3] [,4]
## [1,]     1     4     7    10
## [2,]     2     5     8    11
## [3,]     3     6     9    12
```

Конкретно для подсчета сумм и средних по столбцам и строкам в R есть функции `colSums()`, `rowSums()`, `colMeans()` и `rowMeans()`, которые можно использовать как альтернативы `apply()` в данном случае.

Если же мы хотим прописать дополнительные аргументы для функции, то их можно перечислить через запятую после функции:

```
apply(A, 1, sum, na.rm = TRUE)
## [1] 22 26 30
```

```
apply(A, 1, weighted.mean, w = c(0.2, 0.4, 0.3, 0.1))

## [1] 4.9 5.9 6.9
```

5.5.2 Анонимные функции

Что делать, если мы хотим сделать что-то более сложное, чем просто применить одну функцию? А если функция принимает не первым, а вторым аргументом данные из матрицы? В этом случае нам помогут **анонимные функции**.

Анонимные функции - это функции, которые будут использоваться один раз и без названия.

Питонистам знакомо понятие **лямбда-функций**. Да, это то же самое.

Например, мы можем посчитать отклонения от среднего без называния этой функции:

```
apply(A, 1, function(x) x - mean(x)) #

##      [,1] [,2] [,3]
## [1,] -4.5 -4.5 -4.5
## [2,] -1.5 -1.5 -1.5
## [3,]  1.5  1.5  1.5
## [4,]  4.5  4.5  4.5

apply(A, 2, function(x) x - mean(x)) #

##      [,1] [,2] [,3] [,4]
## [1,]    -1   -1   -1   -1
## [2,]     0     0     0     0
## [3,]     1     1     1     1

apply(A, c(1,2), function(x) x - mean(x)) # , ...

##      [,1] [,2] [,3] [,4]
## [1,]     0     0     0     0
## [2,]     0     0     0     0
## [3,]     0     0     0     0
```

Как и в случае с обычной функцией, в качестве x выступает объект, с которым мы хотим что-то сделать, а дальше следует функция, которую мы собираемся применить к . Можно использовать не , а что угодно, как и в обычных функциях:

```
apply(A, 1, function(whatevername) whatevername - mean(whatevername))

##      [,1] [,2] [,3]
## [1,] -4.5 -4.5 -4.5
## [2,] -1.5 -1.5 -1.5
## [3,]  1.5  1.5  1.5
## [4,]  4.5  4.5  4.5
```

5.5.3 Другие функции семейства apply()

Ок, с `apply()` разобрались. А что с остальными? Некоторые из них еще проще и не требуют индексов, например, `lapply` (для применения к каждому элементу списка) и `sapply()` - упрощенная версия `lapply()`, которая пытается по возможности “упростить” результат до вектора или матрицы.

```
some_list <- list(some = 1:10, list = letters)
lapply(some_list, length)
```

```
## $some
## [1] 10
##
## $list
## [1] 26
```

```
sapply(some_list, length)
```

```
## some list
## 10 26
```

Использование `sapply()` на векторе приводит к тем же результатам, что и просто применить векторизованную функцию обычным способом.

```
sapply(1:10, sqrt)
```

```
## [1] 1.000000 1.414214 1.732051 2.000000 2.236068 2.449490 2.645751 2.828427
## [9] 3.000000 3.162278
```

```
sqrt(1:10)
```

```
## [1] 1.000000 1.414214 1.732051 2.000000 2.236068 2.449490 2.645751 2.828427
## [9] 3.000000 3.162278
```

Зачем вообще тогда нужен `sapply()`, если мы можем просто применить векторизованную функцию? Ключевое слово здесь *векторизованная функция*. Если функция

не векторизована, то `sapply()` становится удобным вариантом для того, чтобы избежать итерирования с помощью циклов `for`.

Еще одна альтернатива - это векторизация невекторизованной функции с помощью `Vectorize()`. Эта функция просто обворачивает функцию одним из вариантов `apply()`.

Можно применять функции `lapply()` и `sapply()` на датафреймах. Поскольку фактически датафрейм - это список из векторов одинаковой длины (см. 2.11), то итерироваться эти функции будут по колонкам:

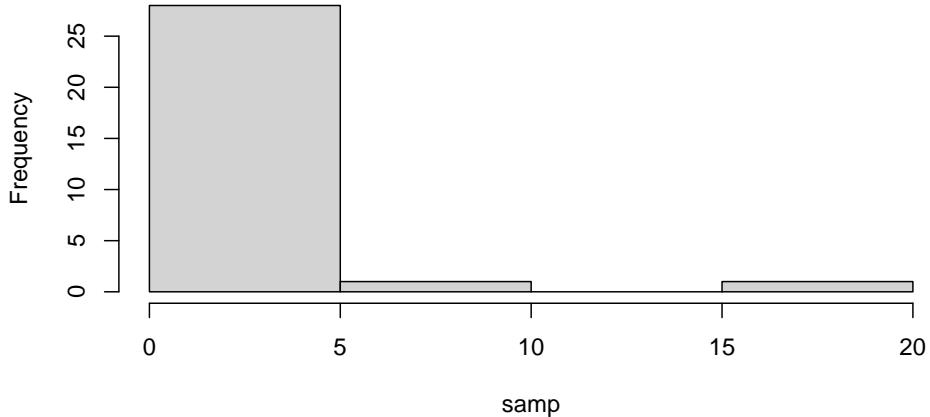
```
heroes <- read.csv("data/heroes_information.csv",
                     na.strings = c("-", "-99"))
sapply(heroes, class)

##           X      name    Gender   Eye.color     Race Hair.color
## "integer" "character" "character" "character" "character" "character"
##      Height Publisher Skin.color Alignment      Weight
## "numeric" "character" "character" "character" "integer"
```

Еще одна функция из семейства `apply()` - функция `replicate()` - самый простой способ повторить одну и ту же операцию много раз. Обычно эта функция используется при симуляции данных и моделировании. Например, давайте сделаем выборку из логнормального распределения:

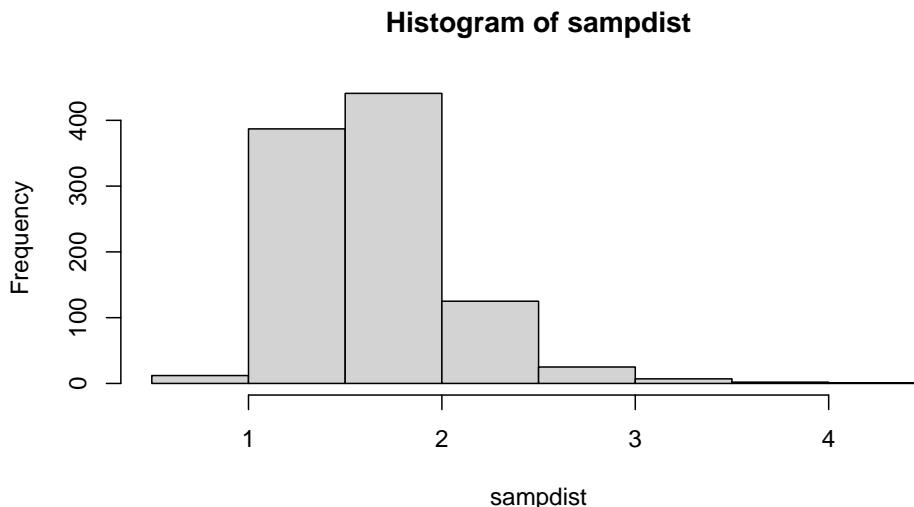
```
samp <- rlnorm(30)
hist(samp)
```

Histogram of samp



А теперь давайте сделаем 1000 таких выборок и из каждой возьмем среднее:

```
sampdist <- replicate(1000, mean(rlnorm(30)))
hist(sampdist)
```



Про функции для генерации случайных чисел и про визуализацию мы поговорим в следующие дни.

Если хотите познакомиться с семейством `apply()` чуточку ближе, то рекомендую вот этот туториал⁵.

В заключение стоит сказать, что семейство функций `apply()` — это очень сильное колдунство, но в tidyverse оно практически полностью перекрывается функциями из пакета `purrr`. Впрочем, если вы поняли логику `apply()`, то при желании вы легко сможете переключиться на альтернативы из пакета `purrr`.

#Введение в tidyverse {#tidy_intro}

5.6 Вселенная tidyverse

tidyverse — это не один, а целое множество пакетов. Есть ключевые пакеты (ядро тайди-верса), а есть побочные — в основном для работы со специфическими видами данных.

*tidyverse*⁶ — это набор пакетов:

- *ggplot2*, для визуализации
- *tibble*, для работы с тиблами, продвинутый вариант датафрейма
- *tidyR*, для формата tidy data
- *readr*, для чтения файлов в R

⁵<https://www.datacamp.com/community/tutorials/r-tutorial-apply-family>

⁶<https://www.tidyverse.org>

- *purrr*, для функционального программирования (замена семейства функций **apply()*)
- *dplyr*, для преобразования данных
- *stringr*, для работы со строковыми переменными
- *forcats*, для работы с переменными-факторами

Полезно также знать о следующих пакетах, не включенных в ядро, но также считающихся частью тайдиверса:

- *vroom*, для быстрой загрузки табличных данных
- *readxl*, для чтения .xls и .xlsx
- *jsonlite*, для работы с JSON
- *xml*, для работы с XML
- *DBI*, для работы с базами данных
- *rvest*, для веб-скраппинга
- *lubridate*, для работы с временем
- *tidytext*, для работы с текстами и корпусами
- *glue*, для продвинутого объединения строк
- *magrittr*, с несколькими вариантами pipe оператора
- *tidymodels*, для моделирования и машинного обучения⁷
- *dtplyr*, для ускорения dplyr за счет перевод синтаксиса на `data.table`

И это еще не все пакеты tidyverse! Есть еще много других небольших пакетов, которые тоже считаются частью tidyverse. Кроме официальных пакетов tidyverse есть множество пакетов, которые пытаются соответствовать принципам tidyverse и дополняют его.

Все пакеты tidyverse объединены tidy философией и взаимосовместимым синтаксисом. Это означает, что, во многих случаях даже не нужно думать о том, из какого именно пакета тайдиверса пришла функция. Можно просто установить и загрузить пакет tidyverse.

```
install.packages("tidyverse")
```

Пакет tidyverse — это такой пакет с пакетами⁸.

```
library("tidyverse")
```

```
## -- Attaching packages -----
## v ggplot2 3.3.2     v purrr    0.3.4
## v tibble   3.0.4     v dplyr    1.0.2
## v tidyr    1.1.2     v stringr  1.4.0
## v readr    1.4.0     v forcats 0.5.0
```

⁷Как и пакет tidyverse, tidymodels — это пакет с несколькими пакетами.

⁸https://cs11.pikabu.ru/post_img/big/2019/03/12/11/1552415351186680692.jpg

```
## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()    masks stats::lag()
```

Подключение пакета `tidyverse` автоматически приводит к подключению ядра `tidyverse`, остальные же пакеты нужно подключать дополнительно при необходимости.

5.7 Загрузка данных с помощью `readr`

Стандартной функцией для чтения .csv файлов в R является функция `read.csv()`, но мы будем использовать функцию `read_csv()` из пакета `readr`. Синтаксис функции `read_csv()` очень похож на `read.csv()`: первым аргументом является путь к файлу (в том числе можно использовать URL), некоторые остальные параметры тоже совпадают.

```
heroes <- read_csv("data/heroes_information.csv",
                    na = c("-", "-99"))
```

```
## Warning: Missing column names filled in: 'X1' [1]
##
## -- Column specification -----
## cols(
##   X1 = col_double(),
##   name = col_character(),
##   Gender = col_character(),
##   `Eye color` = col_character(),
##   Race = col_character(),
##   `Hair color` = col_character(),
##   Height = col_double(),
##   Publisher = col_character(),
##   `Skin color` = col_character(),
##   Alignment = col_character(),
##   Weight = col_double()
## )
```

Подробнее про импорт данных, в том числе в `tidyverse`, смотри в @ref(real_data).

`#tibble`

Когда мы загрузили данные с помощью `read_csv()`, то мы получили `tibble`, а не `data.frame`:

```
class(heroes)

## [1] "spec_tbl_df" "tbl_df"       "tbl"          "data.frame"
```

Тиблл (`tibble`) - это такой “усовершенствованный” `data.frame`. Почти⁹ все, что работает с `data.frame`, работает и с тибллами. Однако у тибллов есть свои дополнительные фишки. Самая очевидная из них - более аккуратный вывод в консоль:

```
heroes

## # A tibble: 734 x 11
##       X1 name  Gender `Eye color` Race  `Hair color` Height Publisher
##   <dbl> <chr> <chr>    <chr> <chr>    <dbl> <chr>
## 1     0 A-Bo~ Male    yellow Human No Hair      203 Marvel C~
## 2     1 Abe ~ Male    blue   Icth~ No Hair      191 Dark Hor~
## 3     2 Abin~ Male    blue   Unga~ No Hair      185 DC Comics
## 4     3 Abom~ Male    green  Huma~ No Hair      203 Marvel C~
## 5     4 Abra~ Male    blue   Cosm~ Black        NA Marvel C~
## 6     5 Abso~ Male    blue   Human No Hair     193 Marvel C~
## 7     6 Adam~ Male    blue   <NA> Blond        NA NBC - He~
## 8     7 Adam~ Male    blue   Human Blond      185 DC Comics
## 9     8 Agen~ Female blue   <NA> Blond      173 Marvel C~
## 10    9 Agen~ Male    brown  Human Brown      178 Marvel C~
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>
```

Выводятся только первые 10 строк, если какие-то колонки не влезают на экран, то они просто перечислены внизу. Ну а тип данных написан прямо под названием колонки.

Функции различных пакетов tidyverse сами конвертируют в тиблл при необходимости. Если же нужно это сделать самостоятельно, то можно это сделать так:

```
heroes_df <- as.data.frame(heroes) #
class(heroes_df)

## [1] "data.frame"

as_tibble(heroes_df) #

## # A tibble: 734 x 11
##       X1 name  Gender `Eye color` Race  `Hair color` Height Publisher
##   <dbl> <chr> <chr>    <chr> <chr>    <dbl> <chr>
## 1     0 A-Bo~ Male    yellow Human No Hair      203 Marvel C~
## 2     1 Abe ~ Male    blue   Icth~ No Hair      191 Dark Hor~
## 3     2 Abin~ Male    blue   Unga~ No Hair      185 DC Comics
## 4     3 Abom~ Male    green  Huma~ No Hair      203 Marvel C~
## 5     4 Abra~ Male    blue   Cosm~ Black        NA Marvel C~
## 6     5 Abso~ Male    blue   Human No Hair     193 Marvel C~
```

⁹<https://www.jumpingrivers.com/blog/the-trouble-with-tibbles/>

```

## 7     6 Adam~ Male   blue      <NA> Blond      NA NBC - He-
## 8     7 Adam~ Male   blue      Human Blond    185 DC Comics
## 9     8 Agen~ Female blue      <NA> Blond      173 Marvel C-
## 10    9 Agen~ Male   brown     Human Brown   178 Marvel C-
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>

```

В дальнейшем мы будем работать только с tidyverse, а это значит, что только с тиблами, а не обычными датафреймами. Тем не менее, тиблы и датафреймы будут в дальнейшем использоваться как синонимы.

Можно создавать тиблы вручную с помощью функции `tibble()`, которая работает аналогично функции `data.frame()`:

```

tibble(
  a = 1:3,
  b = letters[1:3]
)

```

```

## # A tibble: 3 x 2
##       a     b
##   <int> <chr>
## 1     1     a
## 2     2     b
## 3     3     c

```

5.8 magrittr::%>%

Оператор `%>%` называется “пайпом” (pipe), т.е. “трубой”. Он означает, что следующая функция (справа от пайпа) принимает на вход в качестве первого аргумента результат выполнения предыдущей функции (той, что слева). Фактически, это примерно то же самое, что и вставлять результат выполнения функции в качестве первого аргумента в другую функцию. Просто выглядит это красивее и читабельнее. Как будто данные пропускаются через трубы функций или конвейерную ленту на заводе, если хотите. А то, что первый параметр функции - это почти всегда данные, работает нам здесь на руку. Этот оператор взят из пакета `magrittr`¹⁰. Возможно, даже если вы не захотите пользоваться tidyverse, использование пайпов Вам понравится.

Важно понимать, что пайп не дает какой-то дополнительной функциональности или дополнительной скорости работы¹¹. Он создан исключительно для читабельности и комфорта.

С помощью пайпов вот эту команду...

¹⁰Если быть точным, то оператор `%>%` был импортирован во все основные пакеты tidyverse, а сам пакет `magrittr` не входит в базовый набор tidyverse. Тем не менее, в самом `magrittr` есть еще несколько интересных операторов.

¹¹Даже наоборот, использование пайпов незначительно снижает скорость выполнения команды.

```
sum(sqrt(abs(sin(1:22))))
```

```
## [1] 16.72656
```

...можно переписать вот так:

```
1:22 %>%
  sin() %>%
  abs() %>%
  sqrt() %>%
  sum()
```

```
## [1] 16.72656
```

В очень редких случаях результат выполнения функции нужно вставить не на первую позицию (или же мы хотим использовать его несколько раз). В этих случаях можно использовать `..`, чтобы обозначить, куда мы хотим вставить результат выполнения выражения слева от `%>%`.

```
"           ! " %>%
  c("—", .., "—")
```

```
## [1] "—"           "           ! "   "—"
```

5.9 Главные пакеты tidyverse: dplyr и tidyverse

`dplyr`¹² — это самая основа всего `tidyverse`. Этот пакет предоставляет основные функции для манипуляции с тиблами. Пакет `dplyr` является наследником и более усовершенствованной версией `plyr`, так что если увидите использование пакета `plyr`, то, скорее всего, скрипт был написан очень давно.

Пакет `tidyverse` дополняет `dplyr`, предоставляя полезные функции для тайдификации тиблов. Тайдификация (“аккуратизация”) данных означает приведение табличных данных к такому формату, в котором:

- Каждая переменная имеет собственный столбец
- Каждый наблюдение имеет собственную строку
- Каждое значение имеет свою собственную ячейку

Впрочем, многие функции `dplyr` часто используются при тайдификации, так же как и многие функции `tidyverse` имеют применение вне тайдификации. В общем, функционал этих двух пакетов несколько смешался, поэтому мы будем рассматривать их вместе. А чтобы представлять, какая функция относится к какому пакету (хотя запомнить это необязательно), я буду использовать запись с двумя двоеточиями `::`, которая

¹² Есть споры о том, как это правильно читать¹³. Используемые варианты: `диплаер`, `диплер`, `диплр`.

обычно используется для использования функции без подгрузки всего пакета, при первом упоминании функции.

Пакет `tidyverse` — это более усовершенствованная версия пакета `reshape2`, который в свою очередь является усовершенствованной версией `reshape`. По аналогии с `plyr`, если вы видите использование этих пакетов, то это указывает на то, что перед вами морально устаревший код.

Код с использованием `dplyr` и `tidyverse` сильно непохож на то, что мы видели раньше. Большинство функций `dplyr` и `tidyverse` работают с целым тиблом сразу, принимая его в качестве первого аргумента и возвращая измененный тибл. Это позволяет превратить весь код в последовательный набор применяемых функций, соединенный пайпами. На практике это выглядит очень элегантно, и вы в этом скоро убедитесь.

5.10 Работа с колонками тиббла

5.10.1 Выбор колонок: `dplyr::select()`

Функция `dplyr::select()` позволяет выбирать колонки по номеру или имени (кавычки не нужны).

```
heroes %>%
  select(1,5)
```

```
## # A tibble: 734 x 2
##       X1 Race
##   <dbl> <chr>
## 1     0 Human
## 2     1 Icthyo Sapien
## 3     2 Ungaran
## 4     3 Human / Radiation
## 5     4 Cosmic Entity
## 6     5 Human
## 7     6 <NA>
## 8     7 Human
## 9     8 <NA>
## 10    9 Human
## # ... with 724 more rows
```

```
heroes %>%
  select(name, Race, Publisher, `Hair color`)
```

```
## # A tibble: 734 x 4
##       name      Race      Publisher      `Hair color`
##   <chr>      <chr>      <chr>          <chr>
## 1 A-Bomb    Human    Marvel Comics    No Hair
```

```

##  2 Abe Sapien    Icthyo Sapien    Dark Horse Comics No Hair
##  3 Abin Sur     Ungaran        DC Comics      No Hair
##  4 Abomination  Human / Radiation Marvel Comics No Hair
##  5 Abraxas      Cosmic Entity   Marvel Comics Black
##  6 Absorbing Man Human          Marvel Comics No Hair
##  7 Adam Monroe   <NA>           NBC - Heroes Blond
##  8 Adam Strange  Human          DC Comics      Blond
##  9 Agent 13     <NA>           Marvel Comics Blond
## 10 Agent Bob    Human          Marvel Comics Brown
## # ... with 724 more rows

```

Обратите внимание, если в названии колонки присутствует пробел или, например, колонка начинается с цифры или точки и цифры, то это синтаксически невалидное имя (2.5.3). Это не значит, что такие названия колонок недопустимы. Но такие названия колонок нужно обособлять ‘грависом’ (правый штрих, на клавиатуре находится там же где и буква ё и ~).

Еще обратите внимание на то, что функции tidyverse не изменяют сами изначальные тибблы/датафреймы. Это означает, что если вы хотите полученный результат сохранить, то нужно добавить присвоение:

```

heroes_some_cols <- heroes %>%
  select(name, Race, Publisher, `Hair color`)
heroes_some_cols

```

```

## # A tibble: 734 x 4
##   name      Race      Publisher `Hair color`
##   <chr>     <chr>     <chr>       <chr>
## 1 A-Bomb   Human    Marvel Comics No Hair
## 2 Abe Sapien Icthyo Sapien Dark Horse Comics No Hair
## 3 Abin Sur  Ungaran  DC Comics      No Hair
## 4 Abomination Human / Radiation Marvel Comics No Hair
## 5 Abraxas   Cosmic Entity Marvel Comics Black
## 6 Absorbing Man Human    Marvel Comics No Hair
## 7 Adam Monroe <NA>      NBC - Heroes Blond
## 8 Adam Strange Human   DC Comics      Blond
## 9 Agent 13   <NA>      Marvel Comics Blond
## 10 Agent Bob  Human   Marvel Comics Brown
## # ... with 724 more rows

```

5.10.2 Мини-язык tidyselect для выбора колонок

Для выбора столбцов (не только в `select()`, но и для других функций tidyverse) используется специальный мини-язык `tidyselect` из одноименного пакета¹⁴. `tidyselect` да-

¹⁴Как и в случае с `magrittr`, пакет `tidyselect` не содержится в базовом tidyverse, но функции импортируются основными пакетами tidyverse.

ет очень широкие возможности для выбора колонок.

Можно использовать оператор : для выбора нескольких соседних колонок (по аналогии с созданием числового вектора с шагом 1).

```
heroes %>%
  select(name:Publisher)

## # A tibble: 734 x 7
##   name      Gender `Eye color` Race      `Hair color` Height Publisher
##   <chr>     <chr>    <chr>     <chr>    <chr>       <dbl> <chr>
## 1 A-Bomb    Male    yellow   Human     No Hair      203 Marvel Comics
## 2 Abe Sapien Male    blue    Ichtyo Sapien No Hair      191 Dark Horse C-
## 3 Abin Sur   Male    blue    Ungaran   No Hair      185 DC Comics
## 4 Abomination Male   green   Human / Radi~ No Hair      203 Marvel Comics
## 5 Abraxas    Male    blue    Cosmic Entity Black        NA Marvel Comics
## 6 Absorbing~ Male   blue    Human     No Hair      193 Marvel Comics
## 7 Adam Monr~ Male   blue    <NA>      Blond        NA NBC - Heroes
## 8 Adam Stra~ Male   blue    Human     Blond        185 DC Comics
## 9 Agent 13   Female  blue    <NA>      Blond        173 Marvel Comics
## 10 Agent Bob  Male   brown   Human     Brown       178 Marvel Comics
## # ... with 724 more rows

heroes %>%
  select(name:`Eye color`, Publisher:Weight)

## # A tibble: 734 x 7
##   name      Gender `Eye color` Publisher      `Skin color` Alignment Weight
##   <chr>     <chr>    <chr>     <chr>    <chr>       <chr>     <dbl>
## 1 A-Bomb    Male    yellow   Marvel Comics <NA>       good      441
## 2 Abe Sapien Male    blue    Dark Horse Com~ blue       good      65
## 3 Abin Sur   Male    blue    DC Comics     red       good      90
## 4 Abomination Male   green   Marvel Comics <NA>       bad       441
## 5 Abraxas    Male    blue    Marvel Comics <NA>       bad       NA
## 6 Absorbing M~ Male   blue    Marvel Comics <NA>       bad      122
## 7 Adam Monroe Male   blue    NBC - Heroes <NA>       good      NA
## 8 Adam Strange Male   blue    DC Comics     <NA>       good      88
## 9 Agent 13   Female  blue    Marvel Comics <NA>       good      61
## 10 Agent Bob  Male   brown   Marvel Comics <NA>       good      81
## # ... with 724 more rows
```

Используя ! можно вырезать ненужные колонки.

```
heroes %>%
  select(!X1)
```

```

## # A tibble: 734 x 10
##   name Gender `Eye color` Race `Hair color` Height Publisher `Skin color`
##   <chr> <chr> <chr>     <chr> <chr>      <dbl> <chr>     <chr>
## 1 A-Bo~ Male  yellow   Human No Hair      203 Marvel C~ <NA>
## 2 Abe ~ Male  blue    Icth~ No Hair     191 Dark Hor~ blue
## 3 Abin~ Male  blue    Unga~ No Hair     185 DC Comics red
## 4 Abom~ Male  green   Huma~ No Hair     203 Marvel C~ <NA>
## 5 Abra~ Male  blue    Cosm~ Black       NA Marvel C~ <NA>
## 6 Abso~ Male  blue    Human No Hair    193 Marvel C~ <NA>
## 7 Adam~ Male  blue    <NA> Blond        NA NBC - He~ <NA>
## 8 Adam~ Male  blue    Human Blond      185 DC Comics <NA>
## 9 Agen~ Female blue   <NA> Blond        173 Marvel C~ <NA>
## 10 Agen~ Male  brown   Human Brown     178 Marvel C~ <NA>
## # ... with 724 more rows, and 2 more variables: Alignment <chr>, Weight <dbl>

heroes %>%
  select(!(Gender:Height))

## # A tibble: 734 x 6
##   X1 name          Publisher `Skin color` Alignment Weight
##   <dbl> <chr>        <chr>     <chr>     <chr>      <dbl>
## 1 0 A-Bomb        Marvel Comics <NA>      good      441
## 2 1 Abe Sapien    Dark Horse Comics blue    good      65
## 3 2 Abin Sur     DC Comics      red      good      90
## 4 3 Abomination  Marvel Comics <NA>      bad      441
## 5 4 Abraxas       Marvel Comics <NA>      bad      NA
## 6 5 Absorbing Man Marvel Comics <NA>      bad      122
## 7 6 Adam Monroe   NBC - Heroes <NA>      good      NA
## 8 7 Adam Strange  DC Comics     <NA>      good      88
## 9 8 Agent 13      Marvel Comics <NA>      good      61
## 10 9 Agent Bob    Marvel Comics <NA>      good      81
## # ... with 724 more rows

```

Другие известные нам логические операторы (`&` и `|`) тоже работают в `tidyselect`.

В дополнение к логическим операторам `и` и `:`, в `tidyselect` есть набор вспомогательных функций, работающих исключительно в контексте выбора колонок с помощью `tidyselect`.

Вспомогательная функция `last_col()` позволит обратиться к последней колонке тибла:

```

heroes %>%
  select(name:last_col())

## # A tibble: 734 x 10

```

```

##   name  Gender `Eye color` Race  `Hair color` Height Publisher `Skin color`
##   <chr> <chr>  <chr>      <chr> <chr>       <dbl> <chr>    <chr>
## 1 A-Bo~ Male    yellow    Human No Hair      203 Marvel C~ <NA>
## 2 Abe ~ Male    blue     Icth~ No Hair      191 Dark Hor~ blue
## 3 Abin~ Male    blue     Unga~ No Hair     185 DC Comics red
## 4 Abom~ Male    green    Huma~ No Hair     203 Marvel C~ <NA>
## 5 Abra~ Male    blue     Cosm~ Black        NA Marvel C~ <NA>
## 6 Abso~ Male    blue     Human No Hair     193 Marvel C~ <NA>
## 7 Adam~ Male    blue     <NA> Blond        NA NBC - He~ <NA>
## 8 Adam~ Male    blue     Human Blond       185 DC Comics <NA>
## 9 Agen~ Female  blue     <NA> Blond        173 Marvel C~ <NA>
## 10 Agen~ Male   brown    Human Brown      178 Marvel C~ <NA>
## # ... with 724 more rows, and 2 more variables: Alignment <chr>, Weight <dbl>

```

А функция `everything()` позволяет выбрать все колонки.

```

heroes %>%
  select(everything())

```



```

## # A tibble: 734 x 11
##   X1 name  Gender `Eye color` Race  `Hair color` Height Publisher
##   <dbl> <chr> <chr>  <chr> <chr>       <dbl> <chr>
## 1 0 A-Bo~ Male    yellow    Human No Hair      203 Marvel C~
## 2 1 Abe ~ Male    blue     Icth~ No Hair      191 Dark Hor~
## 3 2 Abin~ Male    blue     Unga~ No Hair     185 DC Comics
## 4 3 Abom~ Male    green    Huma~ No Hair     203 Marvel C~
## 5 4 Abra~ Male    blue     Cosm~ Black        NA Marvel C~
## 6 5 Abso~ Male    blue     Human No Hair     193 Marvel C~
## 7 6 Adam~ Male    blue     <NA> Blond        NA NBC - He~
## 8 7 Adam~ Male    blue     Human Blond       185 DC Comics
## 9 8 Agen~ Female  blue     <NA> Blond        173 Marvel C~
## 10 9 Agen~ Male   brown    Human Brown      178 Marvel C~
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>

```

При этом `everything()` не будет дублировать выбранные колонки, поэтому можно использовать `everything()` для перестановки колонок в тиббле:

```

heroes %>%
  select(name, Publisher, everything())

```



```

## # A tibble: 734 x 11
##   name  Publisher X1 Gender `Eye color` Race  `Hair color` Height
##   <chr> <chr>    <dbl> <chr>  <chr> <chr>       <dbl>
## 1 A-Bo~ Marvel C~      0 Male    yellow    Human No Hair      203
## 2 Abe ~ Dark Hor~      1 Male    blue     Icth~ No Hair      191

```

```

##  3 Abin~ DC Comics      2 Male   blue      Unga~ No Hair      185
##  4 Abom~ Marvel C~     3 Male   green     Huma~ No Hair      203
##  5 Abra~ Marvel C~     4 Male   blue      Cosm~ Black       NA
##  6 Abso~ Marvel C~     5 Male   blue      Human No Hair    193
##  7 Adam~ NBC - He~     6 Male   blue      <NA> Blond       NA
##  8 Adam~ DC Comics      7 Male   blue      Human Blond     185
##  9 Agen~ Marvel C~     8 Female blue     <NA> Blond     173
## 10 Agen~ Marvel C~     9 Male   brown     Human Brown    178
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>

```

Впрочем, для перестановки колонок удобнее использовать специальную функцию `relocate()` (@ref(tidy_relocate)) Можно даже выбирать колонки по паттернам в названиях. Например, с помощью `ends_with()` можно выбрать все колонки, заканчивающиеся одинаковым суффиксом:

```

heroes %>%
  select(ends_with("color"))

## # A tibble: 734 x 3
##   `Eye color` `Hair color` `Skin color`
##   <chr>        <chr>        <chr>
## 1 yellow      No Hair     <NA>
## 2 blue        No Hair     blue
## 3 blue        No Hair     red
## 4 green       No Hair     <NA>
## 5 blue        Black       <NA>
## 6 blue        No Hair     <NA>
## 7 blue        Blond       <NA>
## 8 blue        Blond       <NA>
## 9 blue        Blond       <NA>
## 10 brown       Brown      <NA>
## # ... with 724 more rows

```

Аналогично, с помощью функции `starts_with()` можно найти колонки с одинаковым префиксом, с помощью `contains()` — все колонки с выбранным паттерном в любой части названия колонки¹⁵.

```

heroes %>%
  select(starts_with("Eye") & ends_with("color"))

## # A tibble: 734 x 1
##   `Eye color`

```

¹⁵ Выбранный паттерн будет найден посимвольно, если же вы хотите искать по регулярным выражениям, то вместо `contains()` нужно использовать `matches()`.

```

##      <chr>
## 1 yellow
## 2 blue
## 3 blue
## 4 green
## 5 blue
## 6 blue
## 7 blue
## 8 blue
## 9 blue
## 10 brown
## # ... with 724 more rows

```

```

heroes %>%
  select(contains("eight"))

```

```

## # A tibble: 734 x 2
##       Height Weight
##      <dbl>   <dbl>
## 1     203     441
## 2     191      65
## 3     185      90
## 4     203     441
## 5       NA      NA
## 6     193     122
## 7       NA      NA
## 8     185      88
## 9     173      61
## 10    178      81
## # ... with 724 more rows

```

Ну и наконец, можно выбирать по содержимому колонок с помощью `where()`. Это напоминает применение `sapply()(@ref(apply_other))` на датафрейме для индексирования колонок: в качестве аргумента для `where` принимается функция, которая применяется для каждой из колонок, после чего выбираются только те колонки, для которых было получено TRUE.

```

heroes %>%
  select(where(is.numeric))

```

```

## # A tibble: 734 x 3
##       X1 Height Weight
##      <dbl>   <dbl>   <dbl>
## 1     0     203     441
## 2     1     191      65

```

```
##  3    2    185    90
##  4    3    203   441
##  5    4     NA     NA
##  6    5    193   122
##  7    6     NA     NA
##  8    7    185    88
##  9    8    173    61
## 10   9    178    81
## # ... with 724 more rows
```

Функция `where()` дает невиданную мощь. Например, можно выбрать все колонки без `NA`:

```
heroes %>%
  select(where(function(x) !any(is.na(x))))
```

```
## # A tibble: 734 x 3
##       X1 name      Publisher
##   <dbl> <chr>     <chr>
## 1     0 A-Bomb    Marvel Comics
## 2     1 Abe Sapien Dark Horse Comics
## 3     2 Abin Sur   DC Comics
## 4     3 Abomination Marvel Comics
## 5     4 Abraxas    Marvel Comics
## 6     5 Absorbing Man Marvel Comics
## 7     6 Adam Monroe NBC - Heroes
## 8     7 Adam Strange DC Comics
## 9     8 Agent 13   Marvel Comics
## 10    9 Agent Bob  Marvel Comics
## # ... with 724 more rows
```

###Переименование колонок: `dplyr::rename()`

Внутри `select()` можно не только выбирать колонки, но и переименовывать их:

```
heroes %>%
  select(id = X1)
```

```
## # A tibble: 734 x 1
##       id
##   <dbl>
## 1     0
## 2     1
## 3     2
## 4     3
## 5     4
```

```
## 6    5
## 7    6
## 8    7
## 9    8
## 10   9
## # ... with 724 more rows
```

Однако удобнее для этого использовать специальную функцию `dplyr::rename()`. Синтаксис у нее такой же, как и у `select()`, но `rename()` не выбрасывает колонки, которые не были упомянуты.

```
heroes %>%
  rename(id = X1)

## # A tibble: 734 x 11
##       id name  Gender `Eye color` Race `Hair color` Height Publisher
##     <dbl> <chr> <chr>      <chr> <chr>      <dbl> <chr>
## 1     0 A-Bo~ Male    yellow Human No Hair      203 Marvel C~
## 2     1 Abe ~ Male    blue  Icth~ No Hair      191 Dark Hor~
## 3     2 Abin~ Male    blue  Unga~ No Hair      185 DC Comics
## 4     3 Abom~ Male    green Huma~ No Hair      203 Marvel C~
## 5     4 Abra~ Male    blue  Cosm~ Black        NA Marvel C~
## 6     5 Abso~ Male    blue Human No Hair      193 Marvel C~
## 7     6 Adam~ Male    blue    <NA> Blond        NA NBC - He~
## 8     7 Adam~ Male    blue Human Blond       185 DC Comics
## 9     8 Agen~ Female blue    <NA> Blond       173 Marvel C~
## 10    9 Agen~ Male    brown Human Brown      178 Marvel C~
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>
```

Для массового переименования колонок можно использовать функцию `rename_with()`. Эта функция так же использует tidyselect синтаксис для выбора колонок (по умолчанию выбираются все колонки) и применяет функцию в качестве аргумента, которая изменяет

```
heroes %>%
  rename_with(make.names)

## # A tibble: 734 x 11
##       X1 name  Gender Eye.color Race  Hair.color Height Publisher Skin.color
##     <dbl> <chr> <chr>    <chr> <chr>      <dbl> <chr>      <chr>
## 1     0 A-Bo~ Male    yellow Human No Hair      203 Marvel C~ <NA>
## 2     1 Abe ~ Male    blue  Icth~ No Hair      191 Dark Hor~ blue
## 3     2 Abin~ Male    blue  Unga~ No Hair      185 DC Comics red
## 4     3 Abom~ Male    green Huma~ No Hair      203 Marvel C~ <NA>
## 5     4 Abra~ Male    blue  Cosm~ Black        NA Marvel C~ <NA>
```

```

## 6   5 Absor~ Male blue Human No Hair      193 Marvel C~ <NA>
## 7   6 Adam~ Male blue <NA> Blond        NA NBC - He~ <NA>
## 8   7 Adam~ Male blue Human Blond       185 DC Comics <NA>
## 9   8 Agen~ Female blue <NA> Blond       173 Marvel C~ <NA>
## 10  9 Agen~ Male brown Human Brown      178 Marvel C~ <NA>
## # ... with 724 more rows, and 2 more variables: Alignment <chr>, Weight <dbl>

###Перестановка колонок:dplyr::relocate() {#tidy_relocate}

```

Для изменения порядка колонок можно использовать функцию `relocate()`. Она тоже работает похожим образом на `select()` и `rename()`¹⁶. Как и `rename()`, функция `relocate()` не выкидывает неиспользованные колонки:

```
heroes %>%
```

```
  relocate(Publisher)
```

```

## # A tibble: 734 x 11
##   Publisher X1 name Gender `Eye color` Race `Hair color` Height
##   <chr>     <dbl> <chr> <chr>   <chr> <chr> <dbl>
## 1 Marvel    0 A-Bo~ Male yellow Human No Hair    203
## 2 Dark Hor~ 1 Abe ~ Male blue  Icth~ No Hair    191
## 3 DC Comics 2 Abin~ Male blue Unga~ No Hair    185
## 4 Marvel    3 Abom~ Male green Huma~ No Hair    203
## 5 Marvel    4 Abra~ Male blue Cosm~ Black      NA
## 6 Marvel    5 Absor~ Male blue Human No Hair    193
## 7 NBC - He~ 6 Adam~ Male blue <NA> Blond      NA
## 8 DC Comics 7 Adam~ Male blue Human Blond      185
## 9 Marvel    8 Agen~ Female blue <NA> Blond      173
## 10 Marvel   9 Agen~ Male brown Human Brown     178
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>
```

При этом `relocate()` имеет дополнительные параметры `.after =` и `.before =`, которые позволяют выбирать, куда поместить выбранные колонки.

```
heroes %>%
```

```
  relocate(Publisher, .after = name)
```

```

## # A tibble: 734 x 11
##   X1 name Publisher Gender `Eye color` Race `Hair color` Height
##   <dbl> <chr> <chr> <chr>   <chr> <chr> <dbl>
## 1 0 A-Bo~ Marvel C~ Male yellow Human No Hair    203
## 2 1 Abe ~ Dark Hor~ Male blue  Icth~ No Hair    191
## 3 2 Abin~ DC Comics Male blue Unga~ No Hair    185
## 4 3 Abom~ Marvel C~ Male green Huma~ No Hair    203
```

¹⁶ `relocate()` не позволяет переименовывать колонки в отличие от `select()` и `rename()`

```

## 5     4 Abra~ Marvel C~ Male   blue      Cosm~ Black       NA
## 6     5 Abso~ Marvel C~ Male   blue      Human No Hair    193
## 7     6 Adam~ NBC - He~ Male   blue      <NA>  Blond       NA
## 8     7 Adam~ DC Comics Male   blue      Human Blond     185
## 9     8 Agen~ Marvel C~ Female blue      <NA>  Blond     173
## 10    9 Agen~ Marvel C~ Male   brown     Human Brown    178
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>

```

`relocate()` очень хорошо работает в сочетании с выбором колонок с помощью `tidyselect`. Например, можно передвинуть в одно место все колонки с одним типом данных:

```

heroes %>%
  relocate(Publisher, where(is.numeric), .after = name)

```

```

## # A tibble: 734 x 11
##   name Publisher   X1 Height Weight Gender `Eye color` `Race` `Hair color`
##   <chr> <chr>     <dbl>  <dbl>  <dbl> <chr>   <chr>   <chr>
## 1 A-Bo~ Marvel      0     203    441  Male   yellow  Human  No Hair
## 2 Abe ~ Dark Hor~   1     191     65  Male   blue   Icth~  No Hair
## 3 Abin~ DC Comics    2     185     90  Male   blue   Unga~  No Hair
## 4 Abom~ Marvel      3     203    441  Male   green  Huma~  No Hair
## 5 Abra~ Marvel      4     NA     NA  Male   blue   Cosm~ Black
## 6 Abso~ Marvel      5     193    122  Male   blue   Human  No Hair
## 7 Adam~ NBC - He~    6     NA     NA  Male   blue   <NA>  Blond
## 8 Adam~ DC Comics    7     185     88  Male   blue   Human  Blond
## 9 Agen~ Marvel      8     173     61  Female blue   <NA>  Blond
## 10 Agen~ Marvel     9     178     81  Male   brown  Human Brown
## # ... with 724 more rows, and 2 more variables: `Skin color` <chr>,
## #   Alignment <chr>

```

Последняя важная функция для выбора колонок — `pull()`. Эта функция делает то же самое, что и индексирование с помощью `$`, т.е. вытаскивает из тиббла вектор с выбранным названием. Это лучше вписывается в логику tidyverse, поскольку позволяет извлечь колонку из тиббла с использованием пайпа:

```

heroes %>%
  select(Height) %>%
  pull() %>%
  head()

```

```

## [1] 203 191 185 203 NA 193

```

```
heroes %>%
  pull(Height) %>%
  head()
```

```
## [1] 203 191 185 203 NA 193
```

У функции `pull()` есть аргумент `name =`, который позволяет создать проименованный вектор:

```
heroes %>%
  pull(Height, name) %>%
  head()
```

	A-Bomb	Abe Sapien	Abin Sur	Abomination	Abraxas
##	203	191	185	203	NA
## Absorbing Man					
##	193				

В отличие от базового R, tidyverse никогда не сокращает имплицитно результат вычислений до вектора, поэтому функция `pull()` - это основной способ извлечения колонки из тибла как вектора.

5.11 Работа со строками тибла

5.11.1 Выбор строк по номеру: `dplyr::slice()`

Начнем с выбора строк. Функция `dplyr::slice()` выбирает строчки по их числовому индексу.

```
heroes %>%
  slice(1:3)
```

```
## # A tibble: 3 x 11
##       X1 name  Gender `Eye color` Race  `Hair color` Height Publisher
##       <dbl> <chr> <chr>    <chr>   <chr>    <chr>    <dbl> <chr>
## 1      0 A-Bo~ Male    yellow   Human No Hair      203 Marvel C~
## 2      1 Abe ~ Male    blue     Icth~ No Hair     191 Dark Hor~
## 3      2 Abin~ Male    blue     Unga~ No Hair     185 DC Comics
## # ... with 3 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>
```

5.11.2 Выбор строк по условию: `dplyr::filter()`

Функция `dplyr::filter()` делает то же самое, что и `slice()`, но уже по условию. Причем для условий нужно использовать не векторы из тибла, а название колонок (без кавычек) как будто бы они были переменными в окружении.

```
heroes %>%
  filter(Publisher == "DC Comics")
```

```
## # A tibble: 215 x 11
##   X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr> <chr> <chr> <chr> <dbl> <chr>
## 1 2 Abin~ Male blue Unga~ No Hair     185 DC Comics
## 2 7 Adam~ Male blue Human Blond      185 DC Comics
## 3 13 Alan~ Male blue <NA> Blond       180 DC Comics
## 4 16 Alfr~ Male blue Human Black     178 DC Comics
## 5 19 Amazo Male red Andr~ <NA>        257 DC Comics
## 6 27 Anim~ Male blue Human Blond      183 DC Comics
## 7 31 Anti~ Male yellow God ~ No Hair   61 DC Comics
## 8 35 Aqua~ Male blue <NA> Blond       NA DC Comics
## 9 36 Aqua~ Male blue Atla~ Black      178 DC Comics
## 10 37 Aqua~ Male blue Atla~ Blond     185 DC Comics
## # ... with 205 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>
```

5.11.3 Семейство функций slice()

У функции `slice()` есть множество родственников, которые объединяют функционал обычного `slice()` и `filter()`. Например, с помощью функций `dplyr:::slice_max()` и `dplyr:::slice_min()` можно выбрать заданное количество строк, содержащих наибольшие или наименьшие значения по колонке соответственно:

```
heroes %>%
  slice_max(Weight, n = 3)
```

```
## # A tibble: 3 x 11
##   X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr> <chr> <chr> <chr> <dbl> <chr>
## 1 575 Sasq~ Male red <NA> Orange     305 Marvel C-
## 2 373 Jugg~ Male blue Human Red      287 Marvel C-
## 3 203 Dark~ Male red New ~ No Hair  267 DC Comics
## # ... with 3 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>
```

```
heroes %>%
  slice_min(Weight, n = 3)
```

```
## # A tibble: 3 x 11
##   X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr> <chr> <chr> <chr> <dbl> <chr>
```

```
## 1 346 Iron~ Male blue <NA> No Hair NA Marvel C~
## 2 302 Groot Male yellow Flor~ <NA> 701 Marvel C~
## 3 350 Jack~ Male blue Human Brown 71 Dark Hor~
## # ... with 3 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>
```

Функция `slice_sample()` позволяет выбирать заданное количество случайных строчек:

```
heroes %>%
  slice_sample(n = 3)
```

```
## # A tibble: 3 x 11
##   X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr> <chr> <chr> <chr> <dbl> <chr>
## 1 114 Blink Female green Mut~ Magenta 165 Marvel C~
## 2 467 Molt~ Male gold <NA> Gold 196 Marvel C~
## 3 602 Simo~ Male bown Human Black NA DC Comics
## # ... with 3 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>
```

Или же долю строчек:

```
heroes %>%
  slice_sample(prop = .01)
```

```
## # A tibble: 7 x 11
##   X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr> <chr> <chr> <chr> <dbl> <chr>
## 1 44 Armor Female black <NA> Black 163 Marvel C~
## 2 615 Spec~ Male white God ~ No Hair NA DC Comics
## 3 91 Bish~ Male brown Mut~ No Hair 198 Marvel C~
## 4 347 Isis Female <NA> <NA> <NA> NA DC Comics
## 5 272 Gala~ Male black Cosm~ Black 876 Marvel C~
## 6 170 Chan~ Male brown <NA> Black 180 Marvel C~
## 7 157 Capt~ Male blue Human Black 175 DC Comics
## # ... with 3 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>
```

Если поставить значение параметра `prop =` равным 1, то таким образом можно перемешать порядок строчек в тibble:

```
heroes %>%
  slice_sample(prop = 1)
```

```
## # A tibble: 734 x 11
##   X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr> <chr> <chr> <chr> <dbl> <chr>
```

```

## 1 128 Bomb~ Female <NA> <NA> <NA> NA Image Co~
## 2 225 Doct~ Male grey Human Black 188 Marvel C~
## 3 135 Brai~ Male green Andr~ No Hair 198 DC Comics
## 4 333 Hunt~ Female blue <NA> Black 180 DC Comics
## 5 707 Warl~ Male red <NA> Blond 188 Marvel C~
## 6 595 Shri~ Female <NA> <NA> <NA> NA DC Comics
## 7 4 Abra~ Male blue Cosm~ Black NA Marvel C~
## 8 388 Kilo~ Male red Bolo~ No Hair 234 DC Comics
## 9 343 Invi~ Female blue Huma~ Blond 168 Marvel C~
## 10 164 Catw~ Female green Human Black 175 DC Comics
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## # Alignment <chr>, Weight <dbl>

```

5.11.4 Удаление строчек с NA: tidyverse::drop_na()

Если нужно выбрать только строчки без пропущенных значений, то можно воспользоваться удобной функцией `tidyverse::drop_na()`.

```

heroes %>%
  drop_na()

```

```

## # A tibble: 50 x 11
##       X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr> <chr> <chr> <chr> <dbl> <chr>
## 1     1 Abe ~ Male blue Icth~ No Hair    191 Dark Hor~
## 2     2 Abin~ Male blue Unga~ No Hair    185 DC Comics
## 3    34 Apoc~ Male red Muta~ Black      213 Marvel C~
## 4    39 Arch~ Male blue Muta~ Blond      183 Marvel C~
## 5    41 Ardi~ Female white Alien Orange  193 Marvel C~
## 6    56 Azaz~ Male yellow Neya~ Black    183 Marvel C~
## 7    74 Beast Male blue Muta~ Blue       180 Marvel C~
## 8    75 Beas~ Male green Human Green    173 DC Comics
## 9    92 Biza~ Male black Biza~ Black     191 DC Comics
## 10   108 Blac~ Male red Demon White    191 Marvel C~
## # ... with 40 more rows, and 3 more variables: `Skin color` <chr>,
## # Alignment <chr>, Weight <dbl>

```

Можно выбрать колонки, наличие NA в которых будет приводить к удалению соответствующих строчек (не затрагивая другие строчки, в которых есть NA в остальных столбцах).

```

heroes %>%
  drop_na(Weight)

```

```

## # A tibble: 495 x 11

```

```
##      X1 name Gender `Eye color` Race `Hair color` Height Publisher
##      <dbl> <chr> <chr> <chr> <chr> <chr> <dbl> <chr>
## 1    0 A-Bo~ Male   yellow   Human No Hair      203 Marvel C~
## 2    1 Abe ~ Male   blue    Icth~ No Hair      191 Dark Hor~
## 3    2 Abin~ Male   blue    Unga~ No Hair     185 DC Comics
## 4    3 Abom~ Male   green   Huma~ No Hair     203 Marvel C~
## 5    5 Abso~ Male   blue   Human No Hair     193 Marvel C~
## 6    7 Adam~ Male   blue   Human Blond      185 DC Comics
## 7    8 Agen~ Female blue   <NA> Blond      173 Marvel C~
## 8    9 Agen~ Male   brown   Human Brown     178 Marvel C~
## 9   10 Agen~ Male   <NA>   <NA> <NA>      191 Marvel C~
## 10   11 Air~~ Male   blue   <NA> White      188 Marvel C~
## # ... with 485 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>
```

Для выбора колонок в `drop_na()` используется `tidyselect`, с которым мы недавно познакомились (5.10.2).

5.11.5 Сортировка строк: `dplyr::arrange()`

Функция `dplyr::arrange()` сортирует строчки от меньшего к большему (или по алфавиту - для текстовых значений) по выбранной колонке.

```
heroes %>%
  arrange(Weight)
```

```
## # A tibble: 734 x 11
##      X1 name Gender `Eye color` Race `Hair color` Height Publisher
##      <dbl> <chr> <chr> <chr> <chr> <chr> <dbl> <chr>
## 1    346 Iron~ Male   blue   <NA> No Hair      NA Marvel C~
## 2    302 Groot Male   yellow Flor~ <NA>      701 Marvel C~
## 3    350 Jack~ Male   blue   Human Brown     71 Dark Hor~
## 4    272 Gala~ Male   black  Cosm~ Black     876 Marvel C~
## 5    731 Yoda~ Male   brown  Yoda~ White     66 George L~
## 6    255 Fin ~ Male   red   Kaka~ No Hair    975 Marvel C~
## 7    330 Howa~ Male   brown  <NA> Yellow     79 Marvel C~
## 8    396 Kryp~ Male   blue   Kryp~ White     64 DC Comics
## 9    568 Rock~ Male   brown  Anim~ Brown    122 Marvel C~
## 10   208 Dash~ Male   blue   Human Blond    122 Dark Hor~
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>
```

Чтобы отсортировать в обратном порядке, воспользуйтесь функцией `desc()`.

```
heroes %>%
  arrange(desc(Weight))
```

```
## # A tibble: 734 x 11
##       X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr>    <chr> <chr>    <dbl> <chr>
## 1 575 Sasq~ Male  red      <NA> Orange     305  Marvel C~
## 2 373 Jugg~ Male  blue     Human Red      287  Marvel C~
## 3 203 Dark~ Male  red      New ~ No Hair  267  DC Comics
## 4 283 Giga~ Female green  <NA> Red        62.5 DC Comics
## 5 331 Hulk  Male  green   Huma~ Green     244  Marvel C~
## 6 549 Red ~ Male  yellow  Huma~ Black     213  Marvel C~
## 7 119 Bloo~ Female blue   Human Brown    218  Marvel C~
## 8 718 Wolf~ Female green  <NA> Auburn    366  Marvel C~
## 9 657 Than~ Male  red      Eter~ No Hair  201  Marvel C~
## 10 0 A-Bo~ Male  yellow   Human No Hair 203  Marvel C~
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>
```

Можно сортировать по нескольким колонкам сразу. В таких случаях удобно в качестве первой переменной выбирать переменную, обозначающую принадлежность к группе, а в качестве второй — континуальную числовую переменную:

```
heroes %>%
  arrange(Gender, desc(Weight))
```

```
## # A tibble: 734 x 11
##       X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr>    <chr> <chr>    <dbl> <chr>
## 1 283 Giga~ Female green  <NA> Red        62.5 DC Comics
## 2 119 Bloo~ Female blue   Human Brown    218  Marvel C~
## 3 718 Wolf~ Female green  <NA> Auburn    366  Marvel C~
## 4 591 She~~ Female green  Human Green    201  Marvel C~
## 5 320 Hela  Female green  Asga~ Black     213  Marvel C~
## 6 686 Valk~ Female blue   <NA> Blond     191  Marvel C~
## 7 596 Sif   Female blue   Asga~ Black     188  Marvel C~
## 8 271 Frig~ Female blue   <NA> White     180  Marvel C~
## 9 667 Thun~ Female green  <NA> Red       218  Marvel C~
## 10 592 She~~ Female blue  Huma~ No Hair  183  Marvel C~
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>
```

5.12 Создание колонок: `dplyr::mutate()` и `dplyr::transmute()`

Функция `dplyr::mutate()` позволяет создавать новые колонки в тиббле.

```
heroes %>%
  mutate(imt = Weight/(Height/100)^2) %>%
  select(name, imt) %>%
  arrange(desc(imt))

## # A tibble: 734 x 2
##       name      imt
##   <chr>     <dbl>
## 1 Utgard-Loki 2510.
## 2 Giganta    1613.
## 3 Red Hulk    139.
## 4 Darkseid    115.
## 5 Machine Man 114.
## 6 Thanos      110.
## 7 Destroyer    108.
## 8 A-Bomb      107.
## 9 Abomination 107.
## 10 Hulk        106.
## # ... with 724 more rows
```

`dplyr::transmute()` - это аналог `mutate()`, который не только создает новые колонки, но и сразу же выкидывает все старые:

```
heroes %>%
  transmute(imt = Weight/(Height/100)^2)

## # A tibble: 734 x 1
##       imt
##   <dbl>
## 1 107.
## 2 17.8
## 3 26.3
## 4 107.
## 5 NA
## 6 32.8
## 7 NA
## 8 25.7
## 9 20.4
## 10 25.6
## # ... with 724 more rows
```

Внутри `mutate()` и `transmute()` мы можем использовать либо векторизованные

операции (длина новой колонки должна равняться длине датафрейма), либо операции, которые возвращают одно значение. В последнем случае значение будет одинаковым на всю колонку, т.е. будет работать правило ресайклнга (2.8.3):

```
heroes %>%
  transmute(name, weight_mean = mean(Weight, na.rm = TRUE))

## # A tibble: 734 x 2
##   name      weight_mean
##   <chr>        <dbl>
## 1 A-Bomb     112.
## 2 Abe Sapien 112.
## 3 Abin Sur   112.
## 4 Abomination 112.
## 5 Abraxas    112.
## 6 Absorbing Man 112.
## 7 Adam Monroe 112.
## 8 Adam Strange 112.
## 9 Agent 13    112.
## 10 Agent Bob   112.
## # ... with 724 more rows
```

Однако в функциях `mutate()` и `transmute()` правило ресайклнга не будет работать в остальных случаях: если полученный вектор будет не равен 1 или длине датафрейма, то мы получим ошибку.

```
heroes %>%
  mutate(one_and_two = 1:2)

## Error: Problem with `mutate()` input `one_and_two`.
## x Input `one_and_two` can't be recycled to size 734.
## i Input `one_and_two` is `1:2`.
## i Input `one_and_two` must be size 734 or 1, not 2.
```

Это не баг, а фича: авторы пакета `dplyr` считают, что ресайклнг кратных друг другу векторов — это слишком удобное место для выстрелов себе в ногу. Поэтому в таких случаях разработчики `dplyr` рекомендуют использовать функцию `rep()`, знакомую нам уже очень давно (2.8).

```
heroes %>%
  mutate(one_and_two = rep(1:2, length.out = nrow(.)))

## # A tibble: 734 x 12
##   name  Gender `Eye color` Race  `Hair color` Height Publisher
##   <chr> <chr>   <chr>   <chr> <chr>       <dbl> <chr>
```

```

## 1   0 A-Bo~ Male    yellow      Human No Hair    203 Marvel C-
## 2   1 Abe ~ Male   blue       Icth~ No Hair   191 Dark Hor-
## 3   2 Abin~ Male   blue       Unga~ No Hair   185 DC Comics
## 4   3 Abom~ Male   green     Huma~ No Hair   203 Marvel C-
## 5   4 Abra~ Male   blue       Cosm~ Black    NA Marvel C-
## 6   5 Abso~ Male   blue       Human No Hair  193 Marvel C-
## 7   6 Adam~ Male   blue      <NA> Blond    NA NBC - He-
## 8   7 Adam~ Male   blue       Human Blond   185 DC Comics
## 9   8 Agen~ Female blue      <NA> Blond   173 Marvel C-
## 10  9 Agen~ Male   brown     Human Brown   178 Marvel C-
## # ... with 724 more rows, and 4 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>, one_and_two <int>

```

5.13 Агрегация данных в тиббле

5.13.1 Подытоживание: `summarise()`

Агрегация по группам - это очень часто возникающая задача, например, это может использоваться для усреднения данных по испытуемым или условиям. Сделать агрегацию в датафрейме удобной Хэдли Уикхэм пытался еще в предшественнике `dplyr`, пакете `plyr`. `dplyr` позволяет делать агрегацию очень симпатичным и понятным способом. Агрегация в `dplyr` состоит из двух этапов: группировки (`group_by()`) и подытоживания (`summarise()`). Начнем с последнего.

Функция `dplyr::summarise()`¹⁷ позволяет агрегировать данные в тиббле. Работает она очень похоже на `mutate()`, но если внутри `mutate()` используются векторизованные функции, возвращающие вектор такой же длины, что и колонки, использовавшиеся для расчетов, то в `summarise()` используются функции, которые возвращают вектор длиной 1. Например, `min()`, `mean()`, `max()` и т.д. Можно создавать несколько колонок через запятую (это работает и для `mutate()`).

```

heroes %>%
  mutate(imt = Weight/(Height/100)^2) %>%
  summarise(min(imt, na.rm = TRUE),
            max(imt, na.rm = TRUE))

## # A tibble: 1 x 2
##   `min(imt, na.rm = TRUE)` `max(imt, na.rm = TRUE)`
##                   <dbl>                <dbl>
## 1                 0.0814             2510.

```

В `dplyr` есть дополнительные суммирующие функции для более удобного индексирования в стиле tidyverse. Например, функции `dplyr::nth()`, `dplyr::first()` и

¹⁷У функции `dplyr::summarise()` есть синоним `dplyr::summarize()`, которая делает абсолютно то же самое. Просто потому что в американском английском и британском английском это слово пишется по-разному.

`dplyr::last()`, которые позволяют вытаскивать значения из вектора по индексу (что-то вроде `slice()`, но для векторов)

```
heroes %>%
  mutate(imt = Weight/(Height/100)^2) %>%
  arrange(imt) %>%
  summarise(first = first(imt),
            tenth = nth(imt, 10),
            last = last(imt))

## # A tibble: 1 x 3
##   first tenth last
##     <dbl> <dbl> <dbl>
## 1 0.0814 16.7  NA
```

В отличие от `mutate()`, функции внутри `summarise()` вполне позволяют функциям внутри возвращать вектор из нескольких значений, создавая тиббл такой же длины, как и получившийся вектор.

```
heroes %>%
  mutate(imt = Weight/(Height/100)^2) %>%
  summarise(imt_range = range(imt, na.rm = TRUE)) #      range()

## # A tibble: 2 x 1
##   imt_range
##     <dbl>
## 1 0.0814
## 2 2510.
```

5.13.2 Группировка: `group_by()`

`dplyr::group_by()` - это функция для группировки данных в тиббле по дискретной переменной для дальнейшей агрегации с помощью `summarise()`. После применения `group_by()` тиббл будет выглядеть так же, но у него появится атрибут `groups`¹⁸:

```
heroes %>%
  group_by(Gender)

## # A tibble: 734 x 11
## # Groups:   Gender [3]
##       X1 name  Gender `Eye color` Race  `Hair color` Height Publisher
##       <dbl> <chr> <chr>    <chr> <chr>    <chr> <dbl> <chr>
## 1     0 A-Bo~ Male    yellow   Human No Hair      203 Marvel C~
```

¹⁸Снять группировку можно с помощью функции `ungroup()`.

```

## 2    1 Abe ~ Male   blue      Icth~ No Hair    191 Dark Hor-
## 3    2 Abin~ Male   blue      Unga~ No Hair    185 DC Comics
## 4    3 Abom~ Male   green     Huma~ No Hair    203 Marvel C-
## 5    4 Abra~ Male   blue      Cosm~ Black     NA Marvel C-
## 6    5 Abso~ Male   blue      Human No Hair   193 Marvel C-
## 7    6 Adam~ Male   blue      <NA> Blond     NA NBC - He-
## 8    7 Adam~ Male   blue      Human Blond    185 DC Comics
## 9    8 Agen~ Female blue      <NA> Blond     173 Marvel C-
## 10   9 Agen~ Male   brown     Human Brown   178 Marvel C-
## # ... with 724 more rows, and 3 more variables: `Skin color` <chr>,
## #   Alignment <chr>, Weight <dbl>

```

Если после этого применить на тibble функию `summarise()`, то мы получим не тibble длиной один, а тibble со значением для каждой из групп.

```

heroes %>%
  mutate(imt = Weight/(Height/100)^2) %>%
  group_by(Gender) %>%
  summarise(min(imt, na.rm = TRUE),
            max(imt, na.rm = TRUE))

## `summarise()` ungrouping output (override with `.`groups` argument)

## # A tibble: 3 x 3
##   Gender `min(imt, na.rm = TRUE)` `max(imt, na.rm = TRUE)`
##   <chr>          <dbl>           <dbl>
## 1 Female         15.5            1613.
## 2 Male           0.0814          2510.
## 3 <NA>           16.3            114.

```

Схематически это выглядит вот так:



5.13.3 Подсчет строк: `dplyr::n()`, `dplyr::count()`

Для подсчет количества значений можно воспользоваться функцией `n()`.

```

heroes %>%
  group_by(Gender) %>%

```

```
summarise(n = n())

## `summarise()` ungrouping output (override with `groups` argument)

## # A tibble: 3 x 2
##   Gender     n
##   <chr>    <int>
## 1 Female    200
## 2 Male      505
## 3 <NA>       29
```

Функция `n()` вместе с `group_by()` внутри `filter()` позволяет удобным образом “отрезать” от тиббла редкие группы...

```
heroes %>%
  group_by(Race) %>%
  filter(n() > 10) %>%
  select(name, Race)

## # A tibble: 611 x 2
## # Groups:   Race [6]
##   name        Race
##   <chr>      <chr>
## 1 A-Bomb     Human
## 2 Abomination Human / Radiation
## 3 Absorbing Man Human
## 4 Adam Monroe <NA>
## 5 Adam Strange Human
## 6 Agent 13    <NA>
## 7 Agent Bob   Human
## 8 Agent Zero  <NA>
## 9 Air-Walker   <NA>
## 10 Ajax        Cyborg
## # ... with 601 more rows
```

или же наоборот, выделить только маленькие группы:

```
heroes %>%
  group_by(Race) %>%
  filter(n() == 1) %>%
  select(name, Race)
```

```
## # A tibble: 34 x 2
## # Groups:   Race [34]
##   name        Race
```

```

## <chr>      <chr>
## 1 Abe Sapien  Icthyo Sapien
## 2 Abin Sur   Ungaran
## 3 Alien       Xenomorph XX121
## 4 Azazel     Neyaphem
## 5 Bizarro    Bizarro
## 6 Boba Fett   Human / Clone
## 7 Darth Maul  Dathomirian Zabrak
## 8 Fin Fang Foom Kakarantharaian
## 9 Gamora     Zen-Whoberian
## 10 Gladiator  Strontian
## # ... with 24 more rows

```

Таблицу частот можно создать без `group_by()` и `summarise(n = n())`. Функция `count()` заменяет эту конструкцию:

```

heroes %>%
  count(Gender)

```

```

## # A tibble: 3 x 2
##   Gender     n
##   <chr>   <int>
## 1 Female    200
## 2 Male      505
## 3 <NA>      29

```

Эту таблицу частот удобно сразу проранжировать, указав в параметре `sort =` значение `TRUE`.

```

heroes %>%
  count(Gender, sort = TRUE)

```

```

## # A tibble: 3 x 2
##   Gender     n
##   <chr>   <int>
## 1 Male      505
## 2 Female    200
## 3 <NA>      29

```

Функция `count()`, несмотря на свою простоту, является одной из наиболее используемых в tidyverse.

5.13.4 Уникальные значения: `dplyr::distinct()`

`dplyr::distinct()` - это более быстрый аналог `unique()`, позволяет извлекать уникальные значения для одной или нескольких колонок.

```
heroes %>%
  distinct(Gender)
```

```
## # A tibble: 3 x 1
##   Gender
##   <chr>
## 1 Male
## 2 Female
## 3 <NA>
```

```
heroes %>%
  distinct(Gender, Race)
```

```
## # A tibble: 81 x 2
##   Gender Race
##   <chr>  <chr>
## 1 Male   Human
## 2 Male   Icthyo Sapien
## 3 Male   Ungaran
## 4 Male   Human / Radiation
## 5 Male   Cosmic Entity
## 6 Male   <NA>
## 7 Female <NA>
## 8 Male   Cyborg
## 9 Male   Xenomorph XX121
## 10 Male  Android
## # ... with 71 more rows
```

Иногда нужно агрегировать данные, но при этом сохранить исходную структуру тиббла. Например, нужно посчитать размер групп или посчитать средние значения по группе для последующего сравнения с индивидуальными значениями.

5.13.5 Создание колонок с группировкой

В tidyverse это можно сделать с помощью сочетания `group_by()` и `mutate()` (вместо `summarise()`):

```
heroes %>%
  group_by(Race) %>%
  mutate(Race_n = n()) %>%
  select(Race, name, Gender, Race_n)

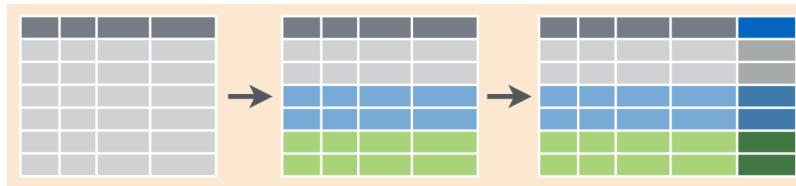
## # A tibble: 734 x 4
## # Groups:   Race [62]
```

```

##   Race           name      Gender Race_n
##   <chr>         <chr>     <chr>    <int>
## 1 Human          A-Bomb    Male     208
## 2 Icthyo Sapien Abe Sapien Male      1
## 3 Ungaran       Abin Sur   Male     1
## 4 Human / Radiation Abomination Male    11
## 5 Cosmic Entity Abraxas   Male     4
## 6 Human          Absorbing Man Male    208
## 7 <NA>           Adam Monroe Male   304
## 8 Human          Adam Strange Male   208
## 9 <NA>           Agent 13   Female  304
## 10 Human          Agent Bob   Male    208
## # ... with 724 more rows

```

Результаты агрегации были записаны в отдельную колонку, при этом значения этой колонки внутри одной группы повторяются:



5.14 Трансформация нескольких колонок: `dplyr::across()`

Допустим, вы хотите посчитать среднюю массу и рост, группируя по полу супергероев. Можно посчитать это внутри одного `summarise()`, используя запятую:

```

heroes %>%
  group_by(Gender) %>%
  summarise(height = mean(Height, na.rm = TRUE),
            weight = mean(Weight, na.rm = TRUE))

```

```

## `summarise()` ungrouping output (override with `^.groups` argument)

## # A tibble: 3 x 3
##   Gender height weight
##   <chr>    <dbl>  <dbl>
## 1 Female    175.   78.8
## 2 Male      192.   126.
## 3 <NA>     177.   129.

```

Если таких колонок будет много, то это уже станет сильно неудобным, нам придется много копировать код, а это чревато ошибками и очень скучно.

Поэтому в `dplyr` есть функция для операций над несколькими колонками сразу:

`dplyr::across()`¹⁹. Эта функция работает похожим образом на функции семейства `apply()` и использует `tidyselect` для выбора колонок.

Таким образом, конструкции с функцией `across()` можно разбить на три части:

1. Выбор колонок с помощью `tidyselect`. Здесь работают все те приемы, которые мы изучили при выборе колонок (5.10.2).
2. Собственно применение функции `across()`. Первый аргумент `.col` — колонки, выбранные на первом этапе с помощью `tidyselect`, по умолчанию это `everything()`, т.е. все колонки. Второй аргумент `.fns` — это функция или целый список из функций, которые будут применены к выбранным колонкам. Если функции требуют дополнительных аргументов, то они могут быть перечислены внутри `across()`.
3. Использование `summarise()` или другой функции `dplyr`. В этом случае в качестве аргумента для функции используется результат работы функции `across()`.

Вот такой вот бутерброд выходит. Давайте посмотрим, как это работает на практике и посчитаем среднее значение по колонкам `Height` и `Weight`.

```
heroes %>%
  group_by(Gender) %>%
  summarise(across(c(Height,Weight), mean))

## `summarise()` ungrouping output (override with `.`groups` argument)

## # A tibble: 3 x 3
##   Gender Height Weight
##   <chr>    <dbl>   <dbl>
## 1 Female     NA     NA
## 2 Male       NA     NA
## 3 <NA>      NA     NA
```

Здесь мы столкнулись с уже известной нам проблемой: функция `mean()` при столкновении хотя бы с одним `NA` будет возвращать `NA`, если мы не изменим параметр `na.rm = TRUE`. Как и в случае с функциями семейства `apply()` (`@ref{apply_f}`), дополнительные параметры для функции можно перечислить через запятую после самой функции:

```
heroes %>%
  group_by(Gender) %>%
  summarise(across(c(Height, Weight), mean, na.rm = TRUE))
```

¹⁹Функция `across()` появилась в пакете `dplyr` относительно недавно, до этого для работы с множественными колонками в `tidyverse` использовались многочисленные функции `*_at()`, `*_if()`, `*_all()`, например, `summarise_at()`, `summarise_if()`, `summarize_all()`. Эти функции до сих пор присутствуют в `dplyr`, но считаются устаревшими. Другая альтернатива - использование пакета `purrr` (?) или семейства функций `apply()` (`@ref{apply_f}`).

```
## `summarise()` ungrouping output (override with `groups` argument)

## # A tibble: 3 x 3
##   Gender Height Weight
##   <chr>    <dbl>   <dbl>
## 1 Female    175.   78.8
## 2 Male      192.   126.
## 3 <NA>     177.   129.
```

До этого мы просто использовали выбор колонок по их названию. Но именно внутри `across()` использование `tidyselect` раскрывается как удивительно элегантный и мощный инструмент. Например, можно посчитать среднее для всех numeric колонок:

```
heroes %>%
  drop_na(Height, Weight) %>%
  group_by(Gender) %>%
  summarise(across(where(is.numeric), mean, na.rm = TRUE))
```

```
## `summarise()` ungrouping output (override with `groups` argument)

## # A tibble: 3 x 4
##   Gender   X1 Height Weight
##   <chr>    <dbl>   <dbl>   <dbl>
## 1 Female    394.   174.   78.3
## 2 Male      369.   193.   126.
## 3 <NA>     375.   182.   129.
```

Или длину строк для строковых колонок. Для этого нам понадобится вспомнить, как создавать анонимные функции (`@ref(anon_f)`).

```
heroes %>%
  group_by(Gender) %>%
  summarise(across(where(is.character),
                  function(x) mean(nchar(x), na.rm = TRUE)))
```

```
## `summarise()` ungrouping output (override with `groups` argument)

## # A tibble: 3 x 8
##   Gender name `Eye color` `Race` `Hair color` Publisher `Skin color` Alignment
##   <chr>    <dbl>        <dbl>       <dbl>        <dbl>       <dbl>        <dbl>
## 1 Female    9.04        4.68       6.42        5.05       11.5       4.57       3.88
## 2 Male      9.05        4.53       6.75        5.48       11.4       5.02       3.78
## 3 <NA>     9.48        5.16      10.1        6.44       11.9        4          3.96
```

Или же даже посчитать и то, и другое внутри одного `summarise()`!

```
heroes %>%
  group_by(Gender) %>%
  summarise(across(where(is.numeric), mean, na.rm = TRUE),
            across(where(is.character),
                   function(x) mean(nchar(x), na.rm = TRUE)))
```

`summarise()` ungrouping output (override with `groups` argument)

A tibble: 3 x 11

	Gender	X1	Height	Weight	name	Eye color	Race	Hair color	Publisher	
## 1	Female	395.	175.	78.8	9.04	4.68	6.42	5.05	11.5	<dbl>
## 2	Male	357.	192.	126.	9.05	4.53	6.75	5.48	11.4	<dbl>
## 3	<NA>	329	177.	129.	9.48	5.16	10.1	6.44	11.9	<dbl>

... with 2 more variables: `Skin color` <dbl>, Alignment <dbl>

Внутри одного `across()` можно применить не одну функцию к каждой из выбранных колонок, а сразу несколько функций для каждой из колонок. Для этого нам нужно использовать список функций (желательно - проименованный).

```
heroes %>%
  group_by(Gender) %>%
  summarise(across(c(Height, Weight),
                  list(minimum = min,
                       average = mean,
                       maximum = max),
                  na.rm = TRUE))
```

`summarise()` ungrouping output (override with `groups` argument)

A tibble: 3 x 7

	Gender	Height_minimum	Height_average	Height_maximum	Weight_minimum	
## 1	Female	62.5	175.	366	41	<dbl>
## 2	Male	15.2	192.	975	2	<dbl>
## 3	<NA>	108	177.	198	39	<dbl>

... with 2 more variables: Weight_average <dbl>, Weight_maximum <dbl>

Бот нам и понадобился список функций (@ref(functions_objects))!

```
heroes %>%
  group_by(Gender) %>%
  summarise(across(c(Height, Weight),
                  list(min = function(x) min(x, na.rm = TRUE),
                       mean = function(x) mean(x, na.rm = TRUE),
```

```

        max = function(x) max(x, na.rm = TRUE),
        na_n = function(x, ...) sum(is.na(x)))
    )
}

## `summarise()` ungrouping output (override with `groups` argument)

## # A tibble: 3 x 9
##   Gender Height_min Height_mean Height_max Height_na_n Weight_min Weight_mean
##   <chr>     <dbl>      <dbl>      <dbl>      <int>      <dbl>      <dbl>
## 1 Female     62.5      175.      366       56       41      78.8
## 2 Male       15.2      192.      975      147        2      126.
## 3 <NA>        108      177.      198       14       39      129.
## # ... with 2 more variables: Weight_max <dbl>, Weight_na_n <int>

```

Хотя основное применение функции `across()` — это массовое подытоживание с помощью `summarise()`, `across()` можно использовать и с другими функциями `dplyr`. Например, можно делать массовые операции с колонками с помощью `mutate()`:

```

heroes %>%
  mutate(across(where(is.character), as.factor))

## # A tibble: 734 x 11
##   X1 name  Gender `Eye color` Race  `Hair color` Height Publisher
##   <dbl> <fct> <fct>   <fct> <fct>   <dbl> <fct>
## 1 0 A-Bo~ Male  yellow  Human No Hair    203 Marvel C~
## 2 1 Abe ~ Male  blue   Icth~ No Hair    191 Dark Hor~
## 3 2 Abin~ Male  blue   Unga~ No Hair    185 DC Comics
## 4 3 Abom~ Male  green  Huma~ No Hair    203 Marvel C~
## 5 4 Abra~ Male  blue   Cosm~ Black     NA Marvel C~
## 6 5 Abso~ Male  blue   Human No Hair   193 Marvel C~
## 7 6 Adam~ Male  blue   <NA> Blond     NA NBC - He~
## 8 7 Adam~ Male  blue   Human Blond    185 DC Comics
## 9 8 Agen~ Female blue   <NA> Blond    173 Marvel C~
## 10 9 Agen~ Male  brown  Human Brown   178 Marvel C~
## # ... with 724 more rows, and 3 more variables: `Skin color` <fct>,
## #   Alignment <fct>, Weight <dbl>

```

Менее очевидный способ применения `across()` — использование `across()` внутри `count()` вместе с функцией `n_distinct()`, которая считает количество уникальных значений в векторе. Это позволяет посмотреть таблицу частот для группирующих переменных:

```

heroes %>%
  select(where(function(x) n_distinct(x) <= 6))

```

```

## # A tibble: 734 x 2
##   Gender Alignment
##   <chr>  <chr>
## 1 Male   good
## 2 Male   good
## 3 Male   good
## 4 Male   bad
## 5 Male   bad
## 6 Male   bad
## 7 Male   good
## 8 Male   good
## 9 Female good
## 10 Male  good
## # ... with 724 more rows

heroes %>%
  count(across(where(function(x) n_distinct(x) <= 6)))

## # A tibble: 11 x 3
##   Gender Alignment     n
##   <chr>  <chr>    <int>
## 1 Female bad        35
## 2 Female good       161
## 3 Female neutral    4
## 4 Male   bad        165
## 5 Male   good       316
## 6 Male   neutral    18
## 7 Male   <NA>        6
## 8 <NA>   bad         7
## 9 <NA>   good        19
## 10 <NA>  neutral      2
## 11 <NA>  <NA>        1

```

5.15 Объединение нескольких датафреймов

5.15.1 Соединение структурно схожих датафреймов: bind_rows(), bind_cols()

Для начала создадим следующие тибблы и сохраним их как dc, marvel и other_publishers:

```

dc <- heroes %>%
  filter(Publisher == "DC Comics") %>%
  group_by(Gender)

```

```

  summarise(weight_mean = mean(Weight, na.rm = TRUE))

## `summarise()` ungrouping output (override with `groups` argument)

dc

## # A tibble: 3 x 2
##   Gender weight_mean
##   <chr>      <dbl>
## 1 Female     76.8
## 2 Male       113.
## 3 <NA>       NaN

marvel <- heroes %>%
  filter(Publisher == "Marvel Comics") %>%
  group_by(Gender) %>%
  summarise(weight_mean = mean(Weight, na.rm = TRUE))

## `summarise()` ungrouping output (override with `groups` argument)

marvel

## # A tibble: 3 x 2
##   Gender weight_mean
##   <chr>      <dbl>
## 1 Female     80.1
## 2 Male       134.
## 3 <NA>       129.

other_publishers <- heroes %>%
  filter(!(Publisher %in% c("DC Comics", "Marvel Comics"))) %>%
  group_by(Gender) %>%
  summarise(weight_mean = mean(Weight, na.rm = TRUE))

## `summarise()` ungrouping output (override with `groups` argument)

other_publishers

## # A tibble: 3 x 2
##   Gender weight_mean
##   <chr>      <dbl>
## 1 Female     70.8

```

```
## 2 Male      111.
## 3 <NA>      NaN
```

Несколько тибллов можно объединить вертикально с помощью функции `bind_rows()`. Для корректного объединения тибллы должны иметь одинаковые названия колонок.

```
bind_rows(dc, marvel)
```

```
## # A tibble: 6 x 2
##   Gender weight_mean
##   <chr>     <dbl>
## 1 Female    76.8
## 2 Male      113.
## 3 <NA>      NaN
## 4 Female    80.1
## 5 Male      134.
## 6 <NA>      129.
```

Чтобы соединить тибллы горизонтально, воспользуйтесь функцией `bind_cols()`.

```
bind_cols(dc, marvel)
```

```
## New names:
## * Gender -> Gender...1
## * weight_mean -> weight_mean...2
## * Gender -> Gender...3
## * weight_mean -> weight_mean...4

## # A tibble: 3 x 4
##   Gender...1 weight_mean...2 Gender...3 weight_mean...4
##   <chr>          <dbl> <chr>          <dbl>
## 1 Female        76.8 Female        80.1
## 2 Male          113. Male          134.
## 3 <NA>          NaN  <NA>          129.
```

Функции `bind_rows()` и `bind_cols()` могут работать не только с двумя, но сразу с несколькими датафреймами.

```
bind_rows(dc, marvel, other_publishers)
```

```
## # A tibble: 9 x 2
##   Gender weight_mean
##   <chr>     <dbl>
## 1 Female    76.8
## 2 Male      113.
## 3 <NA>      NaN
```

```
## 4 Female      80.1
## 5 Male        134.
## 6 <NA>        129.
## 7 Female      70.8
## 8 Male        111.
## 9 <NA>        NaN
```

На входе в функции `bind_rows()` и `bind_cold()` можно подавать как сами датафреймы или тибллы через запятую, так и список из датафреймов/тибллов.

```
heroes_list_of_df <- list(DC = dc,
                           Marvel = marvel,
                           Other = other_publishers)
bind_rows(heroes_list_of_df)
```

```
## # A tibble: 9 x 2
##   Gender weight_mean
##   <chr>     <dbl>
## 1 Female     76.8
## 2 Male       113.
## 3 <NA>        NaN
## 4 Female     80.1
## 5 Male       134.
## 6 <NA>        129.
## 7 Female     70.8
## 8 Male       111.
## 9 <NA>        NaN
```

Чтобы не потерять, из какого датафрейма какие данные, можно указать любое строковое значение (название будущей колонки) для необязательного аргумента `.id =`.

```
bind_rows(heroes_list_of_df, .id = "Publisher")
```

```
## # A tibble: 9 x 3
##   Publisher Gender weight_mean
##   <chr>     <chr>     <dbl>
## 1 DC        Female     76.8
## 2 DC        Male      113.
## 3 DC        <NA>       NaN
## 4 Marvel    Female     80.1
## 5 Marvel    Male      134.
## 6 Marvel    <NA>       129.
## 7 Other     Female     70.8
## 8 Other     Male      111.
## 9 Other     <NA>       NaN
```

`bind_rows()` обычно используется, когда ваши данные находятся в разных файлах с одинаковой структурой. Тогда вы можете прочитать все таблицы в папке, сохранить их в качестве списка из датафреймов и объединить в один датафрейм с помощью `bind_rows()`.

5.15.2 Реляционные данные: `*_join()`

В реальности иногда возникает ситуация, когда нужно соединить две таблички, у которых есть общий столбец (или несколько столбцов), но все остальные столбцы различаются. Табличек может быть и больше, это может быть целая сеть таблиц, некоторые из которых содержат основные данные, а некоторые - дополнительные, которые необходимо на определенном этапе “включить” в анализ. Например, таблица с расшифровкой аббревиатур или сокращений вроде коротких названий стран или таблица телефонных кодов разных стран. Совокупность нескольких связанных друг с другом таблиц называют реляционными данными.

В случае с реляционными данными простых `bind_rows()` и `bind_cols()` становится недостаточно.

Эти две таблички нужно объединить (*join*). Эта задача обычно возникает не очень часто, обычно это происходит один-два раза в одном проекте, когда нужно дополнить имеющиеся данные дополнительной информацией извне или объединить два набора данных, обрабатывавшихся в разных программах. Всякий раз, когда такая задача возникает, это доставляет много боли. `dplyr` предлагает интуитивно понятный инструмент для объединения реляционных данных - семейство функций `*_join()`.

Возьмем для примера два тibble `band_members` и `band_instruments`, встроенных в `dplyr` специально для демонстрации работы функций `*_join()`.

```
band_members
```

```
## # A tibble: 3 x 2
##   name   band
##   <chr> <chr>
## 1 Mick  Stones
## 2 John  Beatles
## 3 Paul  Beatles
```

```
band_instruments
```

```
## # A tibble: 3 x 2
##   name   plays
##   <chr> <chr>
## 1 John  guitar
## 2 Paul  bass
## 3 Keith guitar
```

У этих двух тибллов есть колонка с одинаковым названием, которая по своему смыслу соединяет данные обоих тибллов. Такая колонка называется **ключом**. Ключ должен однозначно идентифицировать наблюдения²⁰.

Давайте попробуем поссоединять `band_members` и `band_instruments` разными вариантами `*_join()` и посмотрим, что у нас получится. Все эти функции имеют на входе два обязательных аргумента (`x` = и `y` =) в которые мы должны подставить два датафрейма/тиблла которые мы хотим объединить. Главное различие между этими функциями заключается в том, что они будут делать, если уникальные значения в ключах `x` и `y` не соответствуют друг другу.

Mutating Joins

x1	x2	x3
A	1	T
B	2	F
C	3	NA

dplyr::left_join(a, b, by = "x1")
Join matching rows from b to a.

x1	x3	x2
A	T	1
B	F	2
D	T	NA

dplyr::right_join(a, b, by = "x1")
Join matching rows from a to b.

x1	x2	x3
A	1	T
B	2	F

dplyr::inner_join(a, b, by = "x1")
Join data. Retain only rows in both sets.

x1	x2	x3
A	1	T
B	2	F

dplyr::full_join(a, b, by = "x1")
Join data. Retain all values, all rows.

x1	x2	x3
A	1	T
B	2	F
C	3	NA
D	NA	T

- `left_join()`:

```
band_members %>%
  left_join(band_instruments)
```

```
## Joining, by = "name"
## # A tibble: 3 x 3
##   name  band   plays
```

²⁰Если ключи будут неуникальными, то функции `*_join()` не будут выдавать ошибку. Вместо этого они добавят в итоговую таблицу все возможные пересечения повторяющихся ключей. С этим нужно быть очень осторожным, поэтому рекомендуется, во-первых, проверять уникальность ключей на входе и, во-вторых, проверять тибл на выходе. Ну или использовать эту особенность работы функции `*_join()` себе во благо.

```
## <chr> <chr> <chr>
## 1 Mick Stones <NA>
## 2 John Beatles guitar
## 3 Paul Beatles bass
```

`left_join()` - это самая простая для понимания и самая используемая функция из семейства `*_join()`. Она как бы “дополняет” информацию из первого тиббла вторым тибблом. В этом случае сохраняются все уникальные наблюдения в `x`, но отбрасываются лишние наблюдения в тиббле `y`. Тем значениям, которым не нашлось соответствия в `y`, в колонках, взятых их `y`, ставятся значения `NA`.

Вы можете сами задать колонки-ключи параметром `by =`, по умолчанию это все колонки с одинаковыми названиями в двух тибблах.

```
band_members %>%
  left_join(band_instruments, by = "name")
```

```
## # A tibble: 3 x 3
##   name band   plays
##   <chr> <chr> <chr>
## 1 Mick Stones <NA>
## 2 John Beatles guitar
## 3 Paul Beatles bass
```

Часто случается, что колонки-ключи называются по-разному в двух тибблах. Их необязательно переименовывать, можно поставить соответствие вручную используя преименованный вектор:

```
band_members %>%
  left_join(band_instruments2, by = c("name" = "artist"))
```

```
## # A tibble: 3 x 3
##   name band   plays
##   <chr> <chr> <chr>
## 1 Mick Stones <NA>
## 2 John Beatles guitar
## 3 Paul Beatles bass
```

· `right_join()`:

```
band_members %>%
  right_join(band_instruments)
```

```
## Joining, by = "name"
## # A tibble: 3 x 3
```

```
##   name  band   plays
##   <chr> <chr>   <chr>
## 1 John Beatles guitar
## 2 Paul Beatles bass
## 3 Keith <NA>     guitar
```

`right_join()` отбрасывает строчки в `x`, которых не было в `y`, но сохраняет соответствующие строчки `y` — `left_join()` наоборот.

- `full_join()`:

```
band_members %>%
  full_join(band_instruments)
```

```
## Joining, by = "name"
## # A tibble: 4 x 3
##   name  band   plays
##   <chr> <chr>   <chr>
## 1 Mick Stones <NA>
## 2 John Beatles guitar
## 3 Paul Beatles bass
## 4 Keith <NA>     guitar
```

Функция `full_join()` сохраняет все строчки из `x` и `y`. Пожалуй, наиболее используемая функция после `left_join()` — благодаря `full_join()` вы точно ничего не потеряете при объединении.

- `inner_join()`:

```
band_members %>%
  inner_join(band_instruments)
```

```
## Joining, by = "name"
## # A tibble: 2 x 3
##   name  band   plays
##   <chr> <chr>   <chr>
## 1 John Beatles guitar
## 2 Paul Beatles bass
```

Функция `full_join()` сохраняет только строчки, которые присутствуют и в `x`, и в `y`.

- `semi_join()`:

```
band_members %>%
  semi_join(band_instruments)
```

```
## Joining, by = "name"
## # A tibble: 2 x 2
##   name   band
##   <chr> <chr>
## 1 John  Beatles
## 2 Paul  Beatles
· anti_join():

band_members %>%
  anti_join(band_instruments)
```

```
## Joining, by = "name"
## # A tibble: 1 x 2
##   name   band
##   <chr> <chr>
## 1 Mick  Stones
```

Функции `semi_join()` и `anti_join()` не присоединяют второй датафрейм/тиббл (`y`) к первому. Вместо этого они используются как некоторый словарь-фильтр для отделения только тех значений в `x`, которые есть в `y` (`semi_join()`) или, наоборот, которых нет в `y` (`anti_join()`).

5.16 Tidydata:tidyr::pivot_longer(),tidyr::pivot_wider()

Принцип tidy data предполагает, что каждая строчка содержит в себе одно измерение, а каждая колонка - одну характеристику. Тем не менее, это не говорит однозначно о том, как именно хранить повторные измерения. Их можно хранить как одну колонку для каждого измерения (широкий формат) и как две колонки: одна колонка - для идентификатора измерения, другая колонка - для записи самого измерения.

Это лучше понять на примере. Например, вес до и после прохождения курса. Как это лучше записать - как два числовых столбца (один испытуемый - одна строка) или же создать отдельную “группирующую” колонку, в которой будет написано время измерения, а в другой - измеренные значения (одно измерение - одна строка)?

- Широкий формат:

Студент	До курса по R	После курса по R
Маша	70	63
Рома	80	74
Антонина	86	71

- Длинный”формат:

Студент	Время измерения	Масса (кг)
Маша	До курса по R	70
Рома	До курса по R	80
Антонина	До курса по R	86
Маша	После курса по R	63
Рома	После курса по R	74
Антонина	После курса по R	71

На самом деле, оба варианта приемлемы, оба варианта возможны в реальных данных, а разные функции и статистические пакеты могут требовать от вас как длинный, так и широкий форматы.

Таким образом, нам нужно научиться переводить из широкого формата в длинный и наоборот.

- `tidy::pivot_longer()`: из широкого в длинный формат
- `tidy::pivot_wider()`: из длинного в широкий формат

```
new_diet <- tibble(
  student = c(" ", " ", " "),
  before_r_course = c(70, 80, 86),
  after_r_course = c(63, 74, 71)
)
new_diet

## # A tibble: 3 x 3
##   student  before_r_course after_r_course
##   <chr>        <dbl>         <dbl>
## 1          70            63
## 2          80            74
## 3          86            71
```

Тибл new_diet - это пример широкого формата данных.

Превратим тибл new_diet длинный:

```
new_diet %>%
  pivot_longer(cols = before_r_course:after_r_course,
               names_to = "measurement_time",
               values_to = "weight_kg")

## # A tibble: 6 x 3
##   student measurement_time weight_kg
##   <chr>     <chr>           <dbl>
## 1          before_r_course    70
## 2          after_r_course     63
## 3          before_r_course    80
## 4          after_r_course     74
## 5          before_r_course    86
## 6          after_r_course     71
```

```
## 2      after_r_course      63
## 3      before_r_course     80
## 4      after_r_course      74
## 5      before_r_course     86
## 6      after_r_course      71
```

А теперь обратно в короткий:

```
new_diet %>%
  pivot_longer(cols = before_r_course:after_r_course,
               names_to = "measurement_time",
               values_to = "weight_kg") %>%
  pivot_wider(names_from = "measurement_time",
              values_from = "weight_kg")

## # A tibble: 3 x 3
##   student before_r_course after_r_course
##   <chr>        <dbl>         <dbl>
## 1 1            70           63
## 2 2            80           74
## 3 3            86           71
```


Глава 6

Визуализация данных

```
library("tidyverse")
```

6.1 Зачем визуализировать данные?

6.1.1 КвартетAnscombe

В работе Anscombe, F. J. (1973). "Graphs in Statistical Analysis" представлен следующий датасет:

```
quartet <- read_csv("https://raw.githubusercontent.com/agricolamz/2020-2021-ds4dh/master/data/anscombes_quartet.csv")
quartet
```

```
## # A tibble: 44 x 4
##       id dataset     x     y
##   <dbl>   <dbl> <dbl> <dbl>
## 1     1      1    10  8.04
## 2     1      1    10  9.14
## 3     1      1    10  7.46
## 4     1      1     8  6.58
## 5     2      2     8  6.95
## 6     2      2     8  8.14
## 7     2      2     8  6.77
## 8     2      2     8  5.76
## 9     3      1    13  7.58
## 10    3      1    13  8.74
## # ... with 34 more rows
```

```

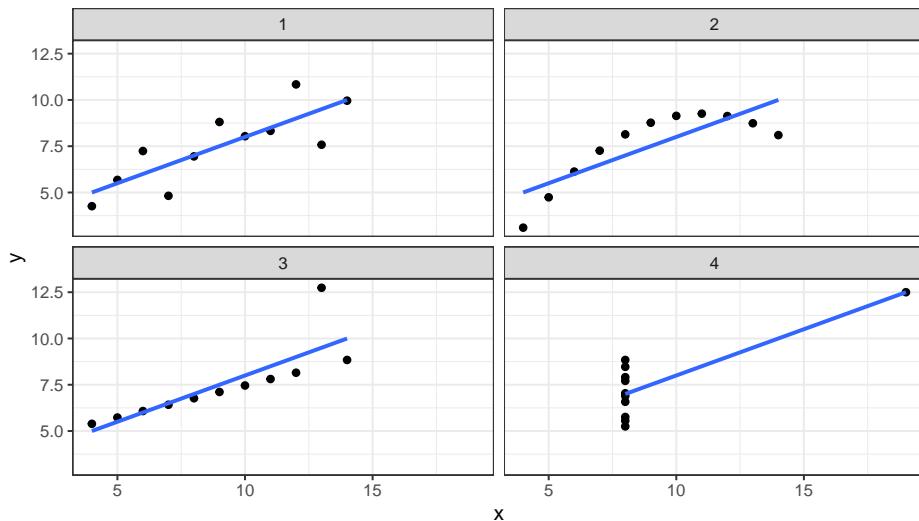
quartet %>%
  group_by(dataset) %>%
  summarise(mean_X = mean(x),
            mean_Y = mean(y),
            sd_X = sd(x),
            sd_Y = sd(y),
            cor = cor(x, y),
            n_obs = n()) %>%
  select(-dataset) %>%
  round(2)

```

```

## # A tibble: 4 x 6
##   mean_X mean_Y  sd_X  sd_Y    cor n_obs
##     <dbl>   <dbl> <dbl> <dbl>  <dbl>   <dbl>
## 1      9     7.5  3.32  2.03  0.82     11
## 2      9     7.5  3.32  2.03  0.82     11
## 3      9     7.5  3.32  2.03  0.82     11
## 4      9     7.5  3.32  2.03  0.82     11

```



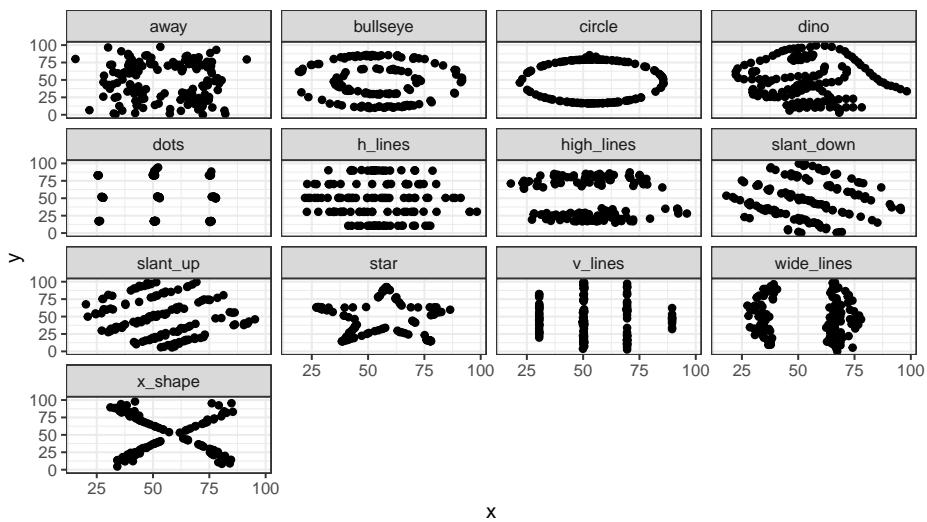
6.1.2 Датазаурус

В работе Matejka and Fitzmaurice (2017) “Same Stats, Different Graphs”¹ были представлены следующие датасеты:

¹<https://www.autodeskresearch.com/sites/default/files/SameStats-DifferentGraphs.pdf>

```
datasaurus <- read_csv("https://raw.githubusercontent.com/agricolamz/2020-2021-ds4dh/master/data/datasaurus")
```

```
## # A tibble: 1,846 x 3
##   dataset      x     y
##   <chr>    <dbl> <dbl>
## 1 dino      55.4  97.2
## 2 dino      51.5  96.0
## 3 dino      46.2  94.5
## 4 dino      42.8  91.4
## 5 dino      40.8  88.3
## 6 dino      38.7  84.9
## 7 dino      35.6  79.9
## 8 dino      33.1  77.6
## 9 dino      29.0  74.5
## 10 dino     26.2  71.4
## # ... with 1,836 more rows
```



```
datasaurus %>%
  group_by(dataset) %>%
  summarise(mean_X = mean(x),
            mean_Y = mean(y),
            sd_X = sd(x),
            sd_Y = sd(y),
            cor = cor(x, y),
            n_obs = n()) %>%
  select(-dataset) %>%
```

```
round(1)
```

```
## `summarise()` ungrouping output (override with `groups` argument)

## # A tibble: 13 x 6
##   mean_X  mean_Y  sd_X  sd_Y  cor n_obs
##   <dbl>   <dbl>   <dbl>   <dbl> <dbl> <dbl>
## 1 54.3    47.8   16.8   26.9 -0.1  142
## 2 54.3    47.8   16.8   26.9 -0.1  142
## 3 54.3    47.8   16.8   26.9 -0.1  142
## 4 54.3    47.8   16.8   26.9 -0.1  142
## 5 54.3    47.8   16.8   26.9 -0.1  142
## 6 54.3    47.8   16.8   26.9 -0.1  142
## 7 54.3    47.8   16.8   26.9 -0.1  142
## 8 54.3    47.8   16.8   26.9 -0.1  142
## 9 54.3    47.8   16.8   26.9 -0.1  142
## 10 54.3   47.8   16.8   26.9 -0.1  142
## 11 54.3   47.8   16.8   26.9 -0.1  142
## 12 54.3   47.8   16.8   26.9 -0.1  142
## 13 54.3   47.8   16.8   26.9 -0.1  142
```

6.2 Основы ggplot2

Пакет `ggplot2` – современный стандарт для создания графиков в R. Для этого пакета пишут массу расширений². В сжатом виде информация про `ggplot2` содержиться здесь³.

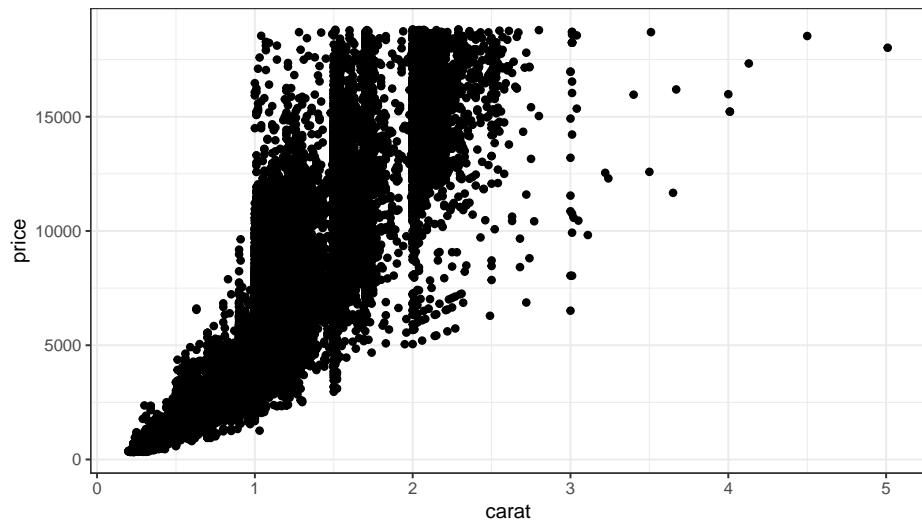
6.2.1 Диаграмма рассеяния (Scaterplot)

- `ggplot2`

```
ggplot(data = diamonds, aes(carat, price)) +
  geom_point()
```

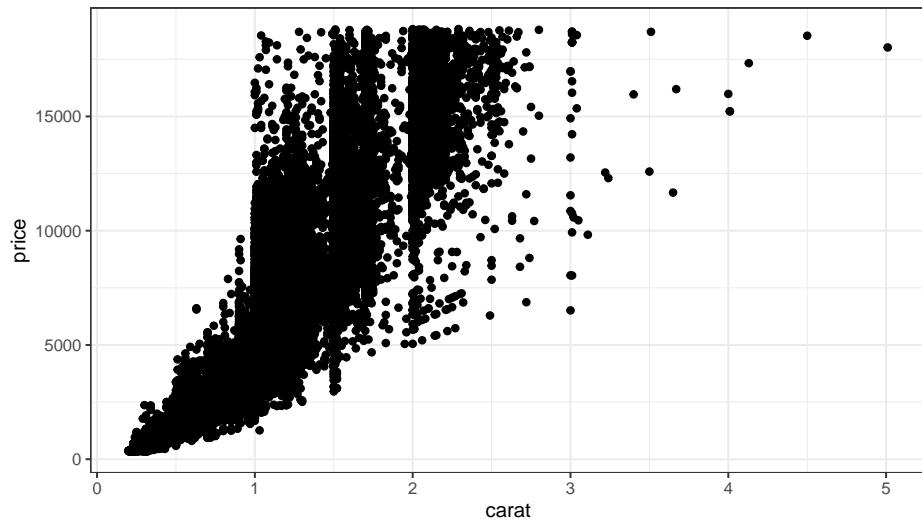
²<http://www.ggplot2-exts.org/gallery/>

³<https://github.com/rstudio/cheatsheets/raw/master/data-visualization-2.1.pdf>



```
• dplyr, ggplot2
```

```
diamonds %>%
  ggplot(aes(carat, price)) +
  geom_point()
```

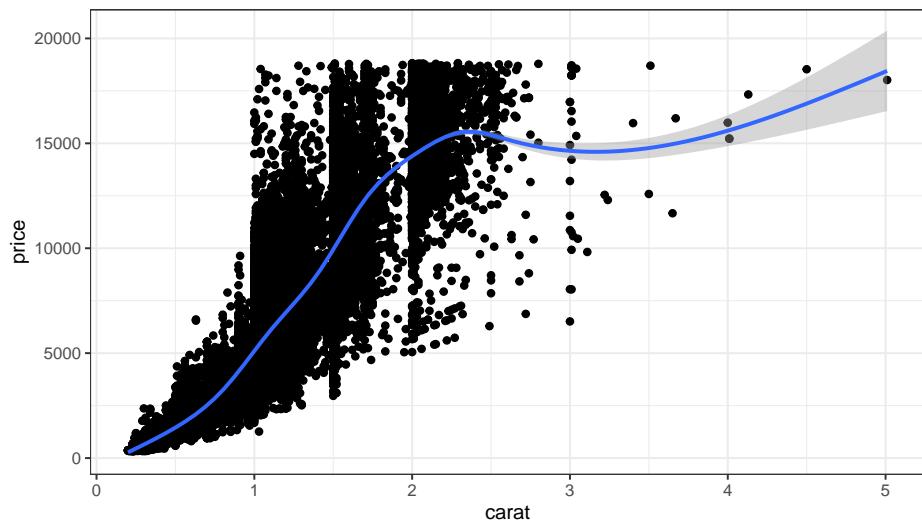


6.2.2 Слои

```
diamonds %>%
  ggplot(aes(carat, price)) +
```

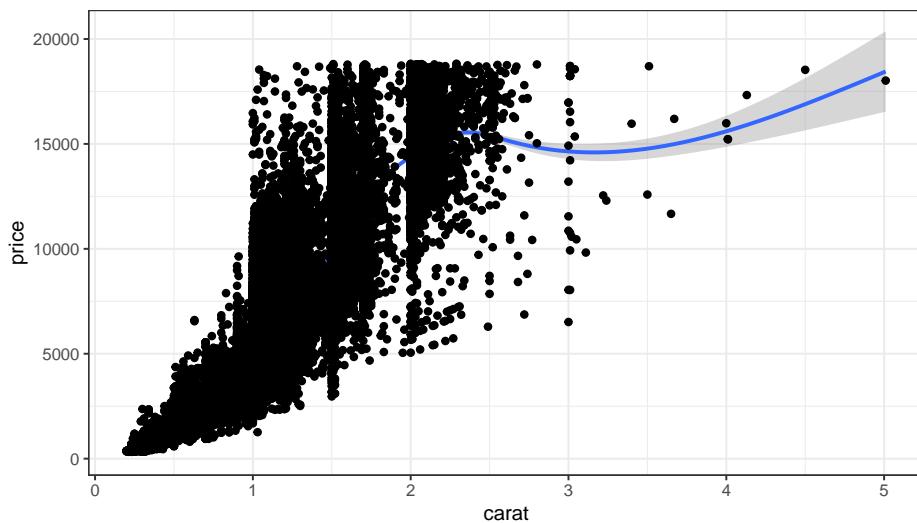
```
geom_point()+
  geom_smooth()
```

```
## `geom_smooth()` using method = 'gam' and formula 'y ~ s(x, bs = "cs")'
```



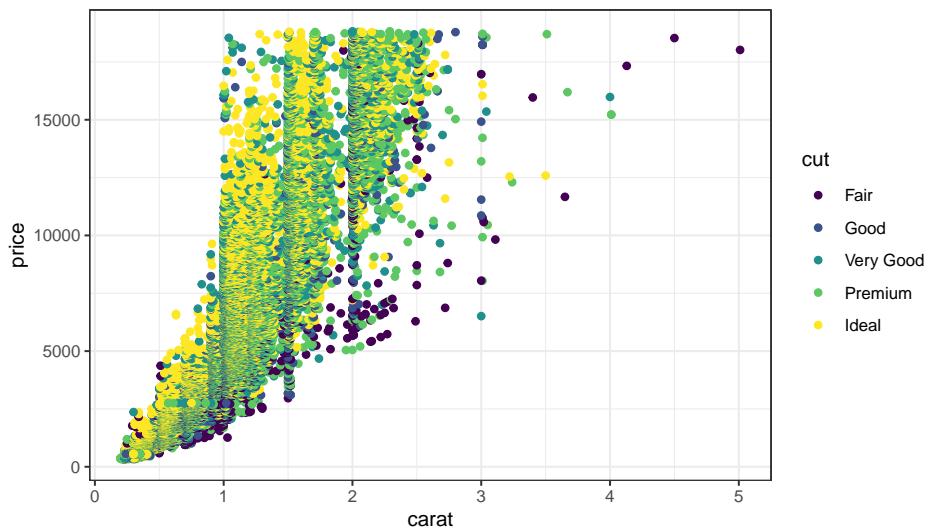
```
diamonds %>%
  ggplot(aes(carat, price))+
  geom_smooth()+
  geom_point()
```

```
## `geom_smooth()` using method = 'gam' and formula 'y ~ s(x, bs = "cs")'
```

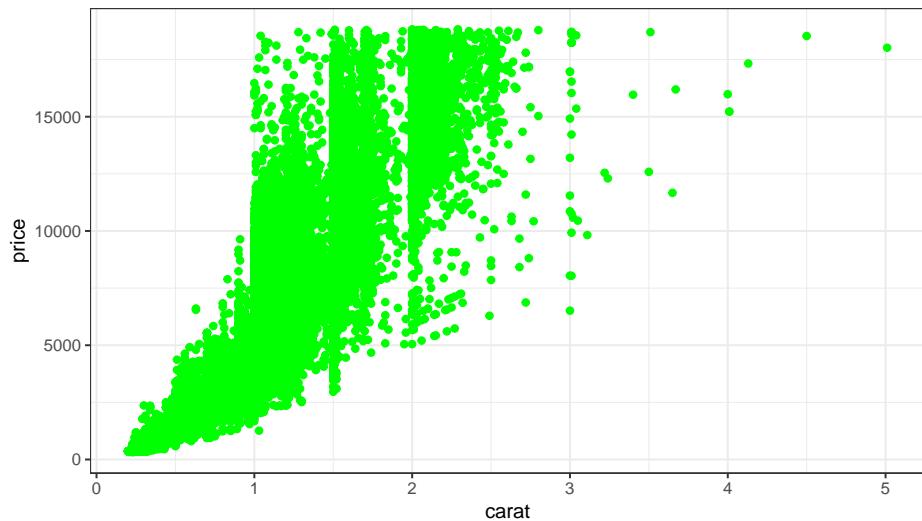


6.2.3 aes()

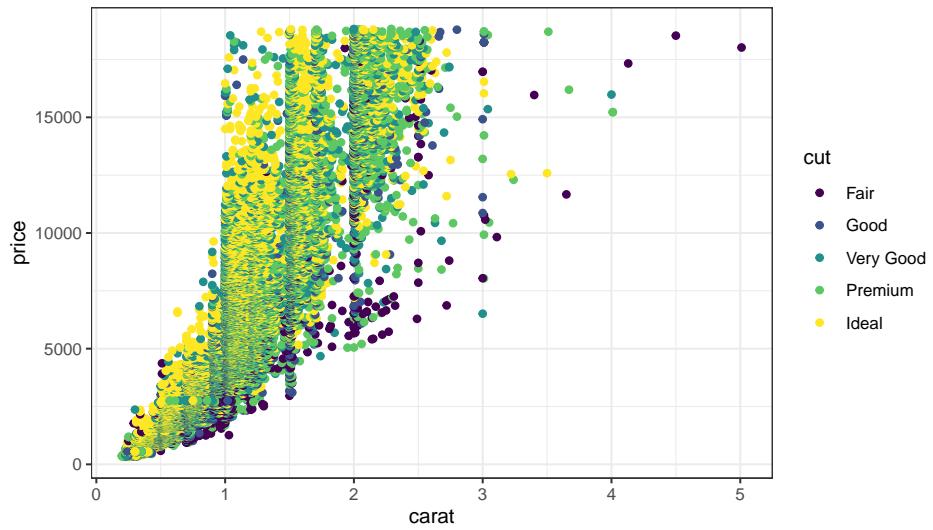
```
diamonds %>%
  ggplot(aes(carat, price, color = cut)) +
  geom_point()
```



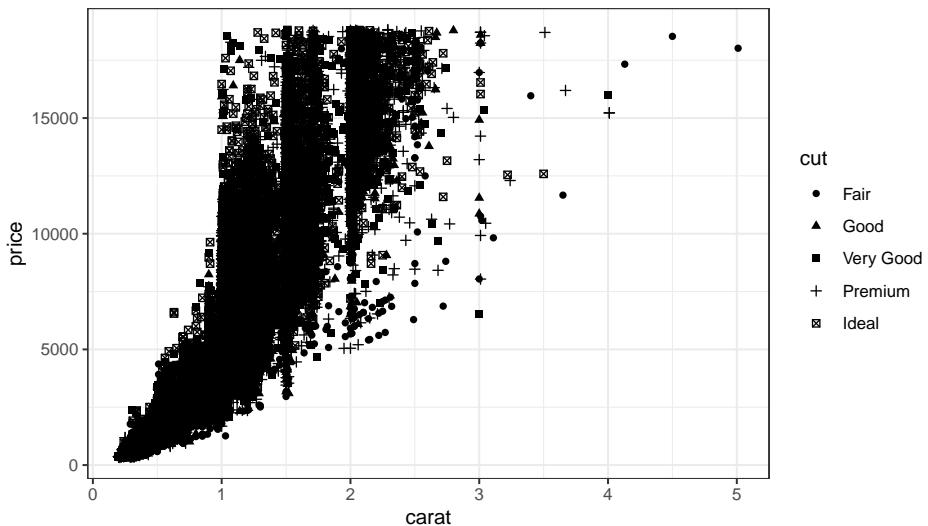
```
diamonds %>%
  ggplot(aes(carat, price)) +
  geom_point(color = "green")
```



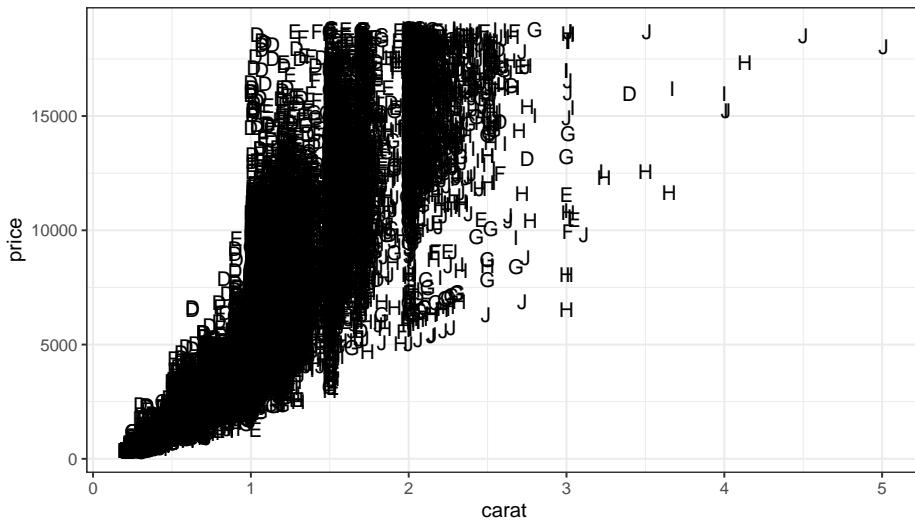
```
diamonds %>%
  ggplot(aes(carat, price)) +
  geom_point(aes(color = cut))
```



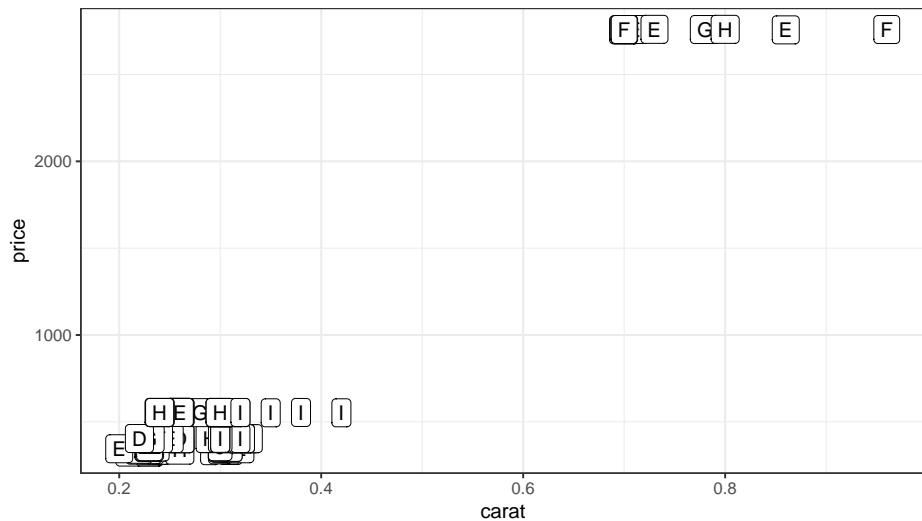
```
diamonds %>%
  ggplot(aes(carat, price, shape = cut)) +
  geom_point()
```



```
diamonds %>%
  ggplot(aes(carat, price, label = color)) +
  geom_text()
```

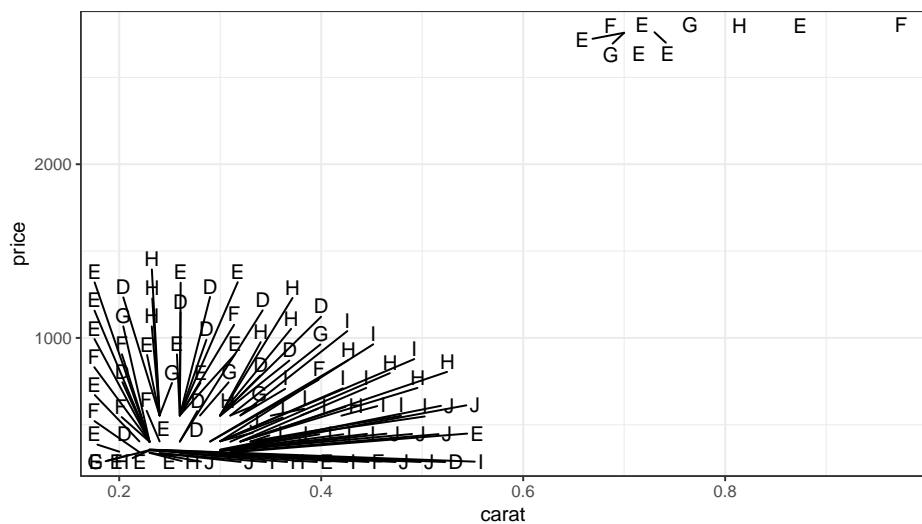


```
diamonds %>%
  slice(1:100) %>%
  ggplot(aes(carat, price, label = color)) +
  geom_label()
```



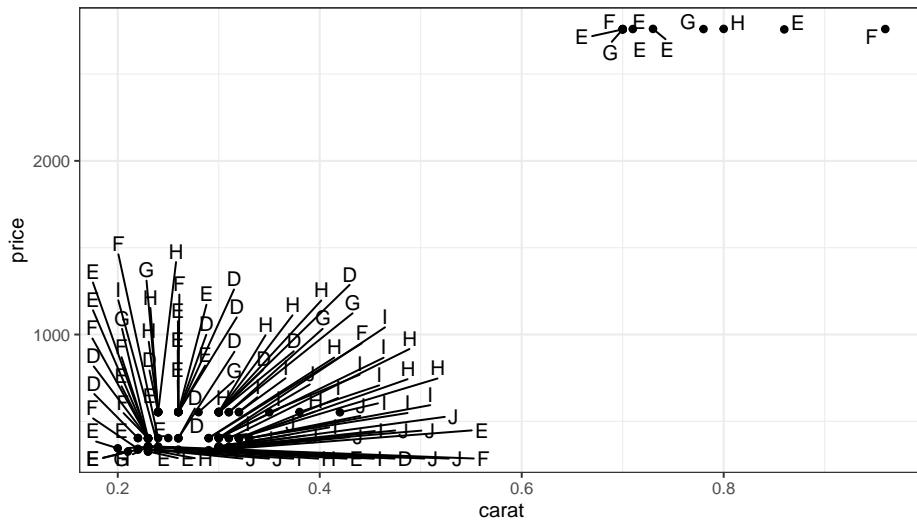
Иногда аннотации налекают друг на друга:

```
library(ggrepel)
diamonds %>%
  slice(1:100) %>%
  ggplot(aes(carat, price, label = color)) +
  geom_text_repel()
```

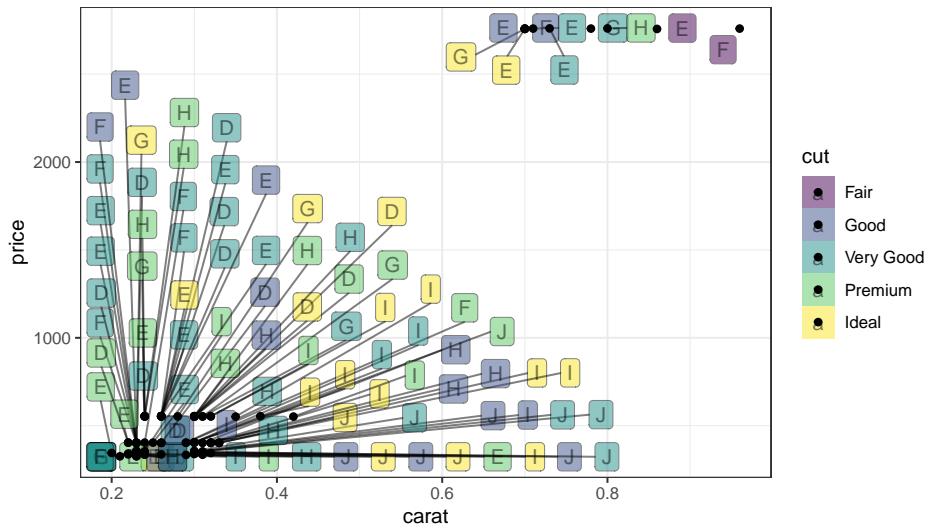


```
diamonds %>%  
  slice(1:100) %>%
```

```
ggplot(aes(carat, price, label = color))+
  geom_text_repel()+
  geom_point()
```

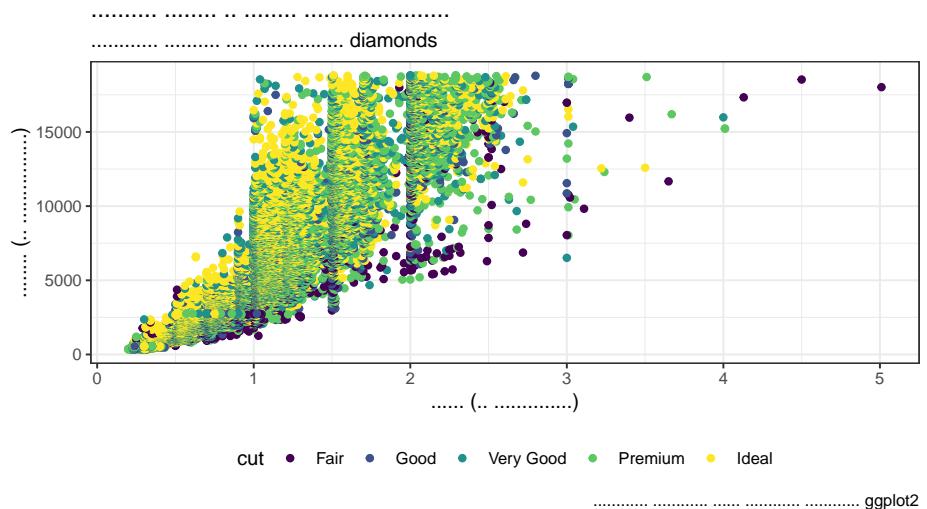


```
diamonds %>%
  slice(1:100) %>%
  ggplot(aes(carat, price, label = color, fill = cut)) # fill
  geom_label_repel(alpha = 0.5) # alpha
  geom_point()
```

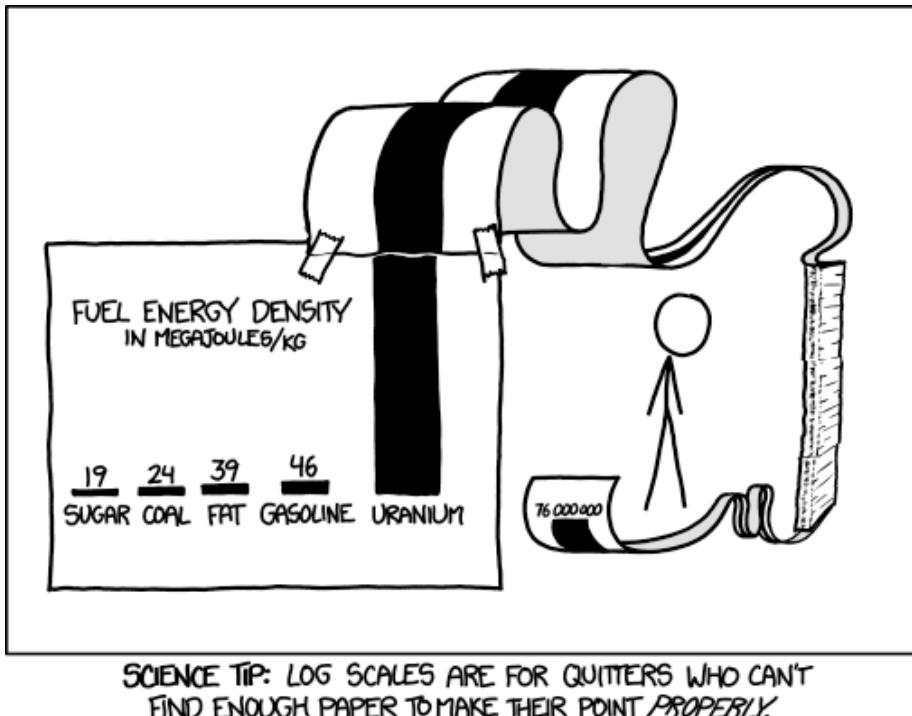


6.2.4 Оформление

```
diamonds %>%
  ggplot(aes(carat, price, color = cut)) +
  geom_point() +
  labs(x = " ( )",
       y = " ( )",
       title = "",
       subtitle = " diamonds",
       caption = " ggplot2") +
  theme(legend.position = "bottom") # theme()
```



6.2.5 Логарифмические шкалы

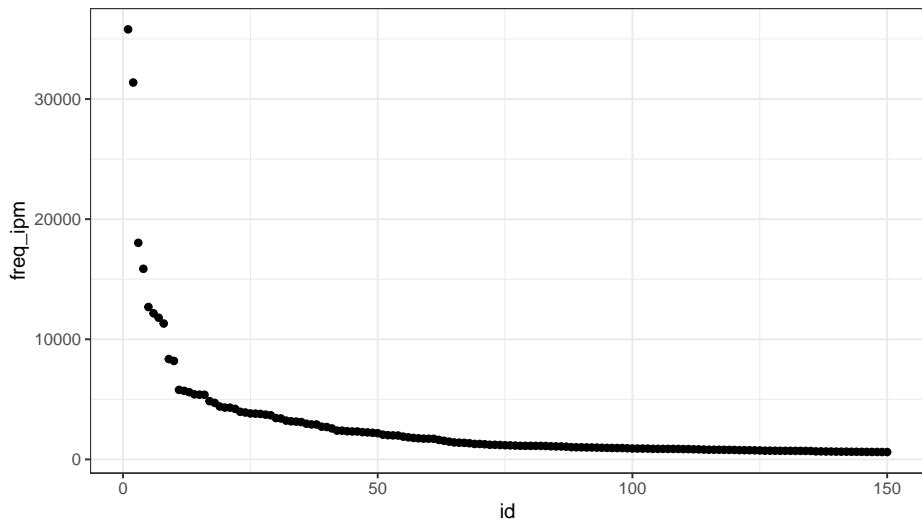


Рассмотрим словарь [Ляшевской, Шарова 2011]

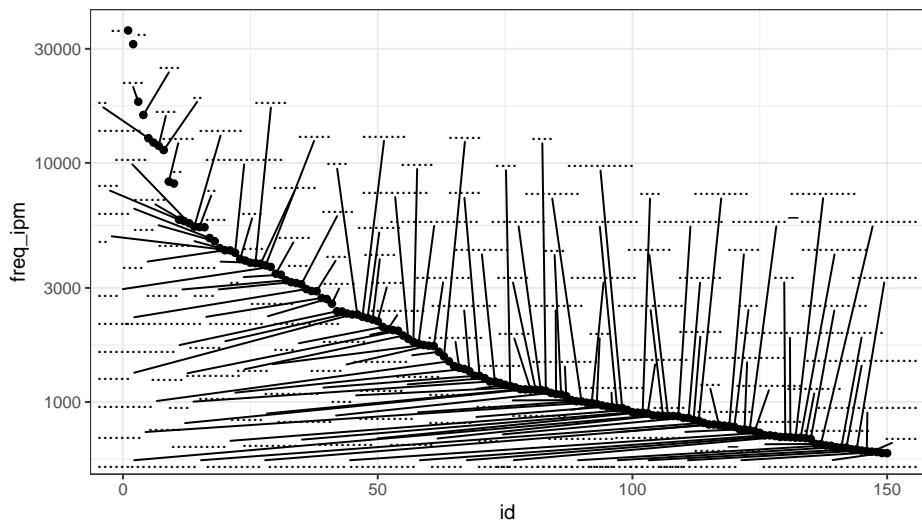
```
freqdict <- read_tsv("https://github.com/agricolamz/2020-2021-ds4dh/raw/master/data/freq_dict_2021-01-10.csv")
```

```
## 
## -- Column specification --
## cols(
##   lemma = col_character(),
##   pos = col_character(),
##   freq_ipm = col_double()
## )
```

```
freqdict %>%
  arrange(desc(freq_ipm)) %>%
  mutate(id = 1:n()) %>%
  slice(1:150) %>%
  ggplot(aes(id, freq_ipm)) +
  geom_point()
```



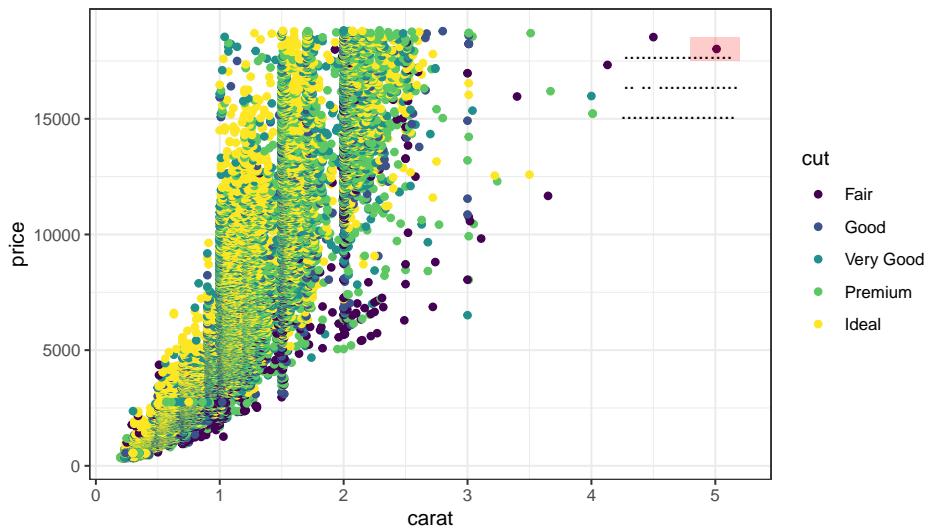
```
freqdict %>%
  arrange(desc(freq_ipm)) %>%
  mutate(id = 1:n()) %>%
  slice(1:150) %>%
  ggplot(aes(id, freq_ipm, label = lemma)) +
  geom_point() +
  geom_text_repel() +
  scale_y_log10()
```



6.2.6 `annotate()`

Функция `annotate` добавляет `geom` к графику.

```
diamonds %>%
  ggplot(aes(carat, price, color = cut)) +
  geom_point() +
  annotate(geom = "rect", xmin = 4.8, xmax = 5.2,
          ymin = 17500, ymax = 18500, fill = "red", alpha = 0.2) +
  annotate(geom = "text", x = 4.7, y = 16600,
          label = "... \n ...")
```



Скачайте вот этот датасет⁴ и постройте диаграмму рассеяния.

6.3 Столбчатые диаграммы (barplots)

Одна и та же информация может быть представлена в агрегированном и не агрегированном варианте:

```
misspelling <- read_csv("https://raw.githubusercontent.com/agricolamz/2020-2021-ds4dh/master/data/misspellings.csv")
```

```
## 
## -- Column specification --
## cols(
##   correct = col_character(),
##   spelling = col_character(),
```

```
##   count = col_double()
## )
```

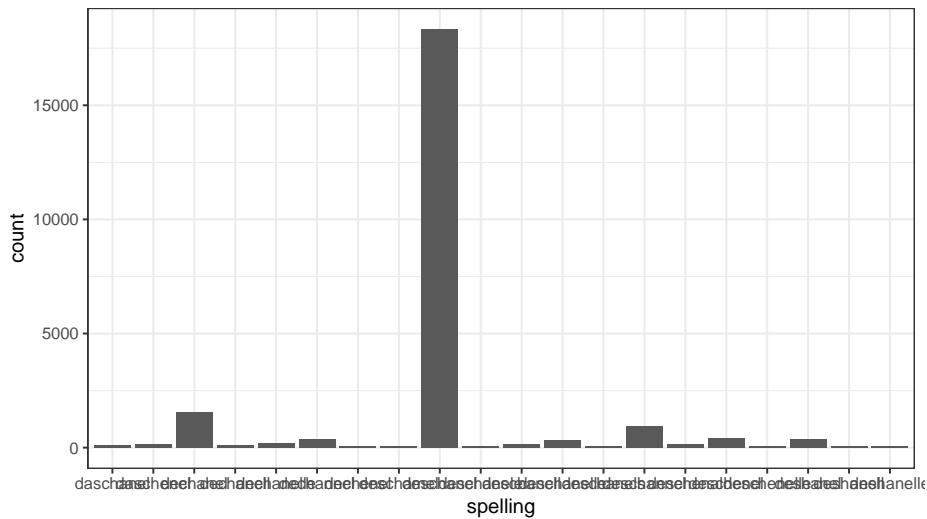
misspelling

```
## # A tibble: 15,477 x 3
##   correct spelling   count
##   <chr>    <chr>     <dbl>
## 1 deschanel deschanel 18338
## 2 deschanel dechanel  1550
## 3 deschanel deschannel 934
## 4 deschanel deschenel  404
## 5 deschanel deshanel  364
## 6 deschanel dechannel 359
## 7 deschanel deschanelle 316
## 8 deschanel dechanelle 192
## 9 deschanel deschanell 174
## 10 deschanel deschenal 165
## # ... with 15,467 more rows
```

- переменные `spelling` **аггрегированы**: для каждого значения представлено значение в столбце `count`, которое обозначает количество каждого из написаний
- переменные `correct` **неаггрегированы**: в этом столбце она повторяется, для того, чтобы сделать вывод, нужно отдельно посчитать количество вариантов

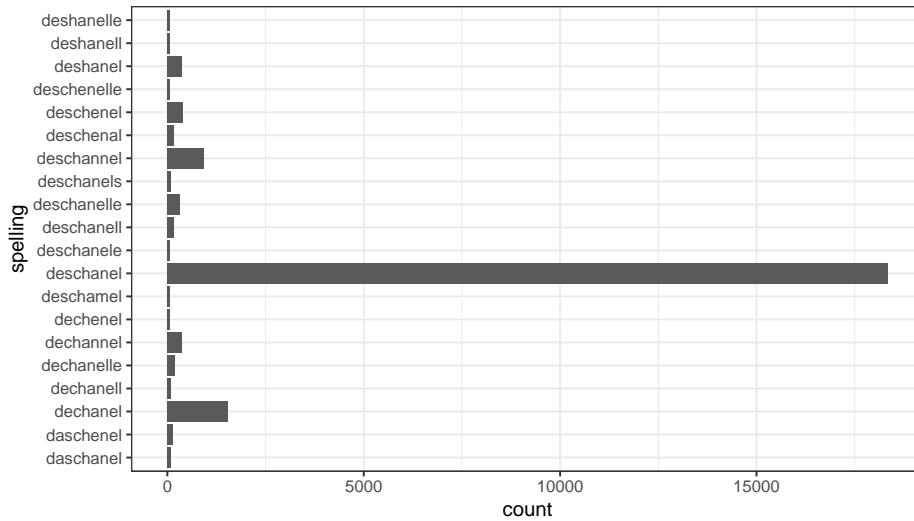
Для агрегированных данных используется `geom_col()`

```
misspelling %>%
  slice(1:20) %>%
  ggplot(aes(spelling, count)) +
  geom_col()
```



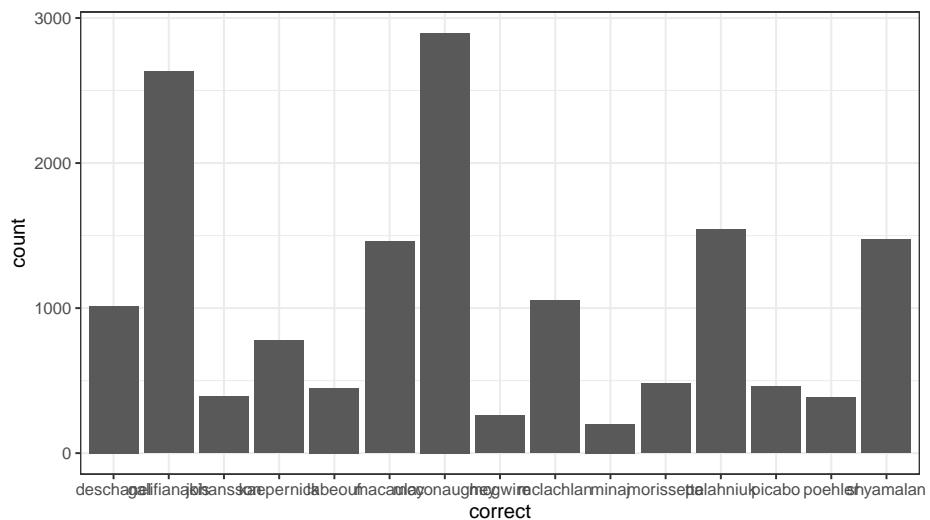
Перевернем оси:

```
misspelling %>%
  slice(1:20) %>%
  ggplot(aes(spelling, count)) +
  geom_col() +
  coord_flip()
```



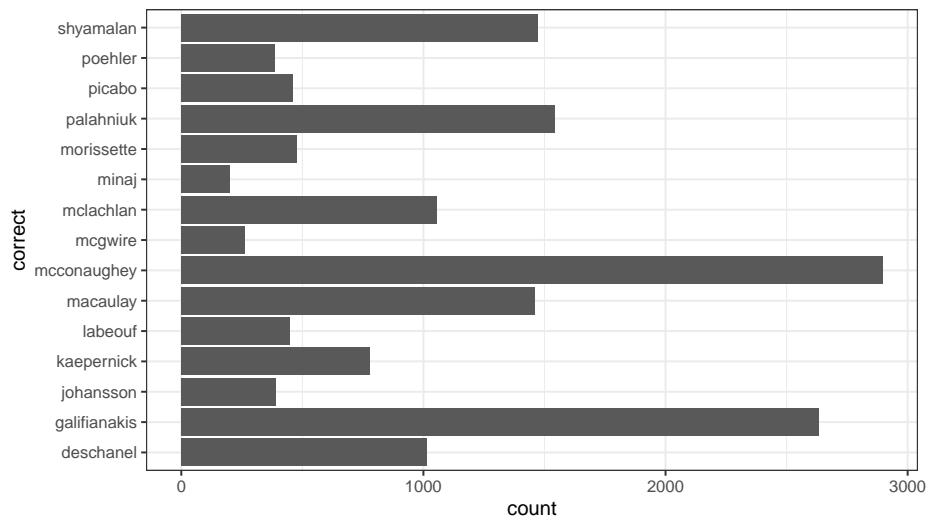
Для неаггрегированных данных используется `geom_bar()`

```
misspelling %>%  
  ggplot(aes(correct)) +  
  geom_bar()
```



Перевернем оси:

```
misspelling %>%  
  ggplot(aes(correct)) +  
  geom_bar() +  
  coord_flip()
```



Неаггрегированный вариант можно перевести в агрегированный:

```
diamonds %>%
  count(cut)
```

```
## # A tibble: 5 x 2
##   cut      n
##   <ord>    <int>
## 1 Fair     1610
## 2 Good     4906
## 3 Very Good 12082
## 4 Premium   13791
## 5 Ideal    21551
```

Агрегированный вариант можно перевести в неаггрегированный:

```
diamonds %>%
  count(cut) %>%
  uncount(n)
```

```
## # A tibble: 53,940 x 1
##   cut
##   <ord>
## 1 Fair
## 2 Fair
## 3 Fair
## 4 Fair
## 5 Fair
## 6 Fair
## 7 Fair
## 8 Fair
## 9 Fair
## 10 Fair
## # ... with 53,930 more rows
```

6.4 Факторы

Как можно заметить по предыдущему разделу, переменные на графике упорядочены по алфавиту. Чтобы это исправить нужно обсудить факторы:

```
my_factor <- factor(misspellings$correct)
head(my_factor)
```

```
## [1] deschanel deschanel deschanel deschanel deschanel deschanel
```

```
## 15 Levels: deschanel galifianakis johansson kaepernick labeouf ... shyamalan
```

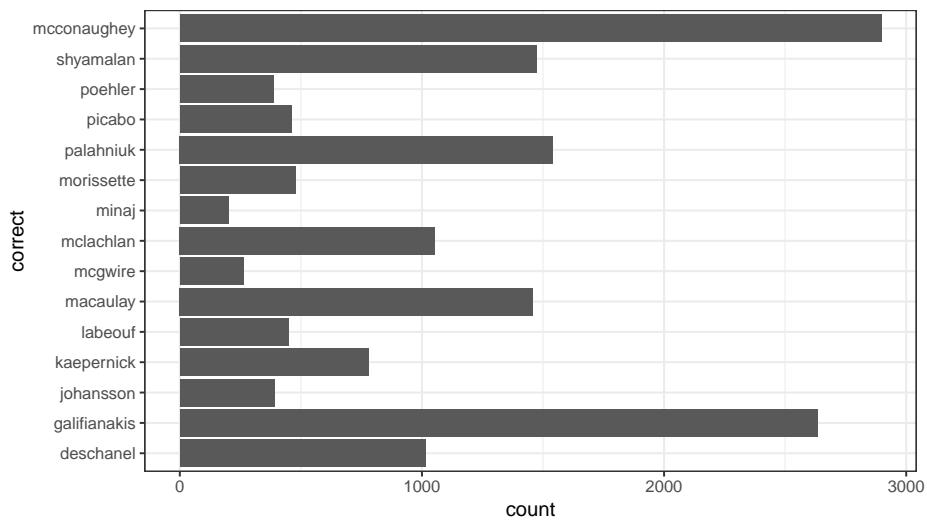
```
levels(my_factor)
```

```
## [1] "deschanel"     "galifianakis"   "johansson"      "kaepernick"    "labeouf"
## [6] "macaulay"      "mcconaughey"    "mcgwire"        "mclachlan"     "minaj"
## [11] "morissette"    "palahniuk"      "picabo"         "poehler"       "shyamalan"
```

```
levels(my_factor) <- rev(levels(my_factor))
head(my_factor)
```

```
## [1] shyamalan shyamalan shyamalan shyamalan shyamalan shyamalan
## 15 Levels: shyamalan poehler picabo palahniuk morissette minaj ... deschanel
```

```
misspelling %>%
  mutate(correct = factor(correct, levels = c("deschanel",
                                                "galifianakis",
                                                "johansson",
                                                "kaepernick",
                                                "labeouf",
                                                "macaulay",
                                                "mcgwire",
                                                "mclachlan",
                                                "minaj",
                                                "morissette",
                                                "palahniuk",
                                                "picabo",
                                                "poehler",
                                                "shyamalan",
                                                "mcconaughey")))) %>%
  ggplot(aes(correct)) +
  geom_bar() +
  coord_flip()
```



Для работы с факторами удобно использовать пакет `forcats` (входит в `tidyverse`, вот ссылка на cheatsheet⁵).

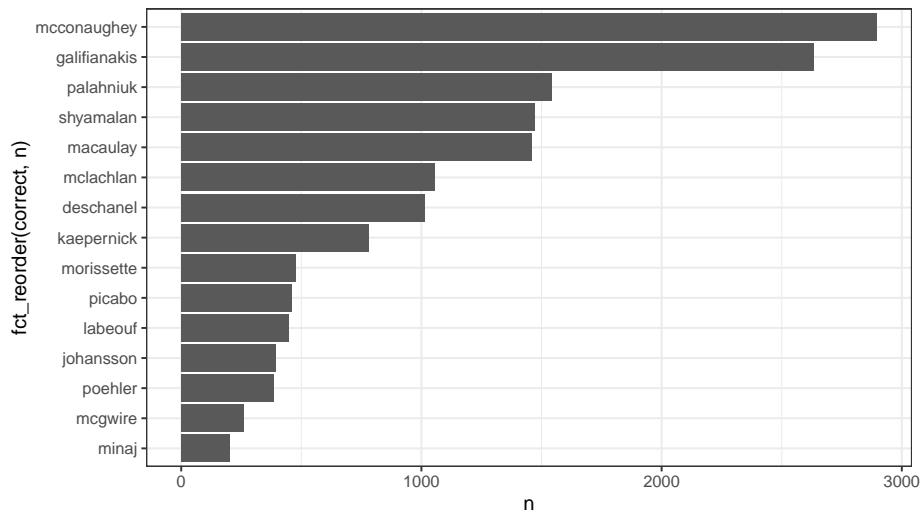
Иногда полезной бывает функция `fct_reorder()`:

```
misspelling %>%
  count(correct)
```

```
## # A tibble: 15 x 2
##   correct      n
##   <chr>     <int>
## 1 deschanel    1015
## 2 galifianakis  2633
## 3 johansson     392
## 4 kaepernick     779
## 5 labeouf       449
## 6 macaulay      1458
## 7 mcconaughey    2897
## 8 mcgwire        262
## 9 mclachlan     1054
## 10 minaj         200
## 11 morissette    478
## 12 palahniuk     1541
## 13 picabo        460
## 14 poehler        386
## 15 shyamalan     1473
```

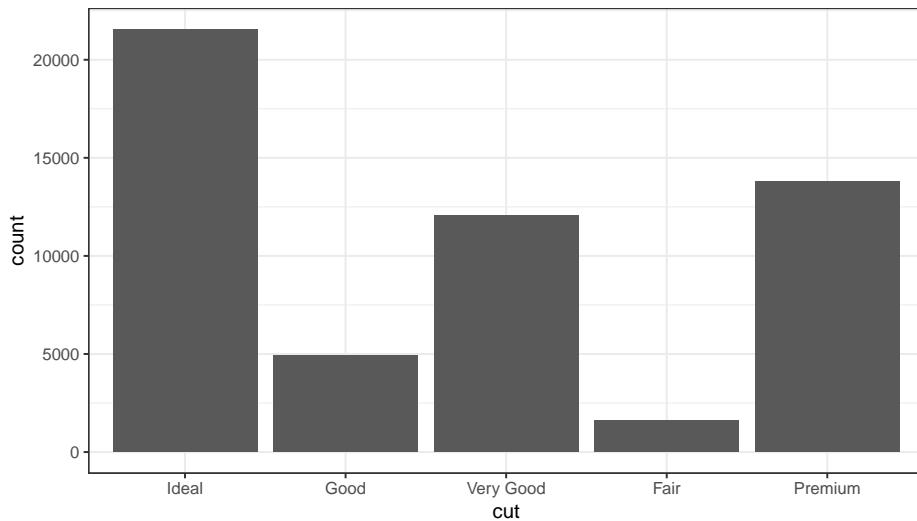
⁵<https://github.com/rstudio/cheatsheets/raw/master/factors.pdf>

```
misspellings %>%
  count(correct) %>%
  ggplot(aes(fct_reorder(correct, n), n)) +
  geom_col() +
  coord_flip()
```



Кроме того, в функцию `fct_reorder()` можно добавить функцию, которая будет считаться на векторе, по которому группируют:

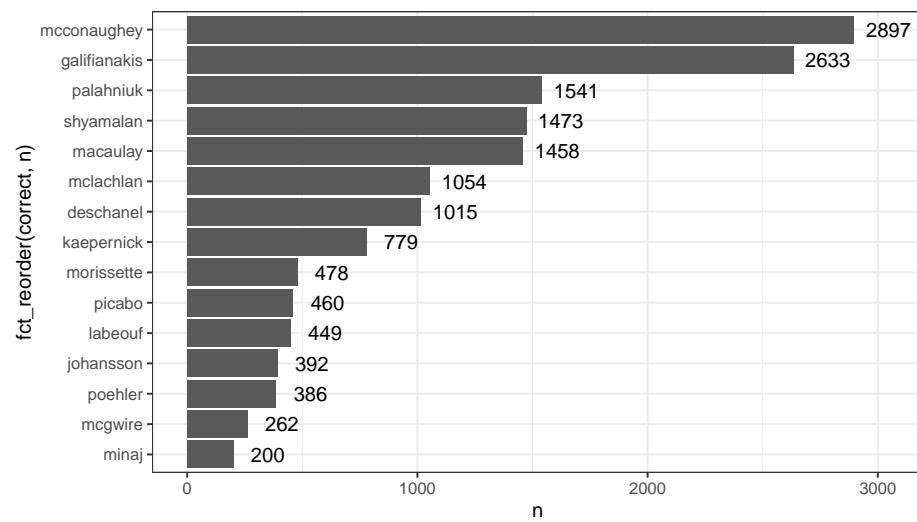
```
diamonds %>%
  mutate(cut = fct_reorder(cut, price, mean)) %>%
  ggplot(aes(cut)) +
  geom_bar()
```



В этом примере переменная `cut` упорядочена по средней `mean` цене `price`. Естественно, вместо `mean` можно использовать другие функции (`median`, `min`, `max` или даже собственные функции).

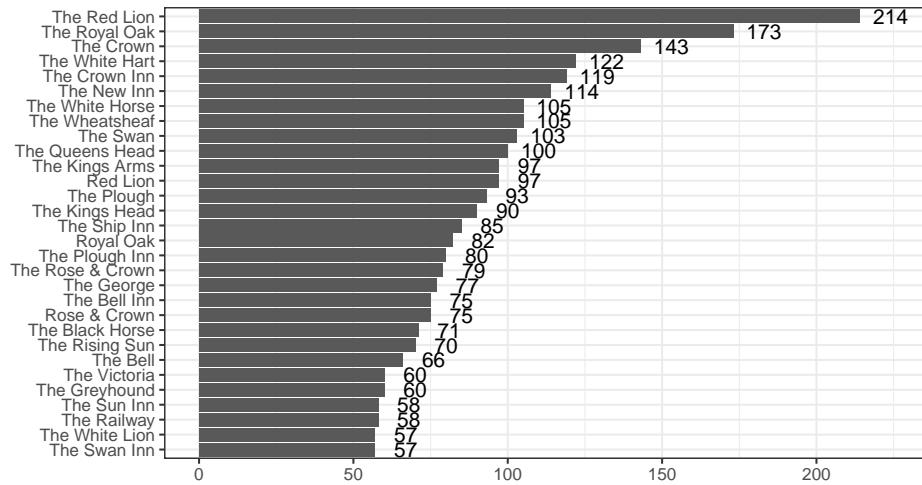
Можно совмещать разные `geom_...`:

```
misspelling %>%
  count(correct) %>%
  ggplot(aes(fct_reorder(correct, n), n, label = n)) +
  geom_col() +
  geom_text(nudge_y = 150) +
  coord_flip()
```





На Pudding вышла статья про английские пабы⁶. Здесь⁷ лежит немного обработанный датасет, которые они использовали. Визуализируйте 30 самых частотных названий пабов в Великобритании.



data from <https://pudding.cool/2019/10/pubs/>

☒ СПИСОК ПОДСКАЗОК ☒

☒ Как получить нужный датафрейм, где все посчитано?☒ Этому можно сделать функцией `count`.

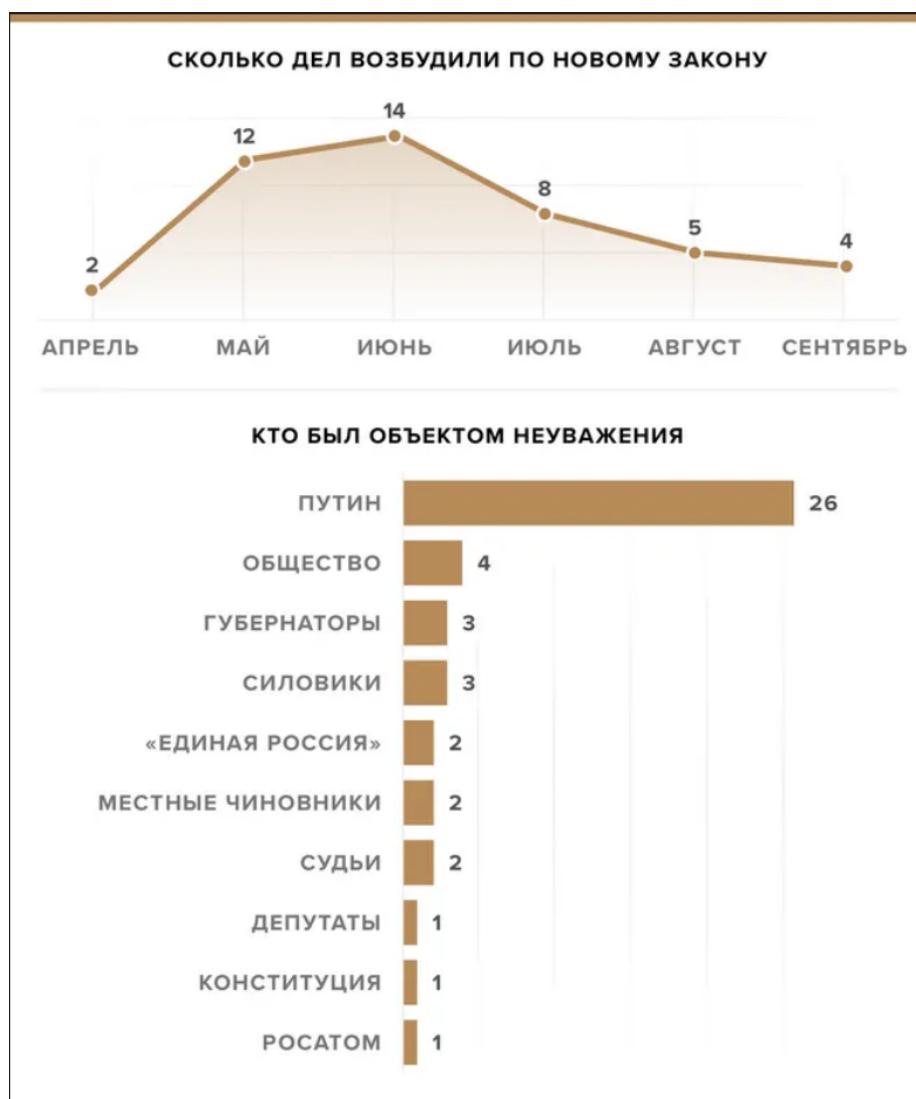
☒ Стоп, а почему у меня нарисовалось так много значений?☒ Может быть нужно было, как написано в задании, взять лишь 30 наблюдений? Полезная функция для этого `slice()`.

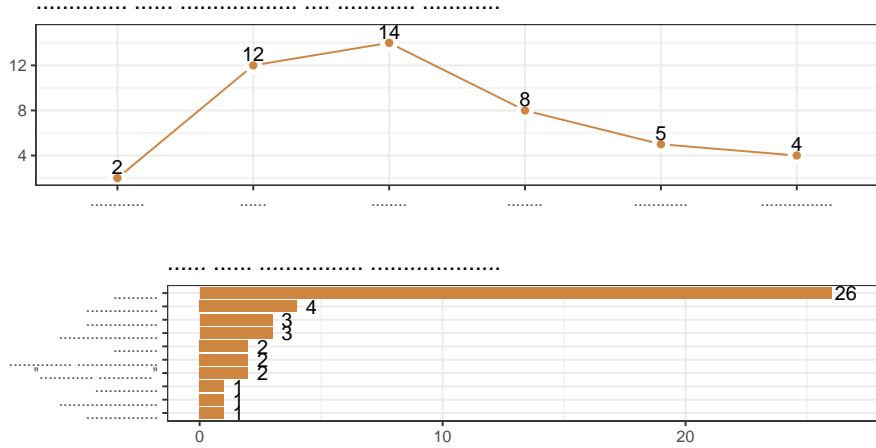
☒ Почему нарисовались лишь бары с частотностью 1?☒ По умолчанию `count` не сортирует вообще, так что в `slice()` попали бары с частотностью 1. Надо отсортировать от большего к меньшему, перед тем как делать `slice()`. Это можно сделать при помощи функции `arrange()` или использовать аргумент `sort = TRUE` в функции `count()`

☒ Кажется все?☒ А Вы убрали подписи осей x и y? А подпись добавили?



На новостном портале meduza.io недавно вышла новость о применении закона “о неуважении к власти в интернете”⁸. Постройте графики из этой новости. При построении графиков я использовал цвет “tan3”.





meduza.io

▢ список подсказок ▢

▢ А ссылка на датафрейм, где все посчитано? ▢ А ее нет. Вам надо самим создать датафрейм. Вспомните функцию `tibble()`

▢ Не понятно, а что это за `geom_` такой линия с точкой? ▢ Такого `geom_-a` нет. Нужно использовать три `geom_-a`: `geom_point()`, `geom_text()` и `geom_line()`.

▢ Почему все рисуется в алфавитном порядке? ▢ Здесь нужно использовать функцию `factor()`, чтобы задать эксплицитный порядок.

▢ Почему точки рисуются, а линия не хочет? Спойлер: самим тут не справиться. ▢ Действительно, здесь спрятана хитрость: `ggplot` не знает как ему соединить имеющиеся точки, поэтому чтобы все заработало нужно создать новую переменную в датафрейме (например, `type = 1`), а в функции `aes()` вставить аргумент `group = type`. Тогда `ggplot` объединит линией все, что имеет одно и то же значение в аргументе `group`.

▢ Ой, а как добавить белое окружение вокруг точек? ▢ Нужно пойти на военную хитрость: добавить еще один `geom_point()` белого цвета и большего размера, а потом уже наложить обычные точки. Тут и возникают проблемы с порядком: сначала нужно нарисовать линию, потом белые точки, а потом уже коричневые. А где должен быть `geom_text()`?

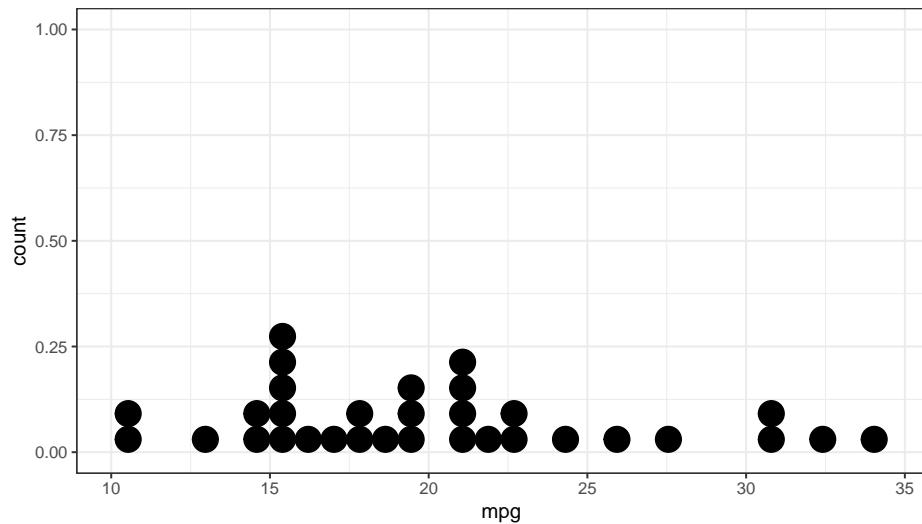
▢ Кажется все? ▢ А Вы убрали подписи осей x и y? А подпись добавили?

6.5 Дотплот

Иногда для случаев, когда мы исследуем числовую переменную подходит простой график, который отображает распределение наших наблюдений на одной соответствующей числовой шкале.

```
mtcars %>%
  ggplot(aes(mpg)) +
  geom_dotplot(method = "histodot")
```

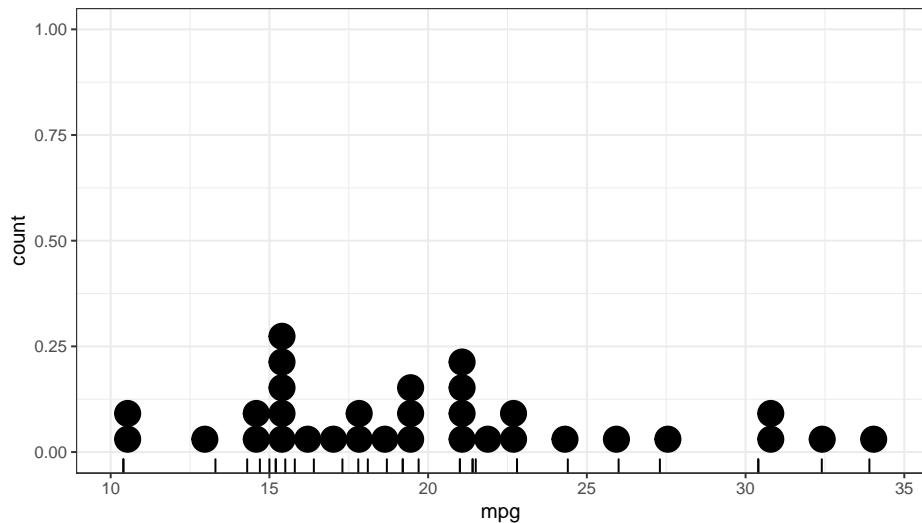
`stat_bindot()` using `bins = 30`. Pick better value with `binwidth`.



По оси x отложена наша переменная, каждая точка – одно наблюдение, а отложенное по оси y стоит игнорировать – оно появляется из-за ограничений пакета `ggplot2`. Возможно чуть понятнее будет, если добавить `geom_rug()`, который непосредственно отображает **каждое** наблюдение.

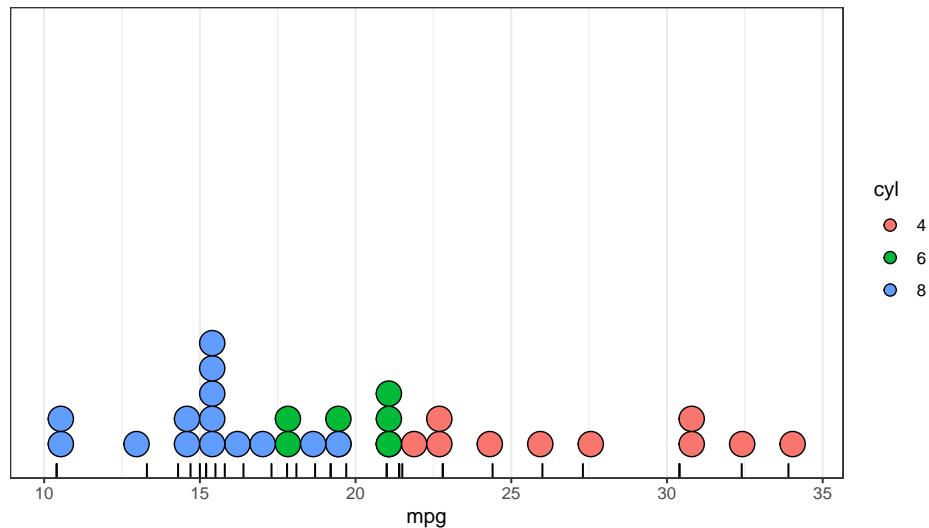
```
mtcars %>%
  ggplot(aes(mpg)) +
  geom_rug() +
  geom_dotplot(method = "histodot")
```

`stat_bindot()` using `bins = 30`. Pick better value with `binwidth`.



Больший смысл имеет раскрашенный вариант:

```
mtcars %>%
  mutate(cyl = factor(cyl)) %>%
  ggplot(aes(mpg, fill = cyl)) +
  geom_rug() +
  geom_dotplot(method = "histodot") +
  scale_y_continuous(NULL, breaks = NULL) # y
## `stat_bindot()` using `bins = 30`. Pick better value with `binwidth`.
```



Как видно, на графике, одна синяя точка попала под одну зеленую: значит они имеют

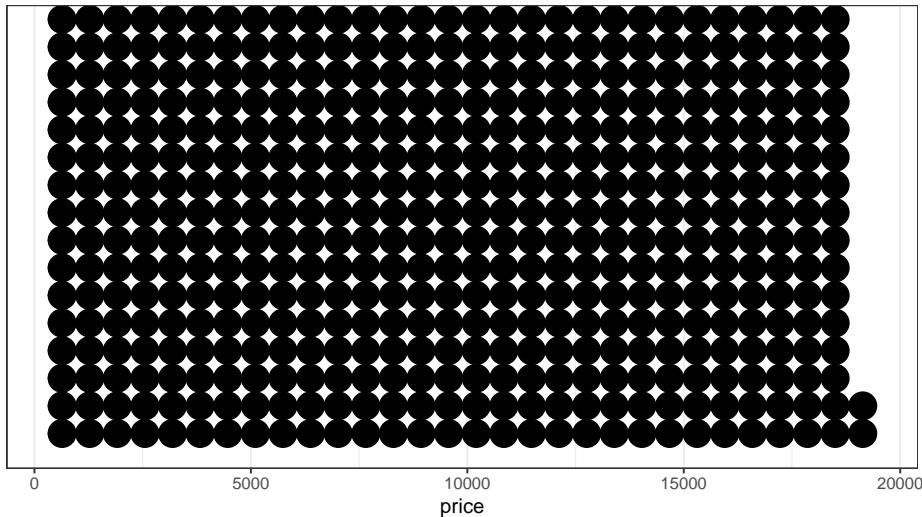
общее наблюдение.

6.6 Гистограммы

Если наблюдений слишком много, дотплот не имеет много смысла:

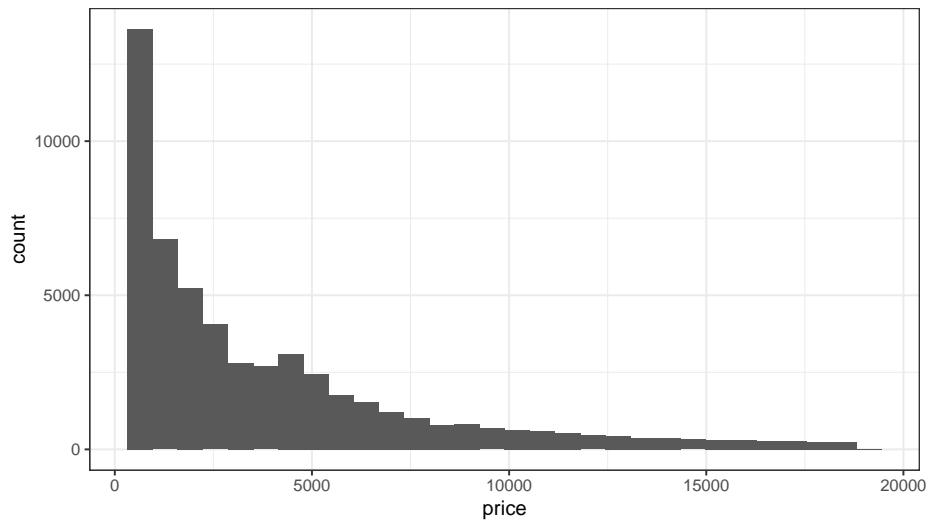
```
diamonds %>%
  ggplot(aes(price)) +
  geom_dotplot(method = "histodot") +
  scale_y_continuous(NULL, breaks = NULL) # y
```

`stat_bindot()` using `bins = 30`. Pick better value with `binwidth`.



```
diamonds %>%
  ggplot(aes(price)) +
  geom_histogram()
```

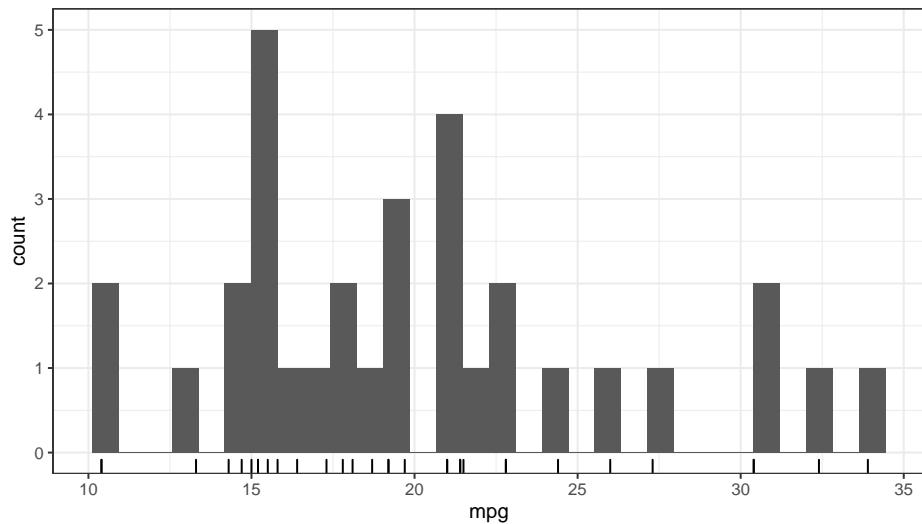
`stat_bin()` using `bins = 30`. Pick better value with `binwidth`.



Обсудим на предыдущем примере

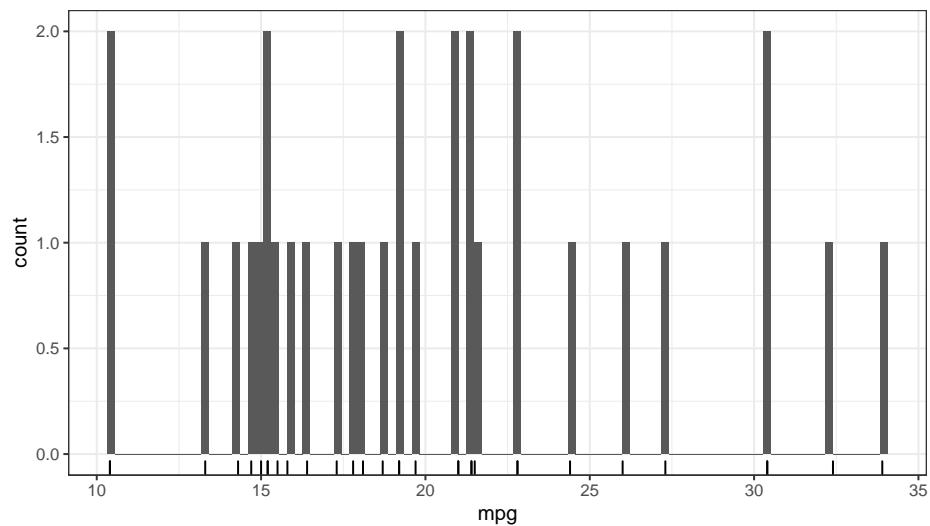
```
mtcars %>%
  ggplot(aes(mpg)) +
  geom_rug() +
  geom_histogram()
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

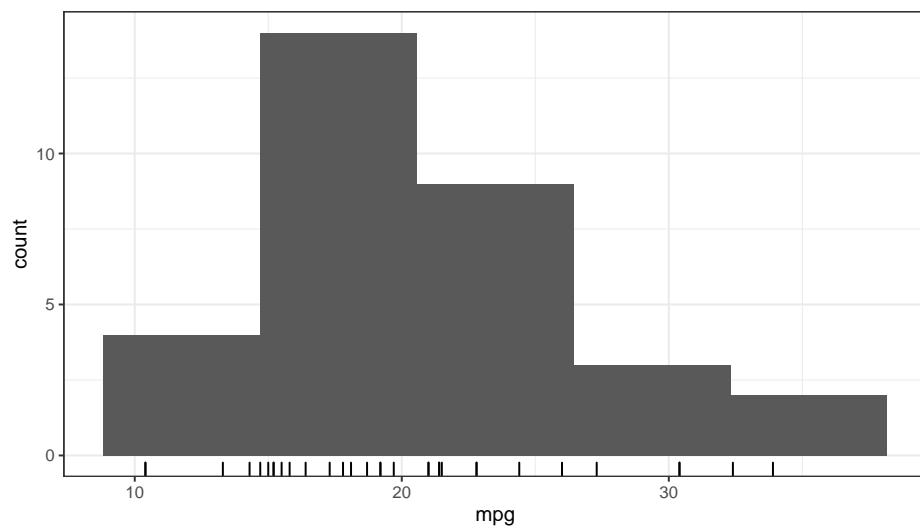


По оси x отложена наша переменная, а высота столбца говорит, сколько наблюдений имеют такое же наблюдение. Однако многое зависит от того, что мы считаем одноковым значением:

```
mtcars %>%
  ggplot(aes(mpg)) +
  geom_rug() +
  geom_histogram(bins = 100)
```



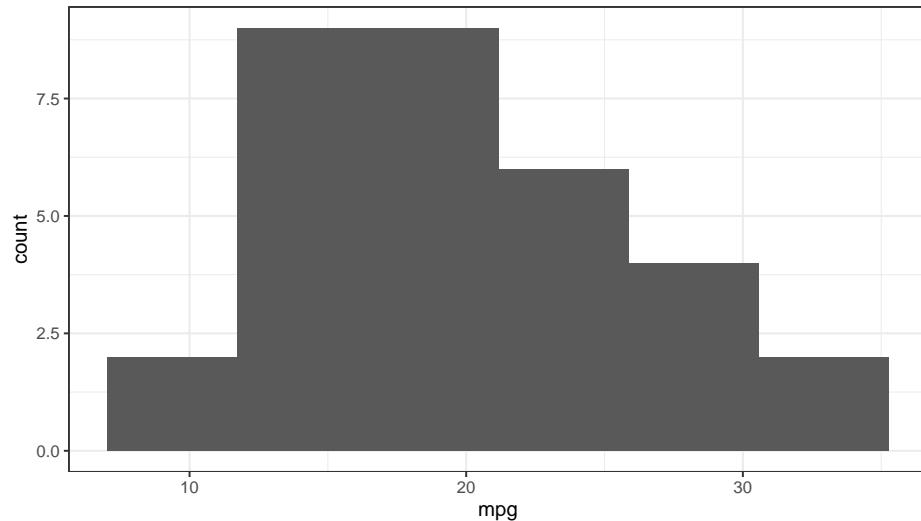
```
mtcars %>%
  ggplot(aes(mpg)) +
  geom_rug() +
  geom_histogram(bins = 5)
```



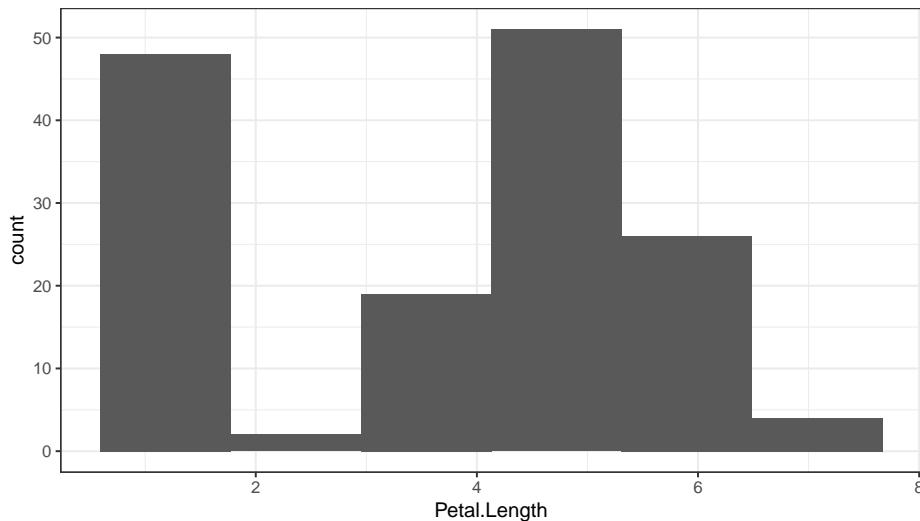
Существует три алгоритма встроенные в R, которые можно использовать и снимать с себя ответственность:

- [Sturges 1926] `nclass.Sturges(mtcars$mpg)`
- [Scott 1979] `nclass.scott(mtcars$mpg)`
- [Freedman, Diaconis 1981] `nclass.FD(mtcars$mpg)`

```
mtcars %>%
  ggplot(aes(mpg)) +
  geom_histogram(bins = nclass.FD(mtcars$mpg))
```



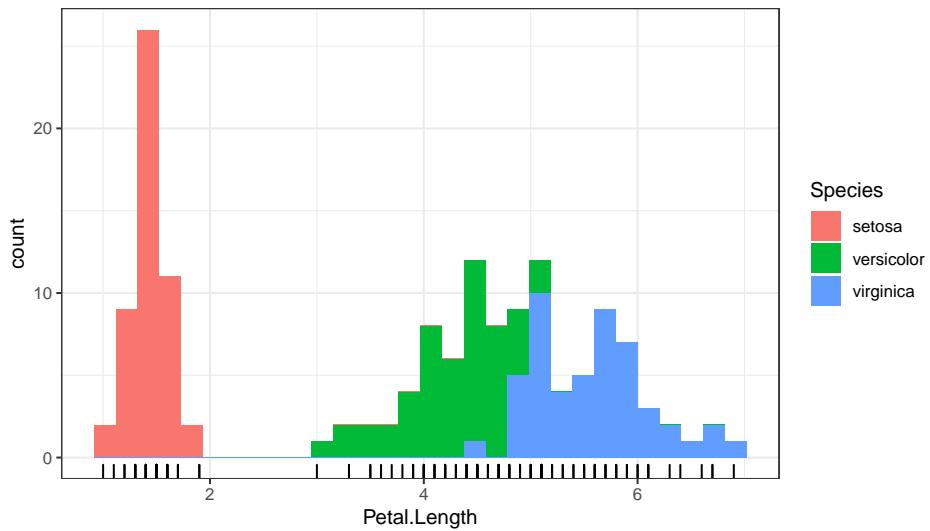
Какой из методов использовался при создании следующего графика на основе встроенного датасета `iris`?



В этом типе графика точно так же можно раскрашивать на основании другой переменной:

```
iris %>%
  ggplot(aes(Petal.Length, fill = Species)) +
  geom_rug() +
  geom_histogram()
```

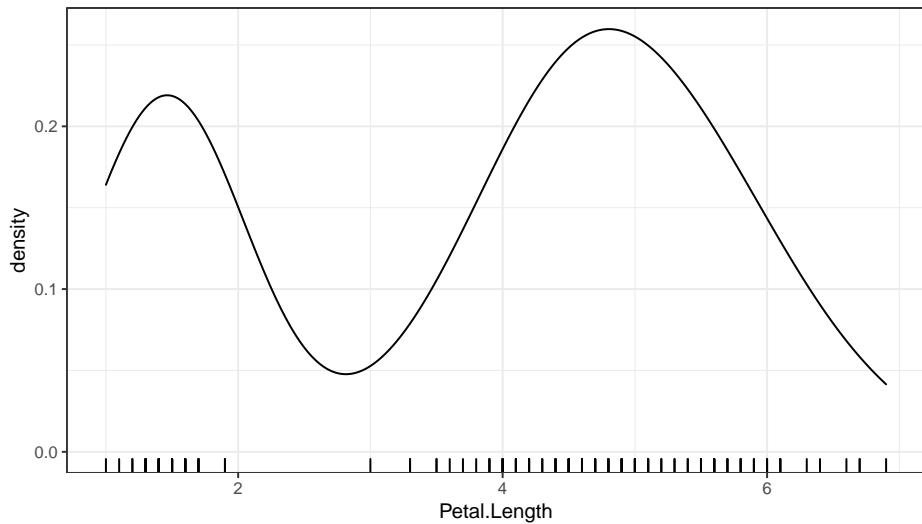
`stat_bin()` using `bins = 30`. Pick better value with `binwidth`.



6.7 Функции плотности

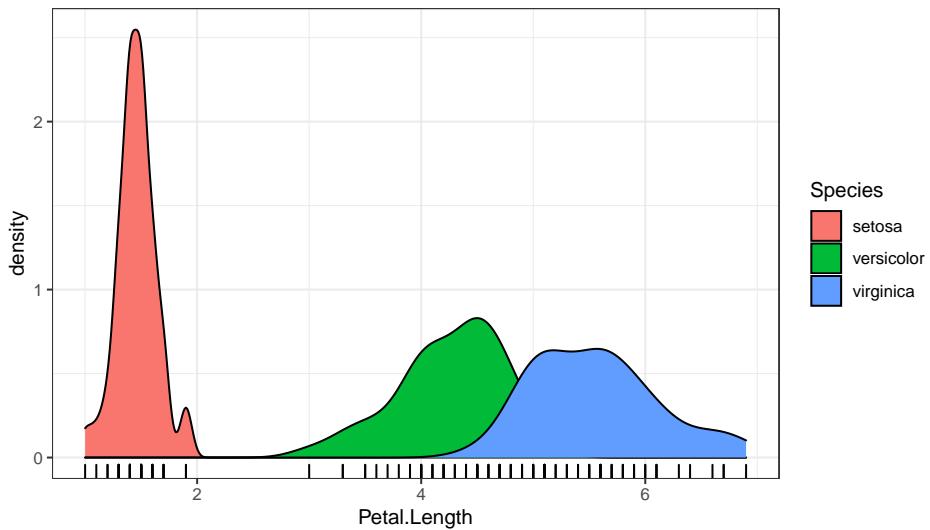
Кроме того, существует способ использовать не такой рубленный график, а его сглаженную варианты, который строиться при помощи функции плотнодерной оценки ности. Важное свойство, которое стоит понимать про функцию плотности — что кривая, получаемая ядерной оценкой плотности, не зависит от величины коробки гистделения (хотя есть аргумент, который от `adjust`вечает за степень “близости” функции плотности к гистограмме).

```
iris %>%
  ggplot(aes(Petal.Length)) +
  geom_rug() +
  geom_density()
```



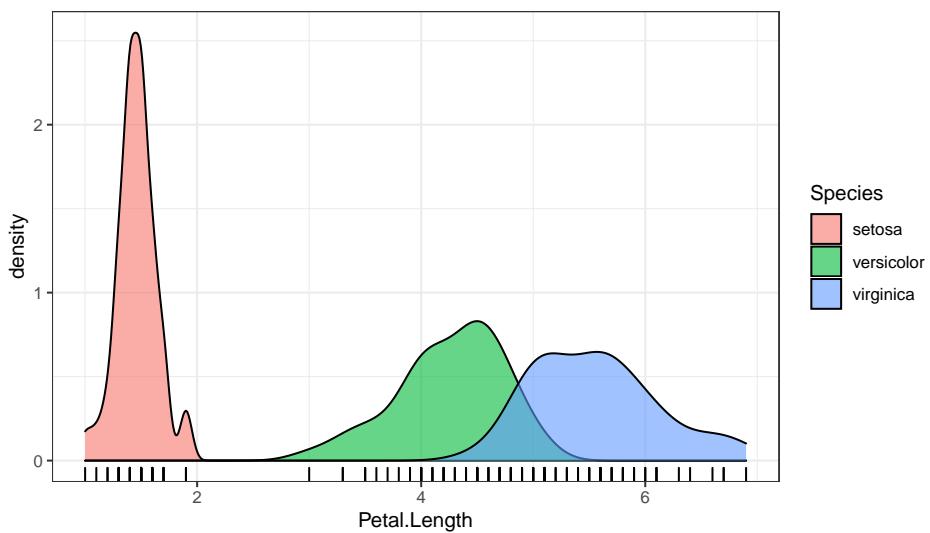
Таким образом мы можем сравнивать распределения:

```
iris %>%
  ggplot(aes(Petal.Length, fill = Species)) +
  geom_rug() +
  geom_density()
```



Часто имеет смысл настроить прозрачность:

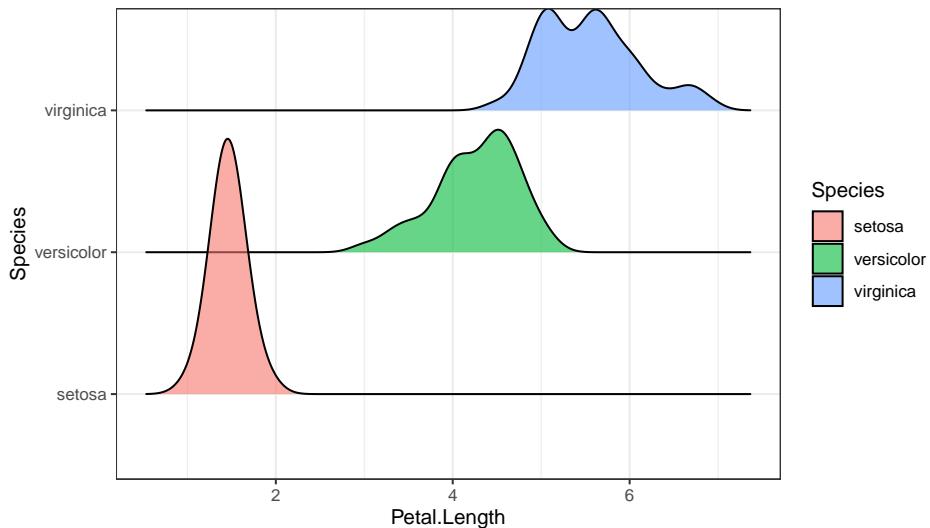
```
iris %>%
  ggplot(aes(Petal.Length, fill = Species)) +
  geom_rug()+
  geom_density(alpha = 0.6) # 0 1
```



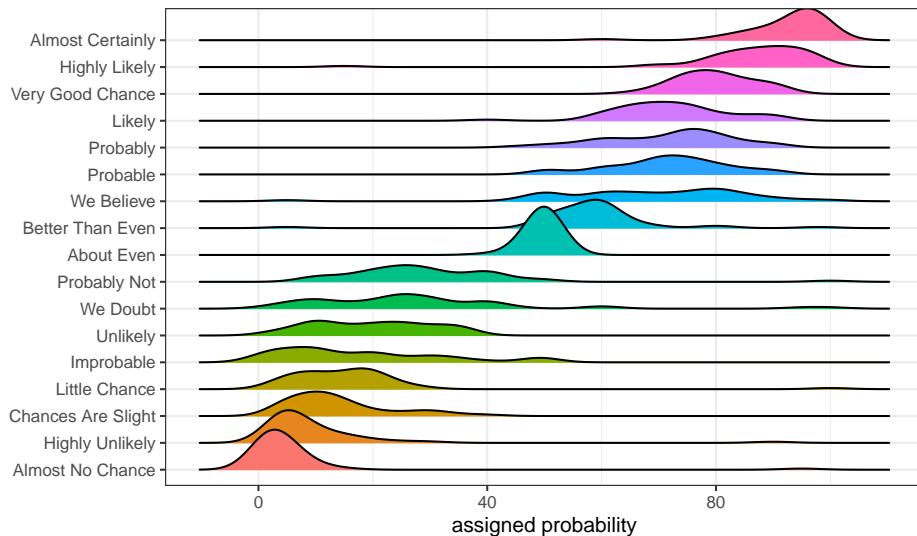
Кроме того, иногда удобно разделять группы на разные уровни:

```
# install.packages(ggridges)
library(ggridges)
iris %>%
  ggplot(aes(Petal.Length, Species, fill = Species)) +
  geom_density_ridges(alpha = 0.6) # 0 1
```

```
## Picking joint bandwidth of 0.155
```



В длинный список “2015 Kantar Information is Beautiful Awards” попала визуализация *Perceptions of Probability*⁹, сделанная пользователем zonination¹⁰ в ggplot2. Попробуйте воспроизвести ее с этими данными¹¹.



⊕ список подсказок ⊕

⊕ как преобразовать в нужный формат? ⊕ Я делал это при помощи функции `pivot_longer()`.

⊕ не получается обратиться к колонкам ⊕ Да, если в названиях столбцов есть пробел или цифры, то к ним можно обратиться, воспользовавшись обратными ковычками `:

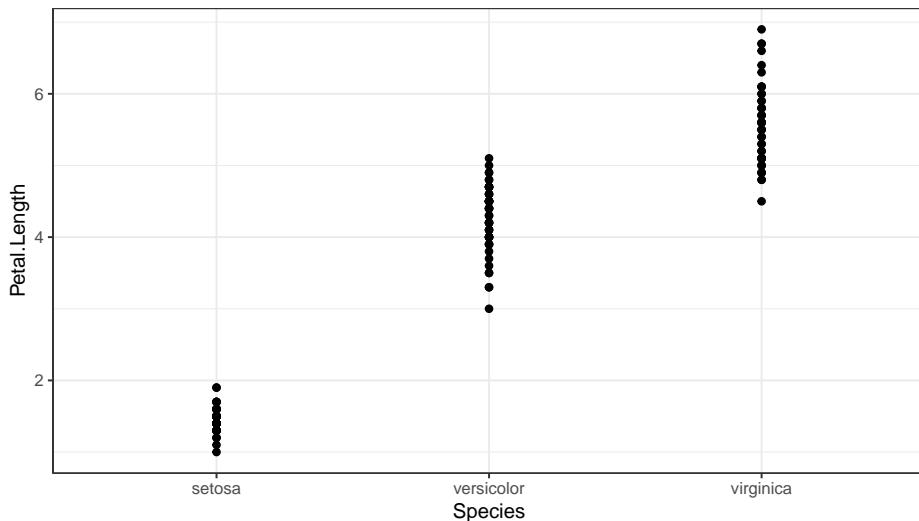
⊕ получается, но порядок неправильный... ⊕ Ага, мы обсуждали факторы. Функция `fct_reorder()` позволяет менять порядок и даже задавать функцию, вроде среднего или медианы, которая должна быть применена к каждой группе.

⊕ а как убрать легенду? ⊕ Легенду можно убрать добавив `show.legend = FALSE` в соответствующий `geom_`

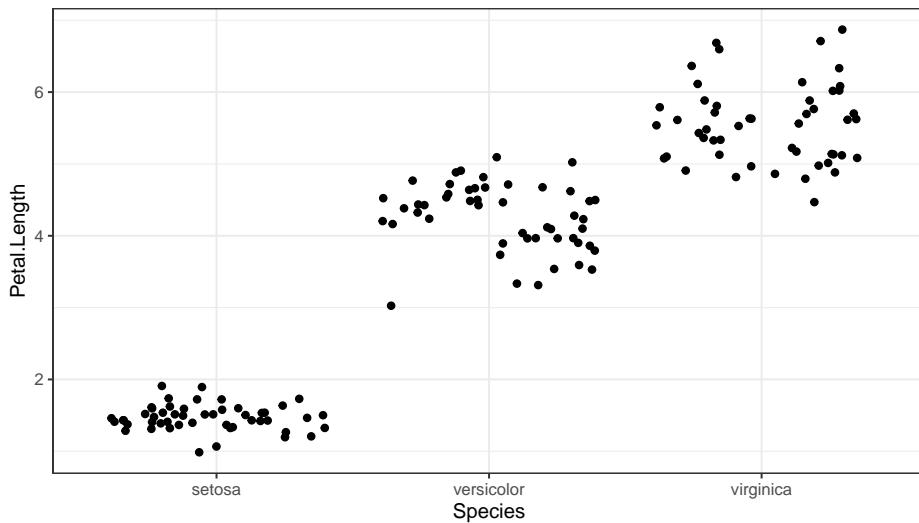
6.8 Точки, джиттер (jitter), вайолинплот (violinplot), ящики с усами (boxplot),

Вот другие способы показать распределение числовой переменной:

```
iris %>%
  ggplot(aes(Species, Petal.Length)) +
  geom_point()
```

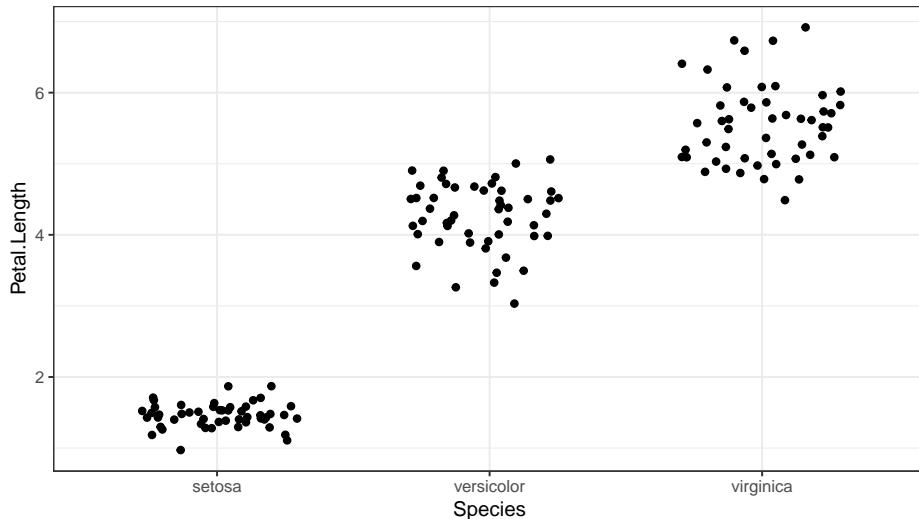


```
iris %>%
  ggplot(aes(Species, Petal.Length)) +
  geom_jitter()
```

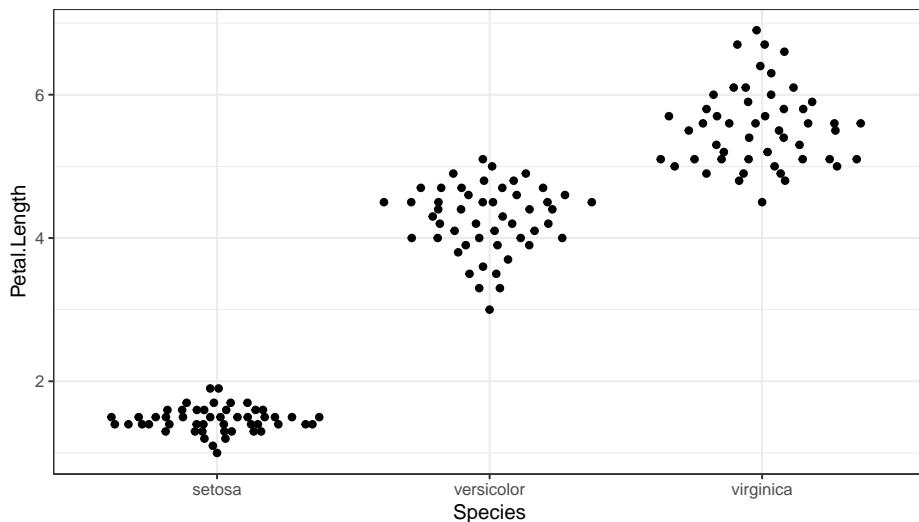


```
iris %>%
  ggplot(aes(Species, Petal.Length)) +
  geom_jitter(width = 0.3)
```

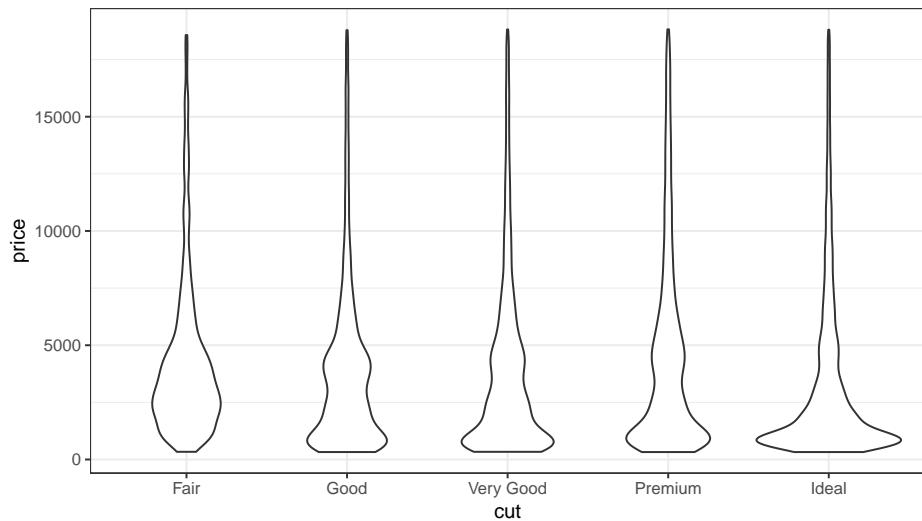
6.8. ТОЧКИ, ДЖИТТЕР (JITTER), ВАЙОЛИНПЛОТ (VIOLINPLOT), ЯЩИКИ С УСАМИ (BOXPLOT), 163



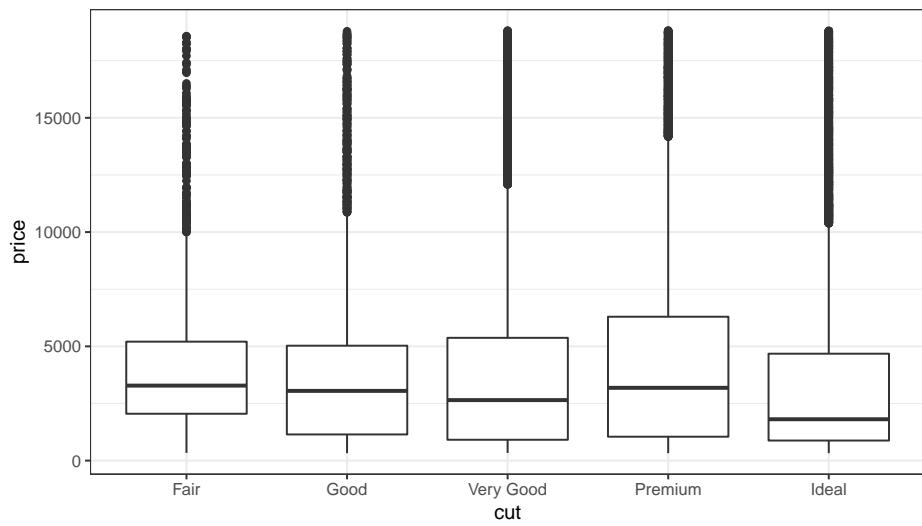
```
library("ggbeeswarm")
iris %>%
  ggplot(aes(Species, Petal.Length)) +
  geom_quasirandom()
```



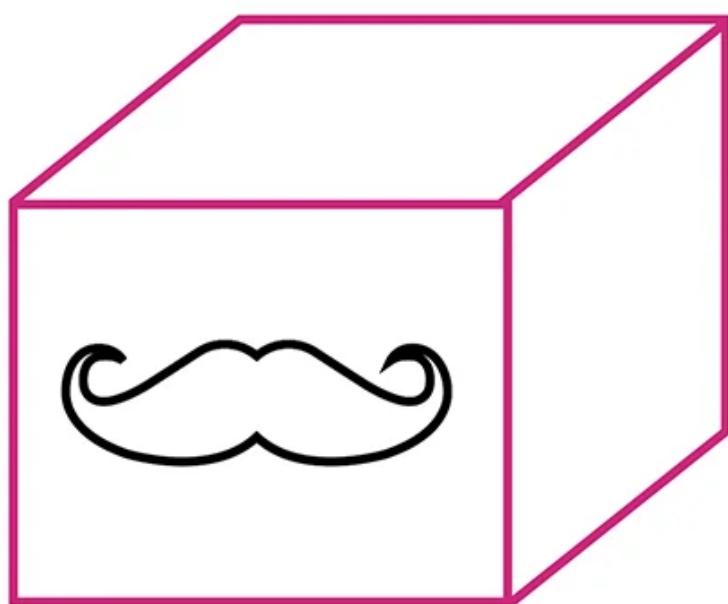
```
diamonds %>%
  ggplot(aes(cut, price)) +
  geom_violin()
```



```
diamonds %>%
  ggplot(aes(cut, price)) +
  geom_boxplot()
```



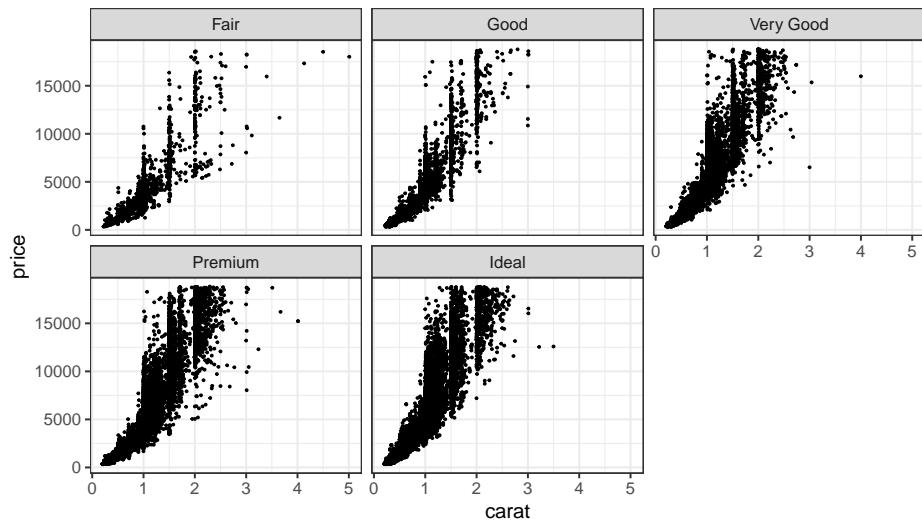
БОКСПЛОТ



6.9 Фасетизация

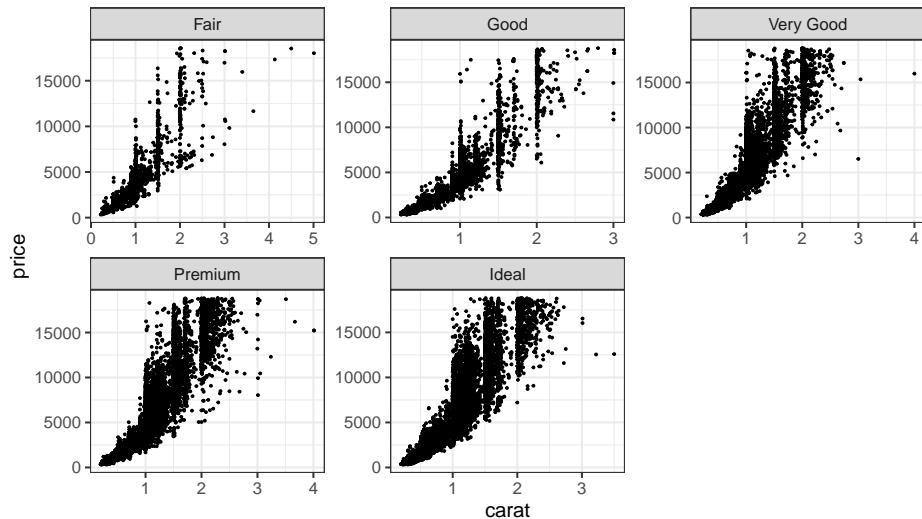
Достаточно мощным инструментом анализа данных является фасетизация, которая позволяет разбивать графики на основе какой-то переменной.

```
diamonds %>%
  ggplot(aes(carat, price)) +
  geom_point(size = 0.3) +
  facet_wrap(~cut)
```



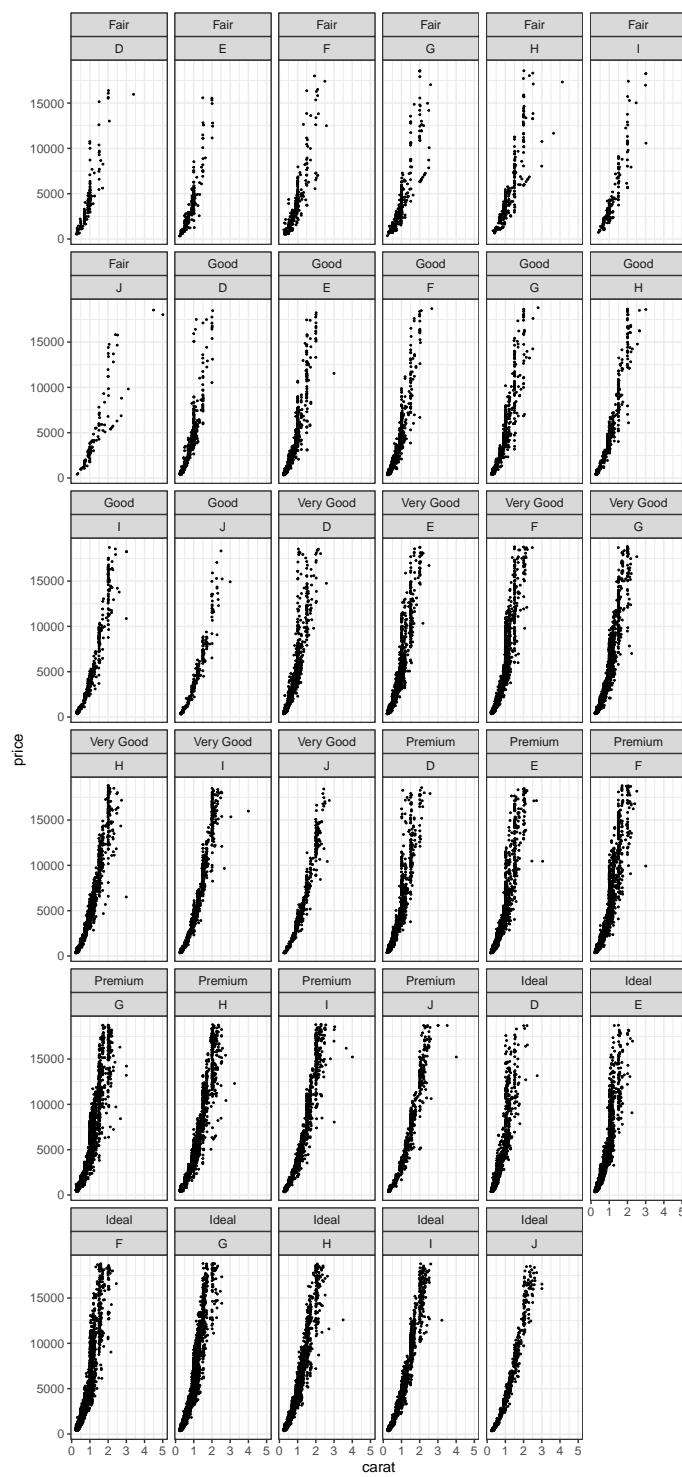
При этом иногда так бывает, что наличие какой-то одного значение в одном из фасетов, заставляет иметь одну и ту же шкалу для всех остальных. Это можно изменить при помощи аргумента `scales`:

```
diamonds %>%
  ggplot(aes(carat, price)) +
  geom_point(size = 0.3) +
  facet_wrap(~cut, scales = "free")
```



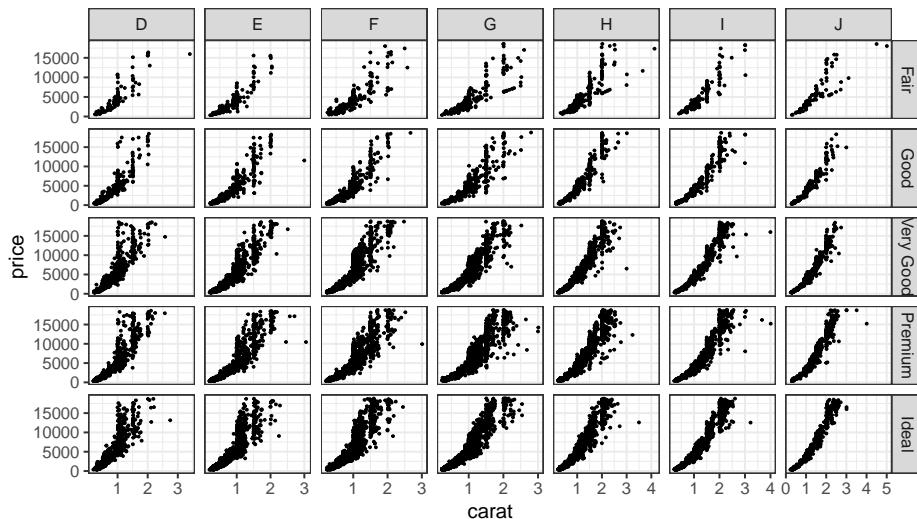
Кроме того, можно добавлять дополнительные аргументы:

```
diamonds %>%
  ggplot(aes(carat, price)) +
  geom_point(size = 0.3) +
  facet_wrap(~cut + color)
```



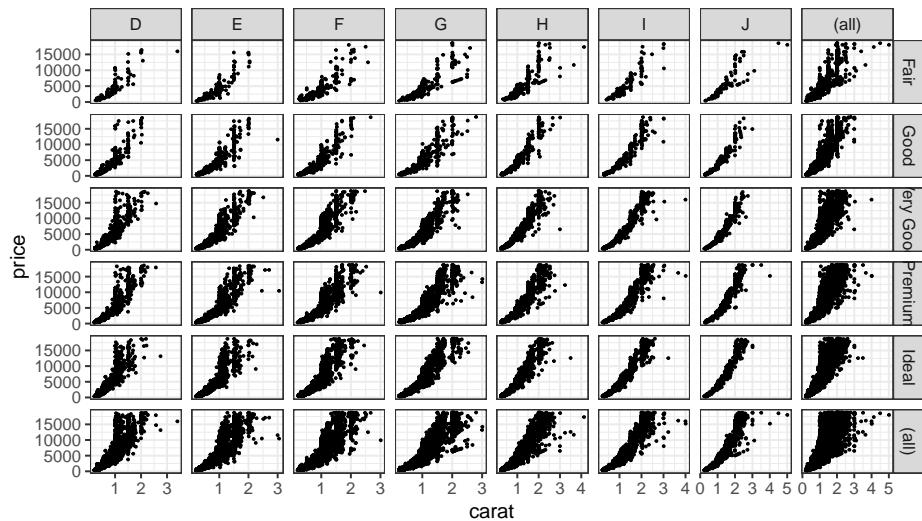
Кроме того, можно создавать сетки переменных используя `geom_grid()`, они `facet_grid()` выше места, чем `facet_wrap()`:

```
diamonds %>%
  ggplot(aes(carat, price)) +
  geom_point(size = 0.3) +
  facet_grid(cut~color, scales = "free")
```



Кроме того `facet_grid()` позволяет делать обобщающие поля, где представлены все данные по какой-то строчке или столбцу:

```
diamonds %>%
  ggplot(aes(carat, price)) +
  geom_point(size = 0.3) +
  facet_grid(cut~color, scales = "free", margins = TRUE)
```



6.10 Визуализация комбинаций признаков

6.10.1 Потоковая Диаграмма (Sankey diagram)

Один из способов визуализации отношений между признаками называется потоковой диаграммой¹².

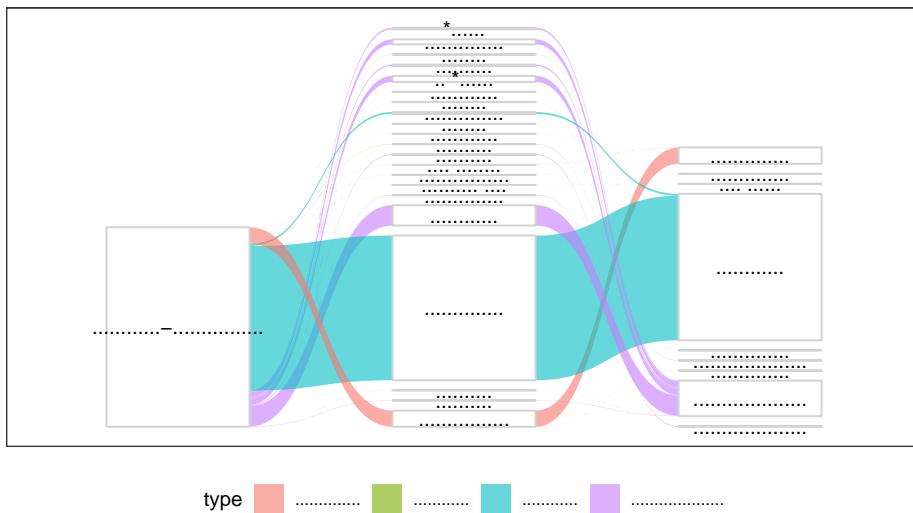
```
library("ggforce")
zhadina <- read_csv("https://raw.githubusercontent.com/agricolamz/2020-2021-ds4dh/mast...")

## 
## -- Column specification -----
## cols(
##   word_1 = col_character(),
##   word_2 = col_character(),
##   word_3 = col_character(),
##   type = col_character(),
##   n = col_double()
## )

zhadina %>%
  gather_set_data(1:3) %>%
  ggplot(aes(x, id = id, split = y, value = n)) +
  geom_parallel_sets(aes(fill = type), alpha = 0.6, axis.width = 0.5) +
  geom_parallel_sets_axes(axis.width = 0.5, color = "lightgrey", fill = "white") +
```

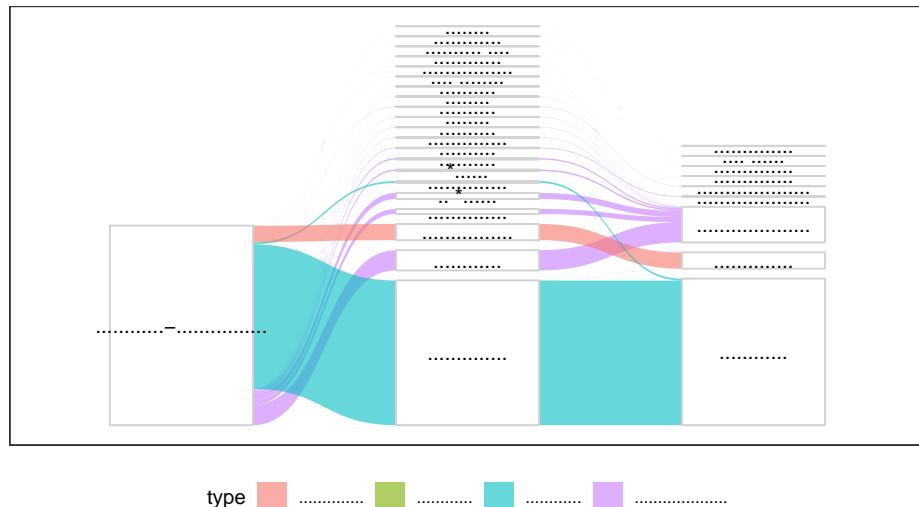
¹²https://en.wikipedia.org/wiki/Sankey_diagram

```
geom_parallel_sets_labels(angle = 0) +
theme_no_axes() +
theme(legend.position = "bottom")
```



А как поменять порядок? Снова факторы.

```
zhadina %>%
gather_set_data(1:3) %>%
mutate(y = fct_reorder(y, n, mean)) %>%
ggplot(aes(x, id = id, split = y, value = n)) +
geom_parallel_sets(aes(fill = type), alpha = 0.6, axis.width = 0.5) +
geom_parallel_sets_axes(axis.width = 0.5, color = "lightgrey", fill = "white") +
geom_parallel_sets_labels(angle = 0) +
theme_no_axes() +
theme(legend.position = "bottom")
```



Можно донастроить, задав собственный порядок в аргументе `levels` функции `factor()`.

6.10.2 UpSet Plot

Если диаграмма Sankey визуализирует попарные отношения между переменными, то график UpSet потенциально может визуализировать все возможные комбинации и является хорошей альтернативой диаграмме Вена, с большим количеством переменных (см. эту статью Лауры Эллис¹³).

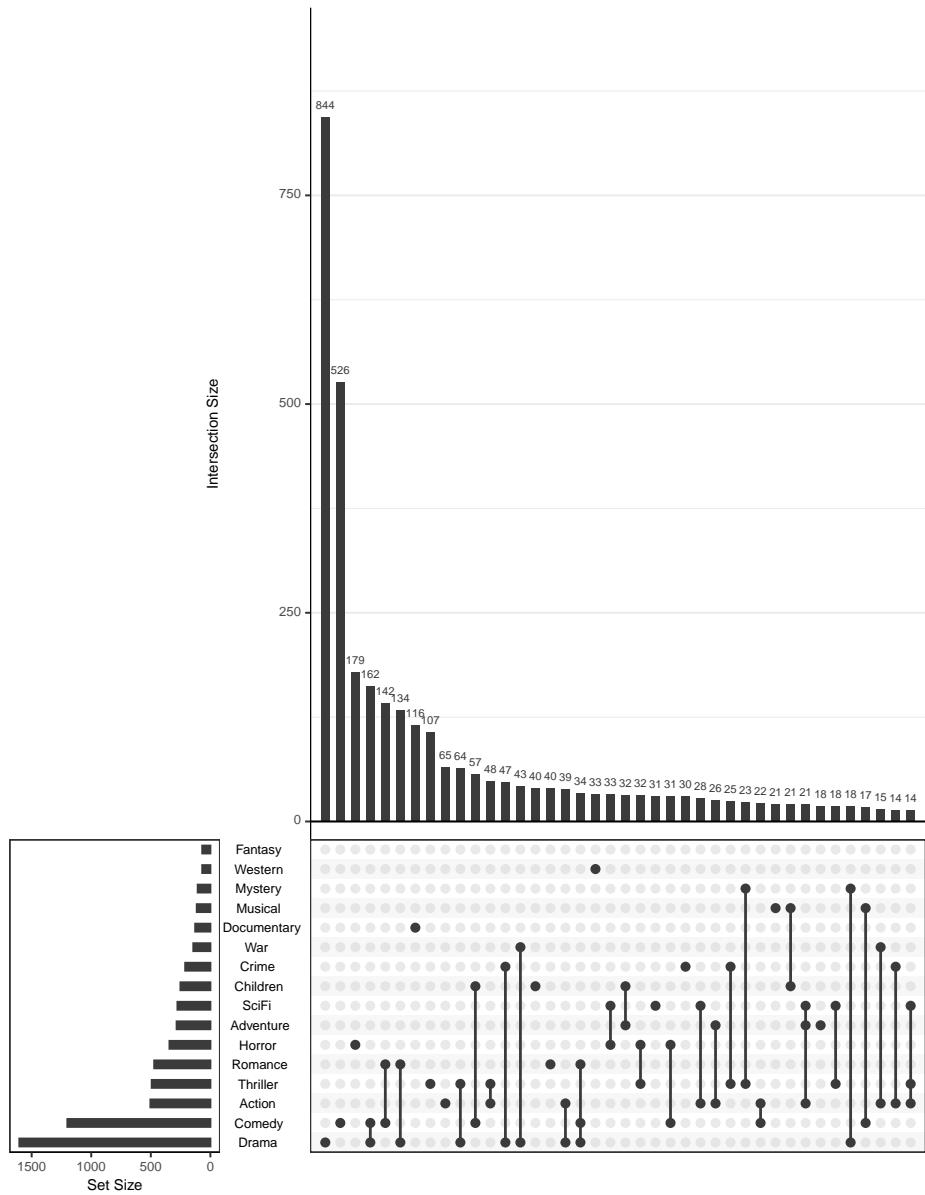
```
library(UpSetR)
movies <- read.csv( system.file("extdata", "movies.csv", package = "UpSetR"), header=TRUE)
str(movies)

## 'data.frame': 3883 obs. of 21 variables:
## $ Name      : chr "Toy Story (1995)" "Jumanji (1995)" "Grumpier Old Men (1995)" ...
## $ ReleaseDate: int 1995 1995 1995 1995 1995 1995 1995 1995 1995 1995 ...
## $ Action     : int 0 0 0 0 0 1 0 0 1 1 ...
## $ Adventure  : int 0 1 0 0 0 0 0 1 0 1 ...
## $ Children   : int 1 1 0 0 0 0 0 1 0 0 ...
## $ Comedy     : int 1 0 1 1 1 0 1 0 0 0 ...
## $ Crime      : int 0 0 0 0 0 1 0 0 0 0 ...
## $ Documentary: int 0 0 0 0 0 0 0 0 0 0 ...
## $ Drama      : int 0 0 0 1 0 0 0 0 0 0 ...
## $ Fantasy    : int 0 1 0 0 0 0 0 0 0 0 ...
## $ Noir       : int 0 0 0 0 0 0 0 0 0 0 ...
## $ Horror     : int 0 0 0 0 0 0 0 0 0 0 ...
```

¹³<https://www.littlemissdata.com/blog/set-analysis>

```
## $ Musical    : int  0 0 0 0 0 0 0 0 0 0 0 0 ...
## $ Mystery    : int  0 0 0 0 0 0 0 0 0 0 0 0 ...
## $ Romance    : int  0 0 1 0 0 0 1 0 0 0 0 0 ...
## $ SciFi      : int  0 0 0 0 0 0 0 0 0 0 0 0 ...
## $ Thriller   : int  0 0 0 0 0 1 0 0 0 1 0 0 ...
## $ War         : int  0 0 0 0 0 0 0 0 0 0 0 0 ...
## $ Western    : int  0 0 0 0 0 0 0 0 0 0 0 0 ...
## $ AvgRating  : num  4.15 3.2 3.02 2.73 3.01 3.88 3.41 3.01 2.66 3.54 ...
## $ Watches    : int  2077 701 478 170 296 940 458 68 102 888 ...
```

```
upset(movies[,3:19], nsets = 16, order.by = "freq")
```



Глава 7

Задания

```
##Начало работы в R {#task_begin}
```

- Разделите 9801 на 9.

```
## [1] 1089
```

- Посчитайте логарифм от 8912162342 по основанию 6.

```
## [1] 12
```

- Теперь натуральный логарифм 10 и умножьте его на 5.

```
## [1] 11.51293
```

- С помощью функции `sin()` посчитайте $\sin(\pi)$, $\sin\left(\frac{\pi}{2}\right)$, $\sin\left(\frac{\pi}{6}\right)$.

Значение π - зашитая в R константа (`pi`).

```
## [1] 1.224647e-16
```

```
## [1] 1
```

```
## [1] 0.5
```

```
##Создание векторов {#task_new_vecs}
```

- Создайте вектор из значений 2, 30 и 4000.

```
## [1] 2 30 4000
```

- Создайте вектор от 1 до 20.

```
## [1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20
```

- Создайте вектор от 20 до 1.

```
## [1] 20 19 18 17 16 15 14 13 12 11 10 9 8 7 6 5 4 3 2 1
```

Функция `sum()` возвращает сумму элементов вектора на входе. Посчитайте сумму первых 100 натуральных чисел (т.е. всех целых чисел от 1 до 100).

```
## [1] 5050
```

- Создайте вектор от 1 до 20 и снова до 1. Число 20 должно присутствовать только один раз!

```
## [1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 19 18 17 16 15
## [26] 14 13 12 11 10 9 8 7 6 5 4 3 2 1
```

- Создайте вектор значений 5, 4, 3, 2, 2, 3, 4, 5:

```
## [1] 5 4 3 2 2 3 4 5
```

- Создайте вектор 2, 4, 6, ..., 18, 20.

```
## [1] 2 4 6 8 10 12 14 16 18 20
```

- Создайте вектор 0.1, 0.2, 0.3, ..., 0.9, 1.

```
## [1] 0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0
```

- 2020 год — високосный. Следующий високосный год через 4 года — это будет 2024 год. Составьте календарь всех високосных годов XXI века, начиная с 2020 года.

2100 год относится к XXI веку, а не к XXII.

```
## [1] 2020 2024 2028 2032 2036 2040 2044 2048 2052 2056 2060 2064 2068 2072 2076
## [16] 2080 2084 2088 2092 2096 2100
```

- Создайте вектор, состоящий из 20 повторений “Хэй!”.

```
## [1] "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!"
```

- Как я и говорил, многие функции, работающие с одним значением на входе, также прекрасно работают и с целыми векторами. Попробуйте посчитать квадратный корень чисел от 1 до 10 с помощью функции `sqrt()` и сохраните результат в векторе `roots`.

```
## [1] 1.000000 1.414214 1.732051 2.000000 2.236068 2.449490 2.645751 2.828427
```

```
## [9] 3.000000 3.162278
```

- Давайте убедимся, что это действительно квадратные корни. Для этого возведите все значения вектора `roots` в квадрат!

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

- Если все верно, то того же самого можно добиться поэлементным умножением вектора `roots` на себя.

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

- *Создайте вектор из одной единицы, двух двоек, трех троек, ..., девяти девяток.

```
## [1] 1 2 2 3 3 3 4 4 4 4 5 5 5 5 6 6 6 6 6 7 7 7 7 7 7 8 8 8 8 8 8 9 9
## [39] 9 9 9 9 9 9 9
```

7.1 Приведение типов

- Сделайте вектор `vec1`, в котором соедините 3, а также значения " " и " ".

```
## [1] "3"      " "      " "
```

- Попробуйте вычесть TRUE из 10.

```
## [1] 9
```

- Соедините значение 10 и TRUE в вектор `vec2`.

```
## [1] 10 1
```

- Соедините вектор `vec2` и значение "r":

```
## [1] "10" "1"  "r"
```

- Соедините значения 10, TRUE, "r" в вектор.

```
## [1] "10"  "TRUE" "r"
```

7.2 Векторизация

- Создайте вектор `p`, состоящий из значений 4, 5, 6, 7, и вектор `q`, состоящий из 0, 1, 2, 3.

```
## [1] 4 5 6 7
```

```
## [1] 0 1 2 3
```

- Посчитайте поэлементную сумму векторов `p` и `q`:

```
## [1] 4 6 8 10
```

- Посчитайте поэлементную разницу `p` и `q`:

```
## [1] 4 4 4 4
```

- Поделите каждый элемент вектора `p` на соответствующий ему элемент вектора `q`:

О, да, Вам нужно делить на 0!

```
## [1] Inf 5.000000 3.000000 2.333333
```

- Возведите каждый элемент вектора `p` в степень соответствующего ему элемента вектора `q`:

```
## [1] 1 5 36 343
```

- Умножьте каждое значение вектора `p` на 10.

```
## [1] 40 50 60 70
· Создайте вектор квадратов чисел от 1 до 10:
## [1] 1 4 9 16 25 36 49 64 81 100
· Создайте вектор 0, 2, 0, 4, ..., 18, 0, 20.
## [1] 0 2 0 4 0 6 0 8 0 10 0 12 0 14 0 16 0 18 0 20
· Создайте вектор 1, 0, 3, 0, 5, ..., 17, 0, 19, 0.
## [1] 1 0 3 0 5 0 7 0 9 0 11 0 13 0 15 0 17 0 19 0
· *Создайте вектор, в котором будут содержаться первые 20 степеней двойки.
## [1] 2 4 8 16 32 64 128 256 512
## [10] 1024 2048 4096 8192 16384 32768 65536 131072 262144
## [19] 524288 1048576
· *Создайте вектор из чисел 1, 10, 100, 1000, 10000:
## [1] 1 10 100 1000 10000
· *Посчитать сумму последовательности  $\frac{1}{1 \cdot 2} + \frac{1}{2 \cdot 3} + \frac{1}{3 \cdot 4} + \dots + \frac{1}{50 \cdot 51}$ .
## [1] 0.9803922
· *Посчитать сумму последовательности  $\frac{1}{2^0} + \frac{1}{2^1} + \frac{1}{2^2} + \frac{1}{2^3} + \dots + \frac{1}{2^{20}}$ .
## [1] 1.999999
· *Посчитать сумму последовательности  $1 + \frac{4}{3} + \frac{7}{9} + \frac{10}{27} + \frac{13}{81} + \dots + \frac{28}{19683}$ .
## [1] 3.749174
· *Сколько чисел из последовательности  $1 + \frac{4}{3} + \frac{7}{9} + \frac{10}{27} + \frac{13}{81} + \dots + \frac{28}{19683}$  больше
    чем 0.5?
## [1] 3
```

7.3 Индексирование векторов

- Создайте вектор `troiki` со значениями 3, 6, 9, ..., 24, 27.

```
## [1] 3 6 9 12 15 18 21 24 27
· Извлеките 2, 5 и 7 значения вектора troiki.
## [1] 6 15 21
· Извлеките предпоследнее значение вектора troiki.
## [1] 24
· Извлеките все значения вектора troiki кроме предпоследнего:
## [1] 3 6 9 12 15 18 21 27
```

Создайте вектор `vec3`:

```
vec3 <- c(3, 5, 2, 1, 8, 4, 9, 10, 3, 15, 1, 11)
```

- Найдите второй элемент вектора `vec3`.
- ```
[1] 5
```
- Верните второй и пятый элемент вектора `vec3`.
- ```
## [1] 5 8
```
- Попробуйте извлечь сотовое значение вектора `vec3`:
- ```
[1] NA
```
- Верните все элементы вектора `vec3` кроме второго элемента.
- ```
## [1] 3 2 1 8 4 9 10 3 15 1 11
```
- Верните все элементы вектора `vec3` кроме второго и пятого элемента.
- ```
[1] 3 2 1 4 9 10 3 15 1 11
```
- Найдите последний элемент вектора `vec3`.
- ```
## [1] 11
```
- Верните все значения вектора `vec3` кроме первого и последнего.
- ```
[1] 5 2 1 8 4 9 10 3 15 1
```
- Найдите все значения вектора `vec3`, которые больше 4.
- ```
## [1] 5 8 9 10 15 11
```
- Найдите все значения вектора `vec3`, которые больше 4, но меньше 10.
- Если хотите сделать это в одну строчку, то вам помогут логические операторы!
- ```
[1] 5 8 9
```
- Найдите все значения вектора `vec3`, которые меньше 4 или больше 10.
- ```
## [1] 3 2 1 3 15 1 11
```
- Возведите в квадрат каждое значение вектора `vec3`.
- ```
[1] 9 25 4 1 64 16 81 100 9 225 1 121
```
- \*Возведите в квадрат каждое значение вектора на нечетной позиции и извлеките корень из каждого значения на четной позиции вектора `vec3`.
- Извлечение корня - это то же самое, что и возведение в степень 0.5.
- ```
## [1] 9.000000 2.236068 4.000000 1.000000 64.000000 2.000000 81.000000
## [8] 3.162278 9.000000 3.872983 1.000000 3.316625
```

- Создайте вектор $2, 4, 6, \dots, 18, 20$ как минимум 2 новыми способами.

Знаю, это задание может показаться бессмысленным, но это очень базовая операция, с помощью которой можно, например, разделить данные на две части. Чем больше способов Вы знаете, тем лучше!

```
## [1] 2 4 6 8 10 12 14 16 18 20
```

```
##Работа с пропущенными значениями {#task_na}
```

- Создайте вектор `vec4` со значениями $300, 15, 8, 2, 0, 1, 110$:

```
vec4 <- c(300, 15, 8, 20, 0, 1, 110)
vec4
```

```
## [1] 300 15   8   20   0   1 110
```

- Замените все значения `vec4`, которые больше 20 на `NA`.
- Проверьте полученный вектор `vec4`:

```
## [1] NA 15 8 20 0 1 NA
```

- Посчитайте сумму `vec4` с помощью функции `sum()`. Ответ `NA` не считается!

```
## [1] 44
```

7.4 Матрицы

- Создайте матрицу 4×4 , состоящую из единиц. Назовите ее `M1`.

```
##      [,1] [,2] [,3] [,4]
## [1,]     1     1     1     1
## [2,]     1     1     1     1
## [3,]     1     1     1     1
## [4,]     1     1     1     1
```

- Поменяйте все некрайние значения матрицы `M1` (то есть значения на позициях $[2,2], [2,3], [3,2]$ и $[3,3]$) на число 2.

```
##      [,1] [,2] [,3] [,4]
## [1,]     1     1     1     1
## [2,]     1     2     2     1
## [3,]     1     2     2     1
## [4,]     1     1     1     1
```

- Выделите второй и третий столбик из матрицы `M1`.

```
##      [,1] [,2]
## [1,]     1     1
## [2,]     2     2
## [3,]     2     2
```

```
## [4,]    1    1
```

- Сравните (==) вторую колонку и вторую строчку матрицы M1.

```
## [1] TRUE TRUE TRUE TRUE
```

- *Создайте таблицу умножения (9x9) в виде матрицы. Сохраните ее в переменную mult_tab.

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9]
## [1,]    1    2    3    4    5    6    7    8    9
## [2,]    2    4    6    8   10   12   14   16   18
## [3,]    3    6    9   12   15   18   21   24   27
## [4,]    4    8   12   16   20   24   28   32   36
## [5,]    5   10   15   20   25   30   35   40   45
## [6,]    6   12   18   24   30   36   42   48   54
## [7,]    7   14   21   28   35   42   49   56   63
## [8,]    8   16   24   32   40   48   56   64   72
## [9,]    9   18   27   36   45   54   63   72   81
```

- *Из матрицы mult_tab выделите подматрицу, включающую в себя только строчки с 6 по 8 и столбцы с 3 по 7.

```
##      [,1] [,2] [,3] [,4] [,5]
## [1,]   18   24   30   36   42
## [2,]   21   28   35   42   49
## [3,]   24   32   40   48   56
```

- *Создайте матрицу с логическими значениями, где TRUE, если в этом месте в таблице умножения (mult_tab) двузначное число и FALSE, если однозначное.

Матрица - это почти вектор. К нему можно обращаться с единственным индексом.

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9]
## [1,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [2,] FALSE FALSE FALSE FALSE  TRUE  TRUE  TRUE  TRUE  TRUE
## [3,] FALSE FALSE FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [4,] FALSE FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [5,] FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [6,] FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [7,] FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [8,] FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [9,] FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
```

- *Создайте матрицу mult_tab2, в которой все значения tab меньше 10 заменены на 0.

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9]
## [1,]    0    0    0    0    0    0    0    0    0
## [2,]    0    0    0    0   10   12   14   16   18
```

```
## [3,] 0 0 0 12 15 18 21 24 27
## [4,] 0 0 12 16 20 24 28 32 36
## [5,] 0 10 15 20 25 30 35 40 45
## [6,] 0 12 18 24 30 36 42 48 54
## [7,] 0 14 21 28 35 42 49 56 63
## [8,] 0 16 24 32 40 48 56 64 72
## [9,] 0 18 27 36 45 54 63 72 81
```

7.5 Списки

Дан список `list1`:

```
list1 = list(numbers = 1:5, letters = letters, logic = TRUE)
list1
```

```
## $numbers
## [1] 1 2 3 4 5
##
## $letters
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"
##
## $logic
## [1] TRUE
```

- Найдите первый элемент списка `list1`. Ответ должен быть списком длиной один.

```
## $numbers
## [1] 1 2 3 4 5
```

- Теперь найдите содержание первого элемента списка `list1` двумя разными способами. Ответ должен быть вектором.

```
## [1] 1 2 3 4 5
```

```
## [1] 1 2 3 4 5
```

- Теперь возьмите первый элемент содержания первого элемента списка `list1`. Ответ должен быть вектором.

```
## [1] 1
```

- Создайте список `list2`, содержащий в себе два списка `list1`. Один из них будет иметь имя `pupa`, а другой — `lupa`.

```
## $pupa
## $pupa$numbers
## [1] 1 2 3 4 5
```

```

## 
## $pupa$letters
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"
##
## $pupa$logic
## [1] TRUE
##
##
## $lupa
## $lupa$numbers
## [1] 1 2 3 4 5
##
## $lupa$letters
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"
##
## $lupa$logic
## [1] TRUE

• *Извлеките первый элемент списка list2, из него — второй полэлемент, а из него — третье значение.

## [1] "c"

```

7.6 Датафрейм

- Запустите команду `data(mtcars)` чтобы загрузить встроенный датафрейм с информацией про автомобили. Каждая строчка датафрейма - модель автомобиля, каждая колонка - отдельная характеристика. Подробнее см. `?mtcars`.

```

data(mtcars)
mtcars

```

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
## Mazda RX4	21.0	6	160.0	110	3.90	2.620	16.46	0	1	4	4
## Mazda RX4 Wag	21.0	6	160.0	110	3.90	2.875	17.02	0	1	4	4
## Datsun 710	22.8	4	108.0	93	3.85	2.320	18.61	1	1	4	1
## Hornet 4 Drive	21.4	6	258.0	110	3.08	3.215	19.44	1	0	3	1
## Hornet Sportabout	18.7	8	360.0	175	3.15	3.440	17.02	0	0	3	2
## Valiant	18.1	6	225.0	105	2.76	3.460	20.22	1	0	3	1
## Duster 360	14.3	8	360.0	245	3.21	3.570	15.84	0	0	3	4
## Merc 240D	24.4	4	146.7	62	3.69	3.190	20.00	1	0	4	2
## Merc 230	22.8	4	140.8	95	3.92	3.150	22.90	1	0	4	2
## Merc 280	19.2	6	167.6	123	3.92	3.440	18.30	1	0	4	4
## Merc 280C	17.8	6	167.6	123	3.92	3.440	18.90	1	0	4	4

## Merc 450SE	16.4	8	275.8	180	3.07	4.070	17.40	0	0	3	3
## Merc 450SL	17.3	8	275.8	180	3.07	3.730	17.60	0	0	3	3
## Merc 450SLC	15.2	8	275.8	180	3.07	3.780	18.00	0	0	3	3
## Cadillac Fleetwood	10.4	8	472.0	205	2.93	5.250	17.98	0	0	3	4
## Lincoln Continental	10.4	8	460.0	215	3.00	5.424	17.82	0	0	3	4
## Chrysler Imperial	14.7	8	440.0	230	3.23	5.345	17.42	0	0	3	4
## Fiat 128	32.4	4	78.7	66	4.08	2.200	19.47	1	1	4	1
## Honda Civic	30.4	4	75.7	52	4.93	1.615	18.52	1	1	4	2
## Toyota Corolla	33.9	4	71.1	65	4.22	1.835	19.90	1	1	4	1
## Toyota Corona	21.5	4	120.1	97	3.70	2.465	20.01	1	0	3	1
## Dodge Challenger	15.5	8	318.0	150	2.76	3.520	16.87	0	0	3	2
## AMC Javelin	15.2	8	304.0	150	3.15	3.435	17.30	0	0	3	2
## Camaro Z28	13.3	8	350.0	245	3.73	3.840	15.41	0	0	3	4
## Pontiac Firebird	19.2	8	400.0	175	3.08	3.845	17.05	0	0	3	2
## Fiat X1-9	27.3	4	79.0	66	4.08	1.935	18.90	1	1	4	1
## Porsche 914-2	26.0	4	120.3	91	4.43	2.140	16.70	0	1	5	2
## Lotus Europa	30.4	4	95.1	113	3.77	1.513	16.90	1	1	5	2
## Ford Pantera L	15.8	8	351.0	264	4.22	3.170	14.50	0	1	5	4
## Ferrari Dino	19.7	6	145.0	175	3.62	2.770	15.50	0	1	5	6
## Maserati Bora	15.0	8	301.0	335	3.54	3.570	14.60	0	1	5	8
## Volvo 142E	21.4	4	121.0	109	4.11	2.780	18.60	1	1	4	2

- Изучите структуру датафрейма `mtcars` с помощью функции `str()`.

```
## 'data.frame': 32 obs. of 11 variables:
## $ mpg : num 21 21 22.8 21.4 18.7 18.1 14.3 24.4 22.8 19.2 ...
## $ cyl : num 6 6 4 6 8 6 8 4 4 6 ...
## $ disp: num 160 160 108 258 360 ...
## $ hp : num 110 110 93 110 175 105 245 62 95 123 ...
## $ drat: num 3.9 3.9 3.85 3.08 3.15 2.76 3.21 3.69 3.92 3.92 ...
## $ wt : num 2.62 2.88 2.32 3.21 3.44 ...
## $ qsec: num 16.5 17 18.6 19.4 17 ...
## $ vs : num 0 0 1 1 0 1 0 1 1 1 ...
## $ am : num 1 1 1 0 0 0 0 0 0 0 ...
## $ gear: num 4 4 4 3 3 3 3 4 4 4 ...
## $ carb: num 4 4 1 1 2 1 4 2 2 4 ...
```

- Найдите значение третьей строчки четвертого столбца датафрейма `mtcars`.

```
## [1] 93
```

- Извлеките первые шесть строчек и первые шесть столбцов датафрейма `mtcars`.

```
##          mpg cyl disp  hp drat    wt
## Mazda RX4     21.0   6 160 110 3.90 2.620
## Mazda RX4 Wag  21.0   6 160 110 3.90 2.875
## Datsun 710    22.8   4 108  93 3.85 2.320
## Hornet 4 Drive 21.4   6 258 110 3.08 3.215
## Hornet Sportabout 18.7   8 360 175 3.15 3.440
```

```
## Valiant      18.1   6 225 105 2.76 3.460
```

- Извлеките колонку `wt` датафрейма `mtcars` - массу автомобиля в тысячах фунтов.

```
## [1] 2.620 2.875 2.320 3.215 3.440 3.460 3.570 3.190 3.150 3.440 3.440 4.070
## [13] 3.730 3.780 5.250 5.424 5.345 2.200 1.615 1.835 2.465 3.520 3.435 3.840
## [25] 3.845 1.935 2.140 1.513 3.170 2.770 3.570 2.780
```

- Извлеките колонки из `mtcars` в следующем порядке: `hp`, `mpg`, `cyl`.

```
##          hp mpg cyl
## Mazda RX4     110 21.0   6
## Mazda RX4 Wag 110 21.0   6
## Datsun 710    93 22.8   4
## Hornet 4 Drive 110 21.4   6
## Hornet Sportabout 175 18.7   8
## Valiant      105 18.1   6
## Duster 360    245 14.3   8
## Merc 240D     62 24.4   4
## Merc 230      95 22.8   4
## Merc 280      123 19.2   6
## Merc 280C     123 17.8   6
## Merc 450SE    180 16.4   8
## Merc 450SL    180 17.3   8
## Merc 450SLC   180 15.2   8
## Cadillac Fleetwood 205 10.4   8
## Lincoln Continental 215 10.4   8
## Chrysler Imperial 230 14.7   8
## Fiat 128       66 32.4   4
## Honda Civic     52 30.4   4
## Toyota Corolla 65 33.9   4
## Toyota Corona   97 21.5   4
## Dodge Challenger 150 15.5   8
## AMC Javelin     150 15.2   8
## Camaro Z28      245 13.3   8
## Pontiac Firebird 175 19.2   8
## Fiat X1-9        66 27.3   4
## Porsche 914-2    91 26.0   4
## Lotus Europa     113 30.4   4
## Ford Pantera L   264 15.8   8
## Ferrari Dino     175 19.7   6
## Maserati Bora    335 15.0   8
## Volvo 142E      109 21.4   4
```

- Посчитайте количество автомобилей с 4 цилиндрами (`cyl`) в датафрейме `mtcars`.

```
## [1] 11
```

- Посчитайте долю автомобилей с 4 цилиндрами (`cyl`) в датафрейме `mtcars`.

```
## [1] 0.34375
```

- Найдите все автомобили мощностью не менее 100 лошадиных сил (`hp`) в датафрейме `mtcars`.

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
## Mazda RX4	21.0	6	160.0	110	3.90	2.620	16.46	0	1	4	4
## Mazda RX4 Wag	21.0	6	160.0	110	3.90	2.875	17.02	0	1	4	4
## Hornet 4 Drive	21.4	6	258.0	110	3.08	3.215	19.44	1	0	3	1
## Hornet Sportabout	18.7	8	360.0	175	3.15	3.440	17.02	0	0	3	2
## Valiant	18.1	6	225.0	105	2.76	3.460	20.22	1	0	3	1
## Duster 360	14.3	8	360.0	245	3.21	3.570	15.84	0	0	3	4
## Merc 280	19.2	6	167.6	123	3.92	3.440	18.30	1	0	4	4
## Merc 280C	17.8	6	167.6	123	3.92	3.440	18.90	1	0	4	4
## Merc 450SE	16.4	8	275.8	180	3.07	4.070	17.40	0	0	3	3
## Merc 450SL	17.3	8	275.8	180	3.07	3.730	17.60	0	0	3	3
## Merc 450SLC	15.2	8	275.8	180	3.07	3.780	18.00	0	0	3	3
## Cadillac Fleetwood	10.4	8	472.0	205	2.93	5.250	17.98	0	0	3	4
## Lincoln Continental	10.4	8	460.0	215	3.00	5.424	17.82	0	0	3	4
## Chrysler Imperial	14.7	8	440.0	230	3.23	5.345	17.42	0	0	3	4
## Dodge Challenger	15.5	8	318.0	150	2.76	3.520	16.87	0	0	3	2
## AMC Javelin	15.2	8	304.0	150	3.15	3.435	17.30	0	0	3	2
## Camaro Z28	13.3	8	350.0	245	3.73	3.840	15.41	0	0	3	4
## Pontiac Firebird	19.2	8	400.0	175	3.08	3.845	17.05	0	0	3	2
## Lotus Europa	30.4	4	95.1	113	3.77	1.513	16.90	1	1	5	2
## Ford Pantera L	15.8	8	351.0	264	4.22	3.170	14.50	0	1	5	4
## Ferrari Dino	19.7	6	145.0	175	3.62	2.770	15.50	0	1	5	6
## Maserati Bora	15.0	8	301.0	335	3.54	3.570	14.60	0	1	5	8
## Volvo 142E	21.4	4	121.0	109	4.11	2.780	18.60	1	1	4	2

- Найдите все автомобили мощностью не менее 100 лошадиных сил (`hp`) и 4 цилиндрами (`cyl`) в датафрейме `mtcars`.

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
## Lotus Europa	30.4	4	95.1	113	3.77	1.513	16.9	1	1	5	2
## Volvo 142E	21.4	4	121.0	109	4.11	2.780	18.6	1	1	4	2

- Посчитайте максимальную массу (`wt`) автомобиля в выборке, воспользовавшись функцией `max()`:

```
## [1] 5.424
```

- Посчитайте максимальную массу (`wt`) автомобиля в выборке, воспользовавшись функцией `min()`:

```
## [1] 1.513
```

- Найдите строчку датафрейма `mtcars` с самым легким автомобилем.

```
##          mpg cyl disp hp drat    wt  qsec vs am gear carb
## Lotus Europa 30.4   4 95.1 113 3.77 1.513 16.9   1  1     5     2
```

- Извлеките строчки датафрейма `mtcars` с автомобилями, масса которых ниже средней массы.

```
##          mpg cyl disp hp drat    wt  qsec vs am gear carb
## Mazda RX4      21.0   6 160.0 110 3.90 2.620 16.46   0  1     4     4
## Mazda RX4 Wag  21.0   6 160.0 110 3.90 2.875 17.02   0  1     4     4
## Datsun 710     22.8   4 108.0  93 3.85 2.320 18.61   1  1     4     1
## Hornet 4 Drive 21.4   6 258.0 110 3.08 3.215 19.44   1  0     3     1
## Merc 240D      24.4   4 146.7  62 3.69 3.190 20.00   1  0     4     2
## Merc 230       22.8   4 140.8  95 3.92 3.150 22.90   1  0     4     2
## Fiat 128        32.4   4  78.7  66 4.08 2.200 19.47   1  1     4     1
## Honda Civic     30.4   4  75.7  52 4.93 1.615 18.52   1  1     4     2
## Toyota Corolla 33.9   4  71.1  65 4.22 1.835 19.90   1  1     4     1
## Toyota Corona   21.5   4 120.1  97 3.70 2.465 20.01   1  0     3     1
## Fiat X1-9       27.3   4  79.0  66 4.08 1.935 18.90   1  1     4     1
## Porsche 914-2   26.0   4 120.3  91 4.43 2.140 16.70   0  1     5     2
## Lotus Europa    30.4   4 95.1 113 3.77 1.513 16.90   1  1     5     2
## Ford Pantera L 15.8   8 351.0 264 4.22 3.170 14.50   0  1     5     4
## Ferrari Dino    19.7   6 145.0 175 3.62 2.770 15.50   0  1     5     6
## Volvo 142E      21.4   4 121.0 109 4.11 2.780 18.60   1  1     4     2
```

- Масса автомобиля указана в тысячах фунтов. Создайте колонку `wt_kg` с массой автомобиля в килограммах. Результат округлите до целых значений с помощью функции `round()`.

1 фунт = 0.45359237 кг.

```
##          mpg cyl disp hp drat    wt  qsec vs am gear carb wt_kg
## Mazda RX4      21.0   6 160.0 110 3.90 2.620 16.46   0  1     4     4 1188
## Mazda RX4 Wag  21.0   6 160.0 110 3.90 2.875 17.02   0  1     4     4 1304
## Datsun 710     22.8   4 108.0  93 3.85 2.320 18.61   1  1     4     1 1052
## Hornet 4 Drive 21.4   6 258.0 110 3.08 3.215 19.44   1  0     3     1 1458
## Hornet Sportabout 18.7   8 360.0 175 3.15 3.440 17.02   0  0     3     2 1560
## Valiant        18.1   6 225.0 105 2.76 3.460 20.22   1  0     3     1 1569
## Duster 360     14.3   8 360.0 245 3.21 3.570 15.84   0  0     3     4 1619
## Merc 240D      24.4   4 146.7  62 3.69 3.190 20.00   1  0     4     2 1447
## Merc 230       22.8   4 140.8  95 3.92 3.150 22.90   1  0     4     2 1429
## Merc 280       19.2   6 167.6 123 3.92 3.440 18.30   1  0     4     4 1560
## Merc 280C      17.8   6 167.6 123 3.92 3.440 18.90   1  0     4     4 1560
## Merc 450SE     16.4   8 275.8 180 3.07 4.070 17.40   0  0     3     3 1846
## Merc 450SL     17.3   8 275.8 180 3.07 3.730 17.60   0  0     3     3 1692
## Merc 450SLC    15.2   8 275.8 180 3.07 3.780 18.00   0  0     3     3 1715
## Cadillac Fleetwood 10.4   8 472.0 205 2.93 5.250 17.98   0  0     3     4 2381
## Lincoln Continental 10.4   8 460.0 215 3.00 5.424 17.82   0  0     3     4 2460
## Chrysler Imperial 14.7   8 440.0 230 3.23 5.345 17.42   0  0     3     4 2424
```

```

## Fiat 128          32.4   4 78.7 66 4.08 2.200 19.47 1 1 4 1 998
## Honda Civic      30.4   4 75.7 52 4.93 1.615 18.52 1 1 4 2 733
## Toyota Corolla   33.9   4 71.1 65 4.22 1.835 19.90 1 1 4 1 832
## Toyota Corona    21.5   4 120.1 97 3.70 2.465 20.01 1 0 3 1 1118
## Dodge Challenger 15.5   8 318.0 150 2.76 3.520 16.87 0 0 3 2 1597
## AMC Javelin       15.2   8 304.0 150 3.15 3.435 17.30 0 0 3 2 1558
## Camaro Z28        13.3   8 350.0 245 3.73 3.840 15.41 0 0 3 4 1742
## Pontiac Firebird 19.2   8 400.0 175 3.08 3.845 17.05 0 0 3 2 1744
## Fiat X1-9          27.3   4 79.0 66 4.08 1.935 18.90 1 1 4 1 878
## Porsche 914-2      26.0   4 120.3 91 4.43 2.140 16.70 0 1 5 2 971
## Lotus Europa        30.4   4 95.1 113 3.77 1.513 16.90 1 1 5 2 686
## Ford Pantera L     15.8   8 351.0 264 4.22 3.170 14.50 0 1 5 4 1438
## Ferrari Dino       19.7   6 145.0 175 3.62 2.770 15.50 0 1 5 6 1256
## Maserati Bora       15.0   8 301.0 335 3.54 3.570 14.60 0 1 5 8 1619
## Volvo 142E          21.4   4 121.0 109 4.11 2.780 18.60 1 1 4 2 1261

```

7.7 Условные конструкции

- Создайте вектор vec5:

```
vec5 <- c(5, 20, 30, 0, 2, 9)
```

- Создайте новый строковый вектор, где на месте чисел больше 10 в vec5 будет стоять “большое число”, а на месте остальных чисел — “маленькое число”.

```

## [1] "
## [5] "

```

- Загрузите файл heroes_information.csv в переменную heroes.

```
heroes <- read.csv("data/heroes_information.csv",
                    stringsAsFactors = FALSE,
                    na.strings = c("-", "-99"))
```

- Создайте новую колонку hair в heroes, в которой будет значение "Bold" для тех супергероев, у которых в колонке Hair.color стоит "No Hair", и значение "Hairy" во всех остальных случаях.

```

##   X      name Gender Eye.color           Race Hair.color Height
## 1 0    A-Bomb  Male  yellow        Human  No Hair    203
## 2 1    Abe Sapien  Male   blue  Icthyo Sapien  No Hair    191
## 3 2    Abin Sur  Male   blue  Ungaran  No Hair    185
## 4 3 Abomination  Male  green Human / Radiation  No Hair    203
## 5 4    Abraxas  Male   blue Cosmic Entity  Black     NA
## 6 5 Absorbing Man  Male   blue        Human  No Hair    193
##                   Publisher Skin.color Alignment Weight  hair

```

```
## 1   Marvel Comics      <NA>    good   441 Bold
## 2 Dark Horse Comics   blue     good    65  Bold
## 3       DC Comics      red     good    90  Bold
## 4   Marvel Comics      <NA>    bad    441 Bold
## 5   Marvel Comics      <NA>    bad     NA Hairy
## 6   Marvel Comics      <NA>    bad    122 Bold
```

- Создайте новую колонку `tall` в `heroes`, в которой будет значение "tall" для тех супергероев, у которых в колонке `Height` стоит число больше 190, значение "short" для тех супергероев, у которых в колонке `Height` стоит число меньше 170, и значение "middle" во всех остальных случаях.

7.8 Создание функций

- Создайте функцию `plus_one()`, которая принимает число и возвращает это же число + 1.
- Проверьте функцию `plus_one()` на числе 41.

```
plus_one(41)
```

```
## [1] 42
```

- Создайте функцию `circle_area`, которая вычисляет площадь круга по радиусу согласно формуле πr^2 .
- Посчитайте площадь круга с радиусом 5.

```
## [1] 78.53982
```

- Создайте функцию `cels2fahr()`, которая будет превращать градусы по Цельсию в градусы по Фаренгейту.
- Проверьте на значениях -100, -40 и 0, что функция `cels2fahr()` работает корректно.

```
cels2fahr(c(-100, -40, 0))
```

```
## [1] -148  -40    32
```

- Напишите функцию `highlight()`, которая принимает на входе строковый вектор, а возвращает тот же вектор, но дополненный значением "***" в начале и конце вектора. Лучше всего это рассмотреть на примере:

```
highlight(c(" ", "    !"))
```

```
## [1] "***"    " "      "    !"    "***"
```

- Теперь сделайте функцию `highlight` более гибкой. Добавьте в нее параметр `wrapper` =, который по умолчанию равен "***". Значение параметра `wrapper` = и будет вставлено в начало и конец вектора.
- Проверьте написанную функцию на векторе с (" " !").

```
highlight(c(" ", " !"))
## [1] "***"      " "      " !" "***"
```

```
highlight(c(" ", " !"), wrapper = "_")
## [1] "_"      " "      " !" "_"
```

- Создайте функцию `trim()`, которая будет возвращать вектор без первого и последнего значения (вне зависимости от типа данных).
- Проверьте, что функция `trim()` работает корректно:

```
trim(1:7)
## [1] 2 3 4 5 6
```

```
trim(letters)
```

```
## [1] "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s" "t"
## [20] "u" "v" "w" "x" "y"
```

- Теперь добавьте в функцию `trim()` параметр `n` = со значением по умолчанию 1. Этот параметр будет обозначать сколько значений нужно отрезать слева и справа от вектора.
- Проверьте полученную функцию:

```
trim(letters)
```

```
## [1] "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s" "t"
## [20] "u" "v" "w" "x" "y"
```

```
trim(letters, n = 2)
```

```
## [1] "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s" "t" "u"
## [20] "v" "w" "x"
```

- Сделайте так, чтобы функция `trim()` работала корректно с `n = 0`, т.е. функция возвращала бы исходный вектор без изменений.

```
trim(letters, n = 0)
```

```
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"
```

- Теперь добавьте проверку на адекватность входных данных: функция `trim()` должна выдавать ошибку, если `n` = меньше нуля или если `n` = слишком большой и отрезает все значения вектора:
- Проверьте полученную функцию `trim()`:

```
trim(1:6, 3)
```

```
## Error in trim(1:6, 3): n !
```

```
trim(1:6, -1)
```

```
## Error in trim(1:6, -1): n !
```

- Создайте функцию `na_n()`, которая будет возвращать количество `NA` в векторе.
- Проверьте функцию `na_n()` на векторе:

```
na_n(c(NA, 3:5, NA, 2, NA))
```

```
## [1] 3
```

- Напишите функцию `factors()`, которая будет возвращать все делители числа в виде числового вектора.

Здесь может понадобиться оператор для получения остатка от деления:
`%%`.

- Проверьте функцию `factors()` на простых и сложных числах:

```
factors(3)
```

```
## [1] 1 3
```

```
factors(161)
```

```
## [1] 1 7 23 161
```

```
factors(1984)
```

```
## [1] 1 2 4 8 16 31 32 62 64 124 248 496 992 1984
```

- *Напишите функцию `is_prime()`, которая проверяет, является ли число простым.

Здесь может пригодиться функция `any()` — она возвращает TRUE, если в векторе есть хотя бы один TRUE.

- Проверьте какие годы были для нас простыми, а какие нет:

```
is_prime(2017)
```

```
## [1] TRUE
```

```
is_prime(2019)
```

```
## [1] FALSE
```

```
2019/3 #2019 3
```

```
## [1] 673
```

```
is_prime(2020)
```

```
## [1] FALSE
```

```
is_prime(2021)
```

```
## [1] FALSE
```

- *Создайте функцию `monotonic()`, которая возвращает TRUE, если значения в векторе не убывают (то есть каждое следующее — больше или равно предыдущему) или не возрастают.

Полезная функция для этого — `diff()` — возвращает разницу соседних значений.

```
monotonic(1:7)
```

```
## [1] TRUE
```

```
monotonic(c(1:5,5:1))
```

```
## [1] FALSE
```

```
monotonic(6:-1)
```

```
## [1] TRUE
```

```
monotonic(c(1:5, rep(5, 10), 5:10))
```

```
## [1] TRUE
```

Бинарные операторы типа `+` или `%in%` тоже представляют собой функции. Более того, мы можем создавать свои бинарные операторы! В этом нет особой сложности — нужно все так же создавать функцию (для двух переменных), главное окружать их `%` и название обрамлять обратными штихами `'`. Например, можно сделать свой бинарный оператор `%notin%`, который будет выдавать `TRUE`, если значения слева *нет* в векторе справа:

```
`%notin%` <- function(x, y) ! (x %in% y)
1:10 %notin% c(1, 4, 5)
```

```
## [1] FALSE TRUE TRUE FALSE FALSE TRUE TRUE TRUE TRUE TRUE
```

- Создайте бинарный оператор `%without%`, который будет возвращать все значения вектора слева без значений вектора справа.

```
c(" ", " ", " ", " ", " ", " ", " ") %without% c(" ", " ")
```

```
## [1] " " " " " " " "
```

- Создайте бинарный оператор `%between%`, который будет возвращать `TRUE`, если значение в векторе слева находится в *диапазоне* значений вектора справа:

```
1:10 %between% c(1, 4, 5)
```

```
## [1] TRUE TRUE TRUE TRUE TRUE FALSE FALSE FALSE FALSE
```

7.9 Семейство функций `apply()`

- Создайте матрицу `M2`:

```
M2 <- matrix(c(20:11, 11:20), nrow = 5)
M2
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    20    15    11    16
```

```
## [2,] 19 14 12 17
## [3,] 18 13 13 18
## [4,] 17 12 14 19
## [5,] 16 11 15 20

· Посчитайте максимальное значение матрицы M2 по каждой строчке.
```

```
## [1] 20 19 18 19 20

· Посчитайте максимальное значение матрицы M2 по каждому столбцу.
```

```
## [1] 20 15 15 20

· Посчитайте среднее значение матрицы M2 по каждой строке.
```

```
## [1] 15.5 15.5 15.5 15.5 15.5

· Посчитайте среднее значение матрицы M2 по каждому столбцу.
```

```
## [1] 18 13 13 18

· Создайте список list3:
```

```
list3 <- list(
  a = 1:5,
  b = 0:20,
  c = 4:24,
  d = 6:3,
  e = 6:25
)
```

· Найдите максимальное значение каждого вектора списка list3.

```
## a b c d e
## 5 20 24 6 25
```

· Посчитайте сумму каждого вектора списка list3.

```
## a b c d e
## 15 210 294 18 310
```

· Посчитайте длину каждого вектора списка list3.

```
## a b c d e
## 5 21 21 4 20
```

· Напишите функцию max_item(), которая будет принимать на входе список, а возвращать - (первый) самый длинный его элемент.

Для этого вам может понадобиться функция which.max(), которая возвращает индекс максимального значения (первого, если их несколько).

· Проверьте функцию max_item() на списке list3.

```
max_item(list3)
```

```
## [1] 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20
```

- Теперь мы сделаем сложный список list4:

```
list4 <- list(1:3, 3:40, list3)
```

- Посчитайте длину каждого вектора в списке, в т.ч. для списка внутри. Результат должен быть списком с такой же структурой, как и изначальный список list4.

Для этого может понадобиться функция `rapply()`: recursive lapply

```
## [[1]]
## [1] 3
##
## [[2]]
## [1] 38
##
## [[3]]
## [[3]]$a
## [1] 5
##
## [[3]]$b
## [1] 21
##
## [[3]]$c
## [1] 21
##
## [[3]]$d
## [1] 4
##
## [[3]]$e
## [1] 20
```

- *Загрузите набор данных `heroes` и посчитайте, сколько NA в каждом из столбцов.

Для этого удобно использовать ранее написанную функцию `na_n()`.

	X	name	Gender	Eye.color	Race	Hair.color	Height
##	0	0	29	172	304	172	217
##	Publisher	Skin.color	Alignment	Weight	hair	tall	
##	0	662	7	239	172	217	

- Используя ранее написанную функцию `is_prime()`, напишите функцию `prime_numbers()`, которая будет возвращать все простые числа до выбранного числа.

```
prime_numbers(200)
```

```
## [1] 3 5 7 11 13 17 19 23 29 31 37 41 43 47 53 59 61 67 71
## [20] 73 79 83 89 97 101 103 107 109 113 127 131 137 139 149 151 157 163 167
## [39] 173 179 181 191 193 197 199
```

7.10 magrittr::%>%

- Перепишите следующие выражения, используя %>%:

```
sqrt(sum(1:10))
```

```
## [1] 7.416198
## [1] 7.416198
```

```
abs(min(-5:5))
```

```
## [1] 5
## [1] 5
```

```
c(" ", 2, " ", sqrt(2))
```

```
## [1] " " "2" " " "1.4142135623731"
## [1] " " "2" " " "1.4142135623731"
```

Выбор строк: dplyr::slice() и dplyr::filter() {#task_filt}

- Выберите только те строчки, в которых содержится информация о супергероях тяжелее 500 кг.

```
## # A tibble: 6 x 11
##       X1 name Gender `Eye color` Race `Hair color` Height Publisher
##       <dbl> <chr> <chr> <chr> <chr> <chr> <dbl> <chr>
## 1     203 Dark~ Male   red    New ~ No Hair    267 DC Comics
## 2     283 Giga~ Female green <NA> Red      62.5 DC Comics
## 3     331 Hulk  Male   green Huma~ Green    244 Marvel C~
## 4     373 Jugg~ Male   blue  Human Red    287 Marvel C~
## 5     549 Red ~ Male   yellow Huma~ Black    213 Marvel C~
## 6     575 Sasq~ Male   red   <NA> Orange   305 Marvel C~
## # ... with 3 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>
```

- Выберите только те строчки, в которых содержится информация о женщинах-супергероях тяжелее 500 кг.

```
## # A tibble: 1 x 11
##   X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr>    <chr> <chr>      <dbl> <chr>
## 1 283 Giga~ Female green     <NA>  Red       62.5 DC Comics
## # ... with 3 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>
```

- Выберите только те строчки, в которых содержится информация о супергероях человеческой расы ("Human") женского пола. Из этих супергероев возьмите первые 5.

```
## # A tibble: 5 x 11
##   X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr>    <chr> <chr>      <dbl> <chr>
## 1 38 Arac~ Female blue     Human Blond    175 Marvel C~
## 2 63 Batg~ Female green    Human Red     170 DC Comics
## 3 65 Batg~ Female green    Human Black   165 DC Comics
## 4 72 Batw~ Female green    Human Red     178 DC Comics
## 5 96 Blac~ Female blue     Human Blond   165 DC Comics
## # ... with 3 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>
```

`# Выбор столбцов: dplyr::select() {#task_select}`

- Выберете первые 4 столбца в powers.

```
## # A tibble: 667 x 4
##   hero_names   Agility `Accelerated Healing` `Lantern Power Ring`
##   <chr>        <lgl>   <lgl>           <lgl>
## 1 3-D Man     TRUE    FALSE            FALSE
## 2 A-Bomb      FALSE   TRUE             FALSE
## 3 Abe Sapien   TRUE    TRUE             FALSE
## 4 Abin Sur    FALSE   FALSE            TRUE
## 5 Abomination FALSE   TRUE             FALSE
## 6 Abraxas     FALSE   FALSE            FALSE
## 7 Absorbing Man FALSE  FALSE            FALSE
## 8 Adam Monroe FALSE  TRUE             FALSE
## 9 Adam Strange FALSE  FALSE            FALSE
## 10 Agent Bob   FALSE  FALSE            FALSE
## # ... with 657 more rows
```

- Выберите все столбцы от Reflexes до Empathy в тиббле powers:

```
## # A tibble: 667 x 7
##   Reflexes Invulnerability `Energy Constru~ `Force Fields` `Self-Sustenanc~
##   <lgl>    <lgl>          <lgl>           <lgl>      <lgl>
## 1 FALSE    FALSE          FALSE           FALSE      FALSE
## 2 FALSE    FALSE          FALSE           FALSE      TRUE
## 3 TRUE     FALSE          FALSE           FALSE      FALSE
## 4 FALSE    FALSE          FALSE           FALSE      FALSE
## 5 FALSE    TRUE           FALSE           FALSE      FALSE
```

```

## 6 FALSE TRUE FALSE FALSE FALSE
## 7 FALSE TRUE FALSE FALSE FALSE
## 8 FALSE FALSE FALSE FALSE FALSE
## 9 FALSE FALSE FALSE FALSE FALSE
## 10 FALSE FALSE FALSE FALSE FALSE
## # ... with 657 more rows, and 2 more variables: `Anti-Gravity` <lgl>,
## #   Empathy <lgl>

```

- Выберите все столбцы тibbleа powers кроме первого (hero_names):

```

## # A tibble: 667 x 167
##   Agility `Accelerated He~ `Lantern Power ~ `Dimensional Aw~ `Cold Resistanc~
##   <lgl> <lgl> <lgl> <lgl> <lgl>
## 1 TRUE FALSE FALSE FALSE FALSE FALSE
## 2 FALSE TRUE FALSE FALSE FALSE FALSE
## 3 TRUE TRUE FALSE FALSE TRUE FALSE
## 4 FALSE FALSE TRUE FALSE FALSE FALSE
## 5 FALSE TRUE FALSE FALSE FALSE FALSE
## 6 FALSE FALSE FALSE TRUE FALSE FALSE
## 7 FALSE FALSE FALSE FALSE TRUE FALSE
## 8 FALSE TRUE FALSE FALSE FALSE FALSE
## 9 FALSE FALSE FALSE FALSE FALSE FALSE
## 10 FALSE FALSE FALSE FALSE FALSE FALSE
## # ... with 657 more rows, and 162 more variables: Durability <lgl>,
## #   Stealth <lgl>, `Energy Absorption` <lgl>, Flight <lgl>, `Danger
## #   Sense` <lgl>, `Underwater breathing` <lgl>, Marksmanship <lgl>, `Weapons
## #   Master` <lgl>, `Power Augmentation` <lgl>, `Animal Attributes` <lgl>,
## #   Longevity <lgl>, Intelligence <lgl>, `Super Strength` <lgl>,
## #   Cryokinesis <lgl>, Telepathy <lgl>, `Energy Armor` <lgl>, `Energy
## #   Blasts` <lgl>, Duplication <lgl>, `Size Changing` <lgl>, `Density
## #   Control` <lgl>, Stamina <lgl>, `Astral Travel` <lgl>, `Audio
## #   Control` <lgl>, Dexterity <lgl>, Omnitrix <lgl>, `Super Speed` <lgl>,
## #   Possession <lgl>, `Animal Oriented Powers` <lgl>, `Weapon-based
## #   Powers` <lgl>, Electrokinesis <lgl>, `Darkforce Manipulation` <lgl>, `Death
## #   Touch` <lgl>, Teleportation <lgl>, `Enhanced Senses` <lgl>,
## #   Telekinesis <lgl>, `Energy Beams` <lgl>, Magic <lgl>, Hyperkinesis <lgl>,
## #   Jump <lgl>, Clairvoyance <lgl>, `Dimensional Travel` <lgl>, `Power
## #   Sense` <lgl>, Shapeshifting <lgl>, `Peak Human Condition` <lgl>,
## #   Immortality <lgl>, Camouflage <lgl>, `Element Control` <lgl>,
## #   Phasing <lgl>, `Astral Projection` <lgl>, `Electrical Transport` <lgl>,
## #   `Fire Control` <lgl>, Projection <lgl>, Summoning <lgl>, `Enhanced
## #   Memory` <lgl>, Reflexes <lgl>, Invulnerability <lgl>, `Energy
## #   Constructs` <lgl>, `Force Fields` <lgl>, `Self-Sustenance` <lgl>,
## #   `Anti-Gravity` <lgl>, Empathy <lgl>, `Power Nullifier` <lgl>, `Radiation
## #   Control` <lgl>, `Psionic Powers` <lgl>, Elasticity <lgl>, `Substance
## #   Secretion` <lgl>, `Elemental Transmogrification` <lgl>,
## #   `Technopath/Cyberpath` <lgl>, `Photographic Reflexes` <lgl>, `Seismic

```

```
## # Power` <lg1>, Animation <lg1>, Precognition <lg1>, `Mind Control` <lg1>,
## # `Fire Resistance` <lg1>, `Power Absorption` <lg1>, `Enhanced
## # Hearing` <lg1>, `Nova Force` <lg1>, Insanity <lg1>, Hypnokinesis <lg1>,
## # `Animal Control` <lg1>, `Natural Armor` <lg1>, Intangibility <lg1>,
## # `Enhanced Sight` <lg1>, `Molecular Manipulation` <lg1>, `Heat
## # Generation` <lg1>, Adaptation <lg1>, Gliding <lg1>, `Power Suit` <lg1>,
## # `Mind Blast` <lg1>, `Probability Manipulation` <lg1>, `Gravity
## # Control` <lg1>, Regeneration <lg1>, `Light Control` <lg1>,
## # Echolocation <lg1>, Levitation <lg1>, `Toxin and Disease Control` <lg1>,
## # Banish <lg1>, `Energy Manipulation` <lg1>, `Heat Resistance` <lg1>,
## # `Natural Weapons` <lg1>, ...
```

7.11 Сортировка строк: dplyr::arrange()

- Выберите из тibbleа heroes колонки name, Gender, Height и отсортируйте строчки по возрастанию Height.

```
## # A tibble: 734 x 3
##   name      Gender Height
##   <chr>     <chr>   <dbl>
## 1 Utgard-Loki  Male    15.2
## 2 Bloodwraith  Male    30.5
## 3 King Kong    Male    30.5
## 4 Anti-Monitor Male    61
## 5 Giganta     Female   62.5
## 6 Krypto       Male    64
## 7 Yoda         Male    66
## 8 Jack-Jack   Male    71
## 9 Howard the Duck Male    79
## 10 Godzilla    <NA>    108
## # ... with 724 more rows
```

- Выберите из тibbleа heroes колонки name, Gender, Height и отсортируйте строчки по убыванию Height.

```
## # A tibble: 734 x 3
##   name      Gender Height
##   <chr>     <chr>   <dbl>
## 1 Fin Fang Foom  Male    975
## 2 Galactus     Male    876
## 3 Groot        Male    701
## 4 MODOK        Male    366
## 5 Wolfsbane   Female   366
## 6 Onslaught    Male    305
## 7 Sasquatch    Male    305
## 8 Ymir         Male    305.
## 9 Rey          Female   297
```

```
## 10 Juggernaut     Male      287
## # ... with 724 more rows
· Выберите из тиббла heroes колонки name, Gender, Height и отсортируйте
строчки сначала по Gender, затем по убыванию Height.

## # A tibble: 734 x 3
##   name    Gender Height
##   <chr>   <chr>   <dbl>
## 1 Wolfsbane Female   366
## 2 Rey       Female   297
## 3 Bloodaxe Female   218
## 4 Thundra   Female   218
## 5 Hela      Female   213
## 6 Frenzy    Female   211
## 7 She-Hulk   Female   201
## 8 Ardina    Female   193
## 9 Starfire   Female   193
## 10 Valkyrie  Female   191
## # ... with 724 more rows
```

7.12 Уникальные значения: dplyr::distinct()

- Извлеките уникальные значения столбца Eye color из тиббла heroes.

```
## # A tibble: 23 x 1
##   `Eye color`
##   <chr>
## 1 yellow
## 2 blue
## 3 green
## 4 brown
## 5 <NA>
## 6 red
## 7 violet
## 8 white
## 9 purple
## 10 black
## # ... with 13 more rows
```

- Извлеките уникальные значения столбца Hair color из тиббла heroes.

```
## # A tibble: 30 x 1
##   `Hair color`
##   <chr>
## 1 No Hair
## 2 Black
## 3 Blond
```

```
##  4 Brown
##  5 <NA>
##  6 White
##  7 Purple
##  8 Orange
##  9 Pink
## 10 Red
## # ... with 20 more rows
```

7.13 Создание колонок: dplyr::mutate() и dplyr::transmute()

- Создайте колонку `height_m` с ростом супергероев в метрах, затем выберите только колонки `name` и `height_m`.

```
## # A tibble: 734 x 2
##   name      height_m
##   <chr>     <dbl>
## 1 A-Bomb    2.03
## 2 Abe Sapien 1.91
## 3 Abin Sur   1.85
## 4 Abomination 2.03
## 5 Abraxas    NA
## 6 Absorbing Man 1.93
## 7 Adam Monroe  NA
## 8 Adam Strange 1.85
## 9 Agent 13    1.73
## 10 Agent Bob   1.78
## # ... with 724 more rows
```

- Создайте новую колонку `hair` в `heroes`, в которой будет значение "Bold" для тех супергероев, у которых в колонке `Hair.color` стоит "No Hair", и значение "Hairy" во всех остальных случаях. Затем выберите только колонки `name`, `Hair.color`, `hair`.

```
## # A tibble: 734 x 3
##   name      `Hair color` hair
##   <chr>     <chr>     <chr>
## 1 A-Bomb    No Hair   Bold
## 2 Abe Sapien No Hair   Bold
## 3 Abin Sur   No Hair   Bold
## 4 Abomination No Hair   Bold
## 5 Abraxas    Black     Hairy
## 6 Absorbing Man No Hair   Bold
## 7 Adam Monroe Blond     Hairy
## 8 Adam Strange Blond     Hairy
## 9 Agent 13    Blond     Hairy
## 10 Agent Bob   Brown     Hairy
```

```
## # ... with 724 more rows
```

7.14 Агрегация: dplyr::group_by() %>% summarise()

- Посчитайте количество супергероев по расам и отсортируйте по убыванию. Извлеките первые 5 строк.

```
## # A tibble: 5 x 2
##   Race      n
##   <chr>    <int>
## 1 <NA>      304
## 2 Human     208
## 3 Mutant    63
## 4 God / Eternal  14
## 5 Cyborg    11
```

- Посчитайте средний пост по полу.

```
## # A tibble: 3 x 2
##   Gender height_mean
##   <chr>    <dbl>
## 1 Female     175.
## 2 Male       192.
## 3 <NA>       177.
```

7.15 Операции с несколькими колонками: across()

- Посчитайте количество NA в каждой колонке, группируя по полу (Gender).

```
## # A tibble: 3 x 11
##   Gender X1 name `Eye color` `Race` `Hair color` Height Publisher
##   <chr>  <int> <int>    <int>    <int>    <int>    <int>    <int>
## 1 Female    0     0        41      98       38      56       0
## 2 Male      0     0       121     184      123     147       0
## 3 <NA>      0     0        10      22       11      14       0
## # ... with 3 more variables: `Skin color` <int>, Alignment <int>, Weight <int>
```

- Посчитайте количество NA в каждой колонке, которая заканчивается на "color", группируя по полу (Gender).

```
## # A tibble: 3 x 4
##   Gender `Eye color` `Hair color` `Skin color`
##   <chr>    <int>      <int>      <int>
## 1 Female      41        38       186
## 2 Male       121       123       449
## 3 <NA>        10        11        27
```

- Создайте из тиббла heroes новый тиббл с колонками name, Height и Weight, где для каждого героя содержится значение " ", если его рост или вес выше среднего по колонке и " ", если ниже или равен среднему.

```
## # A tibble: 734 x 3
##   name      Height     Weight
##   <chr>     <chr>     <chr>
## 1 A-Bomb
## 2 Abe Sapien
## 3 Abin Sur
## 4 Abomination
## 5 Abraxas    <NA>      <NA>
## 6 Absorbing Man
## 7 Adam Monroe  <NA>      <NA>
## 8 Adam Strange
## 9 Agent 13
## 10 Agent Bob
## # ... with 724 more rows
```

- Создайте из тиббла heroes новый тиббл с колонками Gender, name, Height и Weight, где для каждого героя содержится значение " ", если его рост или вес выше среднего по колонке и " ", если ниже или равен среднему *внутри соответствующей группы по полу*.

```
## # A tibble: 734 x 4
## # Groups:   Gender [3]
##   Gender name      Height     Weight
##   <chr>  <chr>     <chr>     <chr>
## 1 Male   A-Bomb
## 2 Male   Abe Sapien
## 3 Male   Abin Sur
## 4 Male   Abomination
## 5 Male   Abraxas    <NA>      <NA>
## 6 Male   Absorbing Man
## 7 Male   Adam Monroe  <NA>      <NA>
## 8 Male   Adam Strange
## 9 Female Agent 13
## 10 Male  Agent Bob
## # ... with 724 more rows
```

7.16 Соединение датафреймов: *join {#task_join}

- Создайте тиббл web_creators, в котором будут супергерои, которые могут плести паутину, т.е. у них стоит TRUE в колонке Web Creation в тиббле powers.

```
## # A tibble: 16 x 12
```

```

##      X1 name  Gender `Eye color` Race  `Hair color` Height Publisher
##      <dbl> <chr> <chr> <chr>     <chr> <chr>      <dbl> <chr>
## 1    33 Anti~ Male   blue   Symb~ Blond       229 Marvel C~
## 2    38 Arac~ Female blue Human Blond       175 Marvel C~
## 3    161 Carn~ Male   green  Symb~ Red        185 Marvel C~
## 4    335 Hybr~ Male   brown  Symb~ Black      175 Marvel C~
## 5    479 Myst~ Male   brown Human No Hair   180 Marvel C~
## 6    580 Scar~ Male   brown Clone Brown     193 Marvel C~
## 7    597 Silk  Female brown Human Black      NA Marvel C~
## 8    620 Spid~ Female blue Human Brown      170 Marvel C~
## 9    621 Spid~ Female blue Human Blond      165 Marvel C~
## 10   622 Spid~ Male   hazel Human Brown      178 Marvel C~
## 11   623 Spid~ <NA>   red   Human Brown      178 Marvel C~
## 12   624 Spid~ Male   brown Human Black      157 Marvel C~
## 13   673 Toxin  Male   blue  Symb~ Brown     188 Marvel C~
## 14   674 Toxin  Male   black Symb~ Blond     191 Marvel C~
## 15   689 Venom  Male   blue  Symb~ Strawberry ~ 191 Marvel C~
## 16   692 Veno~ Male   <NA>  Symb~ <NA>     226 Marvel C~
## # ... with 4 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>,
## #   `Web Creation` <lgl>

```

- Найдите всех супергероев, которые присутствуют в heroes, но отсутствуют в powers. Ответом должен быть строковый вектор с именами супергероев.

```

## [1] "Agent 13"          "Alfred Pennyworth" "Arsenal"
## [4] "Batgirl III"        "Batgirl V"           "Beetle"
## [7] "Black Goliath"       "Black Widow II"    "Blaquesmith"
## [10] "Bolt"                "Boomer"             "Box"
## [13] "Box III"            "Captain Mar-vell" "Cat II"
## [16] "Cecilia Reyes"      "Clea"                "Clock King"
## [19] "Colin Wagner"        "Colossal Boy"     "Corsair"
## [22] "Cypher"              "Danny Cooper"      "Darkside"
## [25] "ERG-1"                "Fixer"              "Franklin Storm"
## [28] "Giant-Man"           "Giant-Man II"     "Goliath"
## [31] "Goliath"              "Goliath"            "Guardian"
## [34] "Hawkwoman"            "Hawkwoman II"     "Hawkwoman III"
## [37] "Howard the Duck"      "Jack Bauer"         "Jesse Quick"
## [40] "Jessica Sanders"      "Jigsaw"             "Jyn Erso"
## [43] "Kid Flash II"         "Kingpin"            "Meteorite"
## [46] "Mister Zsasz"         "Mogo"               "Moloch"
## [49] "Morph"                 "Nite Owl II"        "Omega Red"
## [52] "Paul Blart"           "Penance"            "Penance I"
## [55] "Plastic Lad"          "Power Man"          "Renata Soliz"
## [58] "Ronin"                  "Shrinking Violet"  "Snake-Eyes"
## [61] "Spider-Carnage"        "Spider-Woman II"   "Stacy X"
## [64] "Thunderbird II"        "Two-Face"            "Vagabond"
## [67] "Vision II"             "Vulcan"             "Warbird"

```

```

## [70] "White Queen"      "Wiz Kid"          "Wondra"
## [73] "Wyatt Wingfoot"    "Yellow Claw"

• Найдите всех супергероев, которые присутствуют в powers, но отсутствуют в heroes. Ответом должен быть строковый вектор с именами супергероев.

## [1] "3-D Man"           "Bananaman"        "Bizarro-Girl"
## [4] "Black Vulcan"      "Blue Streak"       "Bradley"
## [7] "Clayface"          "Concrete"         "Dementor"
## [10] "Doctor Poison"     "Fire"              "Hellgramite"
## [13] "Lara Croft"        "Little Epic"       "Lord Voldemort"
## [16] "Orion"              "Peek-a-Boo"        "Queen Hippolyta"
## [19] "Reactron"          "SHDB"              "Stretch Armstrong"
## [22] "TEST"               "Tommy Clarke"      "Tyrant"

```

7.17 Tidy data

- Для начала создайте тибл heroes_weight, скопировав код:

```

heroes_weight <- heroes %>%
  filter(Publisher %in% c("DC Comics", "Marvel Comics")) %>%
  group_by(Gender, Publisher) %>%
  summarise(weight_mean = mean(Weight, na.rm = TRUE)) %>%
  drop_na()
heroes_weight

```

```

## # A tibble: 4 x 3
## # Groups:   Gender [2]
##   Gender Publisher   weight_mean
##   <chr>   <chr>        <dbl>
## 1 Female  DC Comics    76.8
## 2 Female  Marvel Comics 80.1
## 3 Male    DC Comics    113.
## 4 Male    Marvel Comics 134.

```

Функция drop_na() позволяет выбросить все строчки, в которых встречается NA.

- Превратите тибл heroes_weight в широкий тибл:

```

## # A tibble: 2 x 3
## # Groups:   Gender [2]
##   Gender `DC Comics` `Marvel Comics`
##   <chr>      <dbl>        <dbl>
## 1 Female      76.8        80.1
## 2 Male        113.        134.

```

- Затем превратите его обратно в длинный тибл:

```
## # A tibble: 4 x 3
## # Groups:   Gender [2]
##   Gender Publisher    weight_mean
##   <chr>  <chr>          <dbl>
## 1 Female DC Comics      76.8
## 2 Female Marvel Comics 80.1
## 3 Male   DC Comics     113.
## 4 Male   Marvel Comics 134.
```

- Сделайте powers длинным тиблом с тремя колонками: hero_names, power (название суперсилы) и has (наличие суперсилы у данного супергероя).

```
## # A tibble: 111,389 x 3
##   hero_names power           has
##   <chr>      <chr>          <lgl>
## 1 3-D Man    Agility        TRUE
## 2 3-D Man    Accelerated Healing FALSE
## 3 3-D Man    Lantern Power Ring FALSE
## 4 3-D Man    Dimensional Awareness FALSE
## 5 3-D Man    Cold Resistance FALSE
## 6 3-D Man    Durability     FALSE
## 7 3-D Man    Stealth        FALSE
## 8 3-D Man    Energy Absorption FALSE
## 9 3-D Man    Flight         FALSE
## 10 3-D Man   Danger Sense   FALSE
## # ... with 111,379 more rows
```

- Сделайте тибл powers обратно широким, но с новой структурой: каждая строчка означает суперсилу, а каждая колонка - супергероя (за исключением первой колонки - названия суперсилы).

```
## # A tibble: 167 x 668
##   power `3-D Man` `A-Bomb` `Abe Sapien` `Abin Sur` Abomination Abraxas
##   <chr>  <lgl>    <lgl>    <lgl>    <lgl>    <lgl>    <lgl>
## 1 Agil~ TRUE     FALSE    TRUE     FALSE    FALSE    FALSE
## 2 Acce~ FALSE    TRUE     TRUE     FALSE    TRUE    FALSE
## 3 Lant~ FALSE    FALSE    FALSE    TRUE    FALSE    FALSE
## 4 Dime~ FALSE    FALSE    FALSE    FALSE    FALSE    TRUE
## 5 Cold~ FALSE    FALSE    TRUE     FALSE    FALSE    FALSE
## 6 Dura~ FALSE    TRUE     TRUE     FALSE    FALSE    FALSE
## 7 Stea~ FALSE    FALSE    FALSE    FALSE    FALSE    FALSE
## 8 Ener~ FALSE    FALSE    FALSE    FALSE    FALSE    FALSE
## 9 Flig~ FALSE    FALSE    FALSE    FALSE    FALSE    TRUE
## 10 Dang~ FALSE   FALSE    FALSE    FALSE    FALSE    FALSE
## # ... with 157 more rows, and 661 more variables: `Absorbing Man` <lgl>, `Adam
## # Monroe` <lgl>, `Adam Strange` <lgl>, `Agent Bob` <lgl>, `Agent Zero` <lgl>,
## # `Air-Walker` <lgl>, Ajax <lgl>, `Alan Scott` <lgl>, `Alex Mercer` <lgl>,
## # `Alex Woolsly` <lgl>, Alien <lgl>, `Allan Quatermain` <lgl>, Amazo <lgl>,
```

```
## # Ammo <lgl>, `Ando Masahashi` <lgl>, Angel <lgl>, `Angel Dust` <lgl>, `Angel  
## # Salvadore` <lgl>, Angela <lgl>, `Animal Man` <lgl>, Annihilus <lgl>,  
## # `Ant-Man` <lgl>, `Ant-Man II` <lgl>, `Anti-Monitor` <lgl>,  
## # `Anti-Spawn` <lgl>, `Anti-Venom` <lgl>, Apocalypse <lgl>, Aquababy <lgl>,  
## # Aqualad <lgl>, Aquaman <lgl>, Arachne <lgl>, Archangel <lgl>,  
## # Arclight <lgl>, Ardina <lgl>, Ares <lgl>, Ariel <lgl>, Armor <lgl>, `Astro  
## # Boy` <lgl>, Atlas <lgl>, Atom <lgl>, `Atom Girl` <lgl>, `Atom II` <lgl>,  
## # `Atom III` <lgl>, `Atom IV` <lgl>, Aurora <lgl>, Azazel <lgl>,  
## # Azrael <lgl>, Aztar <lgl>, Bananaman <lgl>, Bane <lgl>, Banshee <lgl>,  
## # Bantam <lgl>, Batgirl <lgl>, `Batgirl IV` <lgl>, `Batgirl VI` <lgl>,  
## # Batman <lgl>, `Batman II` <lgl>, Battlestar <lgl>, `Batwoman V` <lgl>,  
## # Beak <lgl>, Beast <lgl>, `Beast Boy` <lgl>, `Ben 10` <lgl>, `Beta Ray  
## # Bill` <lgl>, Beyonder <lgl>, `Big Barda` <lgl>, `Big Daddy` <lgl>, `Big  
## # Man` <lgl>, `Bill Harken` <lgl>, `Billy Kincaid` <lgl>, Binary <lgl>,  
## # `Bionic Woman` <lgl>, `Bird-Brain` <lgl>, `Bird-Man` <lgl>, `Bird-Man  
## # II` <lgl>, Birdman <lgl>, Bishop <lgl>, Bizarro <lgl>,  
## # `Bizarro-Girl` <lgl>, `Black Abbott` <lgl>, `Black Adam` <lgl>, `Black  
## # Bolt` <lgl>, `Black Canary` <lgl>, `Black Cat` <lgl>, `Black Flash` <lgl>,  
## # `Black Knight III` <lgl>, `Black Lightning` <lgl>, `Black Mamba` <lgl>,  
## # `Black Manta` <lgl>, `Black Panther` <lgl>, `Black Vulcan` <lgl>, `Black  
## # Widow` <lgl>, Blackout <lgl>, Blackwing <lgl>, Blackwulf <lgl>,  
## # Blade <lgl>, `Bling!` <lgl>, Blink <lgl>, Blizzard <lgl>, `Blizzard  
## # II` <lgl>, ...
```


Глава 8

Решения заданий

```
##Начало работы в R {#solution_begin}
```

- Разделите 9801 на 9.

```
9801/9
```

```
## [1] 1089
```

- Посчитайте логарифм от 8912162342 по основанию 6.

```
log(2176782336, 6)
```

```
## [1] 12
```

- Теперь натуральный логарифм 10 и умножьте его на 5.

```
log(10)*5
```

```
## [1] 11.51293
```

- С помощью функции `sin()` посчитайте $\sin(\pi)$, $\sin\left(\frac{\pi}{2}\right)$, $\sin\left(\frac{\pi}{6}\right)$.

Значение π - зашитая в R константа (`pi`).

```
sin(pi)
```

```
## [1] 1.224647e-16
```

```
sin(pi/2)
```

```
## [1] 1
```

```
sin(pi/6)
```

```
## [1] 0.5
```

Создание векторов {#solution_new_vecs}

- Создайте вектор из значений 2, 30 и 4000.

```
c(2, 30, 4000)
```

```
## [1] 2 30 4000
```

- Создайте вектор от 1 до 20.

```
1:20
```

```
## [1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20
```

- Создайте вектор от 20 до 1.

```
20:1
```

```
## [1] 20 19 18 17 16 15 14 13 12 11 10 9 8 7 6 5 4 3 2 1
```

Функция `sum()` возвращает сумму элементов вектора на входе. Посчитайте сумму первых 100 натуральных чисел (т.е. всех целых чисел от 1 до 100).

```
sum(1:100)
```

```
## [1] 5050
```

- Создайте вектор от 1 до 20 и снова до 1. Число 20 должно присутствовать только один раз!

```
c(1:20, 19:1)
```

```
## [1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 19 18 17 16 15
## [26] 14 13 12 11 10 9 8 7 6 5 4 3 2 1
```

- Создайте вектор значений 5, 4, 3, 2, 2, 3, 4, 5:

```
c(5:2, 2:5)
```

```
## [1] 5 4 3 2 2 3 4 5
```

- Создайте вектор 2, 4, 6, ..., 18, 20.

```
seq(2, 20, 2)
```

```
## [1] 2 4 6 8 10 12 14 16 18 20
```

- Создайте вектор 0.1, 0.2, 0.3, ..., 0.9, 1.

```
seq(0, 1, 0.1)
```

```
## [1] 0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0
```

- 2020 год — високосный. Следующий високосный год через 4 года — это будет 2024 год. Составьте календарь всех високосных годов XXI века, начиная с 2020 года.

2100 год относится к XXI веку, а не к XXII.

```
seq(2020, 2100, 4)
```

```
## [1] 2020 2024 2028 2032 2036 2040 2044 2048 2052 2056 2060 2064 2068 2072 2076
## [16] 2080 2084 2088 2092 2096 2100
```

- Создайте вектор, состоящий из 20 повторений “Хэй!”.

```
rep("!", 20)
```

```
## [1] "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!" "!"
```

- Как я и говорил, многие функции, работающие с одним значением на входе, также прекрасно работают и с целыми векторами. Попробуйте посчитать квадратный корень чисел от 1 до 10 с помощью функции `sqrt()` и сохраните результат в векторе `roots`.

```
roots <- sqrt(1:10)
```

```
roots
```

```
## [1] 1.000000 1.414214 1.732051 2.000000 2.236068 2.449490 2.645751 2.828427
## [9] 3.000000 3.162278
```

- Давайте убедимся, что это действительно квадратные корни. Для этого возведите все значения вектора `roots` в квадрат!

```
roots ^ 2
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

- Если все верно, то того же самого можно добиться поэлементным умножением вектора `roots` на себя.

```
roots * roots
```

```
## [1] 1 2 3 4 5 6 7 8 9 10
```

- Создайте вектор из одной единицы, двух двоек, трех троек, ..., девяти девяток.

```
rep(1:9, 1:9)
```

```
## [1] 1 2 2 3 3 3 4 4 4 4 5 5 5 5 5 6 6 6 6 6 6 6 6 6 7 7 7 7 7 7 7 7 7 8 8 8 8 8 8 8 8 8 9 9  
## [39] 9 9 9 9 9 9 9
```

8.1 Приведение типов

- Сделайте вектор `vec1`, в котором соедините 3, а также значения " " и " ".

```
vec1 <- c(3, " ", " ")  
vec1
```

```
## [1] "3"      " "      " "
```

- Попробуйте вычесть TRUE из 10.

```
10 - TRUE
```

```
## [1] 9
```

- Соедините значение 10 и TRUE в вектор `vec2`.

```
vec2 <- c(10, TRUE)  
vec2
```

```
## [1] 10 1
```

- Соедините вектор `vec2` и значение "т":

```
c(vec2, "r")
```

```
## [1] "10" "1"   "r"
```

- Соедините значения 10, TRUE, "r" в вектор.

```
c(10, TRUE, "r")
```

```
## [1] "10"    "TRUE"  "r"
```

8.2 Векторизация

- Создайте вектор p, состоящий из значений 4, 5, 6, 7, и вектор q, состоящий из 0, 1, 2, 3.

```
p <- 4:7
```

```
p
```

```
## [1] 4 5 6 7
```

```
q <- 0:3
```

```
q
```

```
## [1] 0 1 2 3
```

- Посчитайте поэлементную сумму векторов p и q:

```
p + q
```

```
## [1] 4 6 8 10
```

- Посчитайте поэлементную разницу p и q:

```
p - q
```

```
## [1] 4 4 4 4
```

- Поделите каждый элемент вектора p на соответствующий ему элемент вектора q:

О, да, Вам нужно делить на 0!

```
p / q
```

```
## [1] Inf 5.000000 3.000000 2.333333
```

- Возведите каждый элемент вектора p в степень соответствующего ему элемента вектора q:

```
p ^ q
```

```
## [1] 1 5 36 343
```

- Умножьте каждое значение вектора p на 10.

```
p * 10
```

```
## [1] 40 50 60 70
```

- Создайте вектор квадратов чисел от 1 до 10:

```
(1:10)^2
```

```
## [1] 1 4 9 16 25 36 49 64 81 100
```

- Создайте вектор 0, 2, 0, 4, ..., 18, 0, 20.

```
1:20 * 0:1
```

```
## [1] 0 2 0 4 0 6 0 8 0 10 0 12 0 14 0 16 0 18 0 20
```

- Создайте вектор 1, 0, 3, 0, 5, ..., 17, 0, 19, 0.

```
1:20 * 1:0
```

```
## [1] 1 0 3 0 5 0 7 0 9 0 11 0 13 0 15 0 17 0 19 0
```

- *Создайте вектор, в котором будут содержаться первые 20 степеней двойки.

```
2 ^ (1:20)
```

```
## [1] 2 4 8 16 32 64 128 256 512
## [10] 1024 2048 4096 8192 16384 32768 65536 131072 262144
## [19] 524288 1048576
```

- *Создайте вектор из чисел 1, 10, 100, 1000, 10000:

```
10 ^ (0:4)
```

```
## [1] 1 10 100 1000 10000
```

- *Посчитать сумму последовательности $\frac{1}{1 \cdot 2} + \frac{1}{2 \cdot 3} + \frac{1}{3 \cdot 4} + \dots + \frac{1}{50 \cdot 51}$.

```
sum(1 / (1:50 * 2:51))
```

[1] 0.9803922

- *Посчитать сумму последовательности $\frac{1}{2^0} + \frac{1}{2^1} + \frac{1}{2^2} + \frac{1}{2^3} + \dots + \frac{1}{2^{20}}$.

```
sum(1 / 2 ^ (0:20))
```

[1] 1.999999

- *Посчитать сумму последовательности $1 + \frac{4}{3} + \frac{7}{9} + \frac{10}{27} + \frac{13}{81} + \dots + \frac{28}{19683}$.

```
sum((3 * (1:10) - 2) / 3 ^ (0:9))
```

[1] 3.749174

- Сколько чисел из последовательности $1 + \frac{4}{3} + \frac{7}{9} + \frac{10}{27} + \frac{13}{81} + \dots + \frac{28}{19683}$ больше чем 0.5?

```
sum((3 * (1:10) - 2) / 3 ^ (0:9) > 0.5)
```

[1] 3

8.3 Индексирование векторов

- Создайте вектор troiki со значениями 3, 6, 9, ..., 24, 27.

```
troiki <- seq(3, 27, 3)
troiki
```

[1] 3 6 9 12 15 18 21 24 27

- Извлеките 2, 5 и 7 значения вектора troiki.

```
troiki[c(2, 5, 7)]
```

[1] 6 15 21

- Извлеките предпоследнее значение вектора troiki.

```
troiki[length(troiki) - 1]
```

```
## [1] 24
```

- Извлеките все значения вектора `troiki` *кроме* предпоследнего:

```
troiki[-(length(troiki) - 1)]
```

```
## [1] 3 6 9 12 15 18 21 27
```

Создайте вектор `vec3`:

```
vec3 <- c(3, 5, 2, 1, 8, 4, 9, 10, 3, 15, 1, 11)
```

- Найдите второй элемент вектора `vec3`.

```
vec3[2]
```

```
## [1] 5
```

- Верните второй и пятый элемент вектора `vec3`.

```
vec3[c(2, 5)]
```

```
## [1] 5 8
```

- Попробуйте извлечь сотое значение вектора `vec3`:

```
vec3[100]
```

```
## [1] NA
```

- Верните все элементы вектора `vec3` *кроме* второго элемента.

```
vec3[-2]
```

```
## [1] 3 2 1 8 4 9 10 3 15 1 11
```

- Верните все элементы вектора `vec3` *кроме* второго и пятого элемента.

```
vec3[c(-2, -5)]
```

```
## [1] 3 2 1 4 9 10 3 15 1 11
```

- Найдите последний элемент вектора `vec3`.

```
vec3[length(vec3)]
```

```
## [1] 11
```

- Верните все значения вектора vec3 кроме первого и последнего.

```
vec3[c(-1, -length(vec3))]
```

```
## [1] 5 2 1 8 4 9 10 3 15 1
```

- Найдите все значения вектора vec3, которые больше 4.

```
vec3[vec3 > 4]
```

```
## [1] 5 8 9 10 15 11
```

- Найдите все значения вектора vec3, которые больше 4, но меньше 10.

Если хотите сделать это в одну строчку, то вам помогут логические операторы!

```
vec3[vec3 > 4 & vec3 < 10]
```

```
## [1] 5 8 9
```

- Найдите все значения вектора vec3, которые меньше 4 или больше 10.

```
vec3[vec3 < 4 | vec3 > 10]
```

```
## [1] 3 2 1 3 15 1 11
```

- Возведите в квадрат каждое значение вектора vec3.

```
vec3 ^ 2
```

```
## [1] 9 25 4 1 64 16 81 100 9 225 1 121
```

- *Возведите в квадрат каждое значение вектора на нечетной позиции и извлеките корень из каждого значения на четной позиции вектора vec3.

Извлечение корня - это то же самое, что и возведение в степень 0.5.

```
vec3 ^ c(2, 0.5)
```

```
## [1] 9.000000 2.236068 4.000000 1.000000 64.000000 2.000000 81.000000
## [8] 3.162278 9.000000 3.872983 1.000000 3.316625
```

- Создайте вектор $2, 4, 6, \dots, 18, 20$ как минимум 2 новыми способами.

Знаю, это задание может показаться бессмысленным, но это очень базовая операция, с помощью которой можно, например, разделить данные на две части. Чем больше способов Вы знаете, тем лучше!

```
(1:20) [c(FALSE, TRUE)]
```

```
## [1] 2 4 6 8 10 12 14 16 18 20
```

```
#(1:10)*2
```

```
##Работа с пропущенными значениями {#solution_na}
```

- Создайте вектор `vec4` со значениями 300, 15, 8, 2, 0, 1, 110:

```
vec4 <- c(300, 15, 8, 20, 0, 1, 110)
vec4
```

```
## [1] 300 15   8   20   0   1 110
```

- Замените все значения `vec4`, которые больше 20 на NA.

```
vec4[vec4 > 20] <- NA
```

- Проверьте полученный вектор `vec4`:

```
vec4
```

```
## [1] NA 15   8   20   0   1 NA
```

- Посчитайте сумму `vec4` с помощью функции `sum()`. Ответ NA не считается!

```
sum(vec4, na.rm = TRUE)
```

```
## [1] 44
```

8.4 Матрицы

- Создайте матрицу 4x4, состоящую из единиц. Назовите ее `M1`.

```
M1 <- matrix(rep(1, 16), ncol = 4)
M1
```

```
##      [,1] [,2] [,3] [,4]
## [1,]     1     1     1     1
## [2,]     1     1     1     1
## [3,]     1     1     1     1
## [4,]     1     1     1     1
```

- Поменяйте все некрайние значения матрицы M1 (то есть значения на позициях [2,2], [2,3], [3,2] и [3,3]) на число 2.

```
M1[2:3, 2:3] <- 2
M1
```

```
##      [,1] [,2] [,3] [,4]
## [1,]     1     1     1     1
## [2,]     1     2     2     1
## [3,]     1     2     2     1
## [4,]     1     1     1     1
```

- Выделите второй и третий столбик из матрицы M1.

```
M1[,2:3]
```

```
##      [,1] [,2]
## [1,]     1     1
## [2,]     2     2
## [3,]     2     2
## [4,]     1     1
```

- Сравните (==) вторую колонку и вторую строчку матрицы M1.

```
M1[,2] == M1[2,]
```

```
## [1] TRUE TRUE TRUE TRUE
```

- *Создайте таблицу умножения (9x9) в виде матрицы. Сохраните ее в переменную mult_tab.

```
mult_tab <- matrix(rep(1:9, rep(9,9))*rep(1:9), nrow = 9)
mult_tab
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9]
## [1,]     1     2     3     4     5     6     7     8     9
## [2,]     2     4     6     8    10    12    14    16    18
## [3,]     3     6     9    12    15    18    21    24    27
## [4,]     4     8    12    16    20    24    28    32    36
## [5,]     5    10    15    20    25    30    35    40    45
```

```
## [6,]    6   12   18   24   30   36   42   48   54
## [7,]    7   14   21   28   35   42   49   56   63
## [8,]    8   16   24   32   40   48   56   64   72
## [9,]    9   18   27   36   45   54   63   72   81
```

```
#  
#outer(1:9, 1:9, "*")  
#1:9 %o% 1:9
```

- *Из матрицы mult_tab выделите подматрицу, включающую в себя только строчки с 6 по 8 и столбцы с 3 по 7.

```
mult_tab[6:8, 3:7]
```

```
##      [,1] [,2] [,3] [,4] [,5]
## [1,]    18   24   30   36   42
## [2,]    21   28   35   42   49
## [3,]    24   32   40   48   56
```

- *Создайте матрицу с логическими значениями, где TRUE, если в этом месте в таблице умножения (mult_tab) двузначное число и FALSE, если однозначное.

Матрица - это почти вектор. К нему можно обращаться с единственным индексом.

```
mult_tab >= 10
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9]
## [1,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
## [2,] FALSE FALSE FALSE FALSE  TRUE  TRUE  TRUE  TRUE  TRUE
## [3,] FALSE FALSE FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [4,] FALSE FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [5,] FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [6,] FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [7,] FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [8,] FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
## [9,] FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
```

- *Создайте матрицу mult_tab2, в которой все значения tab меньше 10 заменены на 0.

```
mult_tab2 <- mult_tab
mult_tab2[mult_tab < 10] <- 0
mult_tab2
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9]
## [1,]    0    0    0    0    0    0    0    0    0
## [2,]    0    0    0    0   10   12   14   16   18
## [3,]    0    0    0   12   15   18   21   24   27
## [4,]    0    0   12   16   20   24   28   32   36
## [5,]    0   10   15   20   25   30   35   40   45
## [6,]    0   12   18   24   30   36   42   48   54
## [7,]    0   14   21   28   35   42   49   56   63
## [8,]    0   16   24   32   40   48   56   64   72
## [9,]    0   18   27   36   45   54   63   72   81
```

8.5 Списки

Дан список `list1`:

```
list1 = list(numbers = 1:5, letters = letters, logic = TRUE)
list1
```

```
## $numbers
## [1] 1 2 3 4 5
##
## $letters
##  [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"
##
## $logic
## [1] TRUE
```

- Найдите первый элемент списка `list1`. Ответ должен быть списком длиной один.

```
list1[1]
```

```
## $numbers
## [1] 1 2 3 4 5
```

- Теперь найдите содержание первого элемента списка `list1` двумя разными способами. Ответ должен быть вектором.

```
list1[[1]]
```

```
## [1] 1 2 3 4 5
```

```
list1$numbers
```

```
## [1] 1 2 3 4 5
```

- Теперь возьмите первый элемент содержания первого элемента списка `list1`. Ответ должен быть вектором.

```
list1[[1]][1]
```

```
## [1] 1
```

- Создайте список `list2`, содержащий в себе два списка `list1`. Один из них будет иметь имя `pupa`, а другой — `lupa`.

```
list2 = list(pupa = list1, lupa = list1)
list2
```

```
## $pupa
## $pupa$numbers
## [1] 1 2 3 4 5
##
## $pupa$letters
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"
##
## $pupa$logic
## [1] TRUE
##
## 
## $lupa
## $lupa$numbers
## [1] 1 2 3 4 5
##
## $lupa$letters
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"
##
## $lupa$logic
## [1] TRUE
```

- *Извлеките первый элемент списка `list2`, из него — второй полэлемент, а из него — третье значение.

```
list2[[1]][[2]][3]
```

```
## [1] "c"
```

8.6 Датафрейм

- Запустите команду `data(mtcars)` чтобы загрузить встроенный датафрейм с информацией про автомобили. Каждая строчка датафрейма - модель автомобиля, каждая колонка - отдельная характеристика. Подробнее см. `?mtcars`.

```
data(mtcars)
mtcars
```

	##	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
## Mazda RX4		21.0	6	160.0	110	3.90	2.620	16.46	0	1	4	4
## Mazda RX4 Wag		21.0	6	160.0	110	3.90	2.875	17.02	0	1	4	4
## Datsun 710		22.8	4	108.0	93	3.85	2.320	18.61	1	1	4	1
## Hornet 4 Drive		21.4	6	258.0	110	3.08	3.215	19.44	1	0	3	1
## Hornet Sportabout		18.7	8	360.0	175	3.15	3.440	17.02	0	0	3	2
## Valiant		18.1	6	225.0	105	2.76	3.460	20.22	1	0	3	1
## Duster 360		14.3	8	360.0	245	3.21	3.570	15.84	0	0	3	4
## Merc 240D		24.4	4	146.7	62	3.69	3.190	20.00	1	0	4	2
## Merc 230		22.8	4	140.8	95	3.92	3.150	22.90	1	0	4	2
## Merc 280		19.2	6	167.6	123	3.92	3.440	18.30	1	0	4	4
## Merc 280C		17.8	6	167.6	123	3.92	3.440	18.90	1	0	4	4
## Merc 450SE		16.4	8	275.8	180	3.07	4.070	17.40	0	0	3	3
## Merc 450SL		17.3	8	275.8	180	3.07	3.730	17.60	0	0	3	3
## Merc 450SLC		15.2	8	275.8	180	3.07	3.780	18.00	0	0	3	3
## Cadillac Fleetwood		10.4	8	472.0	205	2.93	5.250	17.98	0	0	3	4
## Lincoln Continental		10.4	8	460.0	215	3.00	5.424	17.82	0	0	3	4
## Chrysler Imperial		14.7	8	440.0	230	3.23	5.345	17.42	0	0	3	4
## Fiat 128		32.4	4	78.7	66	4.08	2.200	19.47	1	1	4	1
## Honda Civic		30.4	4	75.7	52	4.93	1.615	18.52	1	1	4	2
## Toyota Corolla		33.9	4	71.1	65	4.22	1.835	19.90	1	1	4	1
## Toyota Corona		21.5	4	120.1	97	3.70	2.465	20.01	1	0	3	1
## Dodge Challenger		15.5	8	318.0	150	2.76	3.520	16.87	0	0	3	2
## AMC Javelin		15.2	8	304.0	150	3.15	3.435	17.30	0	0	3	2
## Camaro Z28		13.3	8	350.0	245	3.73	3.840	15.41	0	0	3	4
## Pontiac Firebird		19.2	8	400.0	175	3.08	3.845	17.05	0	0	3	2
## Fiat X1-9		27.3	4	79.0	66	4.08	1.935	18.90	1	1	4	1
## Porsche 914-2		26.0	4	120.3	91	4.43	2.140	16.70	0	1	5	2
## Lotus Europa		30.4	4	95.1	113	3.77	1.513	16.90	1	1	5	2
## Ford Pantera L		15.8	8	351.0	264	4.22	3.170	14.50	0	1	5	4
## Ferrari Dino		19.7	6	145.0	175	3.62	2.770	15.50	0	1	5	6
## Maserati Bora		15.0	8	301.0	335	3.54	3.570	14.60	0	1	5	8
## Volvo 142E		21.4	4	121.0	109	4.11	2.780	18.60	1	1	4	2

- Изучите структуру датафрейма `mtcars` с помощью функции `str()`.

```
str(mtcars)
```

```
## 'data.frame': 32 obs. of 11 variables:
## $ mpg : num 21 21 22.8 21.4 18.7 18.1 14.3 24.4 22.8 19.2 ...
## $ cyl : num 6 6 4 6 8 6 8 4 4 6 ...
## $ disp: num 160 160 108 258 360 ...
## $ hp : num 110 110 93 110 175 105 245 62 95 123 ...
## $ drat: num 3.9 3.9 3.85 3.08 3.15 2.76 3.21 3.69 3.92 3.92 ...
## $ wt : num 2.62 2.88 2.32 3.21 3.44 ...
## $ qsec: num 16.5 17 18.6 19.4 17 ...
## $ vs : num 0 0 1 1 0 1 0 1 1 1 ...
## $ am : num 1 1 1 0 0 0 0 0 0 0 ...
## $ gear: num 4 4 4 3 3 3 3 4 4 4 ...
## $ carb: num 4 4 1 1 2 1 4 2 2 4 ...
```

- Найдите значение третьей строчки четвертого столбца датафрейма `mtcars`.

```
mtcars[3, 4]
```

```
## [1] 93
```

- Извлеките первые шесть строчек и первые шесть столбцов датафрейма `mtcars`.

```
mtcars[1:6, 1:6]
```

```
##          mpg cyl disp  hp drat    wt
## Mazda RX4     21.0   6 160 110 3.90 2.620
## Mazda RX4 Wag 21.0   6 160 110 3.90 2.875
## Datsun 710    22.8   4 108  93 3.85 2.320
## Hornet 4 Drive 21.4   6 258 110 3.08 3.215
## Hornet Sportabout 18.7   8 360 175 3.15 3.440
## Valiant       18.1   6 225 105 2.76 3.460
```

- Извлеките колонку `wt` датафрейма `mtcars` - массу автомобиля в тысячах фунтов.

```
mtcars$wt
```

```
## [1] 2.620 2.875 2.320 3.215 3.440 3.460 3.570 3.190 3.150 3.440 3.440 4.070
## [13] 3.730 3.780 5.250 5.424 5.345 2.200 1.615 1.835 2.465 3.520 3.435 3.840
## [25] 3.845 1.935 2.140 1.513 3.170 2.770 3.570 2.780
```

- Извлеките колонки из `mtcars` в следующем порядке: `hp`, `mpg`, `cyl`.

```
mtcars[, c("hp", "mpg", "cyl")]
##          hp  mpg cyl
## Mazda RX4     110 21.0   6
## Mazda RX4 Wag 110 21.0   6
## Datsun 710    93 22.8   4
## Hornet 4 Drive 110 21.4   6
## Hornet Sportabout 175 18.7   8
## Valiant      105 18.1   6
## Duster 360    245 14.3   8
## Merc 240D     62 24.4   4
## Merc 230      95 22.8   4
## Merc 280      123 19.2   6
## Merc 280C     123 17.8   6
## Merc 450SE    180 16.4   8
## Merc 450SL    180 17.3   8
## Merc 450SLC   180 15.2   8
## Cadillac Fleetwood 205 10.4   8
## Lincoln Continental 215 10.4   8
## Chrysler Imperial 230 14.7   8
## Fiat 128       66 32.4   4
## Honda Civic    52 30.4   4
## Toyota Corolla 65 33.9   4
## Toyota Corona   97 21.5   4
## Dodge Challenger 150 15.5   8
## AMC Javelin    150 15.2   8
## Camaro Z28     245 13.3   8
## Pontiac Firebird 175 19.2   8
## Fiat X1-9       66 27.3   4
## Porsche 914-2   91 26.0   4
## Lotus Europa    113 30.4   4
## Ford Pantera L 264 15.8   8
## Ferrari Dino    175 19.7   6
## Maserati Bora   335 15.0   8
## Volvo 142E     109 21.4   4
```

- Посчитайте *количество* автомобилей с 4 цилиндрами (*cyl*) в датафрейме *mtcars*.

```
sum(mtcars$cyl == 4)
```

```
## [1] 11
```

- Посчитайте *долю* автомобилей с 4 цилиндрами (*cyl*) в датафрейме *mtcars*.

```
mean(mtcars$cyl == 4)
```

```
## [1] 0.34375
```

- Найдите все автомобили мощностью не менее 100 лошадиных сил (hp) в датафрейме mtcars.

```
mtcars[mtcars$hp >= 100, ]
```

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
## Mazda RX4	21.0	6	160.0	110	3.90	2.620	16.46	0	1	4	4
## Mazda RX4 Wag	21.0	6	160.0	110	3.90	2.875	17.02	0	1	4	4
## Hornet 4 Drive	21.4	6	258.0	110	3.08	3.215	19.44	1	0	3	1
## Hornet Sportabout	18.7	8	360.0	175	3.15	3.440	17.02	0	0	3	2
## Valiant	18.1	6	225.0	105	2.76	3.460	20.22	1	0	3	1
## Duster 360	14.3	8	360.0	245	3.21	3.570	15.84	0	0	3	4
## Merc 280	19.2	6	167.6	123	3.92	3.440	18.30	1	0	4	4
## Merc 280C	17.8	6	167.6	123	3.92	3.440	18.90	1	0	4	4
## Merc 450SE	16.4	8	275.8	180	3.07	4.070	17.40	0	0	3	3
## Merc 450SL	17.3	8	275.8	180	3.07	3.730	17.60	0	0	3	3
## Merc 450SLC	15.2	8	275.8	180	3.07	3.780	18.00	0	0	3	3
## Cadillac Fleetwood	10.4	8	472.0	205	2.93	5.250	17.98	0	0	3	4
## Lincoln Continental	10.4	8	460.0	215	3.00	5.424	17.82	0	0	3	4
## Chrysler Imperial	14.7	8	440.0	230	3.23	5.345	17.42	0	0	3	4
## Dodge Challenger	15.5	8	318.0	150	2.76	3.520	16.87	0	0	3	2
## AMC Javelin	15.2	8	304.0	150	3.15	3.435	17.30	0	0	3	2
## Camaro Z28	13.3	8	350.0	245	3.73	3.840	15.41	0	0	3	4
## Pontiac Firebird	19.2	8	400.0	175	3.08	3.845	17.05	0	0	3	2
## Lotus Europa	30.4	4	95.1	113	3.77	1.513	16.90	1	1	5	2
## Ford Pantera L	15.8	8	351.0	264	4.22	3.170	14.50	0	1	5	4
## Ferrari Dino	19.7	6	145.0	175	3.62	2.770	15.50	0	1	5	6
## Maserati Bora	15.0	8	301.0	335	3.54	3.570	14.60	0	1	5	8
## Volvo 142E	21.4	4	121.0	109	4.11	2.780	18.60	1	1	4	2

- Найдите все автомобили мощностью не менее 100 лошадиных сил (hp) и 4 цилиндрами (cyl) в датафрейме mtcars.

```
mtcars[mtcars$hp >= 100 & mtcars$cyl == 4, ]
```

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
## Lotus Europa	30.4	4	95.1	113	3.77	1.513	16.9	1	1	5	2
## Volvo 142E	21.4	4	121.0	109	4.11	2.780	18.6	1	1	4	2

- Посчитайте максимальную массу (wt) автомобиля в выборке, воспользовавшись функцией max():

```
max(mtcars$wt)
```

```
## [1] 5.424
```

- Посчитайте максимальную массу (wt) автомобиля в выборке, воспользовавшись функцией `min()`:

```
min(mtcars$wt)
```

```
## [1] 1.513
```

- Найдите строчку датафрейма `mtcars` с самым легким автомобилем.

```
mtcars[mtcars$wt == min(mtcars$wt), ]
```

```
##          mpg cyl disp hp drat    wt  qsec vs am gear carb
## Lotus Europa 30.4   4 95.1 113 3.77 1.513 16.9   1  1     5     2
```

- Извлеките строчки датафрейма `mtcars` с автомобилями, масса которых ниже средней массы.

```
mtcars[mtcars$wt < mean(mtcars$wt), ]
```

```
##          mpg cyl disp hp drat    wt  qsec vs am gear carb
## Mazda RX4    21.0   6 160.0 110 3.90 2.620 16.46   0  1     4     4
## Mazda RX4 Wag 21.0   6 160.0 110 3.90 2.875 17.02   0  1     4     4
## Datsun 710   22.8   4 108.0  93 3.85 2.320 18.61   1  1     4     1
## Hornet 4 Drive 21.4   6 258.0 110 3.08 3.215 19.44   1  0     3     1
## Merc 240D    24.4   4 146.7  62 3.69 3.190 20.00   1  0     4     2
## Merc 230     22.8   4 140.8  95 3.92 3.150 22.90   1  0     4     2
## Fiat 128     32.4   4  78.7  66 4.08 2.200 19.47   1  1     4     1
## Honda Civic   30.4   4  75.7  52 4.93 1.615 18.52   1  1     4     2
## Toyota Corolla 33.9   4  71.1  65 4.22 1.835 19.90   1  1     4     1
## Toyota Corona 21.5   4 120.1  97 3.70 2.465 20.01   1  0     3     1
## Fiat X1-9      27.3   4  79.0  66 4.08 1.935 18.90   1  1     4     1
## Porsche 914-2  26.0   4 120.3  91 4.43 2.140 16.70   0  1     5     2
## Lotus Europa   30.4   4  95.1 113 3.77 1.513 16.90   1  1     5     2
## Ford Pantera L 15.8   8 351.0 264 4.22 3.170 14.50   0  1     5     4
## Ferrari Dino   19.7   6 145.0 175 3.62 2.770 15.50   0  1     5     6
## Volvo 142E     21.4   4 121.0 109 4.11 2.780 18.60   1  1     4     2
```

- Масса автомобиля указана в тысячах фунтов. Создайте колонку `wt_kg` с массой автомобиля в килограммах. Результат округлите до целых значений с помощью функции `round()`.

1 фунт = 0.45359237 кг.

```
mtcars$wt_kg <- round(mtcars$wt * 1000 * 0.45359237)
mtcars
```

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb	wt_kg
## Mazda RX4	21.0	6	160.0	110	3.90	2.620	16.46	0	1	4	4	1188
## Mazda RX4 Wag	21.0	6	160.0	110	3.90	2.875	17.02	0	1	4	4	1304
## Datsun 710	22.8	4	108.0	93	3.85	2.320	18.61	1	1	4	1	1052
## Hornet 4 Drive	21.4	6	258.0	110	3.08	3.215	19.44	1	0	3	1	1458
## Hornet Sportabout	18.7	8	360.0	175	3.15	3.440	17.02	0	0	3	2	1560
## Valiant	18.1	6	225.0	105	2.76	3.460	20.22	1	0	3	1	1569
## Duster 360	14.3	8	360.0	245	3.21	3.570	15.84	0	0	3	4	1619
## Merc 240D	24.4	4	146.7	62	3.69	3.190	20.00	1	0	4	2	1447
## Merc 230	22.8	4	140.8	95	3.92	3.150	22.90	1	0	4	2	1429
## Merc 280	19.2	6	167.6	123	3.92	3.440	18.30	1	0	4	4	1560
## Merc 280C	17.8	6	167.6	123	3.92	3.440	18.90	1	0	4	4	1560
## Merc 450SE	16.4	8	275.8	180	3.07	4.070	17.40	0	0	3	3	1846
## Merc 450SL	17.3	8	275.8	180	3.07	3.730	17.60	0	0	3	3	1692
## Merc 450SLC	15.2	8	275.8	180	3.07	3.780	18.00	0	0	3	3	1715
## Cadillac Fleetwood	10.4	8	472.0	205	2.93	5.250	17.98	0	0	3	4	2381
## Lincoln Continental	10.4	8	460.0	215	3.00	5.424	17.82	0	0	3	4	2460
## Chrysler Imperial	14.7	8	440.0	230	3.23	5.345	17.42	0	0	3	4	2424
## Fiat 128	32.4	4	78.7	66	4.08	2.200	19.47	1	1	4	1	998
## Honda Civic	30.4	4	75.7	52	4.93	1.615	18.52	1	1	4	2	733
## Toyota Corolla	33.9	4	71.1	65	4.22	1.835	19.90	1	1	4	1	832
## Toyota Corona	21.5	4	120.1	97	3.70	2.465	20.01	1	0	3	1	1118
## Dodge Challenger	15.5	8	318.0	150	2.76	3.520	16.87	0	0	3	2	1597
## AMC Javelin	15.2	8	304.0	150	3.15	3.435	17.30	0	0	3	2	1558
## Camaro Z28	13.3	8	350.0	245	3.73	3.840	15.41	0	0	3	4	1742
## Pontiac Firebird	19.2	8	400.0	175	3.08	3.845	17.05	0	0	3	2	1744
## Fiat X1-9	27.3	4	79.0	66	4.08	1.935	18.90	1	1	4	1	878
## Porsche 914-2	26.0	4	120.3	91	4.43	2.140	16.70	0	1	5	2	971
## Lotus Europa	30.4	4	95.1	113	3.77	1.513	16.90	1	1	5	2	686
## Ford Pantera L	15.8	8	351.0	264	4.22	3.170	14.50	0	1	5	4	1438
## Ferrari Dino	19.7	6	145.0	175	3.62	2.770	15.50	0	1	5	6	1256
## Maserati Bora	15.0	8	301.0	335	3.54	3.570	14.60	0	1	5	8	1619
## Volvo 142E	21.4	4	121.0	109	4.11	2.780	18.60	1	1	4	2	1261

8.7 Условные конструкции

- Создайте вектор vec5:

```
vec5 <- c(5, 20, 30, 0, 2, 9)
```

- Создайте новый строковый вектор, где на месте чисел больше 10 в vec5 будет

стоять “большое число”, а на месте остальных чисел — “маленькое число”.

```
ifelse(vec5 > 10, "      ", "      ")  
  
## [1] "      " "      " "      " "      "  
## [5] "      " "      "
```

- Загрузите файл heroes_information.csv в переменную heroes.

```
heroes <- read.csv("data/heroes_information.csv",  
                    stringsAsFactors = FALSE,  
                    na.strings = c("-", "-99"))
```

- Создайте новую колонку hair в heroes, в которой будет значение "Bold" для тех супергероев, у которых в колонке Hair.color стоит "No Hair", и значение "Hairy" во всех остальных случаях.

```
heroes$hair <- ifelse(heroes$Hair.color == "No Hair", "Bold", "Hairy")  
head(heroes)
```

	X	name	Gender	Eye.color	Race	Hair.color	Height
## 1	0	A-Bomb	Male	yellow	Human	No Hair	203
## 2	1	Abe Sapien	Male	blue	Ichtyo Sapien	No Hair	191
## 3	2	Abin Sur	Male	blue	Ungaran	No Hair	185
## 4	3	Abomination	Male	green	Human / Radiation	No Hair	203
## 5	4	Abraxas	Male	blue	Cosmic Entity	Black	NA
## 6	5	Absorbing Man	Male	blue	Human	No Hair	193
		Publisher	Skin.color	Alignment	Weight	hair	
## 1		Marvel Comics	<NA>	good	441	Bold	
## 2		Dark Horse Comics	blue	good	65	Bold	
## 3		DC Comics	red	good	90	Bold	
## 4		Marvel Comics	<NA>	bad	441	Bold	
## 5		Marvel Comics	<NA>	bad	NA	Hairy	
## 6		Marvel Comics	<NA>	bad	122	Bold	

- Создайте новую колонку tall в heroes, в которой будет значение "tall" для тех супергероев, у которых в колонке Height стоит число больше 190, значение "short" для тех супергероев, у которых в колонке Height стоит число меньше 170, и значение "middle" во всех остальных случаях.

```
# heroes$tall <- dplyr::case_when(  
#   heroes$Height > 190 ~ "tall",  
#   heroes$Height < 170 ~ "short",  
#   TRUE ~ "middle"
```

```
# )
heroes$tall <- ifelse(heroes$Height > 190,
                      "tall",
                      ifelse(heroes$Height < 170,
                            "short",
                            "middle"))
```

8.8 Создание функций

- Создайте функцию `plus_one()`, которая принимает число и возвращает это же число + 1.

```
plus_one <- function(x) x + 1
```

- Проверьте функцию `plus_one()` на числе 41.

```
plus_one(41)
```

```
## [1] 42
```

- Создайте функцию `circle_area`, которая вычисляет площадь круга по радиусу согласно формуле πr^2 .

```
circle_area <- function(r) pi * r ^ 2
```

- Посчитайте площадь круга с радиусом 5.

```
circle_area(5)
```

```
## [1] 78.53982
```

- Создайте функцию `cels2fahr()`, которая будет превращать градусы по Цельсию в градусы по Фаренгейту.

```
cels2fahr <- function(x) x * 9 / 5 + 32
```

- Проверьте на значениях -100, -40 и 0, что функция `cels2fahr()` работает корректно.

```
cels2fahr(c(-100, -40, 0))
```

```
## [1] -148 -40 32
```

- Напишите функцию `highlight()`, которая принимает на входе строковый вектор, а возвращает тот же вектор, но дополненный значением "***" в начале и конце вектора. Лучше всего это рассмотреть на примере:

```
highlight <- function(x) c("/**/", x, "/**/")
```

```
highlight(c(" ", " !"))
```

```
## [1] "/**/"      " "      " "      " !"      "/**/"
```

- Теперь сделайте функцию `highlight` более гибкой. Добавьте в нее параметр `wrapper` =, который по умолчанию равен "***". Значение параметра `wrapper` = и будет вставлено в начало и конец вектора.

```
highlight <- function(x, wrapper = "***") c(wrapper, x, wrapper)
```

- Проверьте написанную функцию на векторе `c(" " !")`.

```
highlight(c(" ", " !"))
```

```
## [1] "/**/"      " "      " "      " !"      "/**/"
```

```
highlight(c(" ", " !"), wrapper = "___")
```

```
## [1] "___"      " "      " "      " !"      "___"
```

- Создайте функцию `trim()`, которая будет возвращать вектор без первого и последнего значения (вне зависимости от типа данных).

```
trim <- function(x) x[c(-1, -length(x))]
```

- Проверьте, что функция `trim()` работает корректно:

```
trim(1:7)
```

```
## [1] 2 3 4 5 6
```

```
trim(letters)
```

```
## [1] "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s" "t"
## [20] "u" "v" "w" "x" "y"
```

- Теперь добавьте в функцию `trim()` параметр `n` = со значением по умолчанию 1. Этот параметр будет обозначать сколько значений нужно отрезать слева и справа от вектора.

```
trim <- function(x, n = 1) x[c(-1:-n, (-length(x)+n-1):-length(x))]
```

- Проверьте полученную функцию:

```
trim(letters)
```

```
## [1] "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s" "t"
## [20] "u" "v" "w" "x" "y"
```

```
trim(letters, n = 2)
```

```
## [1] "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s" "t" "u"
## [20] "v" "w" "x"
```

- Сделайте так, чтобы функция `trim()` работала корректно с `n` = 0, т.е. функция возвращала бы исходный вектор без изменений.

```
trim <- function(x, n = 1) {
  if (n == 0) return(x)
  x[c(-1:-n, (-length(x)+n-1):-length(x))]
```

```
trim(letters, n = 0)
```

```
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
## [20] "t" "u" "v" "w" "x" "y" "z"
```

- *Теперь добавьте проверку на адекватность входных данных: функция `trim()` должна выдавать ошибку, если `n` = меньше нуля или если `n` = слишком большой и отрезает все значения вектора:

```
trim <- function(x, n = 1) {
  if (n < 0) stop("n           !")
  l <- length(x)
  if (n > ceiling(l/2) - 1) stop("n           !")
  if (n == 0) return(x)
  x[c(-1:-n, (-l+n-1):-1)]
```

- *Проверьте полученную функцию `trim()`:

```
trim(1:6, 3)
```

```
## Error in trim(1:6, 3): n !
```

```
trim(1:6, -1)
```

```
## Error in trim(1:6, -1): n !
```

- Создайте функцию `na_n()`, которая будет возвращать количество `NA` в векторе.

```
na_n <- function(x) sum(is.na(x))
```

- Проверьте функцию `na_n()` на векторе:

```
na_n(c(NA, 3:5, NA, 2, NA))
```

```
## [1] 3
```

- Напишите функцию `factors()`, которая будет возвращать все делители числа в виде числового вектора.

Здесь может понадобиться оператор для получения остатка от деления:
`%%`.

```
factors <- function(x) (1:x)[x %% (1:x) == 0]
```

- Проверьте функцию `factors()` на простых и сложных числах:

```
factors(3)
```

```
## [1] 1 3
```

```
factors(161)
```

```
## [1] 1 7 23 161
```

```
factors(1984)
```

```
## [1] 1 2 4 8 16 31 32 62 64 124 248 496 992 1984
```

- *Напишите функцию `is_prime()`, которая проверяет, является ли число простым.

Здесь может пригодиться функция `any()` - она возвращает TRUE, если в векторе есть хотя бы один TRUE.

```
is_prime <- function(x) !any(x%%(2:(x-1)) == 0)
#is_prime <- function(x) length(factors(x)) == 2 #
```

`factors()`

- Проверьте какие годы были для нас простыми, а какие нет:

```
is_prime(2017)
```

```
## [1] TRUE
```

```
is_prime(2019)
```

```
## [1] FALSE
```

```
2019/3 #2019      3
```

```
## [1] 673
```

```
is_prime(2020)
```

```
## [1] FALSE
```

```
is_prime(2021)
```

```
## [1] FALSE
```

- *Создайте функцию `monotonic()`, которая возвращает TRUE, если значения в векторе не убывают (то есть каждое следующее - больше или равно предыдущему) или не возрастают.

Полезная функция для этого — `diff()` — возвращает разницу соседних значений.

```
monotonic <- function(x) all(diff(x)>=0) | all(diff(x)<=0)
```

```
monotonic(1:7)
```

```
## [1] TRUE
```

```
monotonic(c(1:5,5:1))

## [1] FALSE

monotonic(6:-1)

## [1] TRUE

monotonic(c(1:5, rep(5, 10), 5:10))

## [1] TRUE
```

Бинарные операторы типа `+` или `%in%` тоже представляют собой функции. Более того, мы можем создавать свои бинарные операторы! В этом нет особой сложности — нужно все так же создавать функцию (для двух переменных), главное окружать их `%` и название обрамлять обратными штрихами `'`. Например, можно сделать свой бинарный оператор `%notin%`, который будет выдавать `TRUE`, если значения слева *нет* в векторе справа:

```
`%notin%` <- function(x, y) ! (x %in% y)
1:10 %notin% c(1, 4, 5)

## [1] FALSE TRUE TRUE FALSE FALSE TRUE TRUE TRUE TRUE TRUE
```

- *Создайте бинарный оператор `%without%`, который будет возвращать все значения вектора слева без значений вектора справа.

```
`%without%` <- function(x, y) x[!x %in% y]

c(" ", " ", " ", " ", " ", " ") %without% c(" ", " ")

## [1] " "      " "      " "      " "      " "



- Создайте бинарный оператор %between%, который будет возвращать TRUE, если значение в векторе слева находится в диапазоне значений вектора справа:


`%between%` <- function(x, y) x >= min(y) & x <= max(y)

1:10 %between% c(1, 4, 5)

## [1] TRUE TRUE TRUE TRUE TRUE FALSE FALSE FALSE FALSE
```

8.9 Семейство функций apply()

- Создайте матрицу M2:

```
M2 <- matrix(c(20:11, 11:20), nrow = 5)
M2
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    20   15   11   16
## [2,]    19   14   12   17
## [3,]    18   13   13   18
## [4,]    17   12   14   19
## [5,]    16   11   15   20
```

- Посчитайте максимальное значение матрицы M2 по каждой строке.

```
apply(M2, 1, max)
```

```
## [1] 20 19 18 19 20
```

- Посчитайте максимальное значение матрицы M2 по каждому столбцу.

```
apply(M2, 2, max)
```

```
## [1] 20 15 15 20
```

- Посчитайте среднее значение матрицы M2 по каждой строке.

```
apply(M2, 1, mean)
```

```
## [1] 15.5 15.5 15.5 15.5 15.5
```

- Посчитайте среднее значение матрицы M2 по каждому столбцу.

```
apply(M2, 2, mean)
```

```
## [1] 18 13 13 18
```

- Создайте список list3:

```
list3 <- list(
  a = 1:5,
  b = 0:20,
  c = 4:24,
  d = 6:3,
```

```
e = 6:25
)
```

- Найдите максимальное значение каждого вектора списка `list3`.

```
sapply(list3, max)
```

```
## a b c d e
## 5 20 24 6 25
```

- Посчитайте сумму каждого вектора списка `list3`.

```
sapply(list3, sum)
```

```
## a b c d e
## 15 210 294 18 310
```

- Посчитайте длину каждого вектора списка `list3`.

```
sapply(list3, length)
```

```
## a b c d e
## 5 21 21 4 20
```

- Напишите функцию `max_item()`, которая будет принимать на входе список, а возвращать - (первый) самый длинный его элемент.

Для этого вам может понадобиться функция `which.max()`, которая возвращает индекс максимального значения (первого, если их несколько).

```
max_item <- function (x) x[[which.max(sapply(x, length))]]
```

- Проверьте функцию `max_item()` на списке `list3`.

```
max_item(list3)
```

```
## [1] 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20
```

- Теперь мы сделаем сложный список `list4`:

```
list4 <- list(1:3, 3:40, list3)
```

- Посчитайте длину каждого вектора в списке, в т.ч. для списка внутри. Результат должен быть списком с такой же структурой, как и изначальный список `list4`.

Для этого может понадобиться функция `rapply()`: recursive lapply

```
rapply(list4, length, how = "list")

## [[1]]
## [1] 3
##
## [[2]]
## [1] 38
##
## [[3]]
## [[3]]$a
## [1] 5
##
## [[3]]$b
## [1] 21
##
## [[3]]$c
## [1] 21
##
## [[3]]$d
## [1] 4
##
## [[3]]$e
## [1] 20
```

- *Загрузите набор данных `heroes` и посчитайте, сколько `NA` в каждом из столбцов.

Для этого удобно использовать ранее написанную функцию `na_n()`.

```
sapply(heroes, na_n)
```

	X	name	Gender	Eye.color	Race	Hair.color	Height
##	0	0	29	172	304	172	217
##	Publisher	Skin.color	Alignment	Weight	hair	tall	
##	0	662	7	239	172	217	

- *Используя ранее написанную функцию `is_prime()`, напишите функцию `prime_numbers()`, которая будет возвращать все простые числа до выбранного числа.

```
is_prime <- function(x) !any(x %% (2:(x - 1)) == 0)
prime_numbers <- function(x) (2:x)[sapply(2:x, is_prime)]
```

```
prime_numbers(200)

## [1] 3 5 7 11 13 17 19 23 29 31 37 41 43 47 53 59 61 67 71
## [20] 73 79 83 89 97 101 103 107 109 113 127 131 137 139 149 151 157 163 167
## [39] 173 179 181 191 193 197 199

library(tidyverse)
heroes <- read_csv("data/heroes_information.csv",
                    na = c("-", "-99"))
powers <- read_csv("data/super_hero_powers.csv")
```

8.10 magrittr::%>%

- Перепишите следующие выражения, используя %>%:

```
sqrt(sum(1:10))
```

```
## [1] 7.416198
```

```
1:10 %>%
  sum() %>%
  sqrt()
```

```
## [1] 7.416198
```

```
abs(min(-5:5))
```

```
## [1] 5
```

```
-5:5 %>%
  min() %>%
  abs()
```

```
## [1] 5
```

```
c(" ", "2", " ", sqrt(2))
```

```
## [1] " " "2" " " "1.4142135623731"
```

```
2 %>% c("      ", ., "  ", sqrt(.))

## [1] "      "      "2"           "  "           "1.4142135623731"

## Выбор строк: dplyr::slice() и dplyr::filter() {#solution_filt}
```

- Выберите только те строчки, в которых содержится информация о супергероях тяжелее 500 кг.

```
heroes %>%
  filter(Weight > 500)
```

```
## # A tibble: 6 x 11
##   X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr>     <chr> <chr>     <dbl> <chr>
## 1 203 Dark~ Male red       New ~ No Hair    267 DC Comics
## 2 283 Giga~ Female green <NA> Red        62.5 DC Comics
## 3 331 Hulk  Male green   Huma~ Green     244 Marvel C-
## 4 373 Jugg~ Male blue    Human Red     287 Marvel C-
## 5 549 Red ~ Male yellow Huma~ Black     213 Marvel C-
## 6 575 Sasq~ Male red    <NA> Orange    305 Marvel C-
## # ... with 3 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>
```

- Выберите только те строчки, в которых содержится информация о женщинах-супергероях тяжелее 500 кг.

```
heroes %>%
  filter(Weight > 500 & Gender == "Female")
```

```
## # A tibble: 1 x 11
##   X1 name Gender `Eye color` Race `Hair color` Height Publisher
##   <dbl> <chr> <chr>     <chr> <chr>     <dbl> <chr>
## 1 283 Giga~ Female green <NA> Red        62.5 DC Comics
## # ... with 3 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>
```

- Выберите только те строчки, в которых содержится информация о супергероях человеческой расы ("Human") женского пола. Из этих супергероев возьмите первые 5.

```
heroes %>%
  filter(Race == "Human" & Gender == "Female") %>%
  slice(1:5)
```

```
## # A tibble: 5 x 11
##   X1 name Gender `Eye color` Race `Hair color` Height Publisher
```

```
##   <dbl> <chr> <chr> <chr>      <chr> <chr>      <dbl> <chr>
## 1    38 Arac~ Female blue      Human Blond     175 Marvel C~
## 2    63 Batg~ Female green     Human Red      170 DC Comics
## 3    65 Batg~ Female green     Human Black    165 DC Comics
## 4    72 Batw~ Female green     Human Red      178 DC Comics
## 5    96 Blac~ Female blue      Human Blond    165 DC Comics
## # ... with 3 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>
```

Выбор столбцов: dplyr::select() {#solution_select}

- Выберите первые 4 столбца в powers.

```
powers %>%
  select(1:4)
```

```
## # A tibble: 667 x 4
##   hero_names   Agility `Accelerated Healing` `Lantern Power Ring`
##   <chr>        <lgl>   <lgl>                <lgl>
## 1 3-D Man     TRUE    FALSE                FALSE
## 2 A-Bomb       FALSE   TRUE                FALSE
## 3 Abe Sapien   TRUE    TRUE                FALSE
## 4 Abin Sur    FALSE   FALSE               TRUE
## 5 Abomination FALSE   TRUE                FALSE
## 6 Abraxas     FALSE   FALSE               FALSE
## 7 Absorbing Man FALSE  FALSE               FALSE
## 8 Adam Monroe FALSE  TRUE                FALSE
## 9 Adam Strange FALSE  FALSE               FALSE
## 10 Agent Bob   FALSE  FALSE              FALSE
## # ... with 657 more rows
```

- Выберите все столбцы от Reflexes до Empathy в тibble powers:

```
powers %>%
  select(Reflexes:Empathy)
```

```
## # A tibble: 667 x 7
##   Reflexes Invulnerability `Energy Constru~ `Force Fields` `Self-Sustenanc~
##   <lgl>    <lgl>          <lgl>           <lgl>      <lgl>
## 1 FALSE    FALSE          FALSE          FALSE      FALSE
## 2 FALSE    FALSE          FALSE          FALSE      TRUE
## 3 TRUE     FALSE          FALSE          FALSE      FALSE
## 4 FALSE    FALSE          FALSE          FALSE      FALSE
## 5 FALSE    TRUE           FALSE          FALSE      FALSE
## 6 FALSE    TRUE           FALSE          FALSE      FALSE
## 7 FALSE    TRUE           FALSE          FALSE      FALSE
## 8 FALSE    FALSE          FALSE          FALSE      FALSE
```

```
##  9 FALSE    FALSE      FALSE      FALSE      FALSE
## 10 FALSE    FALSE      FALSE      FALSE      FALSE
## # ... with 657 more rows, and 2 more variables: `Anti-Gravity` <lgl>,
## #   Empathy <lgl>
```

- Выберите все столбцы тibbleа powers кроме первого (hero_names):

```
powers %>%
  select(!hero_names)
```

```
## # A tibble: 667 x 167
##   Agility `Accelerated He~ `Lantern Power ~ `Dimensional Aw~ `Cold Resistanc~
##   <lgl> <lgl>      <lgl>      <lgl>      <lgl>
## 1 TRUE   FALSE      FALSE      FALSE      FALSE
## 2 FALSE  TRUE       FALSE      FALSE      FALSE
## 3 TRUE   TRUE       FALSE      FALSE      TRUE
## 4 FALSE  FALSE      TRUE       FALSE      FALSE
## 5 FALSE  TRUE       FALSE      FALSE      FALSE
## 6 FALSE  FALSE      FALSE      TRUE       FALSE
## 7 FALSE  FALSE      FALSE      FALSE      TRUE
## 8 FALSE  TRUE       FALSE      FALSE      FALSE
## 9 FALSE  FALSE      FALSE      FALSE      FALSE
## 10 FALSE FALSE      FALSE     FALSE      FALSE
## # ... with 657 more rows, and 162 more variables: Durability <lgl>,
## #   Stealth <lgl>, `Energy Absorption` <lgl>, Flight <lgl>, `Danger
## #   Sense` <lgl>, `Underwater breathing` <lgl>, Marksmanship <lgl>, `Weapons
## #   Master` <lgl>, `Power Augmentation` <lgl>, `Animal Attributes` <lgl>,
## #   Longevity <lgl>, Intelligence <lgl>, `Super Strength` <lgl>,
## #   Cryokinesis <lgl>, Telepathy <lgl>, `Energy Armor` <lgl>, `Energy
## #   Blasts` <lgl>, Duplication <lgl>, `Size Changing` <lgl>, `Density
## #   Control` <lgl>, Stamina <lgl>, `Astral Travel` <lgl>, `Audio
## #   Control` <lgl>, Dexterity <lgl>, Omnitrix <lgl>, `Super Speed` <lgl>,
## #   Possession <lgl>, `Animal Oriented Powers` <lgl>, `Weapon-based
## #   Powers` <lgl>, Electrokinesis <lgl>, `Darkforce Manipulation` <lgl>, `Death
## #   Touch` <lgl>, Teleportation <lgl>, `Enhanced Senses` <lgl>,
## #   Telekinesis <lgl>, `Energy Beams` <lgl>, Magic <lgl>, Hyperkinesis <lgl>,
## #   Jump <lgl>, Clairvoyance <lgl>, `Dimensional Travel` <lgl>, `Power
## #   Sense` <lgl>, Shapeshifting <lgl>, `Peak Human Condition` <lgl>,
## #   Immortality <lgl>, Camouflage <lgl>, `Element Control` <lgl>,
## #   Phasing <lgl>, `Astral Projection` <lgl>, `Electrical Transport` <lgl>,
## #   `Fire Control` <lgl>, Projection <lgl>, Summoning <lgl>, `Enhanced
## #   Memory` <lgl>, Reflexes <lgl>, Invulnerability <lgl>, `Energy
## #   Constructs` <lgl>, `Force Fields` <lgl>, `Self-Sustenance` <lgl>,
## #   `Anti-Gravity` <lgl>, Empathy <lgl>, `Power Nullifier` <lgl>, `Radiation
## #   Control` <lgl>, `Psionic Powers` <lgl>, Elasticity <lgl>, `Substance
## #   Secretion` <lgl>, `Elemental Transmogrification` <lgl>,
```

```
## # `Technopath/Cyberpath` <lgl>, `Photographic Reflexes` <lgl>, `Seismic
## # Power` <lgl>, Animation <lgl>, Precognition <lgl>, `Mind Control` <lgl>,
## # `Fire Resistance` <lgl>, `Power Absorption` <lgl>, `Enhanced
## # Hearing` <lgl>, `Nova Force` <lgl>, Insanity <lgl>, Hypnokinesis <lgl>,
## # `Animal Control` <lgl>, `Natural Armor` <lgl>, Intangibility <lgl>,
## # `Enhanced Sight` <lgl>, `Molecular Manipulation` <lgl>, `Heat
## # Generation` <lgl>, Adaptation <lgl>, Gliding <lgl>, `Power Suit` <lgl>,
## # `Mind Blast` <lgl>, `Probability Manipulation` <lgl>, `Gravity
## # Control` <lgl>, Regeneration <lgl>, `Light Control` <lgl>,
## # Echolocation <lgl>, Levitation <lgl>, `Toxin and Disease Control` <lgl>,
## # Banish <lgl>, `Energy Manipulation` <lgl>, `Heat Resistance` <lgl>,
## # `Natural Weapons` <lgl>, ...
```

8.11 Сортировка строк: dplyr::arrange()

- Выберите из тиббла heroes колонки name, Gender, Height и отсортируйте строчки *по возрастанию* Height.

```
heroes %>%
  select(name, Gender, Height) %>%
  arrange(Height)
```

```
## # A tibble: 734 x 3
##   name      Gender Height
##   <chr>     <chr>   <dbl>
## 1 Utgard-Loki  Male    15.2
## 2 Bloodwraith  Male    30.5
## 3 King Kong    Male    30.5
## 4 Anti-Monitor Male    61
## 5 Giganta     Female   62.5
## 6 Krypto       Male    64
## 7 Yoda         Male    66
## 8 Jack-Jack   Male    71
## 9 Howard the Duck Male    79
## 10 Godzilla    <NA>    108
## # ... with 724 more rows
```

- Выберите из тиббла heroes колонки name, Gender, Height и отсортируйте строчки *поубыванию* Height.

```
heroes %>%
  select(name, Gender, Height) %>%
  arrange(desc(Height))
```

```
## # A tibble: 734 x 3
```

```
##      name      Gender Height
##    <chr>      <chr>   <dbl>
## 1 Fin Fang Foom  Male     975
## 2 Galactus     Male     876
## 3 Groot        Male     701
## 4 MODOK        Male     366
## 5 Wolfsbane   Female   366
## 6 Onslaught    Male     305
## 7 Sasquatch    Male     305
## 8 Ymir         Male     305.
## 9 Rey          Female   297
## 10 Juggernaut  Male     287
## # ... with 724 more rows
```

- Выберите из тиббла heroes колонки name, Gender, Height и отсортируйте строчки сначала по Gender, затем по убыванию Height.

```
heroes %>%
  select(name, Gender, Height) %>%
  arrange(Gender, desc(Height))
```

```
## # A tibble: 734 x 3
##      name      Gender Height
##    <chr>      <chr>   <dbl>
## 1 Wolfsbane Female   366
## 2 Rey         Female   297
## 3 Bloodaxe   Female   218
## 4 Thundra    Female   218
## 5 Hela        Female   213
## 6 Frenzy      Female   211
## 7 She-Hulk    Female   201
## 8 Ardina     Female   193
## 9 Starfire    Female   193
## 10 Valkyrie   Female   191
## # ... with 724 more rows
```

8.12 Уникальные значения: dplyr::distinct()

- Извлеките уникальные значения столбца Eye color из тиббла heroes.

```
heroes %>%
  distinct(`Eye color`)
```

```
## # A tibble: 23 x 1
##       `Eye color`
```

```
##      <chr>
## 1 yellow
## 2 blue
## 3 green
## 4 brown
## 5 <NA>
## 6 red
## 7 violet
## 8 white
## 9 purple
## 10 black
## # ... with 13 more rows
```

- Извлеките уникальные значения столбца Hair color из таблицы heroes.

```
heroes %>%
  distinct(`Hair color`)
```

```
## # A tibble: 30 x 1
##   `Hair color`
##      <chr>
## 1 No Hair
## 2 Black
## 3 Blond
## 4 Brown
## 5 <NA>
## 6 White
## 7 Purple
## 8 Orange
## 9 Pink
## 10 Red
## # ... with 20 more rows
```

8.13 Создание колонок: dplyr::mutate() и dplyr::transmute()

- Создайте колонку height_m с ростом супергероев в метрах, затем выберите только колонки name и height_m.

```
heroes %>%
  mutate(height_m = Height/100) %>%
  select(name, height_m)
```

```
## # A tibble: 734 x 2
##   name           height_m
##   <chr>          <dbl>
```

```
## 1 A-Bomb      2.03
## 2 Abe Sapien 1.91
## 3 Abin Sur   1.85
## 4 Abomination 2.03
## 5 Abraxas     NA
## 6 Absorbing Man 1.93
## 7 Adam Monroe NA
## 8 Adam Strange 1.85
## 9 Agent 13    1.73
## 10 Agent Bob   1.78
## # ... with 724 more rows
```

- Создайте новую колонку hair в heroes, в которой будет значение “Bold” для тех супергероев, у которых в колонке Hair.color стоит “No Hair”, и значение “Hairy” во всех остальных случаях. Затем выберите только колонки name, Hair.color, hair.

```
heroes %>%
  mutate(hair = ifelse(`Hair color` == "No Hair", "Bold", "Hairy")) %>%
  select(name, `Hair color`, hair)
```

```
## # A tibble: 734 x 3
##   name      `Hair color` hair
##   <chr>     <chr>       <chr>
## 1 A-Bomb    No Hair    Bold
## 2 Abe Sapien No Hair    Bold
## 3 Abin Sur  No Hair    Bold
## 4 Abomination No Hair   Bold
## 5 Abraxas   Black      Hairy
## 6 Absorbing Man No Hair  Bold
## 7 Adam Monroe Blond     Hairy
## 8 Adam Strange Blond     Hairy
## 9 Agent 13   Blond     Hairy
## 10 Agent Bob  Brown     Hairy
## # ... with 724 more rows
```

8.14 Агрегация: dplyr::group_by() %>% summarise()

- Посчитайте количество супергероев по расам и отсортируйте по убыванию. Извлеките первые 5 строк.

```
heroes %>%
  count(Race, sort = TRUE) %>%
  slice(1:5)
```

```
## # A tibble: 5 x 2
##   Race      n
##   <chr>    <int>
## 1 <NA>     304
## 2 Human    208
## 3 Mutant   63
## 4 God / Eternal  14
## 5 Cyborg   11
```

- Посчитайте средний пост по полу.

```
heroes %>%
  group_by(Gender) %>%
  summarise(height_mean = mean(Height, na.rm = TRUE))
```

```
## # A tibble: 3 x 2
##   Gender height_mean
##   <chr>    <dbl>
## 1 Female    175.
## 2 Male      192.
## 3 <NA>      177.
```

8.15 Операции с несколькими колонками: across()

- Посчитайте количество NA в каждой колонке, группируя по полу (Gender).

```
na_n <- function(x) sum(is.na(x))
heroes %>%
  group_by(Gender) %>%
  summarise(across(everything(), na_n))
```

```
## # A tibble: 3 x 11
##   Gender X1 name `Eye color` Race `Hair color` Height Publisher
##   <chr>  <int> <int>        <int> <int>       <int> <int>      <int>
## 1 Female    0    0          41    98         38    56       0
## 2 Male      0    0          121   184        123   147       0
## 3 <NA>      0    0          10    22         11    14       0
## # ... with 3 more variables: `Skin color` <int>, Alignment <int>, Weight <int>
```

- Посчитайте количество NA в каждой колонке, которая заканчивается на "color", группируя по полу (Gender).

```
na_n <- function(x) sum(is.na(x))
heroes %>%
```

```
group_by(Gender) %>%
  summarise(across(ends_with("color"), na_n))
```

```
## # A tibble: 3 x 4
##   Gender `Eye color` `Hair color` `Skin color`
##   <chr>      <int>        <int>        <int>
## 1 Female       41          38         186
## 2 Male        121         123         449
## 3 <NA>         10          11          27
```

- Создайте из тиббла heroes новый тибл с колонками name, Height и Weight, где для каждого героя содержится значение " ", если его рост или вес выше среднего по колонке и " ", если ниже или равен среднему.

```
higher_than_average <- function(x) ifelse(x > mean(x, na.rm = TRUE),
                                         " ", " ",
                                         " ", " ")
heroes %>%
  transmute(name,
            across(c(Height, Weight),
                   higher_than_average))
```

```
## # A tibble: 734 x 3
##   name      Height     Weight
##   <chr>     <chr>     <chr>
## 1 A-Bomb    <NA>      <NA>
## 2 Abe Sapien <NA>      <NA>
## 3 Abin Sur   <NA>      <NA>
## 4 Abomination <NA>      <NA>
## 5 Abraxas    <NA>      <NA>
## 6 Absorbing Man <NA>      <NA>
## 7 Adam Monroe <NA>      <NA>
## 8 Adam Strange <NA>      <NA>
## 9 Agent 13    <NA>      <NA>
## 10 Agent Bob   <NA>      <NA>
## # ... with 724 more rows
```

- Создайте из тиббла heroes новый тибл с колонками Gender, name, Height и Weight, где для каждого героя содержится значение " ", если его рост или вес выше среднего по колонке и " ", если ниже или равен среднему *внутри соответствующей группы по полу*.

```
heroes %>%
  group_by(Gender) %>%
```

```

transmute(name,
  across(c(Height, Weight),
  higher_than_average))

## # A tibble: 734 x 4
## # Groups:   Gender [3]
##   Gender name      Height      Weight
##   <chr>  <chr>       <chr>       <chr>
## 1 Male   A-Bomb    <NA>        <NA>
## 2 Male   Abe Sapien <NA>        <NA>
## 3 Male   Abin Sur   <NA>        <NA>
## 4 Male   Abomination <NA>        <NA>
## 5 Male   Abraxas    <NA>        <NA>
## 6 Male   Absorbing Man <NA>        <NA>
## 7 Male   Adam Monroe <NA>        <NA>
## 8 Male   Adam Strange <NA>        <NA>
## 9 Female Agent 13    <NA>        <NA>
## 10 Male  Agent Bob   <NA>        <NA>
## # ... with 724 more rows

```

8.16 Соединение датафреймов: *_join {#solution_join}

Создайте тиббл web_creators, в котором будут супергерои, которые могут плести паутину, т.е. у них стоит TRUE в колонке Web Creation в тиббле powers.

```

powers_web <- powers %>%
  select(hero_names, `Web Creation`)
web_creators <- left_join(heroes, powers_web, by = c("name" = "hero_names")) %>%
  filter(`Web Creation`)
web_creators

## # A tibble: 16 x 12
##   X1 name  Gender `Eye color` Race  `Hair color` Height Publisher
##   <dbl> <chr> <chr>   <chr> <chr>   <chr> <dbl> <chr>
## 1 33 Anti~ Male   blue   Symb~ Blond   229 Marvel C-
## 2 38 Arac~ Female blue   Human Blond  175 Marvel C-
## 3 161 Carn~ Male   green  Symb~ Red    185 Marvel C-
## 4 335 Hybr~ Male   brown  Symb~ Black  175 Marvel C-
## 5 479 Myst~ Male   brown  Human No Hair 180 Marvel C-
## 6 580 Scar~ Male   brown  Clone Brown 193 Marvel C-
## 7 597 Silk  Female brown  Human Black  NA  Marvel C-
## 8 620 Spid~ Female blue  Human Brown  170 Marvel C-
## 9 621 Spid~ Female blue  Human Blond  165 Marvel C-
## 10 622 Spid~ Male   hazel Human Brown 178 Marvel C-

```

```

## 11   623 Spid~ <NA>   red      Human Brown    178 Marvel C-
## 12   624 Spid~ Male    brown     Human Black   157 Marvel C-
## 13   673 Toxin Male   blue     Symb~ Brown   188 Marvel C-
## 14   674 Toxin Male   black    Symb~ Blond   191 Marvel C-
## 15   689 Venom Male   blue     Symb~ Strawberry ~ 191 Marvel C-
## 16   692 Veno~ Male   <NA>    Symb~ <NA>   226 Marvel C-
## # ... with 4 more variables: `Skin color` <chr>, Alignment <chr>, Weight <dbl>,
## #   `Web Creation` <lgl>

```

- Найдите всех супергероев, которые присутствуют в `heroes`, но отсутствуют в `powers`. Ответом должен быть строковый вектор с именами супергероев.

```

anti_join(heroes, powers, by = c("name" = "hero_names")) %>%
  pull(name)

```

```

## [1] "Agent 13"          "Alfred Pennyworth" "Arsenal"
## [4] "Batgirl III"       "Batgirl V"        "Beetle"
## [7] "Black Goliath"     "Black Widow II"  "Blaquesmith"
## [10] "Bolt"              "Boomer"           "Box"
## [13] "Box III"           "Captain Mar-vell" "Cat II"
## [16] "Cecilia Reyes"    "Clea"              "Clock King"
## [19] "Colin Wagner"     "Colossal Boy"   "Corsair"
## [22] "Cypher"            "Danny Cooper"    "Darkside"
## [25] "ERG-1"              "Fixer"             "Franklin Storm"
## [28] "Giant-Man"         "Giant-Man II"   "Goliath"
## [31] "Goliath"            "Goliath"          "Guardian"
## [34] "Hawkwoman"          "Hawkwoman II"   "Hawkwoman III"
## [37] "Howard the Duck"   "Jack Bauer"      "Jesse Quick"
## [40] "Jessica Sanders"   "Jigsaw"           "Jyn Erso"
## [43] "Kid Flash II"      "Kingpin"          "Meteorite"
## [46] "Mister Zsasz"      "Mogo"             "Moloch"
## [49] "Morph"              "Nite Owl II"     "Omega Red"
## [52] "Paul Blart"         "Penance"          "Penance II"
## [55] "Plastic Lad"       "Power Man"       "Renata Soliz"
## [58] "Ronin"              "Shrinking Violet" "Snake-Eyes"
## [61] "Spider-Carnage"    "Spider-Woman II" "Stacy X"
## [64] "Thunderbird II"    "Two-Face"          "Vagabond"
## [67] "Vision II"          "Vulcan"           "Warbird"
## [70] "White Queen"        "Wiz Kid"           "Wondra"
## [73] "Wyatt Wingfoot"    "Yellow Claw"

```

- Найдите всех супергероев, которые присутствуют в `powers`, но отсутствуют в `heroes`. Ответом должен быть строковый вектор с именами супергероев.

```
anti_join(powers, heroes, by = c("hero_names" = "name")) %>%
  pull(hero_names)

## # A tibble: 22 x 3
##   [1] "3-D Man"          "Bananaman"        "Bizarro-Girl"
##   [4] "Black Vulcan"      "Blue Streak"       "Bradley"
##   [7] "Clayface"          "Concrete"         "Dementor"
##  [10] "Doctor Poison"     "Fire"              "Hellgramite"
##  [13] "Lara Croft"        "Little Epic"       "Lord Voldemort"
##  [16] "Orion"              "Peek-a-Boo"        "Queen Hippolyta"
##  [19] "Reactron"           "SHDB"              "Stretch Armstrong"
##  [22] "TEST"               "Tommy Clarke"      "Tyrant"
```

8.17 Tidy data

- Для начала создайте тиббл heroes_weight, скопировав код:

```
heroes_weight <- heroes %>%
  filter(Publisher %in% c("DC Comics", "Marvel Comics")) %>%
  group_by(Gender, Publisher) %>%
  summarise(weight_mean = mean(Weight, na.rm = TRUE)) %>%
  drop_na()
heroes_weight

## # A tibble: 4 x 3
## # Groups:   Gender [2]
##   Gender Publisher   weight_mean
##   <chr>   <chr>        <dbl>
## 1 Female  DC Comics    76.8
## 2 Female  Marvel Comics 80.1
## 3 Male    DC Comics   113.
## 4 Male    Marvel Comics 134.
```

Функция `drop_na()` позволяет выбросить все строчки, в которых встречается `NA`.

- Превратите тиббл `heroes_weight` в широкий тиббл:

```
heroes_weight %>%
  pivot_wider(names_from = "Publisher", values_from = "weight_mean")

## # A tibble: 2 x 3
## # Groups:   Gender [2]
##   Gender `DC Comics` `Marvel Comics`
##   <chr>        <dbl>        <dbl>
```

```
## 1 Female      76.8      80.1
## 2 Male        113.     134.
```

- Затем превратите его обратно в длинный тибл:

```
heroes_weight %>%
  pivot_wider(names_from = "Publisher", values_from = "weight_mean") %>%
  pivot_longer(cols = !Gender,
               names_to = "Publisher",
               values_to = "weight_mean")
```

```
## # A tibble: 4 x 3
## # Groups:   Gender [2]
##   Gender Publisher weight_mean
##   <chr>  <chr>      <dbl>
## 1 Female DC Comics    76.8
## 2 Female Marvel Comics 80.1
## 3 Male   DC Comics    113.
## 4 Male   Marvel Comics 134.
```

- Сделайте powers длинным тиблом с тремя колонками: hero_names, power (название суперсилы) и has (наличие суперсилы у данного супергероя).

```
powers %>%
  pivot_longer(cols = !hero_names,
               names_to = "power",
               values_to = "has")
```

```
## # A tibble: 111,389 x 3
##   hero_names power          has
##   <chr>      <chr>        <lgl>
## 1 3-D Man    Agility      TRUE
## 2 3-D Man    Accelerated Healing FALSE
## 3 3-D Man    Lantern Power Ring FALSE
## 4 3-D Man    Dimensional Awareness FALSE
## 5 3-D Man    Cold Resistance FALSE
## 6 3-D Man    Durability    FALSE
## 7 3-D Man    Stealth       FALSE
## 8 3-D Man    Energy Absorption FALSE
## 9 3-D Man    Flight        FALSE
## 10 3-D Man   Danger Sense  FALSE
## # ... with 111,379 more rows
```

- Сделайте тибл powers обратно широким, но с новой структурой: каждая строчка означает суперсилу, а каждая колонка - супергероя (за исключением первой колонки - названия суперсилы).

```

powers %>%
  pivot_longer(cols = !hero_names,
               names_to = "power",
               values_to = "has") %>%
  pivot_wider(names_from = hero_names,
              values_from = has)

## # A tibble: 167 x 668
##   power `3-D Man` `A-Bomb` `Abe Sapien` `Abin Sur` `Abomination` Abraxas
##   <chr> <lgl>    <lgl>    <lgl>    <lgl>    <lgl>    <lgl>
## 1 Agil~ TRUE     FALSE    TRUE     FALSE    FALSE    FALSE
## 2 Acce~ FALSE    TRUE     TRUE     FALSE    TRUE     FALSE
## 3 Lant~ FALSE    FALSE    FALSE    TRUE     FALSE    FALSE
## 4 Dime~ FALSE    FALSE    FALSE    FALSE    FALSE    TRUE
## 5 Cold~ FALSE    FALSE    TRUE     FALSE    FALSE    FALSE
## 6 Dura~ FALSE    TRUE     TRUE     FALSE    FALSE    FALSE
## 7 Stea~ FALSE    FALSE    FALSE    FALSE    FALSE    FALSE
## 8 Ener~ FALSE    FALSE    FALSE    FALSE    FALSE    FALSE
## 9 Flig~ FALSE    FALSE    FALSE    FALSE    FALSE    TRUE
## 10 Dang~ FALSE   FALSE    FALSE    FALSE    FALSE    FALSE
## # ... with 157 more rows, and 661 more variables: `Absorbing Man` <lgl>, `Adam
## # Monroe` <lgl>, `Adam Strange` <lgl>, `Agent Bob` <lgl>, `Agent Zero` <lgl>,
## # `Air-Walker` <lgl>, Ajax <lgl>, `Alan Scott` <lgl>, `Alex Mercer` <lgl>,
## # `Alex Woolsly` <lgl>, Alien <lgl>, `Allan Quatermain` <lgl>, Amazo <lgl>,
## # Ammo <lgl>, `Ando Masahashi` <lgl>, Angel <lgl>, `Angel Dust` <lgl>, `Angel
## # Salvadore` <lgl>, Angela <lgl>, `Animal Man` <lgl>, Annihilus <lgl>,
## # `Ant-Man` <lgl>, `Ant-Man II` <lgl>, `Anti-Monitor` <lgl>,
## # `Anti-Spawn` <lgl>, `Anti-Venom` <lgl>, Apocalypse <lgl>, Aquababy <lgl>,
## # Aqualad <lgl>, Aquaman <lgl>, Arachne <lgl>, Archangel <lgl>,
## # Arclight <lgl>, Ardina <lgl>, Ares <lgl>, Ariel <lgl>, Armor <lgl>, `Astro
## # Boy` <lgl>, Atlas <lgl>, Atom <lgl>, `Atom Girl` <lgl>, `Atom II` <lgl>,
## # `Atom III` <lgl>, `Atom IV` <lgl>, Aurora <lgl>, Azazel <lgl>,
## # Azrael <lgl>, Aztar <lgl>, Bananaman <lgl>, Bane <lgl>, Banshee <lgl>,
## # Bantam <lgl>, Batgirl <lgl>, `Batgirl IV` <lgl>, `Batgirl VI` <lgl>,
## # Batman <lgl>, `Batman II` <lgl>, Battlestar <lgl>, `Batwoman V` <lgl>,
## # Beak <lgl>, Beast <lgl>, `Beast Boy` <lgl>, `Ben 10` <lgl>, `Beta Ray
## # Bill` <lgl>, Beyonder <lgl>, `Big Barda` <lgl>, `Big Daddy` <lgl>, `Big
## # Man` <lgl>, `Bill Harken` <lgl>, `Billy Kincaid` <lgl>, Binary <lgl>,
## # `Bionic Woman` <lgl>, `Bird-Brain` <lgl>, `Bird-Man` <lgl>, `Bird-Man
## # II` <lgl>, Birdman <lgl>, Bishop <lgl>, Bizarro <lgl>,
## # `Bizarro-Girl` <lgl>, `Black Abbott` <lgl>, `Black Adam` <lgl>, `Black
## # Bolt` <lgl>, `Black Canary` <lgl>, `Black Cat` <lgl>, `Black Flash` <lgl>,
## # `Black Knight III` <lgl>, `Black Lightning` <lgl>, `Black Mamba` <lgl>,
## # `Black Manta` <lgl>, `Black Panther` <lgl>, `Black Vulcan` <lgl>, `Black

```

```
## #  Widow` <lgl>, Blackout <lgl>, Blackwing <lgl>, Blackwulf <lgl>,
## #  Blade <lgl>, `Bling!` <lgl>, Blink <lgl>, Blizzard <lgl>, `Blizzard
## #  II` <lgl>, ...
```

Литература

- Adler, J. (2010). *R in a nutshell: A desktop quick reference*. "O'Reilly Media, Inc.".
- Baesens, B., Van Vlasselaer, V., and Verbeke, W. (2015). *Fraud analytics using descriptive, predictive, and social network techniques: a guide to data science for fraud detection*. John Wiley & Sons.
- Brooks, H. and Cooper, C. L. (2013). *Science for public policy*. Elsevier.
- Hansjörg, N. (2019). *Data Science for Psychologists*. self published.
- Provost, F. and Fawcett, T. (2013). *Data Science for Business: What you need to know about data mining and data-analytic thinking*. O'Reilly Media, Inc.
- R Core Team (2019). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
- Thomas, N. and Pallett, L. (2019). *Data Science for Immunologists*. CreateSpace Independent Publishing Platform.
- Wickham, H. and Grolemund, G. (2016). *R for data science: import, tidy, transform, visualize, and model data*. O'Reilly Media, Inc.